

«Эта книга – отличный ресурс для руководителей, лидеров, исследователей или инженеров, желающих использовать контролируемые онлайн-эксперименты».

Гарри Шам, исполнительный вице-президент,
группа искусственного интеллекта Microsoft

«Кохави, Тан и Сюй обладают богатым опытом и навыками, поэтому в книге есть множество практических примеров из реального мира и уроков, извлеченных за многие годы применения этих методов в больших масштабах».

Джефф Дин,
старший вице-президент Google Research

Собрать данные легко; собрать данные, которым можно доверять, сложно. Это практическое руководство от ведущих специалистов по экспериментам в Google, LinkedIn и Microsoft научит вас, как ускорить внедрение инноваций, используя доверительные контролируемые онлайн-эксперименты, или A/B-тесты. Основываясь на практическом опыте компаний, каждая из которых проводит более 20 000 экспериментов в год, авторы делятся примерами, предостерегают от ловушек и дают советы для тех, кто только начинает учиться, и профессионалов отрасли, осваивающих методику экспериментов. Обсуждение более сложных вопросов пригодится экспертам, которые хотят улучшить методы принятия решений на основе данных. *Узнайте, как*

С этой книгой вы научитесь:

- использовать научный метод оценки гипотез с помощью контролируемых экспериментов;
- определять ключевые показатели и общий критерий оценки;
- проверять достоверность результатов и получать предупреждения о нарушении предположений;
- создавать масштабируемые платформы, снижающие предельные затраты на эксперименты почти до нуля;
- избегать ловушек, таких как эффекты переноса и закон Тваймана;
- обнаруживать статистические проблемы экспериментальных данных.

Интернет-магазин:
www.dmkpress.com

Оптовая продажа:
КТК «Галактика»
e-mail: books@aliens-kniga.ru

CAMBRIDGE
UNIVERSITY PRESS

ДМК
издательство
www.dmk.pf


ISBN 978-5-97060-913-2



Доверительное A/B-тестирование

Рон Кохави, Диана Тан, Я Сюй

Доверительное A/B-тестирование



ДМК
издательство

Доверительное А/В-тестирование

Практическое руководство
по контролируемым экспериментам

*Рон Кохави
Диана Тан
Я Сюй*



Москва, 2021

УДК 004.85
ББК 32.971.3
К75

Рон Кохави, Диана Тан, Я Сюй

К75 Доверительное А/В-тестирование. Практическое руководство по контролируемым экспериментам / пер. с англ. В. С. Яценкова. – М.: ДМК Пресс, 2021. – 298 с.: ил.

ISBN 978-5-97060-913-2

Сложно понять ценность идеи, пока она не опробована на практике. В этой книге рассказывается о том, как контролируемые онлайн-эксперименты (или, как их еще называют, А/В-тесты) позволяют оценить эффективность тех или иных идей по оптимизации веб-сайтов и добиться максимальной отдачи от их использования. Вы узнаете, как правильно подобрать инструменты для тестирования, провести сбор данных и обеспечить измеримость результатов. На конкретных примерах показано, как при помощи А/В-тестов были улучшены веб-ресурсы известных компаний.

Контролируемые онлайн-эксперименты широко применяются в Amazon, Booking.com, eBay, Facebook, Google, LinkedIn, Microsoft, Twitter, Яндекс и других компаниях. Эта методика становится неотъемлемой частью культуры бизнеса, основанной на данных.

Издание адресовано техническим специалистам и менеджерам, заинтересованным в увеличении прибыльности своих онлайн-проектов.

УДК 004.85
ББК 32.971.3

Copyright Original English language edition published by Cambridge University Press is part of the University of Cambridge. Copyright © 2020 by Ron Kohavi, Diane Tang, Ya Xu. Russian-language edition copyright © 2021 by DMK Press. All rights reserved.

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

ISBN (анг.) 978-1-108-72426-5
ISBN (рус.) 978-5-97060-913-2

© 2020 Ron Kohavi, Diane Tang, and Ya Xu
© Оформление, издание, перевод,
ДМК Пресс, 2021

Отзывы рецензентов о книге

В основе методологии бережливого производства лежат научные методы: разработка гипотез, проведение экспериментов, сбор данных, получение информации и подтверждение или модификация гипотез. А/В-тестирование – это золотой стандарт разработки поддающихся проверке и повторяемых экспериментов, и эта книга подводит окончательный итог.

– Стив Бланк, адъюнкт-профессор Стэнфордского университета, отец современного предпринимательства, автор книг *The Startup Owner's Manual* и *The Four Steps to the Epiphany*

Эта книга – отличный ресурс для руководителей, лидеров, исследователей или инженеров, желающих использовать контролируемые онлайн-эксперименты для повышения качества продукта, эффективности проекта или величины дохода. Я лично знаю, какое влияние оказала работа Кохави на Bing и Microsoft, и рад, что эти знания теперь доступны более широкой аудитории.

– Гарри Шам, исполнительный вице-президент, Группа искусственного интеллекта и исследований Microsoft

Замечательная книга, одновременно строгая и доступная. Читатели узнают, как проводить в своих организациях доверительные контролируемые эксперименты, которые произвели революцию в разработке интернет-продуктов.

– Адам Д'Анджело, соучредитель и генеральный директор Quora и бывший технический директор Facebook

Эта книга – отличный рассказ о том, как несколько компаний используют онлайн-эксперименты и А/В-тестирование для улучшения своих продуктов. Кохави, Тан и Сюй обладают богатым опытом и навыками, поэтому в книге есть множество практических примеров из реального мира и уроков, извлеченных за многие годы применения этих методов в больших масштабах.

– Джефф Дин, старший научный сотрудник Google и старший вице-президент Google Research

Хотите ли вы, чтобы ваша организация постоянно принимала лучшие решения? Это новая библия для желающих перейти от данных к решениям

в эпоху цифровых технологий. Читать эту книгу – все равно что присутствовать на собраниях в Amazon, Google, LinkedIn, Microsoft. Авторы впервые раскрывают способы принятия решений самыми успешными компаниями мира. Вместо болтовни и анекдотов из обычных книг про бизнес эта книга показывает, что надо делать и как делать это хорошо. Это руководство по принятию решений в цифровом мире с отдельными разделами для руководителей предприятий, инженеров и аналитиков данных.

– Скотт Кук, соучредитель и председатель исполнительного комитета Intuit

Управляемые онлайн-эксперименты – это мощные инструменты. Понимание того, как они работают, в чем их сильные стороны и как их можно оптимизировать, может послужить источником вдохновения как специалистам, так и более широкой аудитории. Эта книга представляет собой редкое сочетание авторитетных технических инструкций и увлекательного чтения и посвящена очень важным вопросам.

– Джон П.А. Иоаннидис, профессор медицины, здравоохранения, биомедицинских данных и статистики Стэнфордского университета

Какая онлайн-версия будет лучше? Нам часто приходится делать такой выбор, и мы часто ошибаемся. Чтобы определить, что на самом деле будет работать лучше, нам нужны строгие контролируемые эксперименты, также известные как А/В-тестирование. Эта прекрасная и яркая книга экспертов из Microsoft, Google и LinkedIn делится с нами теорией и передовым опытом А/В-тестирования. Ее обязательно должны прочесть все, кто хоть чем-то занят в интернете!

– Грегори Пятецки-Шапиро, доктор философии, президент KDnuggets, соучредитель SIGKDD и LinkedIn Top Voice в области науки о данных и аналитики

Рон Кохави, Диана Тан и Я Сюй – ведущие мировые эксперты по онлайн-экспериментам. Я опираюсь на их опыт в течение многих лет и рад, что теперь они объединились для написания итогового руководства. Я рекомендую эту книгу всем своим студентам и тем, чья работа связана с онлайн-продуктами и услугами.

– Эрик Бриньольфссон, профессор Массачусетского технологического института и соавтор книги *The Second Machine Age*

Современный бизнес, основанный на программном обеспечении, не может оставаться конкурентоспособным без контролируемых онлайн-экспериментов. Написанная тремя наиболее опытными лидерами в этой области, эта книга представляет основные принципы, иллюстрирует их

убедительными примерами и дает глубокие практические советы. Настоятельно рекомендую к прочтению!

– Фостер Провост, профессор Школы бизнеса Стерна
Нью-Йоркского университета и соавтор бестселлера
Data Science for Business

За последние два десятилетия технологическая индустрия наконец достигла то, что ученые знали на протяжении веков: контролируемые эксперименты являются одним из лучших инструментов для понимания сложных явлений и решения очень сложных проблем. Способность разрабатывать контролируемые эксперименты, проводить их в большом масштабе и интерпретировать результаты лежит в основе работы современных высокотехнологичных предприятий. Авторы разработали и реализовали несколько самых мощных в мире платформ для экспериментов. Эта книга – прекрасная возможность узнать на их опыте, как использовать эти инструменты и методы.

– Кевин Скотт, исполнительный вице-президент
и технический директор *Microsoft*

Онлайн-эксперименты способствовали успеху Amazon, Microsoft, LinkedIn и других ведущих цифровых компаний. Эта практическая книга открывает читателю доступ к многолетнему опыту экспериментов в этих компаниях и должна быть на книжной полке каждого специалиста по данным, разработчика программного обеспечения и продакт-менеджера.

– Штефан Томке, профессор, лауреат гранта
Уильяма Барклая Хардинга,
Гарвардская школа бизнеса, автор книги *Experimentation
Works: The Surprising Power of Business Experiments*

Секрет успеха онлайн-бизнеса – это эксперименты. Но теперь это уже не секрет. В этой книге три мастера описывают ключевые приемы А/В-тестирования, чтобы вы тоже могли постоянно улучшать качество своих онлайн-продуктов.

– Хэл Вариан, главный экономист Google и автор книги
Intermediate Microeconomics: A Modern Approach

Эксперименты – лучший инструмент для онлайн-продуктов и услуг. Эта книга полна практических знаний, полученных в результате многолетнего успешного тестирования в Microsoft, Google и LinkedIn. Понимание и передовой опыт объяснены реальными примерами и ловушками, выявлены их признаки и найдены решения. Я настоятельно рекомендую эту книгу!

– Престон Макафи, бывший главный экономист и вице-президент *Microsoft*

Экспериментирование – это будущее цифровой стратегии, а эта книга станет ее библией. Кохави, Тан и Суй – трое из наиболее заслуживающих внимания современных экспертов по экспериментированию, и их книга представляет собой практическое руководство по проведению экспериментов, которое полезно с первых строк. Тематические исследования по разоблачению экспериментальных заблуждений, которые они проводили на протяжении многих десятилетий в Microsoft, Amazon, Google и LinkedIn, трансформированы в простые для понимания практические решения с огромной глубиной и ясностью. Это обязательное чтение для любого менеджера цифрового бизнеса.

– Синан Арал, профессор менеджмента Дэвида Остина,
Массачусетский технологический институт,
и автор книги *The Hype Machine*

Незаменимая для любого серьезного экспериментатора, эта книга очень практична и необычайно глубока. Она настолько полезна, что кажется, будто ты обретаешь суперсилу. В этой книге вы найдете все – от тонкостей статистики до оценки результатов и измерения долгосрочного воздействия. Рекомендую к прочтению.

– Пип Лаха, эксперт по достижению конверсии,
основатель и директор CXL

Онлайн-эксперименты сыграли решающую роль в изменении корпоративной культуры Microsoft. Когда Сатя Наделла говорит об «установке на рост», экспериментирование – лучший способ попробовать новые идеи и извлечь из них уроки. После того как мы научились быстро повторять контролируемые эксперименты, Bing стал прибыльным и экспериментирование быстро распространилось по Microsoft через Office, Windows и Azure.

– Эрик Бойд, корпоративный вице-президент по
платформе AI, Microsoft

Как предприниматель, ученый и руководитель, я понял (на собственном горьком опыте), что один грамм данных ценнее, чем килограммы интуиции. Но как получить хорошие данные? Эта книга объединяет многолетний опыт работы в Amazon, Google, LinkedIn и Microsoft в доступное, хорошо организованное руководство. Это библия онлайн-экспериментов.

– Орен Эциони, генеральный директор Института
искусственного интеллекта Аллена и профессор
информатики Вашингтонского университета

Интернет-компании развили эксперименты до беспрецедентного масштаба, скорости и сложности. Авторы книги сыграли ключевую роль

в этих разработках, и читателям повезло, что они могут извлечь уроки из их совокупного опыта.

– Дин Эклс, профессор развития карьеры KDD в области коммуникаций и технологий Массачусетского технологического института и бывший ученый в Facebook

Замечательный богатый ресурс для изучения критически важной, но недооцененной области. Реальные тематические исследования в каждой главе иллюстрируют внутреннюю работу и уроки успешного бизнеса. Концентрация внимания на разработке и оптимизации критерия общей оценки (ОЕС) является особенно важным уроком.

– Джереми Ховард, Университет сингулярности, основатель fast.ai, бывший президент и главный научный сотрудник Kaggle

Я видел много пособий по А/В-тестированию, но лишь некоторые из них посвящены доверительным контролируемым онлайн-экспериментам. Я слежу за Ронни Кохави в течение 18 лет и вижу, что его советы отточены практикой и закалены работой в реальных условиях. Когда к нему присоединяются Диана Тан и Я Сюй, широта охвата не имеет себе равных. Я призываю вас сравнить эту книгу с любой другой – конечно, контролируемым образом.

– Джим Стерн, основатель саммита по маркетинговой аналитике и почетный директор Ассоциации цифровой аналитики

Чрезвычайно полезное руководство по проведению онлайн-экспериментов, сочетающее в себе аналитическую сложность, ясное изложение и добытые напряженным трудом уроки практического опыта.

– Джим Манзи, основатель Foundry.ai, основатель и бывший генеральный директор и председатель совета директоров Applied Predictive Technologies, автор книги *Uncontrolled: The Surprising Payoff of Trial-and-Error for Business, Politics, and Society*

Экспериментальный подход совершенствуется каждый раз, когда его применяют в новой области: сельское хозяйство, химия, медицина, а теперь уже и электронная торговля в интернете. Эта книга трех ведущих экспертов изобилует практическими советами и примерами, объясняющими, как и почему нужно экспериментировать в интернете, чтобы вас не обманула собственная интуиция. Эксперименты могут стоить дорого; однако работа вслепую может обойтись еще дороже.

– Арт Оуэн, профессор статистики Стэнфордского университета

Это обязательная книга для руководителей предприятий и операционных менеджеров. Подобно тому, как операции, финансы, бухгалтерский учет и стратегия представляют собой обязательные строительные блоки бизнеса, сегодня, в эпоху искусственного интеллекта, проведение обдуманных контролируемых онлайн-экспериментов становится обязательным навыком. Кохави, Тан и Сюй изложили основы знаний для этой новой и важной прикладной области.

– Карим Р. Лахани, профессор и директор лаборатории инновационных наук Гарварда, член совета директоров Mozilla Corp.

Серьезные организации, основанные на данных, понимают, что аналитики недостаточно; они должны сосредоточиться на экспериментах. Эта удивительно доступная и очень интересная книга представляет собой манифест и руководство по организации эффективных экспериментов. Я считаю, что это вдохновляющий прагматизм. Самое главное, книга поясняет, как сочетание культуры с технической компетенцией становится критическим фактором успеха.

– Майкл Шраге, научный сотрудник Инициативы Массачусетского технологического института по цифровой экономике и автор книги *The Innovator's Hypothesis: How Cheap Experiments Are Worth More than Good Ideas*

Эта важная книга об экспериментировании вобрала в себя мудрость трех выдающихся лидеров крупнейших мировых технологических компаний. Если вы инженер-программист, специалист по данным или менеджер по продукту и пытаетесь внедрить в своей организации культуру бизнеса, основанную на данных, эта книга станет для вас отличным практическим руководством.

– Даниэль Тункеланг, главный научный сотрудник Endeca и бывший директор по науке о данных и инжинирингу в LinkedIn

По мере того как каждая отрасль все больше становится цифровой и управляемой данными, проведение контролируемых онлайн-экспериментов и получение выгоды от них становится необходимым навыком. Кохави, Тан и Сюй предоставляют полное и хорошо проработанное руководство, которое станет обязательным чтением как для практиков, так и для руководителей.

– Евангелос Симудис, соучредитель и управляющий директор Synapse Partners; автор книги *The Big Data Opportunity in Our Driverless Future*

Авторы представляют результат более 10 лет упорного экспериментирования в самой стратегически важной книге для данной дисциплины.

– Колин МакФарланд, директор экспериментальной платформы Netflix

Практическое руководство по А/В-тестированию превращает опыт трех ведущих умов экспериментальной практики в простые и легко усваиваемые блоки ценных прикладных идей. Каждая глава знакомит вас с некоторыми из наиболее важных аспектов при проведении экспериментов – от выбора правильной метрики до пользы институциональной памяти. Если вы ищете наставника по экспериментам, который сочетает в себе науку и практичность, эта книга для вас.

– Дилан Льюис, руководитель службы экспериментов, Intuit

Единственное, что хуже, чем отсутствие эксперимента, – это ошибочное толкование эксперимента, потому что оно дает вам ложную уверенность! В этой книге подробно описаны технические аспекты тестирования, основанные на опыте проведения экспериментов в некоторых крупнейших компаниях мира. Если вы участвуете в онлайн-экспериментах в каком угодно качестве, скорее прочтите эту книгу, чтобы избежать ошибок и получить уверенность в своих результатах.

– Крис Говард, автор книги *You Should Test That!*, основатель и генеральный директор Widerfunnel

Это феноменальная книга. Авторы опираются на богатый опыт и создали удобочитаемое справочное пособие, которое в некотором роде является всеобъемлющим и исчерпывающим. Настоятельно рекомендую прочитать эту книгу всем, кто хочет проводить серьезные цифровые эксперименты.

– Пит Кумен, соучредитель, Optimizely

Авторы – пионеры онлайн-экспериментов. Созданные ими платформы и проводимые ими эксперименты изменили некоторые из крупнейших интернет-брендов. Их исследования и беседы вдохновили другие команды в отрасли на экспериментирование. Эта книга – авторитетный, но практичный труд, которого так ждала отрасль.

– Адиль Айджаз, соучредитель и генеральный директор Split Software

Оглавление

Отзывы рецензентов о книге	5
Предисловие от издательства	18
Вступление	19
Предисловие	21
Благодарности	23
ЧАСТЬ I. ВВЕДЕНИЕ ДЛЯ ВСЕХ	25
Глава 1. Введение и мотивация	27
1.1. Терминология контролируемых онлайн-экспериментов	29
1.2. Зачем нужны эксперименты? Корреляции, причинно-следственная связь и достоверность	33
1.3. Необходимые ингредиенты для проведения эффективных контролируемых экспериментов	35
1.4. Постулаты	36
1.5. Постепенные улучшения	39
1.6. Примеры интересных контролируемых онлайн-экспериментов	41
1.7. Стратегия, тактика и их связь с экспериментами	46
1.8. Дополнительное чтение	50
Глава 2. Проведение и анализ экспериментов. Пример полного цикла	52
2.1. Условия демонстрационного эксперимента	52
2.2. Проверка гипотез: установление статистической значимости	56
2.3. Разработка эксперимента	58
2.4. Проведение эксперимента и сбор данных	61
2.5. Интерпретация результатов	61
2.6. От результатов к решениям	63
Глава 3. Закон Тваймана и надежность экспериментов	66
3.1. Неправильная интерпретация статистических результатов	67
3.1.1. Нехватка статистической мощности	67
3.1.2. Неправильная интерпретация p -значений	67
3.1.3. Отслеживание p -значений	69
3.1.4. Множественные проверки гипотез	69
3.2. Достоверные интервалы	70

3.3. Угрозы внутренней достоверности.....	70
3.3.1. Нарушения правила SUTVA	70
3.2.2. Ошибка выжившего	71
3.2.3. Вынужденное воздействие.....	71
3.2.4. Несоответствие коэффициента выборки	72
3.4. Угрозы внешней достоверности	76
3.4.1. Эффекты первичности.....	76
3.4.2. Эффекты новизны.....	76
3.4.3. Выявление эффектов первичности и новизны.....	78
3.5. Разделение по сегментам	78
3.5.1. Сегментированное представление показателя	79
3.5.2. Сегментированное представление эффекта (гетерогенность эффекта).....	80
3.5.3. Анализ эффекта по сегментам, вводящий в заблуждение.....	81
3.6. Парадокс Симпсона	82
3.7. Поощряйте здоровый скептицизм.....	84

Глава 4. Платформы и культура экспериментов

4.1. Модели зрелости экспериментов.....	85
4.1.1. Лидерство	87
4.1.2. Процесс	88
4.1.3. Разработать самим или купить готовый продукт?	91
4.2. Инфраструктура и инструменты.....	94
4.2.1. Разработка, настройка и управление экспериментом	96
4.2.2. Развертывание эксперимента.....	97
4.2.3. Инструменты для экспериментов.....	100
4.2.4. Масштабирование экспериментов: тонкости назначения вариантов	101
4.2.5. Параллельные эксперименты	103
4.2.6. Анализ экспериментов	105

ЧАСТЬ II. ИЗБРАННЫЕ ТЕМЫ ДЛЯ ВСЕХ

Глава 5. Скорость имеет значение!.....

5.1. Ключевое предположение: локальная линейная аппроксимация	113
5.2. Как измерить быстродействие веб-сайта.....	114
5.3. Схема эксперимента по замедлению	116
5.4. Влияние различных элементов страницы	118
5.5. Экстремальные результаты	119

Глава 6. Организационные показатели

6.1. Таксономия показателей	121
6.2. Выработка показателей: принципы и методы	125
6.3. Оценка показателей.....	128

6.4. Развивающиеся показатели	129
6.5. Дополнительное чтение	130
6.6. Примечание: ограничительные показатели	130
6.7. Примечание: преднамеренная манипуляция показателями.....	132

Глава 7. Показатели экспериментов и общий критерий оценки..... 135

7.1. От бизнес-показателей к показателям, подходящим для экспериментов.....	136
7.2. Объединение ключевых показателей в ОЕС	138
7.3. Пример: ОЕС для электронной почты на Amazon	140
7.4. Пример: ОЕС для поисковой системы Bing.	141
7.5. Закон Гудхарта, закон Кэмпбелла и замечание Лукаса	143

Глава 8. Институциональная память и метаанализ

8.1. Что такое институциональная память?.....	145
8.2. Почему полезна институциональная память?.....	146

Глава 9. Этика контролируемых экспериментов

9.1. Что лежит в основе этики	150
9.1.1. Риски	152
9.1.2. Преимущества и выгоды	153
9.1.3. Возможность выбора	155
9.2. Сбор данных	155
9.3. Культура и процессы	156
9.4. Примечание: идентификация пользователей	157

ЧАСТЬ III. ДОПОЛНИТЕЛЬНЫЕ И АЛЬТЕРНАТИВНЫЕ МЕТОДЫ КОНТРОЛИРУЕМЫХ ЭКСПЕРИМЕНТОВ..... 159

Глава 10. Дополнительные методы..... 163

10.1. Пространство дополнительных методов.....	163
10.2. Анализ на основе журналов	164
10.3. Экспертная оценка.....	166
10.4. Исследование пользовательского опыта.....	167
10.5. Фокус-группы	168
10.6. Обзоры	169
10.7. Внешние данные.....	170
10.8. Подведем итог главы.....	172

Глава 11. Наблюдательные исследования причинно-следственных связей

11.1. Когда контролируемые эксперименты невозможны	174
--	-----

11.2. Планы для наблюдательных исследований причинно-следственных связей	176
11.2.1. Прерывистый временной ряд	176
11.2.2. Эксперименты с чередованием	178
11.2.3. Метод разрывной регрессии	178
11.2.4. Инструментальные переменные и естественные эксперименты.....	180
11.2.5. Отбор подобного по склонности.....	180
11.2.6. Дифференциальная разница.....	181
11.3. Ловушки причинно-следственных связей	182
11.4. Приложение: опровергнутые исследования причинно-следственных связей	185

ЧАСТЬ IV. ПЛАТФОРМЫ ДЛЯ ЭКСПЕРИМЕНТОВ: УГЛУБЛЕННОЕ ИЗУЧЕНИЕ..... 189

Глава 12. Эксперименты на стороне клиента.....	193
12.1. Различия между серверной и клиентской стороной.....	193
12.1.1. Отличие №1: процесс выпуска.....	194
12.1.2. Отличие №2: обмен данными между клиентом и сервером	195
12.2. Следствия из компромиссов	197
12.3. Выводы.....	201

Глава 13. Инструментарий экспериментов.....	202
13.1. Инструменты на стороне клиента и сервера	202
13.2. Обработка журналов из нескольких источников.....	204
13.3. Культура измерений.....	205

Глава 14. Выбор единицы рандомизации	206
14.1. Единица рандомизации и единица анализа	208
14.1 Рандомизация на уровне пользователя	209

Глава 15. Развитие эксперимента: компромисс между скоростью, качеством и риском.	212
15.1. Что такое рампинг?.....	212
15.2. Шаблон SQR для рампинга	213
15.3. Четыре фазы рампинга.....	214
15.3.1. Первая фаза рампинга: до MPR.....	215
15.3.2. Вторая фаза рампинга: MPR.....	216
15.3.3. Третья фаза рампинга: пост-MPR	216
15.3.4. Четвертая фаза рампинга: длительное удержание или репликация.....	216
15.4. Что после рампинга?.....	218

Глава 16. Анализ масштабных экспериментов	219
16.1. Подготовка данных	219
16.2. Вычисление данных	220
16.3. Формирование сводки и визуализация результатов	222

ЧАСТЬ V. РАЗВЕРНУТОЕ ОПИСАНИЕ АНАЛИЗА ЭКСПЕРИМЕНТОВ 225

Глава 17. Статистика контролируемых онлайн-экспериментов	229
17.1. Двухвыборочный t -тест	229
17.2. p -значение и доверительный интервал	230
17.3. Предположение о нормальности	231
17.4. Ошибки типа I/II и статистическая мощность	233
17.5. Смещение	235
17.6. Множественное тестирование	235
17.7. Метаанализ Фишера	236

Глава 18. Оценка дисперсии и повышение чувствительности: подводные камни и решения	238
18.1. Распространенные ошибки	239
18.1.1. Дельта или процентная дельта?	239
18.1.2. Показатели отношения: когда уровень анализа отличается от уровня эксперимента	239
18.1.3. Выбросы	241
18.2. Повышение чувствительности	242
18.3. Дисперсия других статистических данных	244

Глава 19. А/А-тестирование	246
19.1. Почему нужны А/А-тесты?	246
19.1.1. Пример 1: уровень анализа отличается от уровня рандомизации	247
19.1.2. Пример 2: поощрение остановки эксперимента при достижении статистической значимости	249
19.1.3. Пример 3: переадресация браузера	249
19.1.4. Пример 4: неравное распределение по группам	250
19.1.5. Пример 5: различия в оборудовании	251
19.2. Как проводить А/А тесты	251
19.3. Когда А/А-тест не подходит	252

Глава 20. Включение по условию для повышения чувствительности	254
20.1. Примеры включения по условию	254

20.1.1. Пример 1: преднамеренно частичное воздействие	255
20.1.2. Пример 2: условное воздействие	255
20.1.3. Пример 3: Увеличение охвата	256
20.1.4. Пример 4: изменение покрытия	256
20.1.5. Пример 5: контрфактическое включение для моделей машинного обучения	257
20.2. Числовой пример	258
20.3. Оптимальное и консервативное включение	258
20.4. Общий эффект воздействия	259
20.5. Достоверность включения	261
20.6. Распространенные ошибки	261
20.7. Открытые вопросы	263

Глава 21. Несоответствие коэффициента выборки и другие ограничительные показатели

21.1. Несоответствие коэффициента выборки (SRM)	264
21.2. Причины возникновения SRM	266
21.3. Устранение SRM	268
21.4. Другие ограничительные показатели, связанные с доверием	269

Глава 22. Утечка и интерференция между вариантами

22.1. Примеры	272
22.2. Некоторые практические решения	275
22.2.1. Полезное правило: ценность действия в экосистеме	276
22.2.2. Изоляция	277
22.2.3. Анализ на уровне ребер графа	279
22.2.4. Обнаружение и мониторинг взаимовлияния	280

Глава 23. Измерение долгосрочных эффектов

23.1. Что такое долгосрочные эффекты?	281
23.2. Причины, по которым могут различаться краткосрочные и долгосрочные эффекты	282
23.4. Зачем измерять долгосрочные эффекты?	284
23.5. Длительные эксперименты	285
23.6. Альтернативные методы для длительных экспериментов	288
23.6.1. Метод №1: когортный анализ	288
23.6.2. Метод № 2: постпериодный анализ	288
23.6.3. Метод №3: воздействие с интервалом во времени	290
23.6.4. Метод №4: сдерживание и обратный эксперимент	292

Предметный указатель

Предисловие от издательства

ОТЗЫВЫ И ПОЖЕЛАНИЯ

Мы всегда рады отзывам наших читателей. Расскажите нам, что вы думаете об этой книге, – что понравилось или, может быть, не понравилось. Отзывы важны для нас, чтобы выпускать книги, которые будут для вас максимально полезны.

Вы можете написать отзыв на нашем сайте www.dmkpress.com, зайдя на страницу книги и оставив комментарий в разделе «Отзывы и рецензии». Также можно послать письмо главному редактору по адресу dmkpress@gmail.com; при этом укажите название книги в теме письма.

Если вы являетесь экспертом в какой-либо области и заинтересованы в написании новой книги, заполните форму на нашем сайте по адресу http://dmkpress.com/authors/publish_book/ или напишите в издательство по адресу dmkpress@gmail.com.

СПИСОК ОПЕЧАТОК

Хотя мы приняли все возможные меры для того, чтобы обеспечить высокое качество наших текстов, ошибки все равно случаются. Если вы найдете ошибку в одной из наших книг – возможно, ошибку в основном тексте или программном коде, – мы будем очень благодарны, если вы сообщите нам о ней. Сделав это, вы избавите других читателей от недопонимания и можете нам улучшить последующие издания этой книги.

Если вы найдете какие-либо ошибки в коде, пожалуйста, сообщите о них главному редактору по адресу dmkpress@gmail.com, и мы исправим это в следующих тиражах.

НАРУШЕНИЕ АВТОРСКИХ ПРАВ

Пиратство в интернете по-прежнему остается насущной проблемой. Издательство «ДМК Пресс» очень серьезно относится к вопросам защиты авторских прав и лицензирования. Если вы столкнетесь в интернете с незаконной публикацией какой-либо из наших книг, пожалуйста, пришлите нам ссылку на интернет-ресурс, чтобы мы могли применить санкции.

Ссылку на подозрительные материалы можно прислать по адресу dmkpress@gmail.com.

Мы высоко ценим любую помощь по защите наших авторов, благодаря которой мы можем предоставлять вам качественные материалы.

Вступление

Получить числа легко; получить числа, которым можно *доверять*, сложно. Это практическое руководство от ведущих специалистов по экспериментам в Google, LinkedIn и Microsoft научит вас, как ускорить внедрение инноваций, используя *доверительные контролируемые онлайн-эксперименты* (trustworthy online controlled experiments), или, как их чаще называют, *A/B-тесты*. Основываясь на практическом опыте компаний, каждая из которых проводит более 20 000 контролируемых экспериментов в год, авторы делятся примерами, советами и предостережениями со студентами и профессионалами отрасли, приступающими к экспериментам, а также детально раскрывают сложные темы для опытных практиков, которые хотят усовершенствовать процесс принятия решений на основе экспериментальных данных в своей организации.

Прочитав эту книгу, вы научитесь:

- использовать научные методы для оценки гипотез с помощью контролируемых экспериментов;
- определять ключевые показатели и в идеале общий критерий оценки;
- проверять достоверность результатов и предупреждать экспериментаторов о нарушении предположений;
- выполнять быструю интерпретацию и итерации на основе полученных результатов;
- устанавливать ограничения для защиты ключевых бизнес-целей;
- создавать масштабируемые платформы, снижающие предельную стоимость экспериментов почти до нуля;
- избегать ловушек, таких как эффекты переноса, закон Тваймана, парадокс Симпсона и сетевые взаимодействия;
- решать на практике проблемы статистики, в том числе общие нарушения предположений.

Рон Кохави (Ron Kohavi) – вице-президент и технический сотрудник Airbnb. Он трудился над этой книгой, когда был членом технической команды и корпоративным вице-президентом в Microsoft. До этого он был директором по интеллектуальному анализу данных и персонализации в Amazon. Рон получил степень доктора информатики в Стэнфордском университете. Его статьи имеют более 40 000 цитирований, и три из них входят в 1000 наиболее цитируемых статей в области информатики.

Диана Тан (Diane Tang) – научный сотрудник Google, обладающий опытом в области крупномасштабного анализа данных и инфраструктуры, контролируемых онлайн-экспериментов и рекламных систем. Она получила

степень бакалавра гуманитарных наук в Гарварде и степень магистра/доктора в Стэнфорде, имеет патенты и публикации в области мобильных сетей, визуализации информации, методологии экспериментов, инфраструктуры данных, интеллектуального анализа данных и больших данных.

Я Сюй (Ya Xu) возглавляет отдел экспериментов и сбора данных в LinkedIn. Она опубликовала несколько работ по методике экспериментов и часто выступает на авторитетных конференциях и с лекциями в университетах. Ранее она работала в Microsoft и получила докторскую степень по статистике в Стэнфордском университете.

Предисловие

Если у нас есть данные, давайте рассмотрим их.

Если все, что у нас есть, – это мнения, делайте что я скажу.

– Джим Барксдейл,
бывший генеральный директор Netscape

Наша цель при написании этой книги – поделиться практическими уроками, извлеченными из многолетнего опыта проведения масштабных онлайн-экспериментов в Amazon и Microsoft (Рон Кохави), Google (Диана Тан), Microsoft и LinkedIn (Я Сюй). Хотя мы пишем эту книгу как частные лица, а не как представители Google, LinkedIn или Microsoft, мы опираемся на уроки и ошибки, с которыми столкнулись за годы нашей работы, и даем рекомендации как по программным платформам, так и по корпоративным аспектам использования контролируемых экспериментов для формирования культуры, основанной на данных, когда решения принимают исходя из достоверной информации, а не полагаясь на HiPPO (highest paid person's opinion, «мнение самой высокооплачиваемой персоны»). Мы считаем, что многие из этих уроков применимы в онлайн-среде, в больших или малых компаниях, или даже в командах и отделах внутри компании. Мы разделяем озабоченность по поводу необходимости оценки достоверности результатов экспериментов. Мы верим в скептицизм, выраженный законом Тваймана: любое значение, которое выглядит интересным или странным, обычно ошибочно; мы призываем читателей перепроверить результаты и провести тесты на достоверность, особенно если получены исключительно положительные результаты. Получить числа легко; получить числа, которым можно доверять, сложно!

Часть I предназначена для чтения всеми, независимо от уровня подготовки, и состоит из четырех глав:

- глава 1 представляет обзор преимуществ проведения контролируемых онлайн-экспериментов и вводит отраслевые термины;
- в главе 2 рассмотрен пример полного цикла организации и проведения эксперимента;
- в главе 3 описаны распространенные ошибки и способы повышения надежности экспериментов;
- в главе 4 рассказано, что нужно для создания экспериментальной платформы и масштабирования онлайн-экспериментов.

Части со II по V могут быть прочитаны по мере необходимости, но они написаны с упором на конкретную аудиторию. Часть II содержит пять глав,

посвященных основам, таким как показатели организации. Главы части II рекомендуются всем, особенно руководителям и менеджерам среднего звена. Часть III состоит из двух глав, в которых представлены методы, дополняющие контролируемые онлайн-эксперименты. Эти методы могут оказаться полезными для руководителей, специалистов по обработке данных, инженеров, аналитиков, менеджеров по продуктам и других специалистов, стремящихся эффективно расходовать время и усилия. Часть IV посвящена созданию платформы для экспериментов и предназначена для инженеров и разработчиков. Наконец, в части V рассматриваются вопросы расширенного анализа, и она предназначена для специалистов по данным.

Наш веб-сайт **<https://experimentguide.com>** дополняет эту книгу. Он содержит дополнительные материалы, исправления и предоставляет форум для открытого обсуждения. Все доходы от этой книги авторы намерены пожертвовать на благотворительность.

Благодарности

Мы хотим поблагодарить наших коллег, которые работали с нами на протяжении многих лет. Хотя их было слишком много, чтобы перечислить каждое имя, эта книга основана на нашей совместной работе, а также на других исследованиях в отрасли, помимо исследований и проведения контролируемых онлайн-экспериментов. Мы многому у вас научились, спасибо.

Во время работы над книгой мы не переставали благодарить нашего редактора Лорен Коулз за сотрудничество с нами на протяжении всего этого процесса. Чери Вудворд дала нам отличные советы по редактированию и стилю и помогла объединить наши три голоса. Стефани Грей работала с нами над всеми графиками и рисунками, улучшая их раз за разом. Ким Вернон выполнила окончательное редактирование текста и проверку библиографии.

Что наиболее важно, мы глубоко признательны нашим семьям за то, что они позволили нам пожертвовать временем, проведенным с ними, чтобы поработать над этой книгой. Спасибо семье Ронни: Яэль, Орен, Иттаи и Нога, семье Дианы: Бену, Эмме и Лии, а также семье Я Сюй: Томасу, Лере и Тавису. Мы не смогли бы написать эту книгу без вашей поддержки и энтузиазма!

Google: Хэл Вариан, Дэн Рассел, Кэрри Граймс, Найл Кардин, Дейрдри О'Брайен, Хеннинг Хонхольд, Мукунд Сундарараджан, Амир Наджми, Патрик Райли, Эрик Тассон, Джен Дженнаи, Шеннон Валлор, Эрик Миралья, Дэвид Прайс, Кристал Дален, Тэмми Джи Мюррей, Лана Доннелли и все, кто работает над экспериментами в Google, спасибо.

LinkedIn: Стивен Линч, Яв Божинов, Джаида Лю, Вейтао Дуан, Нанью Чен, Гийом Сен-Жак, Элейн Колл, Мин Лю, Арун Свами, Киран Прасад, Игорь Перишич и вся команда экспериментов, спасибо.

Microsoft: Омар Алонсо, Бенджамин Араи, Джордан Атлас, Рича Баяни, Эрик Бойд, Джонни Чан, Алекс Денг, Энди Дрейк, Александр Фабиджан, Брайан Фраска, Скотт Гуд, Сомит Гупта, Адам Густафсон, Томми Гай, Рэнди Хенн, Эдвард Джезерски, Цзин Джин, Дону Ким, Уолдо Кейперс, Джонатан Литц, София Лю, Цзяннан Лу, Ци Лу, Даниэль Миллер, Карл Митчелл, Нильс Полманн, Вен Цинь, Томас Шрайтер, Гарри Шум, Дэн Соммерфилд, Гранат Ваз, Тоби Уокер, Мишель Зункер, а также команда анализа и экспериментов, спасибо.

Особая благодарность Марии Стоун и Маркусу Перссон за отзывы о книге, а также Мишель Н. Мейер за экспертный отзыв по главе, посвященной этике.

Среди тех, кто дал свой отзыв: Адиль Айджаз, Джонас Алвес, Алон Амит, Кевин Андерсон, Джоэл Барахас, Хуман Бедаят, Бо Бендер, Бахадор Биглари, Стюарт Бак, Джике Чонг, Джек Чоу, Павел Дмитриев, Юронг Фан, Георгий Георгиев, Илиас Геростатопулос. Мэтт Гершофф, Уильям Гроссо, Адитья Гупта, Раджеш Гупта, Шилпа Гупта, Крис Джек, Джейкоб Ярнвалл, Дэйв Кароу, Славек Кирнер, Пит Кумен, Дилан Льюис, Брайан Лю, Дэвид Манхейм, Колин МакФарланд, Танаполиндраунчрон, Адитья Рамдас, Андре Рихтер, Цзяньхонг Шен, Ганг Су, Энтони Тан, Лукас Вермеер, Роуэл Виллемс, Ю Ян и Юфэн Ван.

Спасибо всем, кто помогал нам, но здесь не упомянут.

ЧАСТЬ I



Введение для всех

Глава 1

Введение и мотивация

Одно точное измерение стоит тысячи экспертных заключений.

– Адмирал Грейс Хоппер

В 2012 году сотрудник Bing, поисковой системы Microsoft, предложил изменить способ отображения заголовков объявлений. Идея заключалась в том, чтобы удлинить строку заголовка объявлений, объединив ее с текстом из первой строки под заголовком, как показано на рис. 1.1.

Никто не ожидал, что это самое простое изменение из сотен предложенных станет лучшей идеей для увеличения дохода в истории Bing!

Это предложение имело низкий приоритет и ждало своей очереди более шести месяцев, пока программист-разработчик не решил попробовать его, учитывая, насколько легко было внести изменение в код. Он внес изменение и начал проверять эффект на реальных пользователях, случайным образом показывая некоторым из них новый макет заголовка, а другим старый. При этом регистрировались взаимодействия пользователей с веб-сайтом, включая клики по рекламе и полученный от них доход. Это пример А/В-теста, простейшего типа контролируемого эксперимента, в котором сравниваются два варианта: А и В, или *контрольный* (control) и *тестовый* (treatment)¹.

Через несколько часов после запуска теста сработало предупреждение о слишком высоком уровне дохода, указывающее, что с экспериментом что-то не так. Новый макет заголовка приносил слишком много денег от рекламы. Такие предупреждения «слишком хорошо, чтобы быть правдой» очень полезны, поскольку они обычно указывают на серьезную ошибку, например случаи, когда выручка зарегистрирована дважды (двойной биллинг) или когда отображается только реклама, а остальная часть веб-страницы повреждена.

¹ Современная методика контролируемых экспериментов родилась в медицине и фармацевтике, и отсюда распространилась в другие отрасли. Поэтому в зарубежной литературе исторически принято обозначать экспериментальное воздействие и подопытную группу термином treatment (лечение, терапия). – *Прим. перев.*

Однако в этом эксперименте не было ошибки. Выручка Bing увеличилась на колоссальные 12 %, что в то время составляло более 100 млн долл. в год только в США, без заметного ущерба для ключевых показателей взаимодействия с пользователем. Эксперимент повторяли несколько раз в течение длительного периода.




Рис. 1.1. Эксперимент, изменяющий способ отображения рекламы в Bing

Этот пример иллюстрирует несколько ключевых аспектов контролируемых онлайн-экспериментов:

- нам сложно понять ценность идеи. В данном случае простое изменение стоимостью более 100 млн долл. в год ждало своей очереди несколько месяцев;
- небольшие изменения могут оказать большое влияние. **Окупаемость инвестиций** (return on investment, ROI) в размере 100 млн долл. в год от нескольких дней работы одного программиста оказалась настолько экстремальной, насколько это вообще возможно;
- эксперименты с выраженным эффектом встречаются очень редко. Bing проводит более 10 000 экспериментов в год, но простые воздействия, приводящие к значительным улучшениям, появляются только раз в несколько лет;
- накладные расходы на проведение эксперимента должны быть небольшими. Инженеры Bing имели доступ к ExP, экспериментальной системе Microsoft, которая облегчила научную оценку идеи;
- **общий критерий оценки** (overall evaluation criterion, OEC) более подробно описанный в этой главе) должен быть сформулирован очень строго. В данном случае ключевым компонентом OEC была выручка, но одной лишь выручки недостаточно для формирования OEC. Бездумный подход может привести к заваливанию веб-сайта рекламой, что, как известно, отрицательно сказывается на опыте пользователей. Bing использует OEC, который соотносит доход с показателями взаимодействия с пользователем, включая количество сеансов на пользователя (т. е. когда пользователи отказываются от участия или, наоборот, увеличивают вовлеченность) и несколько других компонентов. Ключевым моментом нашего примера является то, что показатели взаимодействия с пользователем существенно не ухудшились, даже несмотря на то, что доход резко вырос.

В следующем разделе вводится терминология контролируемых экспериментов.

1.1. ТЕРМИНОЛОГИЯ КОНТРОЛИРУЕМЫХ ОНЛАЙН-ЭКСПЕРИМЕНТОВ

Контролируемые эксперименты имеют долгую и увлекательную историю, о которой мы уже рассказывали в статьях в интернете. Иногда их называют А/В-тестами, А/В/п-тестами (чтобы подчеркнуть множественность вариантов), *полевыми экспериментами* (field experiment), *рандомизированными контролируемыми экспериментами* (randomized controlled experiment), *сплит-тестами* (split test), *тестами с корзиной* (bucket test) и *пробными полетами* (flight test). В этой книге мы используем термины «контролируемые эксперименты» и «А/В-тесты» как синонимы, независимо от количества вариантов.

Контролируемые онлайн-эксперименты широко используются в таких компаниях, как Airbnb, Amazon, Booking.com, eBay, Facebook, Google, LinkedIn, Lyft, Microsoft, Netflix, Twitter, Uber, Yahoo!, Oath и Яндекс. Эти компании проводят от тысячи до десятков тысяч экспериментов каждый год иногда с участием миллионов пользователей и тестируют все подряд, включая изменения пользовательского интерфейса (UI), алгоритмы релевантности (поиск, реклама, персонализация, рекомендации и т. д.), задержку/быстродействие, системы управления контентом, системы поддержки клиентов и многое другое. Эксперименты проводятся по нескольким каналам: веб-сайтам, приложениям для компьютеров, мобильным приложениям и электронной почте.

В наиболее распространенных контролируемых онлайн-экспериментах пользователи случайным образом распределяются между вариантами на постоянной основе (пользователь получает один и тот же вариант за несколько посещений). В нашем первом примере от Bing контрольным вариантом было исходное отображение рекламы, а вариантом с воздействием – отображение рекламы с более длинными заголовками. Взаимодействие пользователей с веб-сайтом Bing было *измеримым*, т. е. отслеживалось и регистрировалось. По зарегистрированным данным вычисляются показатели, которые позволяют нам оценить разницу между вариантами для каждого показателя.

В простейших контролируемых экспериментах существует два варианта: контрольный (А) и тестовый (В), как показано на рис. 1.2.



Рис. 1.2. Простой контролируемый эксперимент: А/В-тест

Сейчас мы следуем терминологии Кохави и Лонгботтома (2017), а соответствующие термины из других областей будут представлены ниже. Вы найдете много других ресурсов по экспериментированию и А/В-тестированию в конце этой главы в разделе «Дополнительная литература».

Общий критерий оценки (ОЕС): количественный показатель цели эксперимента. Например, ваш ОЕС может быть выражен в днях на пользователя, указывая количество дней во время эксперимента, в течение которых пользователи были активны (т. е. они посетили сайт и предприняли какие-либо действия). Повышение этого показателя означает, что пользователи чаще посещают ваш сайт, что является отличным результатом. ОЕС должен быть измеримым в краткосрочной перспективе (продолжительность эксперимента), но при этом иметь причинное влияние на долгосрочные стратегические цели (см. раздел 1.7 и главу 7). В случае поисковой системы ОЕС может представлять собой комбинацию активности использования (например, количество сеансов на пользователя), релевантности (например, успешные сеансы, время до успеха) и дохода от рекламы (не все поисковые системы используют все перечисленные метрики или только эти метрики).

В статистике это часто называют *реакцией* (response) или *зависимой переменной* (dependent variable); другие синонимы – это *результат* (outcome), *оценка* (evaluation) и *функция пригодности* (fitness function). Эксперименты могут иметь несколько целей, и при анализе может применяться *сбалансированная система показателей* (balanced scorecard), хотя обычно рекомендуется использовать единственную метрику, возможно, представляющую собой взвешенную комбинацию таких целей.

Мы более подробно рассмотрим определение ОЕС для экспериментов в главе 7.

Параметр: контролируемая экспериментальная переменная, которая, как ожидается, влияет на ОЕС или другие интересующие показатели. Параметры иногда называют *факторами* или *переменными*. Параметрам присваивают значения, также называемые *уровнями*. В простых А/В-тестах обычно используют один параметр с двумя значениями. В онлайн-тестировании чаще используют конструкции с одной переменной и несколькими значениями (например, А/В/С/Д). *Многовариантные тесты*, также называемые *мультивариантными* (multivariate test, MVT), оценивают вместе несколько параметров (переменных), таких как цвет и размер шрифта, что позволяет экспериментаторам находить глобальный оптимум при взаимодействии параметров (см. главу 4).

Вариант: тестируемый пользовательский опыт, обычно путем присвоения значений параметрам. В простом А/В-тесте А и В – это два варианта, обычно называемые контрольным и тестовым. В некоторой литературе под вариантом понимают только тест; однако мы рассматриваем контроль как особый вариант: существующую версию, с которой будет выполняться сравнение. Например, в случае обнаружения ошибки в эксперименте вы должны прервать эксперимент и убедиться, что всем пользователям назначен (возвращен) контрольный вариант.

Рандомизатор: к *объектам эксперимента* (например, пользователям или страницам) применяется псевдослучайный процесс (например, хеширование) для сопоставления их с вариантами. Правильная рандомизация важна для обеспечения статистического сходства популяций, отнесенных к различным вариантам, что позволяет с высокой вероятностью определять причинные эффекты. Вы должны сопоставлять объекты с вариантами постоянным и независимым образом (т. е. если объектом рандомизации является пользователь, он должен постоянно видеть один и тот же опыт, а назначение пользователя определенному варианту не должно ничего говорить вам о назначении другого пользователя другому варианту). Этот подход применяется очень часто, и мы тоже настоятельно рекомендуем использовать пользователей в качестве объекта рандомизации при проведении контролируемых экспериментов для онлайн-аудитории. Некоторые экспериментальные проекты выбирают рандомизацию по страницам, сеансам или пользовательским дням (т. е. эксперимент остается неизменным для пользователя в течение каждого 24-часового окна, определенного сервером); см. главу 14 для получения дополнительной информации.

Правильная рандомизация имеет решающее значение! Если планом эксперимента предусмотрен равный процент пользователей для каждого варианта, то у каждого пользователя должны быть равные шансы быть назначенным каждому варианту. Не относитесь к рандомизации легкомысленно. Приведенные ниже примеры демонстрируют сложность и важность правильной рандомизации.

- Корпорации RAND в 1940-х годах потребовались случайные числа для методов Монте-Карло, поэтому они создали книгу из миллиона случайных цифр, сгенерированных с помощью импульсной машины. Однако из-за особенностей оборудования исходная таблица, как выяснилось, имела значительные смещения, и цифры пришлось рандомизировать заново в следующем издании книги (RAND 1955).
- Контролируемые эксперименты изначально использовались в медицине. Управление по делам ветеранов США провело эксперимент по применению стрептомицина для лечения туберкулеза, но испытания не увенчались успехом, поскольку врачи внесли свои предубеждения и повлияли на процесс отбора. Аналогичные испытания в Великобритании были проведены с использованием слепых протоколов и оказались успешными, что стало переломным моментом в методике контролируемых испытаний препаратов.

На присвоение варианта не должен влиять ни один фактор. Пользователи (объекты) не могут быть распределены каким-либо «обдуманном» способом. Важно отметить, что случайность означает не «спонтанный или незапланированный отбор, а преднамеренный выбор, основанный на вероятностях» (Mosteller, Gilbert and McPeck, 1983). В одной из своих работ Сенн (Senn, 2012) обсуждает мифы рандомизации.

1.2. ЗАЧЕМ НУЖНЫ ЭКСПЕРИМЕНТЫ?

КОРРЕЛЯЦИИ, ПРИЧИННО-СЛЕДСТВЕННАЯ СВЯЗЬ И ДОВЕРИТЕЛЬНОСТЬ

Допустим, вы работаете в компании, распространяющей контент по подписке, такой как Netflix, где $X\%$ пользователей уходят (закрывают подписку) каждый месяц. Вы решаете ввести новую функцию интерфейса и видите, что коэффициент оттока пользователей, использующих эту функцию, составляет $0,5X\%$, т. е. половину. У вас может возникнуть соблазн заявить о причинной связи; дескать, новая функция сокращает отток пользователей наполовину. Отсюда следует вывод, что, если мы сделаем эту функцию более заметной и заставим пользователей чаще ее использовать, количество подписок вырастет. Неправильно! На основе имеющихся данных нельзя сделать вывод о том, как влияет на отток пользователей эта функция, и возможны разные варианты – увеличение, уменьшение или неизменность.

Пример, демонстрирующий это заблуждение, можно найти в Microsoft Office 365, другом сервисе по подписке. Пользователи Office 365, которые видят сообщения об ошибках и сталкиваются со сбоями, демонстрируют более низкий коэффициент оттока, но это не означает, что Office 365 должен показывать больше сообщений об ошибках или что компания Microsoft должна снижать качество кода, вызывая больше сбоев. Оказывается, все три события вызваны одним фактором: использованием. Активные пользователи продукта видят больше сообщений об ошибках, сталкиваются с большим количеством сбоев и имеют более низкий процент оттока. Корреляция не подразумевает причинно-следственной связи, и неверная трактовка этих наблюдений приводит к ошибочным решениям.

В 1995 году Гаятт и коллеги представили *иерархию доказательств* как способ оценки рекомендаций в медицинской литературе. Впоследствии Гринхал расширила этот метод в своих исследованиях практики доказательной медицины (1997, 2014). На рис. 1.3 показана простая иерархия доказательств в переводе на нашу терминологию. Рандомизированные контролируемые эксперименты – золотой стандарт для установления причинно-следственной связи. Систематические обзоры, т. е. метаанализ контролируемых экспериментов, предоставляют дополнительные доказательства и возможности обобщения.



Рис. 1.3. Простая иерархия доказательств для оценки качества методики исследования (Greenhalgh, 2014)

Также применяются более сложные модели, такие как *уровни доказательности* (levels of evidence) Оксфордского центра доказательной медицины (2009).

Платформы для экспериментов, используемые нашими компаниями, позволяют экспериментаторам в Google, LinkedIn и Microsoft проводить десятки тысяч контролируемых онлайн-экспериментов в год с высокой степенью доверия к результатам. Мы считаем, что контролируемые онлайн-эксперименты:

- являются лучшим научным способом выявить причинно-следственную связь с высокой степенью достоверности;
- позволяют обнаруживать небольшие изменения, которые труднее обнаружить другими методами, например изменения во времени (чувствительность);
- позволяют обнаруживать неожиданные изменения. Этот момент часто недооценивают, но многие эксперименты демонстрируют неожиданное влияние на другие показатели, будь то снижение быстродействия, увеличение количества сбоев/ошибок или каннибализация¹ кликов от других функций.

Основное внимание в этой книге уделяется выявлению потенциальных ошибок в экспериментах и предложению методов, повышающих доверие к результатам. Контролируемые онлайн-эксперименты предоставляют беспрецедентную возможность автоматически собирать надежные данные в широком масштабе, хорошо рандомизировать объекты и избегать или об-

¹ Перетягивание кликов на себя, зачастую без видимой пользы. – Прим. перев.

наруживать подводные камни (см. главу 11). Мы рекомендуем использовать другие, менее надежные методы, в том числе наблюдательные исследования, лишь в случае невозможности проведения контролируемых онлайн-экспериментов.

1.3. НЕОБХОДИМЫЕ ИНГРЕДИЕНТЫ ДЛЯ ПРОВЕДЕНИЯ ЭФФЕКТИВНЫХ КОНТРОЛИРУЕМЫХ ЭКСПЕРИМЕНТОВ

Не каждое решение может быть подкреплено научной строгостью контролируемого эксперимента. Например, вы не сможете провести контролируемый эксперимент по корпоративным слияниям и поглощениям, так как невозможно одновременно реализовать слияние/поглощение и его противоположность (т. е. отсутствие такого события). Далее мы рассмотрим необходимые технические компоненты для проведения *полезных* контролируемых экспериментов, а затем обсудим организационные постулаты. В главе 4 мы рассматриваем модель зрелости экспериментирования. Итак, для проведения контролируемых экспериментов нужны следующие компоненты и условия.

1. Экспериментальные объекты (например, пользователи), которые могут быть отнесены к разным вариантам без перекрестного взаимного влияния (или с небольшим влиянием); например, пользователи в тестовой группе не влияют на пользователей в контрольной группе (см. главу 22).
2. Достаточное количество экспериментальных объектов (например, пользователей). Чтобы контролируемые эксперименты были полезными, мы рекомендуем использовать тысячи экспериментальных объектов: чем больше число, тем тоньше эффекты, которые можно обнаружить. Хорошая новость заключается в том, что даже небольшие стартапы в области программного обеспечения обычно быстро набирают достаточное количество пользователей и могут начать проводить контролируемые эксперименты, поначалу стремясь к выраженным эффектам. По мере роста бизнеса возрастает значимость мелких эффектов (например, крупные веб-сайты должны иметь возможность обнаруживать небольшие изменения ключевых показателей, влияющих на пользовательский опыт и доли процента изменения дохода), а чувствительность улучшается с ростом базы пользователей.
3. Ключевые показатели, в идеале ОЕС, сформулированы и могут быть измерены на практике. Если реальные цели слишком сложно измерить, важно договориться о суррогатных целях (см. главу 7). Вы должны иметь возможность собирать надежные данные, в идеале – дешево и масштабно. В экспериментах с программным обеспечением обычно легко удастся регистрировать системные события и действия пользователя (см. главу 13).

4. Простота внесения изменений. Программное обеспечение обычно легче изменить, чем оборудование; но даже в программном обеспечении некоторые области требуют определенного уровня гарантии качества. Изменения в рекомендательном алгоритме легко внести и оценить; изменения программного обеспечения в системах управления полетом самолетов требуют совершенно иного процесса утверждения Федеральным управлением гражданской авиации (FAA). Серверное программное обеспечение намного проще изменить, чем клиентское (см. главу 12), поэтому обращение к серверным службам из клиентских приложений становится все более распространенным подходом, что позволяет выполнять обновления и изменения служб быстрее и с помощью контролируемых экспериментов.

Большинство нетривиальных онлайн-сервисов соответствует или может соответствовать необходимым условиям для запуска гибкого процесса разработки, основанного на контролируемых экспериментах. Многие приложения, работающие по принципу обращения к серверным службам, также могут относительно легко подстроиться под эти требования. Томке (Thomke) писал, что организации ощущают максимальную выгоду от экспериментов, когда они используются в сочетании с «инновационной системой». Такой инновационной системой является гибкая разработка программного обеспечения.

Когда контролируемые эксперименты невозможны, можно провести моделирование и использовать другие экспериментальные методы (см. главу 10). Ключевая мысль здесь заключается в том, что если есть возможность проводить контролируемые эксперименты, то лучше их и выбрать, поскольку они предоставляют наиболее надежный и чувствительный механизм для оценки эффекта от изменений.

1.4. Постулаты

В 2013 году Кохави сформулировал три основных постулата для организаций, которые хотят проводить контролируемые онлайн-эксперименты.

1. Организация хочет принимать решения на основе данных и официально оформила ОЕС.
2. Организация готова инвестировать в инфраструктуру и тесты, чтобы проводить контролируемые эксперименты и гарантировать достоверность результатов.
3. Организация осознает, что плохо умеет оценивать значимость идей.

Постулат 1: Организация хочет принимать решения на основе данных и официально оформила ОЕС

Вы редко услышите, как кто-то во главе организации говорит, что они не хотят ориентироваться на данные (заметным исключением являлась Apple под руководством Стива Джобса, где Кен Сегалл заявил, что «мы не тести-

ровали ни одной рекламы для печати, телевидения, рекламных щитов, интернета, розничной торговли и т. д.». Но измерение дополнительных выгод для пользователей от новых функций требует затрат, и объективные измерения обычно показывают, что прогресс не такой радужный, как первоначально предполагалось. Многие организации не будут тратить ресурсы, необходимые для определения и измерения прогресса. Часто бывает проще (и политически выгоднее) составить план, выполнить его и объявить об успехе с ключевым показателем «процент выполнения плана», игнорируя, оказывает ли новая функция хоть какое-то положительное влияние на ключевые показатели компании.

Чтобы стать компанией, опирающейся на данные, необходимо определить ОЕС, легко измеряемый за относительно короткие промежутки времени (например, от одной до двух недель). В крупных организациях может быть несколько ОЕС или несколько ключевых показателей, которые используются совместно с уточнениями для разных областей. Сложнее всего найти показатели, измеримые за короткий период, но при этом достаточно чувствительные, чтобы показать различия, и позволяющие прогнозировать долгосрочные цели. Например, показатель «прибыль» – не лучший вариант ОЕС, поскольку сиюминутные действия (например, повышение цен) могут увеличить краткосрочную прибыль, но и навредить ей в долгосрочной перспективе. И наоборот, *длительность жизненного цикла клиента* (customer lifetime value, CLV) – это стратегически мощный ОЕС. Трудно переоценить важность разработки хорошего ОЕС, который подходит именно вашей организации (см. главу 6).

Чтобы не складывалось впечатление, будто решения в компании зависят от единственного источника данных (например, контролируемого эксперимента), часто используют термины-эвфемизмы, такие как «основанный на больших данных» или «информационно обоснованный». В этой книге мы используем подобные термины как синонимы. Решение и в самом деле следует принимать с использованием множества источников данных, включая контролируемые эксперименты, опросы, оценки затрат на сопровождение нового кода и т. д. Организация, основанная на данных или информационных потоках, собирает соответствующие данные для принятия решения и формирования обоснованного мнения высокопоставленных лиц, а не полагается только на их интуицию.

Постулат 2: Организация готова инвестировать в инфраструктуру и тесты, чтобы проводить контролируемые эксперименты и гарантировать достоверность результатов

В области онлайн-программирования (веб-сайты, мобильные, настольные приложения и сервисы) необходимые условия для контролируемых экспериментов могут быть выполнены с помощью разработки программного обеспечения (см. раздел 1.3): можно надежно рандомизировать пользователей,

есть возможность собирать телеметрию и относительно легко вносить изменения в программное обеспечение, например внедрять новые функции (см. главу 4). Даже на относительно небольших веб-сайтах наберется достаточно пользователей для проведения необходимых статистических тестов.

Контролируемые эксперименты особенно полезны в сочетании с гибкой разработкой программного обеспечения (Мартин, 2008, К. С. Рубин, 2012), процессом развития клиентов (Бланк, 2005) и *минимально жизнеспособными продуктами* (minimum viable product, MVP) – это понятие предложил Эрик Рис в книге «Экономичный стартап» (Ries, 2011).

В других областях может быть трудно или невозможно надежно проводить контролируемые эксперименты. Некоторые воздействия, необходимые для контролируемых экспериментов в области медицины, могут быть неэтичными или незаконными. Аппаратные устройства могут иметь длительные сроки изготовления и модификации, поэтому контролируемые эксперименты с пользователями редко проводятся на новых аппаратных устройствах (например, новых мобильных телефонах). В этих ситуациях могут потребоваться дополнительные методы (см. главу 10), применяемые, когда невозможно провести контролируемые эксперименты.

Предполагая, что вы можете проводить контролируемые эксперименты, важно обеспечить их надежность. При проведении онлайн-экспериментов получить числа легко; получить числа, которым можно доверять, сложно. Глава 3 посвящена получению достоверных результатов.

Постулат 3: Организация осознает, что плохо умеет оценивать значимость идей

Новые функции появляются потому, что команды считают их полезными, однако во многих областях большинство идей не помогают улучшить ключевые показатели. Только треть идей, протестированных в Microsoft, пошла на пользу показателям, на которых была направлена разработка. Еще труднее добиться успеха в хорошо оптимизированных областях, таких как Bing и Google, где показатель успешности некоторых показателей составляет около 10–20 %.

Фарид Мосават (Farid Mosavat), директор по продуктам и жизненному циклу Slack, написал в Twitter, что с учетом всего опыта Slack только около 30 % экспериментов по монетизации показывают положительные результаты: «Если вы работаете в команде экспериментаторов, привыкните к тому, что в лучшем случае 70 % вашей работы пропадет напрасно, и в соответствии с этим выстраивайте свои процессы».

Авинаш Кошик (Avinash Kaushik) написал в своем учебнике по экспериментам и тестированию что «в 80 % случаев мы ошибаемся в оценке того, чего хочет клиент». Майк Моран (Mike Moran) писал, что Netflix считает 90 % того, что они тестируют, заведомо ошибочным. Регис Хадиарис (Regis Hadiaris) из Quicken Loans писал, что «за те пять лет, что я проводил тесты, я примерно

так же правильно угадывал результаты, как бейсболист высшей лиги бьет по мячу. Естественно – я занимаюсь этим пять лет и могу только “угадывать” результат теста примерно в 33 % случаев!» Дэн МакКинли (Dan McKinley) из Etsy написал: «Почти все тесты терпят неудачу», а в отношении новых функций он написал: «Было унижительно осознавать, насколько редко они преуспевают с первой попытки. Я сильно подозреваю, что этот опыт универсален, но он не получил всеобщего признания или принятия». Наконец, Колин Макфарланд (Colin McFarland) в своей книге *Experiment!* написал: «Независимо от того, насколько вы уверены, что это несложно, сколько исследований вы провели или сколько конкурентов занимаются этим, экспериментальные идеи терпят неудачу намного чаще, чем вы думаете».

Такая печальная статистика присуща не каждой области экспериментов, но большинство из тех, кто проводил контролируемые эксперименты на веб-сайтах и приложениях, ориентированных на клиентов, испытали на себе эту унижительную реальность: *мы не умеем правильно оценивать значимость идей.*

1.5. ПОСТЕПЕННЫЕ УЛУЧШЕНИЯ

На практике улучшения ключевых показателей достигаются за счет множества небольших изменений: от 0,1 до 2 %. Многие эксперименты влияют только на определенный сегмент пользователей, поэтому вы должны разделить влияние 5 % улучшения на 10 % ваших пользователей, что приведет к гораздо меньшему влиянию (например, 0,5 %, если подопытная популяция аналогична остальной популяции пользователей); более подробно мы обсудим этот вопрос в главе 3. Как говорит герой Аль Пачино в фильме «Каждое воскресенье», «... к победе идут дюйм за дюймом».

Пример рекламы Google

В 2011 году, после более чем года разработки и дополнительных экспериментов, Google запустил улучшенный механизм ранжирования рекламы. Инженеры разработали и экспериментально проверили новые и улучшенные модели измерения показателя качества рекламы в рамках существующего механизма ранжирования рекламы, а также изменения самого аукциона рекламы. Они провели сотни контролируемых экспериментов и выполнили несколько итераций; некоторые на всех рынках, а некоторые – в долгосрочной перспективе на определенных рынках, чтобы лучше понять влияние на рекламодателей. Это значительное изменение бэкэнда – подкрепленное контролируемыми экспериментами – в конечном итоге подтвердило, что планирование нескольких изменений и их последующее объединение улучшило взаимодействие с пользователем за счет предоставления более качественной рекламы и улучшило опыт рекламодателей, получивших более низкую среднюю цену за более качественную рекламу.

Пример Bing Relevance

Команда подразделения Relevance в Bing состоит из нескольких сотен человек, которым поручено ежегодно улучшать один показатель ОЕС на 2 %. Это сумма эффектов воздействия (т. е. дельта ОЕС) во всех контролируемых экспериментах, проведенных на пользователей в течение года, при условии, что они являются аддитивными. Поскольку команда проводит тысячи экспериментов и некоторые из них могут оказаться положительными случайно, баллы в размере 2 % присваиваются только на основе репликации эксперимента: как только реализация идеи покажется успешной, возможно, после нескольких итераций и уточнений, выполняется *удостоверяющий эксперимент* (certification experiment). Положительный эффект этого эксперимента подтверждает достижение целевого балла 2 %. В последнее время планируется снизить порог эффекта для повышения точности воздействия.

Пример рекламной службы Bing

Команда рекламной службы Bing стабильно увеличивала доход на 15–25 % в год, но большинство улучшений происходило постепенно. Каждый месяц команда формировала «пакеты» – результаты многих экспериментов, как показано на рис. 1.4. Большинство улучшений были небольшими, некоторые ежемесячные пакеты даже оказывались отрицательными из-за нехватки места под рекламу или требований законодательства.




Рис. 1.4. Доход от рекламы Bing во времени (ось Y показывает рост примерно на 20 % в год). Конкретные числа не важны

Любопытно и полезно наблюдать сезонные всплески примерно в декабре, когда покупательное намерение пользователей резко возрастает, поэтому рекламное пространство увеличивается и доход на тысячу поисковых запросов становится больше.

1.6. ПРИМЕРЫ ИНТЕРЕСНЫХ КОНТРОЛИРУЕМЫХ ОНЛАЙН-ЭКСПЕРИМЕНТОВ

Интересны эксперименты, в которых абсолютная разница между ожидаемым и фактическим результатом велика. Если вы предполагали, что что-то должно произойти, и это произошло, это вас мало чему научит. Если вы думали, что что-то должно произойти, а этого не произошло, значит, вы узнали кое-что важное. И если вы думали, что произойдет что-то незначительное, а результаты являются большим сюрпризом и ведут к прорыву, вы узнали что-то очень ценное.

Примеры Bing в начале этой главы и в этом разделе рассказывают истории необычного успеха с удивительными, весьма полезными результатами. Попытка Bing интегрироваться с социальными сетями, такими как Facebook и Twitter, является примером ожидания сильного эффекта и его отсутствия – попытки были прекращены после того, как многочисленные эксперименты не принесли никакой пользы в течение двух лет.

Хотя устойчивый прогресс – это вопрос непрерывных экспериментов и множества небольших улучшений, дальше мы приведем несколько примеров неожиданно большой отдачи, демонстрирующих, насколько плохо мы оцениваем полезность идей.

Пример пользовательского интерфейса: 41 оттенок синего

Мелкие дизайнерские решения могут давать значительный эффект, что неизменно демонстрируют и Google, и Microsoft. Google протестировал 41 градацию синего цвета¹ на страницах результатов поиска, разочаровав тогдашних лидеров визуального дизайна. Тем не менее корректировки цветовой схемы, внесенные Google, в конечном итоге оказали положительное влияние на вовлечение пользователей (обратите внимание, что Google не сообщает о результатах отдельных промежуточных изменений) и привели к тесному сотрудничеству между дизайнерами и разработчиками экспериментов. Доработки цветовой схемы Bing от Microsoft аналогичным образом показали, что пользователи стали более успешны в решении своих задач, период вовлеченности стал длиннее, а монетизация возросла до суммы более 10 млн долл. США в год.

Это отличные примеры крошечных изменений, оказывающих огромное

¹ Цвет выбран не случайно. Оттенки синего цвета, в отличие от других цветов, хорошо различает даже большинство дальтоников. – *Прим. перев.*


влияние, но, если учесть, что уже опробован широкий спектр цветов, маловероятно, что игра с цветами в последующих экспериментах приведет к ощутимым улучшениям.

Предложение в нужное время

В 2004 году Amazon разместил на главной странице рекламный блок кредитной карты. Он был очень прибыльным, но имел слишком низкий *коэффициент отклика* (click-through rate, CTR). Команда провела эксперимент, переместив блок на страницу корзины покупок, которую пользователь видит после добавления товара, и снабдила блок простыми вычислениями, наглядно показывающими экономию, которую получит пользователь (рис. 1.5).

Поскольку пользователи, добавляющие товар в корзину, имеют четкое намерение совершить покупку, это предложение отображается в нужное время. Контролируемый эксперимент показал, что это простое изменение увеличило годовую прибыль Amazon на десятки миллионов долларов.

You could save \$30 today with the Amazon Visa® Card:



The image shows a promotional banner for the Amazon Visa credit card. On the left is a small image of the Amazon Visa card. To its right, the text reads: 'Your current subtotal: \$32.20', followed by 'Amazon Visa discount: - \$30.00' in bold, and 'Your new subtotal: \$2.20'. To the right of this text is a button with a play icon and the text 'Find out how'.

Save \$30 off your first purchase, earn 3% rewards, get a 0% APR*, and pay no annual fee.

Рис. 1.5. Предложение Amazon по кредитной карте с экономией от общей стоимости корзины

Персональные рекомендации

Грег Линден (Greg Linden) из Amazon разработал алгоритм для отображения персонализированных рекомендаций на основе товаров в корзине покупателя. Когда вы добавляете товар, появляются рекомендации; если вы добавите еще один товар, появятся новые рекомендации. Линден отмечает, что, хотя алгоритм выглядел многообещающе, «старший вице-президент по маркетингу был категорически против», утверждая, что это отвлечет людей от покупок. Грегу «строго запретили работать над этим дальше». Тем не менее он провел контролируемый эксперимент, и «нововведение выиграло с таким огромным отрывом, что отказ от него можно было бы компенсировать только значительными изменениями в Amazon. Поэтому рекомендации на основе корзины немедленно запустили в работу». Теперь рекомендации на основе корзины используют многие сайты.

Скорость имеет большое значение

В 2012 году инженер-разработчик Microsoft Bing внес изменения в технологию разработки кода JavaScript, что значительно сократило HTML-код,

отправляемый клиентам, и привело к повышению быстродействия. Контролируемый эксперимент показал удивительное улучшение ключевых показателей. Разработчики провели дополнительный эксперимент, чтобы оценить влияние быстродействия сервера. Результат показал, что повышение быстродействия сервера также значительно улучшает ключевые пользовательские метрики, такие как процент успеха и время до успеха, и каждое улучшение производительности на 10 мс (1/30 длительности моргания глаза) полностью окупает годовые затраты на оклад разработчика.

К 2015 году, когда производительность Bing значительно улучшилась, встал вопрос о том, имеет ли значение дальнейшее повышение быстродействия, если сервер и так возвращает результаты менее чем за секунду на 95-м процентиле (т. е. для 95 % запросов). Команда Bing провела дополнительное исследование, показавшее, что ключевые показатели пользователей по-прежнему значительно улучшаются. Хотя относительное влияние на доход несколько снизилось, выручка Bing за это время выросла настолько, что каждая миллисекунда повышения быстродействия значила больше, чем в прошлом; доход от сокращения времени отклика всего на четыре миллисекунды перекрывал годовой оклад инженера (см. главу 5 с подробным описанием этого эксперимента и анализом важности быстродействия)!

Эксперименты с быстродействием проводились в нескольких компаниях, и результаты показали, насколько важен этот параметр. В Amazon эксперимент с замедлением на 100 мс снизил продажи на 1 %. Совместный доклад инженеров Bing и Google продемонстрировал значительное влияние быстродействия на ключевые показатели, включая отдельные запросы, доход, количество кликов, удовлетворенность и время до клика.

Борьба с вредоносными программами

Реклама – прибыльный бизнес, и устанавливаемые пользователями бесплатные приложения часто содержат вредоносный код, который засоряет страницы рекламой. На рис. 1.6 показано, как страница Bing выглядела для пользователя с вредоносным ПО. Обратите внимание, что на страницу было добавлено несколько рекламных объявлений (выделены красным).

Мало того, что вредоносный код удалял рекламу Bing, лишая Microsoft дохода, он отображал нерелевантную рекламу низкого качества, что создавало неудобства для пользователей, которые, возможно, не понимали, почему они видят так много рекламы. Microsoft провела управляемый эксперимент, направленный на 3,8 млн пользователей, потенциально пострадавших от вредоносного кода, в котором основные процедуры, изменяющие DOM (document object model, объектная модель документа), были переопределены, чтобы разрешить только ограниченные модификации из надежных источников. Результаты показали улучшение всех ключевых показателей Bing, включая количество сеансов на пользователя. Следовательно, пользователи стали посещать сайт чаще или уходить реже. Кроме того, пользователи стали более успешными в поиске, быстрее переходили по по-

лезным ссылкам, а годовой доход увеличился на несколько миллионов долларов. Вдобавок время загрузки страницы – ключевой показатель быстродействия, который мы обсуждали ранее, – для очищенных от вредоносного кода страниц улучшилось на сотни миллисекунд.




Рис. 1.6. Страница Bing, когда у пользователя есть вредоносное ПО, показывает несколько посторонних объявлений

Изменения в бэкенде

Изменения в бэкенд-алгоритмах часто упускаются из виду как область приложения контролируемых экспериментов, но они могут дать существенные результаты. Мы можем видеть это как на примере команд Google, LinkedIn и Microsoft, работающих над множеством небольших изменений, как мы говорили выше, так и в следующем примере с участием Amazon.

Еще в 2004 году существовал хороший алгоритм рекомендаций, основанный на двух наборах. Сначала рекомендация Amazon звучала как «Люди, которые купили товар X, купили товар Y», но затем ее обобщили до вида «Люди, которые *просмотрели* товар X, купили товар Y» и «Люди, которые просмотрели товар X, *просмотрели* товар Y». Было предложено использовать тот же алгоритм для рекомендации «Люди, которые *искали* X, купили товар Y». Стронники обновления алгоритма привели примеры неполных поисковых запросов, таких как «24», который большинство людей ассоциируют с телешоу с Кифером Сазерлендом в главной роли. Поиск Amazon дает плохие результаты (слева на рис. 1.7), такие как компакт-диски с 24 итальянскими песнями, одежда для 24-месячных малышей, 24-дюймовая вешалка для полотенец и т. д. Новый алгоритм дал первоклассные результаты (справа на рис. 1.7), вернув в поисковую выдачу DVD-диски с шоу и соответствующими книгами, на основе того, что люди *действительно* купили после поиска «24». Одной из слабых сторон алгоритма было то, что всплывали некоторые элементы, вообще не имеющие отношения к поисковому запросу; однако Amazon провела контролируемый эксперимент, и, даже несмотря на недостатки, это изменение увеличило общий доход Amazon на 3 % – сотни миллионов долларов.




Рис. 1.7. Поиск Amazon по запросу «24» без рекомендательного алгоритма (слева) и с применением алгоритма (справа)

1.7. СТРАТЕГИЯ, ТАКТИКА И ИХ СВЯЗЬ С ЭКСПЕРИМЕНТАМИ

Мы твердо убеждены, что, если имеются необходимые условия для проведения контролируемых онлайн-экспериментов, они должны использоваться для принятия организационных решений на всех уровнях, от стратегии до тактики.

Стратегия компании и контролируемые эксперименты синергичны. Дэвид Коллис (David Collis) из Lean Strategy писал, что «эффективная стратегия не подавляет предпринимательское поведение, а поощряет его, определяя границы, в которых должны иметь место инновации и эксперименты». Он дает определение процесса *бережливой стратегии* (lean strategy), которая уберегает от крайностей как жесткого планирования, так и безудержного экспериментирования.

Качественно проведенные эксперименты с правильно подобранными показателями дополняют бизнес-стратегию, разработку продукта и повышают операционную эффективность, приводя организацию к управлению данными, а не интуицией. Инкапсулируя стратегию в ОЕС, контролируемые эксперименты могут обеспечить отличную обратную связь для стратегии. Достаточно ли хорошо повышают ОЕС идеи, оцениваемые с помощью экспериментов? С другой стороны, неожиданные результаты экспериментов могут пролить свет на альтернативные стратегические возможности, ведущие к смене вектора развития. Решения по разработке продукта важны для стратегии развития, и тестирование нескольких вариантов разработки обеспечивает разработчикам полезную обратную связь. Наконец, многие тактические изменения могут улучшить *операционную эффективность*, которую Портер определяет как «выполнение аналогичных действий лучше, чем их выполняют конкуренты».

Далее мы рассмотрим два ключевых сценария.

Сценарий 1. *У вас есть бизнес-стратегия, и у вас есть продукт с достаточным количеством пользователей для экспериментов*

В этом сценарии эксперименты могут помочь подняться на холм локального оптимума на основе вашей текущей стратегии и продукта:

- эксперименты помогают выявить области с высокой рентабельностью инвестиций: те, которые улучшают ОЕС больше всего в пересчете на затраты. Тестирование различных областей с помощью MVP помогает быстрее исследовать обширный набор областей до выделения значительных ресурсов;
- эксперименты могут подсказать направление оптимизации, которое не очевидно для разработчиков, но может иметь большое значение для пользователя (например, цвет, интервал, быстроедействие);
- эксперименты помогают непрерывно и постепенно улучшать дизайн сайта, вместо того чтобы вводить радикальное изменение сайта, которое подвергает пользователей шоку отказа от привычки (пользо-

тели привыкли к старому дизайну и его функциям) и обычно терпит неудачу – не только в достижении намеченных целей, но даже не достигает паритета со старым сайтом по ключевым показателям;

- эксперименты могут иметь решающее значение для оптимизации внутренних алгоритмов и инфраструктуры, например алгоритмов рекомендаций и ранжирования.

Наличие стратегии критически важно для проведения экспериментов: именно она определяет выбор ОЕС. Далее контролируемые эксперименты помогают ускорить инновации, побуждая команды оптимизировать и улучшать ОЕС. Как правило, мы наблюдаем неправильное использование экспериментов именно там, где не потрудились выбрать ОЕС должным образом. Выбранные метрики должны соответствовать ключевым характеристикам и не допускать неоднозначности (см. главу 7).

В наших компаниях у нас есть не только команды, которые сосредоточены на правильном проведении экспериментов, но также есть команды, ориентированные на показатели: выбор показателей, проверка показателей и развитие показателей с течением времени. Эволюция показателей будет происходить как по мере развития вашей стратегии с течением времени, так и по мере того, как вы узнаете больше об ограничениях существующих показателей, например о том, что показатель CTR слишком неоднозначен и его необходимо доработать. Группы, отвечающие за показатели, также работают над определением того, какие показатели, измеримые в краткосрочной перспективе, определяют долгосрочные цели, поскольку эксперименты обычно проводятся в относительно короткие сроки. Хаузер и Кац писали, что «фирма должна определить показатели, на которые команда может повлиять сегодня, но в конечном итоге влияющие на долгосрочные цели фирмы» (см. главу 7).

Привязка стратегии к ОЕС также создает *стратегическую целостность* (strategic integrity). Синофски и Иенсити (Sinofski, Iansiti) подчеркивают, что «стратегическая целостность – это не создание блестящей стратегии или наличие идеальной организации: это обеспечение реализации правильных стратегий организацией, которая обладает согласованностью и знает, как их реализовать. Речь идет о согласовании директив, направленных сверху вниз, с задачами, направленными снизу вверх». ОЕС – идеальный механизм, чтобы прояснить стратегию и согласовать желаемые функции со стратегией.

В конце концов, без хорошего ОЕС вы тратите ресурсы впустую – представьте эксперименты по улучшению питания или освещения на тонущем круизном лайнере. Значение показателя безопасности пассажиров в ОЕС для подобных экспериментов должно быть чрезвычайно высоким – на самом деле настолько высоким, чтобы вообще не трогать безопасность. Это может быть определено либо с помощью большого веса показателя в ОЕС, либо, что то же самое, с использованием безопасности пассажиров в качестве *граничного показателя* (см. главу 21). В программном обеспечении ана-

логом безопасности пассажиров круизного лайнера служат сбои программного обеспечения: если доработка увеличивает количество сбоев продукта, опыт считается настолько плохим, что другие факторы в сравнении с ним отступают на второй план.

Определение контрольных показателей для экспериментов важно для определения того, что организация не желает менять, поскольку стратегия, по словам Портера, также «требуется от вас идти на компромисс в конкурентной борьбе – выбирать, чего не следует делать». Злополучный рейс 401 авиакомпании Eastern Air Lines потерпел крушение в 1972 году, потому что экипаж сосредоточил внимание на перегоревшей индикаторной лампочке шасси и не заметил, что случайно отключил автопилот; высота (ключевой ограничительный показатель) постепенно уменьшалась, и самолет разбился в окрестностях города Эверглейдс во Флориде, в результате чего погиб 101 человек. Повышение операционной эффективности может обеспечить компании долгосрочное преимущество, как отметили Портер в статье «Японские компании редко имеют стратегии» (1996) и Вариан в статье о методике Кайдзен (2007).

Сценарий 2. *У вас есть продукт, у вас есть стратегия, но результаты говорят о том, что вам нужно подумать о смене направления*

В первом сценарии контролируемые эксперименты – отличный инструмент для восхождения на холм. Если вы думаете о многомерном пространстве идей с ОЕС как о «высоте», которую нужно оптимизировать, то вы, возможно, делаете шаги к вершине. Но иногда, основываясь на внутренних данных о скорости изменений или внешних данных о темпах роста или других контрольных показателях, вам нужно подумать о смене направления: стремлении к другому месту в пространстве решений, которое может располагаться на более высоком холме, или изменении стратегии и ОЕС (а значит, и ландшафта местности).

В общем, мы рекомендуем всегда иметь портфель идей: в большинстве случаев следует вкладывать средства в попытки оптимизации «рядом» с текущим местоположением, но время от времени следует пробовать несколько радикальных идей, чтобы увидеть, приведет ли смена направления к подножию более высокого холма. Наш опыт показывает, что большинство резких перемен терпят неудачу (например, глубокий редизайн сайта), однако существует определенный компромисс между риском и вознаграждением: редкие успехи могут привести к большим вознаграждениям, перекрывающим многие неудачи.

Когда вы проверяете радикальные идеи, методика проведения и оценка результатов эксперимента имеют свои особенности. В частности, необходимо учитывать:

- *продолжительность экспериментов.* Например, при тестировании значительного изменения дизайна пользовательского интерфейса экспериментальные изменения, измеренные в краткосрочной перспективе, могут зависеть от эффектов новизны или неприятия изменений. Пря-

мое сравнение контрольной и подопытной группы может не показать истинный долгосрочный эффект. На двустороннем рынке тестирование изменения, если оно недостаточно велико, может не повлиять на рынок. Хорошая аналогия – кубик льда в очень холодной комнате: небольшое повышение температуры ближе к комнатной может быть незаметным, но как только вы превысите точку плавления (например, 0 °C), кубик льда растает. В этих сценариях могут потребоваться более длительные и масштабные эксперименты или альтернативные схемы, такие как эксперименты на уровне страны, использованные в приведенном выше примере качества рекламы Google (см. также главу 23);

- *количество протестированных идей.* Вам может понадобиться много разных экспериментов, потому что каждый эксперимент проверяет только определенную тактику, которая является составной частью общей стратегии. Единственный эксперимент, неспособный улучшить ОЕС, может быть связан с плохой конкретной тактикой, что не обязательно указывает на плохую общую стратегию. Эксперименты, по сути своей, проверяют конкретные гипотезы, тогда как охват стратегии намного шире. Тем не менее контролируемые эксперименты помогают уточнить стратегию или показать ее неэффективность и стимулировать смену направления. Если различные тактики, оцененные с помощью контролируемых экспериментов, раз за разом терпят неудачу, возможно, пора вспомнить высказывание Уинстона Черчилля: «Какой бы красивой ни была стратегия, вам следует время от времени смотреть на результаты». Около двух лет подряд Bing придерживался стратегии интеграции с социальными сетями, в частности с Facebook и Twitter, добавив на страницу третью панель с результатами социального поиска. После того как на стратегию было потрачено более 25 млн долл. без значительного влияния на ключевые показатели, от нее пришлось отказаться. Иногда очень трудно отказаться от уже сделанной большой ставки, но экономическая теория говорит нам, что неудачные ставки – это невозвратные затраты, и мы должны принимать дальновидные решения на основе доступных данных, которые собираются по мере проведения новых экспериментов.

Эрик Райс использует термин «достигнутый провал» для компаний, которые успешно, добросовестно и неукоснительно выполняют план, который, как выясняется впоследствии, был заведомо провальным. Вместо этого он дает совет:

«Методология бережливого стартапа рассматривает действия стартапа как эксперименты, проверяющие его стратегию, чтобы понять, какие части стратегии блестящие, а какие провальные. Настоящий эксперимент следует научному подходу. Он начинается с четкой гипотезы, которая предсказывает, что должно произойти. Затем он эмпирически проверяет эту гипотезу».

Из-за того, что проведение экспериментов для оценки стратегии требует времени и трудностей, некоторые авторы, например Синофски и Янсита, пишут:

«... процесс разработки продукта чреват риском и неопределенностью. Это два очень разных понятия. Мы не можем уменьшить неопределенность – вы не знаете, чего вы не знаете».

Мы не согласны: возможность проводить контролируемые эксперименты позволяет значительно снизить неопределенность, тестируя минимально жизнеспособный продукт, получая данные и применяя их. Тем не менее не у всех есть в запасе несколько лет, чтобы потратить их на тестирование новой стратегии, и в этом случае вам, возможно, придется принимать решения в условиях неопределенности.

Есть одна полезная концепция, о которой следует помнить, – это *ожидаемая ценность информации* (expected value of information, EVI), предложенная Дугласом Хаббардом. Она показывает, как дополнительная информация может помочь вам в принятии решений. Возможность проводить контролируемые эксперименты позволяет значительно уменьшить неопределенность, пробуя минимально жизнеспособный продукт, собирая новые данные и повторяя эксперименты.

1.8. ДОПОЛНИТЕЛЬНОЕ ЧТЕНИЕ

Есть несколько книг, непосредственно посвященных онлайн-экспериментам и A/B-тестированию (Siroker and Koomen 2013, Goward 2012, Schrage 2014, McFarland 2012, King et al. 2017). В большинстве своем книги предлагают отличные мотивирующие истории, но мало говорят о статистике. Последняя книга Георгия Георгиева включает исчерпывающие объяснения математической статистики.

Литература, относящаяся к контролируемым экспериментам, обширна (Mason et al. 1989, Box et al. 2005, Keppel, Saufley and Tokunaga 1992, Rossi, Lipsey and Freeman 2004, Imbens and Rubin 2015, Pearl 2009, Angrist and Pischke 2014, Gerber and Green 2012).

Существует несколько учебных пособий по проведению контролируемых экспериментов в сети (Peterson 2004, 76–78, Eisenberg 2005, 283–286, Chatham, Temkin and Amato 2004, Eisenberg 2005, Eisenberg 2004; Peterson 2005, 248–253, Tyler and Ledford 2006, 213–219, Sterne 2002, 116–119, Kaushik 2006).

Многорукий бандит (multi-armed bandit) – это тип эксперимента, в котором распределение трафика эксперимента может динамически обновляться по мере продвижения эксперимента. Например, мы можем по-новому оценивать эксперимент каждый час, чтобы увидеть, как работает каждый из вариантов, и регулировать долю трафика, которую получает каждый ва-

риант. Вариант, который выглядит хорошо, получает больше трафика, а вариант, который неэффективен, получает меньше.

Эксперименты, основанные на многоруких бандитах, обычно более эффективны, чем «классические» А/В-эксперименты, потому что они постепенно перемещают трафик в сторону выигрышных вариантов, а не дожидаются окончания эксперимента. Несмотря на то что существует широкий спектр проблем, для решения которых они подходят, некоторые основные ограничения заключаются в том, что целью оценки должен быть один ОЕС (например, можно просто сформулировать компромисс между несколькими показателями) и что ОЕС должен быть достаточно хорошо измерим между перераспределениями, например рейтинг кликов по сравнению с сеансами. Также может возникнуть потенциальная предвзятость, возникающая из-за того, что пользователи, показавшие плохой результат, неравномерно перераспределяются среди выигрышных вариантов.

В декабре 2018 года трое соавторов этой книги организовали Первый практический саммит контролируемых онлайн-экспериментов. Тринадцать организаций, в том числе Airbnb, Amazon, Booking.com, Facebook, Google, LinkedIn, Lyft, Microsoft, Netflix, Twitter, Uber, Яндекс и Стэнфордский университет, прислали в общей сложности 34 эксперта, которые представили обзор и обсудили проблемы, возникшие в ходе секционных заседаний. Читателям, интересующимся проблемами контролируемых экспериментов, будет полезно ознакомиться с материалами этого саммита.

Глава 2

Проведение и анализ экспериментов. Пример полного цикла

Чем меньше фактов, тем тверже мнение.

– Арнольд Гласов

В главе 1 мы рассказали, что такое контролируемые эксперименты и почему для принятия решений важно получать реальные данные, а не полагаться на интуицию. На примере этой главы мы исследуем основные принципы разработки, проведения и анализа экспериментов. Эти принципы применяются везде, где развернуто программное обеспечение, включая веб-серверы и браузеры, настольные приложения, мобильные приложения, игровые консоли, интернет-помощники и т. д. Для простоты и конкретики мы сосредоточимся на примере оптимизации веб-сайта. В главе 12 мы отдельно рассмотрим особенности проведения экспериментов для полнофункциональных клиентов (толстый клиент, *thick client*), таких как настольные и мобильные приложения.

2.1. Условия демонстрационного эксперимента

В качестве конкретного примера мы возьмем вымышленный сайт онлайн-магазина, торгующего виджетами. Мы можем протестировать широкий спектр изменений: введение новой функции, изменение пользовательского интерфейса (UI), внутреннее изменение кода и т. д.

В нашем примере отдел маркетинга хочет увеличить продажи, рассылая рекламные электронные письма с кодом купона на скидки для виджетов.

Это изменение является потенциальным обновлением бизнес-модели, поскольку компания ранее не предлагала купоны. Однако сотрудник компании недавно прочитал о том, что после добавления кода купона некий предприниматель потерял значительную долю прибыли, а также о том, что отказ от кодов купонов рассматривают как положительный пример на GoodUI.org. С учетом этих внешних данных возникли опасения, что добавление поля для кода купона снизит доход, даже если купонов нет; т. е. сам факт упоминания о купоне замедлит работу пользователей и заставит их искать коды или даже отказаться от покупки.

Мы хотим оценить влияние простого добавления поля для ввода кода купона. Мы можем использовать так называемую фальшивую или нарисованную дверь – представьте, что мы делаем фальшивую дверь или рисуем ее на стене и смотрим, сколько людей пытается ее открыть. В данном случае мы реализуем тривиальное изменение, добавляя поле кода купона на страницу оформления заказа. Мы не применяем настоящую систему кодов купонов, так как коды отсутствуют. Независимо от того, что введет пользователь, система отвечает: «Недействительный код купона». Наша цель – просто оценить влияние этого поля кода купона на доход и проверить обоснованность опасений, что это будет отвлекать людей от оформления заказа. Поскольку это простое изменение, мы протестируем две реализации пользовательского интерфейса. Обычно, чтобы оценить идею посредством реализации, тестируют несколько процедур одновременно. В нашем случае идея заключается в добавлении кода купона, а реализация – в конкретном изменении пользовательского интерфейса.

Этот простой А/В-тест – важный шаг в оценке осуществимости новой бизнес-модели.

При переводе этого предлагаемого изменения пользовательского интерфейса в гипотезу полезно рассматривать процесс покупок в интернете как воронку, показанную на рис. 2.1. Клиент начинает с домашней страницы, просматривает несколько виджетов, добавляет виджет в корзину, запускает процесс покупки и наконец завершает покупку. Конечно, идея воронки упрощена; клиенты редко выполняют шаги последовательно и линейно. Они часто перемещаются между шагами туда и обратно; также есть постоянные посетители, которые пропускают промежуточные шаги. Однако эта простая модель полезна при разработке плана эксперимента и анализа, поскольку эксперименты обычно нацелены на улучшение определенного шага в воронке.




Рис. 2.1. Воронка покупок пользователя в интернете. Пользователи могут не двигаться по воронке линейно, а вместо этого пропускать и повторять шаги или переходить от одного шага к другому

В нашем эксперименте мы добавляем поле кода купона на страницу оформления заказа и тестируем два разных пользовательских интерфейса, как показано на рис. 2.2, и хотели бы оценить влияние (если оно имеется) на доход. Наша гипотеза такова: «Добавление поля кода купона на страницу оформления заказа снизит доход».

Чтобы измерить влияние изменения, нам нужно определить *показатели цели* или *показатели успеха*. Когда у нас есть только один показатель, мы можем использовать его непосредственно в качестве ОЕС (см. главу 7). Очевидным показателем успеха для этого эксперимента может быть доход. Обратите внимание, что, даже если мы стремимся увеличить общий доход, мы не рекомендуем использовать в качестве показателя саму сумму дохода, поскольку она зависит от количества пользователей в каждом варианте. Даже если вы стараетесь поровну распределить пользователей между вариантами, фактическое количество пользователей может измениться случайно. Мы рекомендуем нормализовать ключевые показатели по фактическим размерам выборки, чтобы получить *доход на пользователя*. В нашем случае это будет хороший ОЕС.




Рис. 2.2. (1) Контрольный вариант: старая страница оформления заказа. (2) Первый вариант теста: поле купона или подарочного кода под информацией о кредитной карте. (3) Второй вариант теста: всплывающее окно с купоном или подарочным кодом

Следующий важный вопрос – решить, каких пользователей следует учитывать в знаменателе при вычислении дохода на пользователя:

- **всех пользователей, посетивших сайт.** Это допустимый вариант, однако он дает размытую выборку, потому что в нее входят пользователи, которые никогда не начинали оформление заказа в варианте, где было внесено изменение. Мы знаем, что наши изменения не повлияют на пользователей, которые никогда не начинали оформление заказа. Исключение этих пользователей приведет к более чувствительному А/В-тестированию (см. главу 20);
- **только пользователей, завершивших процесс заказа.** Этот выбор неверен, поскольку предполагает, что изменение повлияет на сумму покупки, а не на процент пользователей, совершивших покупку. Если покупает больше пользователей, доход на пользователя может упасть, даже если совокупный доход увеличится;
- **только пользователей, которые начинают оформление заказа.** Это лучший выбор с учетом того, где находится изменение в воронке. Мы включаем всех потенциально затронутых пользователей, но исключаем незатронутых (пользователей, которые никогда не начинали оформление заказа), искажающих наши результаты.

Наша уточненная гипотеза звучит так: «Добавление поля кода купона на страницу оформления заказа снизит доход на пользователя для пользователей, которые начинают оформление заказа».

2.2. ПРОВЕРКА ГИПОТЕЗ: УСТАНОВЛЕНИЕ СТАТИСТИЧЕСКОЙ ЗНАЧИМОСТИ

Прежде чем мы сможем спланировать, провести или проанализировать наш эксперимент, давайте рассмотрим несколько основополагающих понятий, относящихся к статистической проверке гипотез.

Во-первых, мы характеризуем показатель, определяя *начальное среднее значение* и *стандартную ошибку среднего*, другими словами, насколько изменчивой будет оценка нашего показателя. Нам необходимо знать дисперсию показателя, чтобы правильно оценить наш эксперимент и вычислить статистическую значимость во время анализа. Для большинства показателей мы измеряем среднее значение, но также можем выбрать другой сводный статистический показатель, например процентиля. Снижение стандартной ошибки среднего повышает чувствительность, т. е. способность обнаруживать статистически значимые различия. Обычно этого можно достичь, выделив больше трафика тестовым вариантам или проведя эксперимент дольше, поскольку количество пользователей обычно растет со временем. Последний подход, однако, теряет эффективность спустя примерно две недели, потому что рост числа уникальных пользователей является сублинейным из-за повторных пользователей, в то время как некоторые показатели сами по себе «растут» со временем.

Когда мы проводим эксперимент, мы должны взять характеристические показатели для нескольких выборок. В частности, в контролируемых экспериментах у нас есть одна контрольная выборка и несколько тестовых. Мы количественно проверяем вероятность совпадения между тестовой и контрольной выборкой исходя из *нулевой гипотезы* о том, что средние значения совпадают. Если такое совпадение маловероятно, мы отвергаем нулевую гипотезу и утверждаем, что разница статистически значима. В частности, учитывая оценки дохода на пользователя из контрольной и тестовой выборки, мы вычисляем *p-значение*, которое является вероятностью наблюдения такой или более экстремальной разницы, если предположить, что нулевая гипотеза верна. Мы отвергаем нулевую гипотезу и делаем вывод, что наш эксперимент имеет эффект (или результат статистически значим), если *p-значение* достаточно мало. Но что значит «достаточно мало»?

Общепринятый научный стандарт – использовать значение p меньше 0,05. Это означает, что, если изменение действительно не дает эффекта, мы можем правильно сделать вывод об отсутствии эффекта в 95 случаях из 100. Другой способ проверить, является ли разница статистически значимой, – это проверить, не перекрывает ли *доверительный интервал* нулевое значение. Доверительный интервал 95 % – это диапазон, который покрывает истинную разницу в 95 % случаев, и для достаточно большой выборки он обычно сосредоточен вокруг наблюдаемой дельты между тестом и контролем с расширением 1,96 стандартных ошибок с каждой стороны. На рис. 2.3 показана эквивалентность двух представлений.

Статистическая мощность (statistical power) – это вероятность обнаружения значимого различия между вариантами, когда оно действительно есть. С практической точки зрения вам нужно, чтобы ваш эксперимент обладал достаточной статистической мощностью, чтобы с высокой вероятностью сделать вывод о том, привел ли ваш эксперимент к более значительным изменениям, чем вы предполагали. Обычно чем больше выборка, тем больше мощность. Обычной практикой является планирование экспериментов для мощности 80–90 %. Мы обсудим более подробно эти статистические понятия в главе 17.

Хотя «статистическая значимость» измеряет, насколько вероятно, что наблюдаемый вами или более выраженный результат мог возникнуть случайно при условии, что он равен нулю, не все статистически значимые результаты являются значимыми на практике. Насколько большая разница, в данном случае изменение дохода на пользователя, действительно имеет значение для нас с точки зрения бизнеса? Другими словами, какое изменение практически значимо?

Определение границы значимости важно для понимания того, стоит ли разница затрат на внесение изменений. Если ваш веб-сайт приносит миллиарды долларов, как Google и Bing, то изменение на 0,2 % является значительным. Для сравнения: стартап может посчитать даже изменение на 2 % слишком маленьким, потому что команда ищет изменения, которые улучшают показатель на 10 % или более. В нашем примере давайте примем, что с точки зрения бизнеса увеличение дохода на пользователя на 1 % или больше – это практически значимое изменение.




Рис. 2.3. Вверху: использование p -значения для оценки статистической значимости наблюдаемой разницы (дельты). Если p меньше 0,05, мы заявляем, что разница статистически значима. Внизу: эквивалентное представление использования 95 % доверительного интервала $[\Delta - 1,96\sigma, \Delta + 1,96\sigma]$ для оценки статистической значимости. Если ноль лежит за пределами доверительного интервала, мы заявляем о статистической значимости

2.3. РАЗРАБОТКА ЭКСПЕРИМЕНТА

Теперь мы готовы разработать наш эксперимент. У нас есть гипотеза, граница практической значимости, и мы определили метрику. Теперь, чтобы завершить разработку эксперимента, мы должны ответить на следующие вопросы.

1. Какова у нас единица рандомизации?
2. Какую популяцию единиц рандомизации мы хотим охватить?
3. Насколько большим (по охвату) должен быть наш эксперимент?
4. Как долго мы проводим эксперимент?

А пока предположим, что наша единица рандомизации – это пользователь. В главе 14 обсуждаются альтернативы, но пользователи, безусловно, являются наиболее распространенным выбором.

Ориентация на конкретную популяцию означает, что вы хотите провести эксперимент только для пользователей с определенной характеристикой. Например, вы тестируете новый текст, представленный лишь на нескольких языках; в этом случае вы можете ориентироваться только на пользователей, у которых в языковой настройке интерфейса выбран один из этих языков. Другие распространенные атрибуты таргетинга включают географический регион, платформу и тип устройства. В нашем примере предполагается, что мы охватываем всех пользователей.

Размер эксперимента (для нас количество пользователей) напрямую влияет на точность результатов. Если вы хотите обнаружить небольшое изменение или быть более уверенным в своих выводах, проведите более масштабный эксперимент с большим количеством пользователей. Для повышения точности можно использовать и другие изменения параметров эксперимента:

- если мы будем использовать *индикатор покупки* (т. е. сделал ли пользователь покупку, да/нет, без учета суммы покупки) вместо использования дохода на пользователя в качестве нашего ОЕС, стандартная ошибка будет меньше, а это означает, что нам не нужно подвергать эксперименту как можно большее количество пользователей, чтобы достичь той же чувствительности;
- если мы увеличим наш практический порог значимости, сказав, что больше не заботимся об обнаружении 1 % изменения, а только о более значительных изменениях, мы могли бы уменьшить размер выборки, потому что более крупные изменения легче обнаружить;
- если мы хотим использовать более низкий порог p -значения, например 0,01, чтобы быть более уверенными в наличии эффекта до того, как мы отклоним нулевую гипотезу, нам необходимо увеличить размер выборки.

При выборе размера эксперимента необходимо иметь в виду еще несколько соображений:

- насколько безопасен эксперимент? В случае крупных изменений, когда вы не уверены в реакции пользователей, вы можете сначала подвергнуть тестированию меньшую их долю. Это обоснование не должно влиять на выбор окончательного размера эксперимента, но вместо этого может повлиять на тактику наращивания (более подробно об этом рассказано в главе 15);
- нужно ли в этом эксперименте разделять трафик с другими экспериментами, и если да, то как вы определяете требования к трафику? На верхнем уровне планирования, если у вас есть другие изменения, которые нуждаются в проверке, вы можете запустить эти изменения одновременно или последовательно. Если вам необходимо разделить

трафик между несколькими одновременными тестами, каждый тест получит меньший объем трафика. В главе 4 мы расскажем о выполнении тестов как на одном уровне, так и с перекрытием, и, что более важно, о том, как построить надлежащую инфраструктуру для масштабирования всех экспериментов.

Другой большой вопрос – как долго проводить эксперимент. Есть и другие факторы, которые следует учитывать:

- **рост числа пользователей.** В онлайн-эксперименты с течением времени вовлекается все больше пользователей. Обычно это приводит к увеличению статистической мощности (исключения имеют место, если значение измеряемого параметра накапливается, например количество сеансов, а также увеличивается дисперсия; подробности в главе 18). Скорость накопления пользователей с течением времени также, вероятно, будет сублинейной: если у вас будет N пользователей в первый день, у вас будет меньше $2N$ пользователей во второй день, потому что некоторые пользователи заходили в оба дня;
- **эффект дня недели.** Состав группы пользователей по выходным и будним дням может различаться. Даже один и тот же пользователь может вести себя по-разному в разные дни недели. Важно убедиться, что ваш эксперимент отражает недельный цикл. Мы рекомендуем проводить эксперименты как минимум в течение одной недели;
- **сезонность.** Могут быть и другие моменты, когда пользователи ведут себя иначе, например в праздники. Если у вас есть глобальная база пользователей, то праздничные дни могут давать разный эффект внутри и за пределами страны. Например, продажа подарочных карт может хорошо работать в рождественский сезон, но хуже в другое время года. Это называется *внешняя общезначимость* (external validity) – степень, в которой результаты могут быть обобщены, в данном случае на другие периоды времени;
- **эффекты первенства и новизны.** Существуют эксперименты, которые, как правило, дают больший или меньший начальный эффект, для стабилизации которого требуется время. Например, пользователи могут попробовать нажать новую яркую кнопку и обнаружить, что она бесполезна, поэтому количество нажатий на кнопку со временем будет уменьшаться. С другой стороны, функции, требующие привыкания, требуют времени для создания группы приверженцев.

Наш эксперимент теперь выглядит следующим образом.

1. Единица рандомизации – пользователь.
2. Мы будем ориентироваться на всех пользователей, но анализировать тех, кто посетит страницу оформления заказа.
3. Чтобы иметь 80 % мощности для обнаружения хотя бы 1 % изменения дохода на пользователя, мы проведем анализ мощности для определения размера.

4. Это означает проведение эксперимента минимум четыре дня с разделением 34/33/33 % между контролем, тестом 1 и тестом 2. Мы проведем эксперимент в течение полной недели, чтобы убедиться, что мы отслеживаем эффект дня недели, и, возможно, дольше, если мы обнаружим эффекты новизны или первенства.

В целом чрезмерная статистическая мощность эксперимента – это хорошо и даже рекомендуется, поскольку иногда нам нужно исследовать сегменты пользователей (например, географический регион или платформу) и убедиться, что эксперимент имеет достаточную мощность для обнаружения изменений нескольких ключевых показателей. Например, у нас может быть достаточно мощности для обнаружения влияния на доход всех пользователей, но недостаточно, если мы хотим смотреть только на пользователей в Канаде. Также обратите внимание, что, хотя мы выбрали примерно равные размеры для контрольной и тестовой групп, если количество тестов увеличивается, вы можете рассмотреть возможность увеличения размера контрольной группы, чтобы он превышал размер тестовой группы (более подробно об этом сказано в главе 18).

2.4. ПРОВЕДЕНИЕ ЭКСПЕРИМЕНТА И СБОР ДАННЫХ

Теперь давайте запустим эксперимент и соберем данные. Здесь мы дадим вам лишь краткий обзор необходимых компонентов и предоставим более подробную информацию в главе 4.

Для проведения эксперимента нам понадобятся:

- инструментарий для получения данных журналов о том, как пользователи взаимодействуют с вашим сайтом и к каким экспериментам относятся эти взаимодействия (см. главу 13);
- инфраструктура, позволяющая проводить эксперимент, – от конфигуратора эксперимента до назначения вариантов (см. главу 4 для более подробной информации).

После того как вы запустили эксперимент и собрали данные журналов с помощью инструментов сбора данных, пришло время обработать данные, вычислить сводную статистику и визуализировать результаты (см. главы 4 и 16).

2.5. ИНТЕРПРЕТАЦИЯ РЕЗУЛЬТАТОВ

Итак, у нас есть данные эксперимента! Прежде чем мы приступим к анализу изменений дохода на пользователя, давайте проведем несколько проверок, чтобы убедиться, что эксперимент был проведен правильно.

В эксперименты могут вкратце вкрасться различные ошибки, нарушающие достоверность результатов. Чтобы выявить их, мы посмотрим на инвариантные или ограничительные показатели. Эти показатели должны быть одинаковыми в контрольной и тестовой группе. Если они меняются, любые изме-

ренные различия, скорее всего, являются результатом других изменений, которые мы внесли, а не тестируемой функции.

Есть два типа инвариантных показателей.

1. Доверительные ограничительные показатели, такие как ожидание того, что контрольные и тестовые выборки будут иметь размер в соответствии с конфигурацией эксперимента или что они имеют одинаковую частоту попаданий в кеш.
2. Организационные ограничительные показатели, такие как задержка, которые важны для организации и, как ожидается, будут инвариантом для многих экспериментов. В эксперименте с оформлением заказа было бы очень странно, если бы задержка обработки заказа изменилась от добавления фиктивного поля.

Если эти проверки достоверности не пройдены, вероятно, проблема кроется в основном плане эксперимента, инфраструктуре или обработке данных. Мы обсудим этот вопрос более подробно в главе 21.

После успешной проверки достоверности на основе ограничительных показателей мы готовы рассмотреть результаты (табл. 2.1).

Таблица 2.1. Результаты эксперимента по проверке изменения дохода на пользователя

	Доход на пользователя, тестовая группа	Доход на пользователя, контрольная группа	Разница	<i>p</i> -значение	Доверительный интервал
Тест 1, сравнение с контролем	3,12 долл.	3,21 долл.	−0,09 долл. (−2,8 %)	0,0003	[−4,3 %, −1,3 %]
Тест 2, сравнение с контролем	2,96 долл.	3,21 долл.	−0,25 долл. (−7,8%)	1,5e-23	[−9,3 %, 6,3 %]

Поскольку *p*-значение для обоих тестовых вариантов меньше 0,05, мы отклоняем нулевую гипотезу о том, что контрольные и тестовые группы дают нам одинаковое среднее значение.

Итак, что это значит? Что ж, это означает, что мы подтвердили предположение, согласно которому добавление кода купона в пользовательский интерфейс снижает доход. Если мы углубимся в цифры, результаты показывают, что снижение связано с тем, что меньше пользователей завершают процесс заказа. Таким образом, любое рекламное электронное письмо, которое рассылает коды купонов, должно возмещать не только затраты на внедрение, связанные с добавлением обработки и обслуживания купонов, но и в первую очередь перекрывать негативный эффект от добавления кода купона. Поскольку маркетинговая модель показала небольшое увеличение дохода для целевых пользователей, но А/В-тест показывает значительное снижение дохода для *всех* пользователей, было принято решение отказаться

от идеи введения промокодов. А/В-тестирование с нарисованной дверью сэкономило нам много усилий!

2.6. ОТ РЕЗУЛЬТАТОВ К РЕШЕНИЯМ

Цель проведения А/В-тестов – собрать данные для принятия решений. Много усилий уходит на то, чтобы наши результаты были повторяемыми и заслуживающими доверия, и мы могли бы принять правильное решение. Давайте рассмотрим процесс принятия решений в нескольких типичных случаях.

Для каждого случая у нас есть результаты эксперимента, и наша цель – преобразовать данные в положительное или отрицательное решение. Причина, по которой акцент делается именно на принятии решений, заключается в том, что решение должно учитывать как результат измерения, так и более широкий контекст.

- Вам нужно найти компромисс между различными показателями? Например, стоит ли запускать изменение, в результате которого вовлечение пользователей растет, а доход падает? Другой пример: если увеличивается вычислительная нагрузка, стоимость эксплуатации оборудования может перевесить выгоду от изменения.
- Сколько стоит внедрение этого изменения? Этот показатель включает в себя:
 - ◆ стоимость полной реализации функции перед внедрением. Некоторые функции могли быть полностью созданы до экспериментов. В таких случаях стоимость перехода к 100 % внедрению равна нулю. Это не всегда так. Как и в нашем примере, внедрение нарисованной двери было дешевым, но внедрение полной системы купонов стоит дорого;
 - ◆ стоимость текущего технического обслуживания после запуска, поскольку обслуживание нового кода может оказаться более затратным. Новый код, как правило, содержит больше ошибок и хуже тестируется на предельные случаи. Если новый код намного сложнее, впоследствии могут добавиться и затраты на создание новых изменений поверх него. Если стоимость обслуживания высока, вы должны убедиться, что ожидаемая прибыль может ее покрыть. В таких ситуациях убедитесь, что ваша практическая граница значимости достаточно высока, чтобы отразить это. И наоборот, если стоимость низкая или даже нулевая, вы можете запустить любое положительное изменение, другими словами, граница вашей практической значимости низка.
- В чем заключаются отрицательные последствия неправильных решений? Не все решения равны и не все ошибки равны. Вполне может получиться так, что не будет никакого отрицательного подтекста в запуске изменения, которое не оказывает никакого влияния, но мы получим высокие альтернативные издержки, если откажемся от изме-

нения, которое оказывает влияние, и наоборот. Например, вы можете тестировать на своем сайте два варианта баннера с торговым предложением, а само предложение будет действовать только несколько дней. В этом случае отрицательные последствия неправильного решения незначительны, потому что изменение имеет короткий срок действия. Поэтому вы спокойно можете снизить планку как статистической, так и практической значимости.

Вы должны учитывать эти контексты при определении статистических и практических порогов значимости. Эти пороговые значения имеют решающее значение при переходе от результатов эксперимента к решению или действию. Предполагая, что мы обновили пороговые значения до начала эксперимента, чтобы отразить более широкий контекст, давайте рассмотрим примеры на рис. 2.4, иллюстрирующие, как использовать эти пороги для принятия решений.




Рис. 2.4. Примеры понимания статистической и практической значимости при принятии решений о запуске изменения. Граница практического значения проведена двумя пунктирными линиями. Предполагаемая разница для каждого результата примера – это черный ящик вместе с его доверительным интервалом

1. Результат не является статистически значимым. Ясно также, что в этом нет практического значения. Мы легко приходим к выводу, что изменение мало что дает. Вы можете решить повторить эту идею или отказаться от нее.
2. Результат статистически и практически значимый. И снова простое решение: запускать!
3. Результат значимый статистически, но не практически. В этом случае вы уверены в величине изменений, но этой величины может быть недостаточно, чтобы перевесить другие факторы, такие как стоимость. Возможно, это изменение не стоит запускать.
4. Считайте этот пример нейтральным, как и первый; тем не менее доверительные интервалы выходят за рамки практической значимости. Если вы проведете эксперимент и обнаружите, что он может с равной вероятностью как увеличить, так и уменьшить доход на 10 %, неужели вы сочтете эксперимент удачным и скажете, что изменение нейтрально? Лучше сказать, что у вас недостаточно статистической мощности, чтобы сделать убедительный вывод, а значит, недостаточно данных для принятия какого-либо решения о запуске. Для этого результата мы рекомендуем провести дополнительный тест с большим количеством объектов, что обеспечит большую статистическую мощность.
5. Результат, вероятно, значимый практически, но не статистически. Таким образом, даже если вы предполагаете, что это изменение окажет влияние, которое вам полезно, есть также изрядный шанс, что никакого воздействия не будет. С точки зрения измерения лучшим решением было бы повторить этот тест, но с большей мощностью, чтобы получить более точный результат.
6. Результат статистически значимый и, вероятно, практически значимый. Как и в примере 5, возможно, что изменение не является практически значимым. Поэтому здесь, как и в предыдущем примере, мы предлагаем повторить тест с большей мощностью. Однако, если выбирать между запуском изменения и отказом от запуска, то запуск выглядит более разумным.

Ключевой момент, о котором следует помнить: иногда вам, возможно, придется принимать решение, даже если результаты эксперимента не дают четкого ответа. В таких ситуациях вам необходимо четко понимать, какие факторы вы учитываете, особенно то, как они будут преобразованы в границы практической и статистической значимости. Это послужит основой для будущих решений, а не просто одного сиюминутного вывода.

Глава 3

.....

Закон Тваймана и надежность экспериментов

Закон Тваймана, – возможно, самый важный закон во всем анализе данных. Чем необычнее или интереснее данные, тем больше вероятность, что они получены в результате ошибки того или иного рода.

– Кэтрин Марш и Джейн Эллиотт (2009)

Закон Тваймана: «Любое число, которое выглядит интересно или необычно, как правило, ошибочно».

– А. С. К. Эренберг (1975)

Закон Тваймана: «Любая статистика, которая кажется интересной, почти наверняка является неверной».

– Пол Диксон (1999)

Уильям Энтони Твайман (William Anthony Twyman) был ветераном британского радио и телевидения в области измерения аудитории, которому приписывают формулировку закона о достоверности данных, хотя он, вероятно, никогда не излагал его в письменной форме; существует множество вариантов этого закона, как показано в открывающих эту главу цитатах.

Когда мы видим удивительно положительный результат, например значительное улучшение ключевого показателя, мы склонны строить вокруг него историю, делиться ею с окружающими и праздновать победу. Когда результат неожиданно отрицательный, мы стараемся найти какое-то ограничение исследования или незначительную ошибку и отклонить его.

Опыт подсказывает нам, что экстремальные результаты чаще всего получаются вследствие ошибки в инструментарии (например, регистрации действий пользователя), потери данных (или дублирования данных) или ошибки вычислений.

Чтобы повысить доверие к результатам эксперимента, мы рекомендуем применять набор тестов и методов, выявляющих аномалии в полученных

данных. В базах данных есть ограничения целостности; в безопасном программировании рекомендуется использовать операторы `assert()` для проверки выполнения ограничений. В ходе экспериментов мы можем запускать тесты, которые проверяют основные параметры аналогично `assert()`: если с определенного момента каждый пользователь должен видеть либо контрольный, либо тестовый вариант, то наличие большого количества пользователей в обоих вариантах – это красный флаг; если план эксперимента предусматривает равные проценты в двух вариантах, то большие отклонения, которые по определению маловероятны, также должны вызывать вопросы. Далее мы приведем несколько отличных примеров результатов, иллюстрирующих закон Тваймана, и расскажем, что вы можете сделать, чтобы повысить надежность контролируемых экспериментов.

3.1. НЕПРАВИЛЬНАЯ ИНТЕРПРЕТАЦИЯ СТАТИСТИЧЕСКИХ РЕЗУЛЬТАТОВ

Вот несколько распространенных ошибок в интерпретации статистики контролируемых экспериментов.

3.1.1. Нехватка статистической мощности

В нашей методике проверки значимости нулевой гипотезы мы обычно предполагаем, что нет разницы в значениях показателей между контрольной и тестовой группой (нулевая гипотеза), и отклоняем гипотезу, если данные представляют убедительные доказательства против нее. Распространенной ошибкой является вывод об отсутствии эффекта от изменения лишь на том основании, что показатель не является статистически значимым. Вполне возможно, что эксперименту не хватает статистической мощности для определения размера эффекта, который мы наблюдаем, т. е. для успешного теста просто не хватило пользователей. Например, оценка 115 A/B-тестов на GoodUI.org показывает, что большинство из них были недостаточно мощными (Георгиев, 2018). Это одна из причин, по которой необходимо определить порог практической значимости в вашем контексте (см. главу 2), и убедиться, что у вас достаточно мощности эксперимента, чтобы обнаружить изменение показателя на такую или меньшую величину.

Если эксперимент затрагивает лишь небольшую часть популяции, важно проанализировать только эту затронутую группу; даже большое влияние на небольшую группу пользователей может быть размыто по всей популяции и ускользнет от вашего внимания (см. главу 20).

3.1.2. Неправильная интерпретация p -значений

Значение p подвержено неправильному толкованию. Наиболее распространенной ошибкой интерпретации является убеждение, что p -значение пред-

ставляет собой вероятность того, что среднее значение показателя в контрольной группе отличается от среднего значения показателя в тестовой группе, на основании данных одного эксперимента.

Значение p – это вероятность получения результата, равного или более экстремального, чем наблюдаемый, при условии, что нулевая гипотеза верна. Условие нулевой гипотезы имеет решающее значение.

Вот несколько примеров неверных утверждений и объяснений из статьи «Грязная дюжина: двенадцать заблуждений о p -значениях» (Google Website Optimizer 2008).

1. Если значение $p = 0,05$, вероятность того, что гипотеза о нуле верна, составляет всего 5 %. Это не так. Значение p вычисляется при условии, что гипотеза о нуле верна.
2. Незначительная разница (например, значение $p > 0,05$) означает, что между группами нет никакой разницы. Наблюдаемые результаты согласуются с нулевой гипотезой о нулевом воздействии и рядом других значений. Когда доверительные интервалы показаны для типичного контролируемого эксперимента, они включают ноль. Это не означает, что ноль более вероятен, чем другие значения в доверительном интервале. Вполне возможно, что эксперименту недостает мощности.
3. Значение $p = 0,05$ означает, что мы наблюдали данные, которые встречались бы только в 5 % случаев при нулевой гипотезе. Это неверно из-за определения p -значения, которое включает равные или более экстремальные значения, чем наблюдаемые.
4. Значение $p = 0,05$ означает, что, если вы отвергаете нулевую гипотезу, вероятность ложного срабатывания составляет всего 5 %. Это похоже на первый пример, но ошибку труднее увидеть. Вам поможет другой пример: предположим, вы пытаетесь преобразовать свинец в золото, подвергая его воздействию тепла и давления и поливая его эликсирами. Вы измеряете количество «золотистости» в полученной смеси – это шумное измерение. Поскольку мы знаем, что химические процедуры не могут изменить атомный номер свинца с 82 на 79, любое отклонение от нулевой гипотезы (без изменений атомного номера) будет ложным, поэтому 100 % отклонений являются ложноположительными, независимо от значения p . Чтобы вычислить частоту ложных срабатываний, т. е. когда значение $p < 0,05$ и тем не менее нулевая гипотеза верна (обратите внимание, конъюнкция, не обусловленная истинностью нулевой гипотезы), мы могли бы использовать теорему Байеса и потребовать некоторой априорной вероятности.

Даже приведенное выше общее определение p -значения, которое предполагает, что гипотеза о нуле верна, не высказывает явно другие предположения, такие как способ сбора данных (например, случайная выборка) и предположения, которые делают статистические тесты. Если был проведен промежуточный анализ, который повлиял на выбор анализа для представления, или если

p -значение было выбрано для представления из-за его небольшого размера, то эти предположения явно нарушаются (Greenland et al., 2016).

3.1.3. Отслеживание p -значений

При проведении контролируемого онлайн-эксперимента вы можете постоянно отслеживать p -значения. Фактически даже ранние версии коммерческого продукта Optimizely поощряли этот подход. Такое множественное тестирование гипотезы приводит к значительному смещению (в 5–10 раз) при объявлении результатов статистически значимыми. Вот две альтернативы.

1. Используйте последовательные тесты с всегда действительными p -значениями или байесовскую схему тестирования (Deng, Lu and Chen, Continuous Monitoring of A/B Tests without Pain: Optimal Stopping in Bayesian Testing 2016).
2. Используйте заранее установленную продолжительность эксперимента, например неделю, для определения статистической значимости.

Optimizely реализовал решение, основанное на первом методе, тогда как платформы для экспериментов, используемые в Google, LinkedIn и Microsoft, используют второй.

3.1.4. Множественные проверки гипотез

Следующий диалог мы позаимствовали из забавной книги *What is a p-value anyway?* (Vickers, 2009):

- «**Статистик:** Значит, вы уже вычислили p -значение?
Хирург: Да, я использовал полиномиальную логистическую регрессию.
Статистик: Правда? И почему же вы предпочли именно этот метод?
Хирург: Я пробовал каждый анализ в раскрывающихся меню программы по статистической обработке данных, и это был тот, который давал наименьшее значение p ».

Проблема множественных сравнений – это обобщение упомянутого выше отслеживания p -значений. Когда существует несколько тестов и мы выбираем наименьшее значение p , наши оценки значения p и величины эффекта, скорее всего, будут смещены. Это происходит в следующих случаях.

1. Отслеживание нескольких показателей.
2. Отслеживание p -значений во времени (как указано выше).
3. Анализ сегментов популяции (например, страна, тип браузера, новый/постоянный клиент).
4. Рассмотрение нескольких итераций эксперимента. Например, если эксперимент действительно ничего не дает (A/A), его выполнение 20 раз подряд может случайно привести к p -значению меньше 0,05.

Коэффициент ложного обнаружения (false discovery rate) – ключевая концепция для работы с несколькими тестами (см. также главу 17).

3.2. ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ

Доверительный интервал (confidence interval), грубо говоря, количественно определяет степень неопределенности эффекта от изменения. Уровень доверия показывает, как часто доверительный интервал должен содержать истинный эффект от воздействия. Между p -значениями и доверительными интервалами существует определенное родство. Для нулевой гипотезы об отсутствии разницы, обычно используемой в контролируемых экспериментах, 95%-ный доверительный интервал эффекта воздействия, который не пересекает ноль, означает, что $p < 0,05$.

Распространенной ошибкой является рассмотрение доверительных интервалов отдельно для контрольной и тестовой группы и предположение, что, если они перекрываются, изменение не дает статистически значимого эффекта. Это неверно, как показано в *Statistical Rules of Thumb* (van Belle 2008). Доверительные интервалы могут перекрываться до 29 %, но при этом разница будет статистически значимой. Однако верно и обратное: если 95%-ные доверительные интервалы не перекрываются, то эффект от воздействия статистически значим с $p < 0,05$.

Еще одно распространенное заблуждение относительно доверительных интервалов – это вера в то, что представленный 95%-ный доверительный интервал имеет 95%-ный шанс сдержать истинный эффект от воздействия. Для определенного доверительного интервала истинный эффект воздействия составляет либо 100 % в пределах этого интервала, либо 0 %. 95 % относится к тому, как часто 95%-ные доверительные интервалы, рассчитанные на основе многих исследований, будут содержать истинный эффект воздействия (Greenland et al. 2016); более подробно об этом говорится в главе 17.

3.3. УГРОЗЫ ВНУТРЕННЕЙ ДОСТОВЕРНОСТИ

Внутренняя достоверность (internal validity) относится к правильности экспериментальных результатов, которые не обобщают на другие популяции или периоды времени. Давайте рассмотрим несколько распространенных угроз внутренней достоверности.

3.3.1. Нарушения правила SUTVA

При анализе контролируемых экспериментов обычно применяют *допущение о стабильном влиянии воздействия на экспериментальный объект* (stable unit treatment value assumption, SUTVA), в котором говорится, что экспериментальные объекты (например, пользователи) не мешают друг другу. На их поведение влияют только те воздействия, которые испытывают они сами, а не другие объекты. Допущение может быть явно нарушено в следующих случаях:

- социальные сети, где влияние изменения может распространиться через связи пользователя;

- Skype (инструмент связи), при котором одноранговые вызовы могут нарушать SUTVA;
- инструменты с поддержкой совместного редактирования документов (например, Microsoft Office и Google Docs);
- двусторонние торговые площадки (например, рекламные аукционы, Airbnb, eBay, Lyft или Uber) могут нарушать SUTVA через «другую» сторону. Например, воздействие в виде снижения цен влияет на показатели контрольной группы через аукционы;
- общие ресурсы (такие как процессор, хранилище и кешы) тоже могут повлиять на SUTVA. Если обработка приводит к утечке памяти и замедлению процессов из-за сборки мусора и, возможно, подкачки ресурсов на диск, то страдают все варианты. В проведенном нами эксперименте воздействие приводило к поломке машины при определенных сценариях. Эти сбои также приводили к отключению пользователей, которые находились в контрольной группе, поэтому разница в ключевых показателях не отличалась – обе группы пострадали одинаково.

В главе 22 вы узнаете, как исправить некоторые из этих нарушений.

3.2.2. Ошибка выжившего

Анализ пользователей, которые были активными в течение некоторого времени (например, два месяца), вводит *ошибку выжившего*. Прекрасный пример этой проблемы и вносимых ею ошибок – это Вторая мировая война, когда было принято решение усилить броню бомбардировщиков. Были собраны данные о том, в каких местах самолеты получили наибольшие повреждения, и военные, естественно, захотели добавить броню именно в этих местах. Математик Авраам Вальд указал, что это худшие места для добавления брони. Отверстия от пуль были распределены почти равномерно, поэтому броню нужно добавлять в места, где не было пулевых отверстий, потому что бомбардировщики, у которых пострадали эти места, были сбиты и не прилетели обратно.

3.2.3. Вынужденное воздействие

В некоторых экспериментах наблюдается неслучайное распределение вариантов. Например, в медицинских учреждениях пациенты, проходящие лечение, могут самовольно прекратить прием лекарства, если оно имеет побочные эффекты. В онлайн-мире вы можете предлагать всем рекламодателям возможность оптимизировать свою рекламную кампанию, но только некоторые рекламодатели выбирают предложенную оптимизацию. Анализ только тех, кто согласился участвовать, приводит к смещению отбора и обычно преувеличивает эффект воздействия. «Указание к действию» учитывает побуждение к воздействию, независимо от того, было оно выполнено или нет. Таким образом, мы измеряем эффект воздействия на основании статистики побуждений или намерений к воздействию, а не на том, было ли оно действительно реализовано.

В медийной рекламе и маркетинге по электронной почте мы не наблюдаем воздействия на контрольную группу, и для решения этой проблемы предлагаются методы, основанные на *анализе по выборке с воздействием* (intent-to-treat analysis).

3.2.4. Несоответствие коэффициента выборки

Если соотношение пользователей (или любой другой единицы рандомизации) между вариантами значительно отличается от задуманного значения, эксперимент страдает от *несоответствия коэффициента выборки* (sample ratio mismatch, SRM). Например, если план эксперимента рассчитан на соотношение один к одному (контрольные и тестовые группы одинакового размера), то отклонения в фактическом соотношении пользователей в эксперименте, вероятно, указывают на проблему (см. главу 21), которая требует решения. Ниже мы приводим несколько примеров.

При больших числах коэффициент меньше 0,99 или больше 1,01 для плана эксперимента, который требует 1,0, скорее всего, указывает на серьезную проблему. Система экспериментов должна генерировать строгое предупреждение и скрывать любые оценочные карты и отчеты, если значение p для отношения низкое (например, ниже 0,001).

Как было сказано ранее, p -значение – это вероятность получения результата, равного или более экстремального, чем наблюдаемый, при условии, что гипотеза о нуле верна. Если план эксперимента предусматривал равные распределения для обоих вариантов, то по плану вы должны получить соотношение, близкое к 1,0, т. е. гипотеза о нуле *должна быть* верной. Таким образом, p -значение представляет собой вероятность того, что наблюдаемое нами соотношение согласуется с планом нашего эксперимента. Этот простой тест выявил множество проблем в экспериментах, многие из которых поначалу выглядели либо великолепно, либо ужасно и являли собой иллюстрацию закона Тваймана. Вот несколько примеров.

○ Браузерные перенаправления (Кохаби и Лонгботэм, 2010).

Очень распространенный и практичный механизм реализации A/B-теста – перенаправление обращения на другую страницу. Как и многие идеи, это просто, элегантно и неверно; несколько разных попыток показали, что это решение постоянно вызывает SRM. Причин несколько.

- a. **Различия в производительности.** Пользователи из тестовой группы подвергаются дополнительному перенаправлению, которое может быстро срабатывать в лабораторных условиях, но задержки для реальных пользователей могут быть значительными, порядка сотен миллисекунд, что оказывает заметное влияние на ключевые показатели (см. главу 5).
- b. **Боты.** Роботы по-разному обрабатывают перенаправления: некоторые могут не отрабатывать перенаправление по метатегу `http-equiv = "REFRESH"`; другие помечают эту страницу как новую, достойную глубокого сканирования, и будут сканировать ее чаще.

- с. **Перенаправления асимметричны.** Когда пользователи перенаправляются на тестовую страницу, они могут добавить ее в закладки или передать ссылку своим друзьям. В большинстве реализаций тестовая страница не проверяет, действительно ли текущий пользователь был рандомизирован в тестовую группу, поэтому перенаправление вызывает искажение коэффициента выборки.

Урок здесь заключается в том, чтобы избегать перенаправлений в фронте и отдавать предпочтение механизму на стороне сервера. Когда это невозможно, убедитесь, что и контрольная, и тестовая группа имеют одинаковую «нагрузку», т. е. обе группы одинаково обрабатывают перенаправление.

○ **Измерительные потери.**

Отслеживание кликов чаще всего выполняется с помощью веб-маячков (обычно рисунок GIF размером 1×1, отправляемый на сервер для сигнала о клике), что, как известно, сопровождается потерями (т. е. не 100 % кликов правильно регистрируются). Обычно это не проблема, поскольку потери одинаковы для всех вариантов, но иногда тест может повлиять на коэффициент потерь, заставляя малоактивных пользователей (например, тех, у кого был только один щелчок) реагировать с другой скоростью и вызывать SRM. Когда веб-маячок размещается в другой области страницы, различия во времени отображения также искажают измерения.

○ **Остаточные или переходящие эффекты.**

В новых экспериментах часто используется новый код, и количество ошибок в нем обычно выше. Если новый эксперимент вызывает некоторую неожиданно вопиющую проблему, то его прерывают или продолжают, но уже с целью быстрого исправления ошибки. После исправления ошибки эксперимент продолжается, но некоторые пользователи уже пострадали. В некоторых случаях этот остаточный эффект может быть серьезным и длиться месяцами. Вот почему так важно проводить предварительные A/A-тесты (см. главу 19) и заблаговременно повторно рандомизировать пользователей, отдавая себе отчет, что в некоторых случаях повторная рандомизация нарушает согласованность пользователей, поскольку некоторые пользователи переходят от одного варианта к другому.

Бывает справедливо и обратное. В LinkedIn оценивали новую версию алгоритма «Люди, которых вы можете знать», и она оказалась очень полезной, увеличив количество посещений пользователей. Когда эксперимент был остановлен и перезапущен, наблюдался значительный эффект переноса из предыдущего эксперимента, достаточный для создания SRM и аннулирования результатов.

Остаточная информация в куки-файлах браузера тоже может повлиять на результат эксперимента. Возьмем, к примеру, образовательную кампанию, которая показывает сообщение пользователям тестовой группы, но, чтобы не беспокоить пользователей, сообщение отображается только три раза. Реализация использует куки-файл браузера, который подсчитывает, сколько раз было показано сообщение. Если эксперимент будет перезапущен, не-

которые пользователи из тестовой группы будут иметь куки-файл со счетчиком больше нуля и, таким образом, увидят либо меньше показов, либо не увидят их вообще, что ослабит эффект воздействия или создаст SRM.

○ **Неверная хеш-функция для рандомизации.**

Чжао с коллегами (Zhao et al., 2016) описывает пример неудачного распределения, когда в Yahoo! распределяли пользователей по группам с использованием хеш-функции Фаулера-Нолла-Во, которой было достаточно для одноуровневой рандомизации, но которая не смогла должным образом распределить пользователей в нескольких параллельных экспериментах, когда система была обобщена для перекрывающихся экспериментов. Криптографические хеш-функции, такие как MD5, хороши, но медленны; в Microsoft используют некриптографическую хеш-функцию Дженкинса SpookyHash (www.burtleburtle.net/bob/hash/spooky.html).

○ **Изменение атрибута, вызванное тестовым воздействием.**

Обычно в эксперимент вовлекают только часть пользователей. Например, вы можете задействовать пользователей только в определенной стране. Затем эти пользователи случайным образом распределяются между вариантами.

Если запуск нововведения выполняется на основе атрибутов, которые меняются с течением времени, необходимо убедиться, что тестируемое нововведение не повлияет на эти атрибуты. Например, предположим, что вы запускаете рекламную кампанию по электронной почте, адресованную только пользователям, которые были неактивны в течение трех месяцев. Если кампания эффективна, эти пользователи становятся активными, и в следующей итерации кампании возникнет SRM.

○ **Эффекты времени суток.**

Давайте снова в качестве примера А/В-теста рассмотрим рекламную рассылку по электронной почте с различным текстом сообщения для каждого варианта. В реальном примере пользователи были должным образом рандомизированы в контрольную и тестовую группы одинакового размера, но процент просмотра писем электронной почты, который по замыслу должен быть примерно одинаковым, показывал выраженный SRM.

Долгое расследование показало, что просмотры писем сгруппированы по разным периодам времени. Это привело к предположению, которое позже подтвердилось, что для простоты реализации электронные письма сначала отправляли пользователям контрольной группы, а затем тестовой. Первая группа получала электронные письма в рабочее время, а вторая группа получала их после работы.

○ **Тестовое воздействие затрагивает поток данных.**

Портал MSN (www.msn.com) имеет на странице информационную панель с несколькими слайдами, которые вращаются, и точкой, обозначающей каждый слайд (указаны стрелкой на рис. 3.1).




Рис. 3.1 Пример страницы портала MSN

Ключевым компонентом ОЕС для MSN является количество кликов на пользователя, которое отражает взаимодействие с пользо-пользователем. Команда провела эксперимент, в котором нововведение увеличило количество слайдов в информационной панели с 12 до 16.

Первоначальные результаты показали значительное снижение вовлеченности пользователей в тестовой группе, но в эксперименте просматривался SRM: коэффициент составлял 0,992 вместо 1,0. При более чем 800 000 пользователей в каждом варианте p -значение такого разделения составляло 0,0000007, т. е. вероятность того, что такое разделение произойдет случайно (учитывая, что было задумано строго равное разделение), была крайне мала. В ходе расследования было обнаружено, что из-за увеличения вовлеченности пользователей в тестовой группе некоторые из наиболее активно вовлеченных пользователей были классифицированы как боты и исключены из анализа. После исправления бот-фильтра результаты показали обратный эффект нововведения: вовлеченность пользователей в тестовой группе увеличилась на 3,3 %!

Бот-фильтрация – серьезная проблема, особенно для поисковых систем. Для Bing более 50 % трафика в США исходит от ботов, а в Китае и России это число превышает 90 %.

Проверка SRM критически важна. Как показывает последний пример, даже небольшой дисбаланс может привести к обратному эффекту от тестового воздействия. Сдвиги SRM обычно возникают из-за исключения пользователей (как правило, экспериментальных единиц), которые либо очень хороши, например интенсивные пользователи, либо очень плохи, как пользователи, у которых нет отмеченных кликов. Это говорит о том, что, даже если разница в численности популяции кажется небольшой, она может значительно исказить результаты.

3.4. Угрозы внешней достоверности

Внешняя достоверность (external validity) отражает степень, в которой результаты контролируемого эксперимента могут быть обобщены по направлениям, таким как различные группы населения (например, другие страны, другие веб-сайты) и с течением времени (например, будет ли увеличение дохода на 2 % удерживаться в течение длительного времени, или доход постепенно уменьшится).

Обобщения между популяциями обычно сомнительны; функции, которые работают на одном сайте, могут не работать на другом, но решение обычно простое: перезапустить эксперимент. Например, если эксперимент успешно прошел в США, нововведение обычно проверяют и на других рынках, вместо того чтобы предполагать, что результаты поддаются обобщению.

Обобщения во времени даются еще сложнее. Иногда после эксперимента приходится ждать несколько месяцев, пока утихнут долгосрочные эффекты. В главе 19 мы обсудим методы борьбы с долгосрочными эффектами. Две ключевые угрозы внешней достоверности, связанные со временем, – это *эффекты первичности* (primacy effect) и *эффекты новизны* (novelty effect).

3.4.1. Эффекты первичности

Когда вводится изменение, пользователям может потребоваться время для принятия, поскольку они уже знакомы со старой функцией, т. е. привыкли к тому, как она работает. Алгоритмы машинного обучения также нуждаются в обучении лучшей модели, и это занимает некоторое время в зависимости от цикла обновления.

3.4.2. Эффекты новизны

Эффект новизны, или эффект обновления, – это непродолжительный эффект. Когда вы представляете новую функцию, особенно ту, которую легко заметить, сначала она привлекает пользователей. Если пользователи не найдут эту функцию полезной, повторное использование будет небольшим. Поначалу может показаться, что новинка работает хорошо, но эффект со временем быстро снижается.

Один из примеров того, что нам не нужно, описан в книге *Yes!: 50 Scientifically proven ways to be Persuasive* (Goldstein, Martin, Cialdini, 2008). В этой книге авторы рассказывают, как Коллин Зот написала телевизионную программу, которая побила почти 20-летний рекорд продаж канала покупок на дому. Она изменила несколько слов в стандартной рекламной строке, что привело к огромному увеличению числа людей, купивших ее продукт: вместо привычного «Операторы ждут, пожалуйста, звоните сейчас» стали писать «Если все операторы заняты, пожалуйста, позвоните еще раз». Авторы объясняют, что это социальная манипуляция; зрители думают: «Если телефонные линии заняты, значит звонят и другие люди, такие как я, которые тоже смотрят этот рекламный ролик».

Уловки, подобные описанным выше, имеют короткий срок годности, если пользователи осознают, что они используются регулярно. В контролируемом эксперименте анализ покажет эффект, который быстро уменьшается.

На веб-сайте MSN вверху была полоса инструментов, которая показана на рис. 3.2.




Рис. 3.2 Страница MSN со ссылкой на Outlook.com

Microsoft изменила ссылку и иконку Outlook.com, чтобы напрямую открывать приложение Outlook Mail (рис. 3.3), что дает пользователям более простой и удобный доступ к электронной почте.




Рис. 3.3. На страницу MSN добавлена прямая ссылка на приложение Outlook

Как и ожидалось, эксперимент показал, что в тестовой группе больше пользователей использовало приложение Outlook Mail, по сравнению с контролем, но никто не ожидал, что резко вырастет рейтинг кликов. Удивительно, но количество переходов по этой ссылке в тестовой группе увеличилось на 28 %. Что, пользователям больше нравится приложение Outlook Mail, и они чаще используют его? Нет. Исследование показало, что пользователи были сбиты с толку тем, что сайт Outlook.com не открывался, и переходили по ссылке несколько раз.

Наконец, китайский производитель кроссовок Kaiwei Ni запустил рекламу в Instagram, где на фотографии был изображен фальшивый волос, как показано на рис. 3.4. Обманутые пользователи пытались смахнуть волос пальцем, и многие из них случайно нажали на рекламу. Эффект новизны здесь оказался значительным до такой степени, что дело не закончилось удалением рекламы из Instagram – была заблокирована учетная запись рекламодателя.



Рис. 3.4. Реклама с фальшивым волосом в расчете, что вы проведете пальцем по экрану смартфона и нажмете по ошибке на рекламное объявление

3.4.3. Выявление эффектов первичности и новизны

Важной проверкой на эффекты первичности и новизны является построение графика использования во времени, чтобы определить, не происходит ли снижение. Возьмем приведенный выше пример MSN. Процент пользователей, нажавших ссылку Mail, со временем явно уменьшился, как показано на графике на рис. 3.5.

Стандартный подход к экспериментам предполагает, что эффект нововведения постоянен во времени. Тренд на снижение – это красный флаг, указывающий на нарушение предположений. Такие эксперименты должны длиться дольше, чтобы выяснить, когда стабилизируется эффект. Во многих случаях, как это подчеркивается в примере выше, простого понимания достаточно, чтобы объявить идею плохой. Этот подход прост и эффективен в большинстве случаев, но мы должны предупредить вас, что есть некоторые нюансы, которых следует остерегаться, особенно если вы проводите эксперимент в течение длительного времени (см. главу 23).

Еще один способ выявить возможные эффекты первичности/новизны – взять пользователей, которые появились в первые один-два дня (в отличие от всех пользователей за длительный период), и построить для них график эффекта воздействия с течением времени.



Рис. 3.5. Вовлеченность пользователей MSN снижается со временем

3.5. РАЗДЕЛЕНИЕ ПО СЕГМЕНТАМ

Анализ показателей по разным сегментам иногда приводит к интересным открытиям. К некоторым открытиям мы применяем закон Тваймана и об-

наруживаем недостатки или используем эти открытия как источник идей для будущих итераций эксперимента. Это расширенные тесты, которые вы можете применить на более поздних этапах развития вашей экспериментальной системы.

По каким признакам лучше всего разбивать на сегменты объекты эксперимента? Вот несколько примеров:

- рынок или страна: некоторые функции работают лучше в отдельных странах; иногда провал новой функции является следствием плохого перевода на другой язык, т. е. локализации;
- устройство или платформа: где открыт пользовательский интерфейс – это настольный компьютер или мобильный телефон? Какую мобильную платформу они используют: iOS или Android? Иногда разделение по версии браузера помогает выявить ошибки и несовместимости JavaScript. Производители мобильных телефонов (например, Samsung, Motorola) используют надстройки, которые могут вызывать сбой функций;
- время суток и день недели: построение графика эффекта с течением времени может показать интересные закономерности. Пользователи в выходные могут отличаться по многим характеристикам;
- тип пользователя: новый или существующий, где новые пользователи – это те, кто присоединился после определенной даты (например, начала эксперимента или, возможно, за месяц до этого);
- характеристики учетной записи пользователя: одна или общая учетная запись в Netflix или один путешественник/семья на Airbnb.

Сегментированные представления обычно используются двумя способами.

1. Сегментированное представление показателя, независимое от какого-либо эксперимента.
2. Сегментированное представление эффекта от воздействия в контексте эксперимента – так называемая гетерогенность эффекта, отражающая неоднородность или однородность эффекта для разных сегментов.

3.5.1. Сегментированное представление показателя

Когда CTR мобильных объявлений Bing были сегментированы по разным мобильным операционным системам, они сильно различались, как показано на графике на рис. 3.6.

Первоначальная идея заключалась в том, чтобы составлять истории о лояльности пользователей и различиях между ними, но расследование показало, что результат зависит от различий в механизмах отслеживания кликов, используемых в разных операционных системах. Существует несколько способов отслеживания кликов, и они различаются по точности, а это приводит к разному уровню потерь. В iOS и Windows Phone для отслеживания кликов использовалось перенаправление, т. е. клик всегда отправляется на сервер, регистрируется и затем перенаправляется к месту назначения. Эта

методика имеет высокую точность, но замедляет пользовательский опыт. На Android отслеживание кликов осуществлялось с помощью веб-маяка, который указывал на клик, а затем перенаправлял браузер на целевую страницу. Этот метод быстрее с точки зрения пользователя, но с потерями; некоторые веб-маяки не выполняют свою задачу, и переход не регистрируется. Этим можно объяснить разницу в рейтинге кликов (CTR) между iOS и Android, но почему CTR для Windows Phone был таким высоким? В ходе расследования было обнаружено, что наряду с перенаправлением в коде была ошибка, при которой пролистывание пользователя неправильно записывалось как клик. Да, ошибки неизбежны. Когда вы видите аномальные данные, вспоминайте о законе Тваймана и исследуйте проблему.




Рис. 3.6. CTR для различных мобильных операционных систем

3.5.2. Сегментированное представление эффекта (гетерогенность эффекта)

В одном эксперименте было внесено изменение в пользовательский интерфейс, что привело к очень сильной разнице между сегментами на основе браузера. Практически для всех сегментов браузеров изменение сопровождалось небольшим улучшением ключевых показателей, но для сегмента Internet Explorer 7 наблюдался резко отрицательный эффект по ключевым показателям. Как и в случае любого аномального эффекта (положительного или отрицательного), здесь пришлось обратиться к закону Тваймана и углубиться в причину. Расследование показало, что используемый код JavaScript несовместим с Internet Explorer 7. Это вызывало ошибку, не позволяющую пользователям переходить по ссылкам в определенных сценариях.

Такое расследование возможно только при включенной детализации сегментов, т. е. при просмотре эффектов от изменения для различных сегментов, также называемых в статистике *эффектами условного среднего воздействия* (conditional average treatment effects, CATE). Хороший обзор rete-

рогенных эффектов представлен в материалах EGAP-2018 (<https://egap.org>). Выявление интересных сегментов или поиск взаимодействий между ними можно выполнить с помощью машинного обучения и статистических методов, таких как деревья решений и случайный лес.

Если вы можете предупредить экспериментатора о наличии интересных сегментов, вы получите много интересных идей (но не забудьте внести поправки на проверку множественных гипотез, как отмечалось выше). Вовлечение организаций в проведение А/В-тестов – важный шаг; но предоставление им информации более обширной, чем просто общий эффект от изменений, дает новые идеи, которые помогают ускорить инновации.

3.5.3. Анализ эффекта по сегментам, вводящий в заблуждение

Можно оценить эффект воздействия для двух взаимно исчерпывающих и исключаящих сегментов и обнаружить, что ОЕС увеличивается для обоих, но в целом снижается. В отличие от парадокса Симпсона (описанного в следующем разделе), это связано с миграцией пользователей из одного сегмента в другой.

Например, предположим, что у вас есть интересующий вас показатель – число сеансов на пользователя. Вы работаете над новой версией функции продукта F, которую используют немногие пользователи, поэтому вы сосредотачиваетесь на двух сегментах: пользователях F и тех, кто не использует F. Вы видите, что в вашем эксперименте после внедрения новой версии количество сеансов на пользователя F увеличилось. Теперь вы смотрите на второй сегмент и видите, что количество сеансов на пользователя тоже выросло. Можете ли вы праздновать успех? НЕТ! Возможно, что общее количество сеансов на пользователя уменьшилось или осталось на прежнем уровне.

Например, пользователи функции F в среднем давали 20 сеансов на пользователя, а те, кто не использует F, в среднем давали 10 сеансов на пользователя. Если обновление заставит пользователей с 15 сеансами на пользователя прекратить использовать F, среднее количество сеансов на пользователя вырастет для сегмента, использующего F (мы игнорируем пользователей с количеством сеансов на пользователя ниже среднего), и оно будет расти для второго сегмента (мы добавили пользователей с более высоким средним числом сеансов на пользователя), но совокупное значение может вести себя как угодно – расти, снижаться или оставаться неизменным.

Когда пользователи переходят от одного сегмента к другому, интерпретация показателей на уровне сегмента может вводить в заблуждение, поэтому следует использовать несегментированный (агрегатный) показатель. В идеале сегментирование должно выполняться только по значениям, которые определены до эксперимента, чтобы воздействие не могло заставить пользователей менять сегменты, хотя на практике такое ограничение сегментов не всегда легко реализуемо.

3.6. ПАРАДОКС СИМПСОНА

Если мы проводим эксперимент с накоплением (см. главу 15), т. е. имеем два или более периода с разными процентными долями распределения вариантов, объединение результатов может привести к смещенной неверной оценке эффектов воздействия, т. е. тест может быть лучше, чем контроль как в первой, так и во второй фазе, но в целом хуже, когда два периода объединены. Это интуитивно непонятное явление называется *парадоксом Симпсона* (Simpson, 1951).

В табл. 3.1 показан простой пример, когда веб-сайт посещает 1 млн человек в день в течение двух дней: пятницу и субботу. В пятницу эксперимент проводится с 1 % трафика, предназначенного для тестирования. В субботу доля тестового трафика повышается до 50 %. Несмотря на то что у тестовой группы (Т) коэффициент конверсии лучше как в пятницу (2,30 против 2,02 %), так и в субботу (1,2 против 1,00 %), если данные просто объединить за два дня, похоже, что тест работает хуже (1,20 против 1,68 %).

Таблица 3.1. Конверсия за два дня. Каждый день дает 1 млн посещений, и каждый день тест (Т) лучше, чем контроль (К), но в целом тест хуже

	Пятница	Суббота	Итого
	Контроль/тест: 99 / 1 %	Контроль/тест: 50 / 50 %	
К	$\frac{20000}{990000} = 2,02 \%$	$\frac{5000}{500000} = 1,00 \%$	$\frac{25000}{1940000} = 1,68 \%$
Т	$\frac{230}{10000} = 2,30 \%$	$\frac{6000}{500000} = 1,20 \%$	$\frac{6230}{510000} = 1,20 \%$

В приведенных выше числах нет ничего странного. Математически возможно, что $\frac{a}{b} < \frac{A}{B}$ и $\frac{c}{d} < \frac{C}{D}$, однако $\frac{a+c}{b+d} > \frac{A+C}{B+D}$. Причина, по которой это кажется нелогичным, заключается в том, что мы имеем дело со *средне-взвешенными* значениями, и суббота, которая была днем с худшим общим коэффициентом конверсии, сильнее повлияла на средний эффект, потому что у нее было больше пользователей, подвергшихся тестированию.

Вот другие примеры контролируемых экспериментов, в которых может возникнуть парадокс Симпсона:

- различие выборок пользователей. Если существует озабоченность по поводу получения репрезентативной выборки для всех типов браузеров, выборка не является единообразной, и пользователи некоторых браузеров (например, Орега или Firefox) выбираются чаще. Возможно, общие результаты покажут, что тестовый вариант лучше, но, как только пользователи будут сегментированы по типам браузеров, тестовый вариант станет хуже для всех типов браузеров;

- эксперимент проводится на веб-сайте, который работает в нескольких странах, например в США и Канаде. Пропорции, назначаемые для контроля и теста, различаются в зависимости от страны (например, в США для тестовой группы достаточно 1 % пользователей, в то же время канадцы проводят расчеты статистической мощности и определяют, что им для теста необходимо 50 %). Если результаты объединить, тестовый вариант может выиграть, даже если в результатах, сегментированных по странам, он показал худший результат. Этот пример напрямую совпадает с предыдущим примером возрастания совокупного показателя;
- эксперимент проводится с процентным отношением 50/50 между группами контроль/тест, но защитник наиболее ценных клиентов (скажем, 1 % с наибольшими расходами) обеспокоен и убеждает владельцев бизнеса в том, что этот сегмент клиентов будет оставаться стабильным и только 1 % участвует в эксперименте. Как и в приведенном выше примере, возможно, что эксперимент будет в целом положительным, но по отдельности он будет хуже как для наиболее ценных клиентов, так и для «менее ценных»;
- допустим, мы выполняем обновление веб-сайта для клиентов, подключенных к центру обработки данных DC1, и их удовлетворенность повышается. Затем мы выполняем обновление для клиентов, подключенных к центру обработки данных DC2, и удовлетворенность клиентов там также повышается. Вполне возможно, что аудиторы, проверившие объединенные данные по обновлению, отметят снижение общей удовлетворенности клиентов.

Хотя парадокс Симпсона интуитивно непонятен, это не редкость. Мы несколько раз сталкивались с этим парадоксом в реальных экспериментах. Нужно быть осторожными при агрегировании данных, собранных в разных процентных отношениях.

Инверсия парадокса Симпсона, похоже, подразумевает, что для тестового воздействия математически можно увеличить вероятность выздоровления в совокупной популяции, но при этом уменьшить вероятность (что плохо) в каждой субпопуляции, например у мужчин и женщин. На практике это означает, что следует принимать лекарство, если пол пациента неизвестен, но избегать приема, если пол мужской или женский, что явно абсурдно. Перл (Pearl, 2009) показал, что данные наблюдений сами по себе не помогают нам разрешить этот парадокс, поскольку причинная модель будет определять, какие данные использовать (совокупность или субпопуляции). Теорема «Принципа уверенности» утверждает, что, если действие увеличивает вероятность события E в каждой подгруппе популяции, оно также должно увеличивать вероятность E в популяции в целом.

3.7. Поощряйте здоровый скептицизм

Прошло шесть месяцев с тех пор, как мы начали прилагать скоординированные усилия по А/В-тестированию в SumAll, и мы пришли к неудобному выводу: большинство наших успешных результатов никак не отражалось на росте привлечения пользователей. Если мы и двигались, то куда-то вбок...

– Питер Борден (2014)

Иногда организациям сложно инвестировать в доверительные эксперименты, поскольку они представляют собой инвестиции в неизвестное – создание тестов, которые сделают недействительными ранее полученные результаты, если тесты сработают. Хорошие специалисты по данным являются скептиками: они выискивают аномалии, ставят под сомнение результаты и применяют закон Тваймана, когда результаты выглядят слишком хорошо.

Глава 4

Платформы и культура экспериментов

Если вам нужно перецеловать много лягушек, чтобы найти принца, набирайте побольше лягушек и целуйте их все быстрее и быстрее.

– Майк Моран, из книги *Do It Wrong Quickly* (2007)

Как мы говорили в главе 1, проведение доверительных контролируемых экспериментов – это золотой научный стандарт при оценке многих (но не всех) идей и принятия решений на основе данных. Что менее очевидно, упрощение проведения контролируемых экспериментов также ускоряет инновации за счет снижения затрат на опробование новых идей, как показывает цитата из книги Морана в эпиграфе, и обучение на их основе в рамках полезной обратной связи. В этой главе мы сосредоточимся на том, что нужно для создания надежной и заслуживающей доверия экспериментальной платформы. Мы начнем с рассмотрения *моделей зрелости экспериментов*, описывающих различные фазы, через которые организация обычно проходит, начиная проводить эксперименты, а затем углубимся в технические детали создания платформы для экспериментов.

Наиболее важные организационные аспекты включают руководство, процесс и обучение, выбор между выполнением работы внутри компании и на аутсорсинге и как в конечном итоге используются результаты. Технические инструменты предназначены для поддержки планирования экспериментов, развертывания, масштабирования и анализа и способствуют быстрому пониманию ситуации.

4.1. Модели зрелости экспериментов

Модели зрелости экспериментов состоят из этапов, которые, как правило, должна пройти организация, чтобы считаться основанной на данных, и подразумевают внедрение каждого изменения с помощью А/В-экспериментов.

Мы используем четыре фазы зрелости, предложенные Александром Фабианом (Alexander Fabijan) из команды Microsoft Research в 2017 году.

1. **Запуск:** цель этапа заключается в строительстве фундамента экспериментальной платформы, в частности подбора инструментов и базовых методов науки о данных, для вычисления сводной статистики, задействованной в проверке гипотез, чтобы вы могли спланировать, запустить и проанализировать несколько экспериментов. Проведение нескольких успешных экспериментов, где успех означает, что результаты достоверно указывают на прогресс, имеет решающее значение для мотивации перехода к следующему этапу.
2. **Разбег:** переход от фундаментальных условий и проведения нескольких экспериментов к определению стандартных показателей и побуждению организации к проведению дополнительных экспериментов. На этом этапе вы повышаете доверие, проверяя средства измерения, выполняя тесты А/А и тесты на несоответствие отношения выборок (SRM) (см. главу 21).
3. **Взлет:** переход к масштабному проведению экспериментов. Показатели являются всеобъемлющими, и цель состоит в том, чтобы достичь согласованного набора показателей или пройти весь путь до кодификации ОЕС, которая описывает компромиссы между несколькими показателями. Организация использует эксперименты для оценки большинства новых функций и изменений.
4. **Полет:** на этом этапе вы проводите А/В-эксперименты как норму для каждого изменения. Специализированные группы должны уметь анализировать большинство экспериментов, особенно простых, без помощи специалистов по данным. Акцент смещается на автоматизацию для поддержки масштабного экспериментирования, а также на создание институциональной памяти, которая представляет собой запись всех проведенных экспериментов и изменений, что позволяет извлекать уроки из прошлых экспериментов (см. главу 17) для обмена примечательными результатами и передовым опытом с целью повышения культуры экспериментирования.

На этапе запуска организация проводит эксперименты примерно раз в месяц (~ 10 в год), и на каждом этапе количество экспериментов увеличивается в 45 раз: организации на этапе разбега будут проводить эксперименты примерно раз в неделю (~ 50 в год), на этапе взлета – почти ежедневно (~ 250 в год), а этап полета начнется, когда вы превысите тысячу экспериментов в год.

По мере прохождения этих этапов техническая направленность, ОЕС и даже состав команд будут меняться. Прежде чем мы углубимся в технические аспекты создания экспериментальной платформы на этапах разбега, взлета и полета, давайте выделим несколько аспектов, на которых организациям следует сосредоточиться независимо от этапа. Прежде всего это лидерство и процессы.

4.1.1. Лидерство

Вовлеченность руководства имеет решающее значение для создания сильной культуры экспериментирования и внедрения А/В-тестирования в качестве неотъемлемой части процесса разработки продукта. Наш опыт показывает, что не только организация, но и культура в ней проходит этапы принятия экспериментов. Первая стадия, предшествующая любым экспериментам, – это высокомерие, когда измерения и эксперименты не нужны из-за уверенности в HiPPO («мнение самого высокооплачиваемого человека»). Далее наступает этап измерений и контроля, когда организация начинает измерять ключевые показатели и отслеживать необъяснимые различия. Как отмечает Томас Кун, смена парадигмы происходит «только из-за того, что сначала что-то идет не так в нормальной деятельности». Тем не менее все еще остается сильная зависимость от HiPPO и укоренившихся норм, убеждений и парадигм, поскольку организация склонна отвергать новые знания, которые противоречат привычному положению дел. Только через постоянные измерения, экспериментирование и накопление знаний организация может достичь фундаментального понимания, в котором причины ясны, а модели действительно работают.

По нашему опыту, для достижения этой последней стадии не обойтись без участия руководителей и менеджеров на разных уровнях, куда входят:

- участие в процессе установления общих целей и согласование целевых показателей высокого уровня и контрольных показателей (см. главу 18) и – в идеале – кодификации компромиссов для создания ОЕС (см. главу 7);
- постановка целей для улучшения показателей, а не целей по выпуску функций X и Y. Существует определенный фундаментальный сдвиг, который происходит, когда команды переходят от внедрения функции, которая не влияет на ключевые показатели, к ОТКАЗУ ОТ ВНЕДРЕНИЯ функции, если она не улучшает ключевые показатели. Использование экспериментов в качестве запретительного фактора требует сложной культурной перестройки, особенно для крупных, устоявшихся команд, которые переходят к культуре, основанной на данных;
- предоставление командам возможности вводить новшества и улучшать ключевые показатели в рамках организационных ограждений (см. главу 21). Осознание того, что идеи должны пройти оценку и многие из них потерпят неудачу, и достойное смирение, когда идеи не могут изменить показатели, которые они были призваны улучшить. Формирование культуры «быстрых неудач»;
- требование надлежащего инструментария и высокого качества данных;
- анализ результатов экспериментов, знание того, как их интерпретировать, обеспечение соблюдения стандартов интерпретации (например, для предотвращения *p*-заблуждений) и открытость механизма влияния результатов на принятие решений;

- как было сказано в главе 1, многие из решений, которым лучше всего помогают эксперименты, являются оптимизационными; долгая последовательность экспериментов также может способствовать выработке общей стратегии. Например, от интеграции Bing с социальными сетями, такими как Facebook и Twitter, отказались после того, как эксперименты не приносили пользы в течение двух лет. В качестве другого примера – ответ на вопрос о том, приводит ли включение видео в рекламные электронные письма к более высокому коэффициенту конверсии, потребует тестирования нескольких реализаций;
- выбор портфеля проектов с высоким риском / высокой прибылью вместо проектов с небольшим гарантированным доходом, понимание того, что лишь некоторые из них будут работать, а многие – даже большинство – потерпят неудачу. Способность учиться на неудачах пригодится для успешных инноваций;
- поддержка долгосрочного обучения на основе экспериментов, например проведение экспериментов только для сбора данных или определения рентабельности инвестиций (ROI). Эксперименты не только полезны для принятия решений по отдельным изменениям, но также играют важную роль в измерении эффекта и оценке окупаемости инвестиций для различных инициатив. Мы будем говорить об этом в главе 5;
- повышение гибкости с помощью коротких циклов запуска изменений для создания продуктивной и быстрой петли обратной связи при проведении экспериментов, требующих установления чувствительных суррогатных показателей (см. главу 7).

Лидеры не могут просто взять и предоставить организации платформу и инструменты для экспериментов. Они должны обеспечивать правильные стимулы, процессы и полномочия для организации, принимающей решения на основе данных. Лидерство, вовлеченное в эти действия, особенно важно на этапах запуска и разбега, когда важно установить согласованные цели организации.

4.1.2. Процесс

По мере того как организация проходит стадии экспериментальной зрелости, для обеспечения надежных результатов необходимо настроить процессы обучения и установить культурные нормы. Обучение должно гарантировать, что каждый член команды имеет базовые знания, необходимые для хорошей работы по разработке и проведению доверительных экспериментов и правильной интерпретации результатов. Культурные нормы помогают формировать ожидание инноваций, отмечать неожиданные неудачи и всегда стремиться учиться. Обратите внимание, что это общая задача, так как на саммите в 2019 году с участием 13 онлайн-компаний, проводящих эксперименты, докладчики отмечали, что формирование культуры и про-

цессов, которые поощряют эксперименты и инновации, по-прежнему остаются проблемой (Гупта, Кохави и др., 2019).

Что касается обучения, то своевременное и правильное планирование эксперимента и анализ результатов и в самом деле повышают организованность процессов. Давайте рассмотрим этот момент на примере от Google: поначалу, когда экспериментаторы, работающие над поиском, хотели провести эксперимент, они должны были заполнить опросный лист, который затем проверяли эксперты. Опросный лист включал важные вопросы, такие как: «Какова ваша гипотеза?» и «Насколько большие изменения вас волнуют?» – и постепенно подводил экспериментаторов к вопросам анализа статистической мощности. Поскольку пытаться научить всех и сразу проводить надлежащий анализ мощности было нереалистично, контрольный список также помогал убедиться в том, что эксперименты были достаточно достоверны. Когда организационный уровень экспериментов достаточно вырос, поисковая организация перестала нуждаться в столь явном контрольном списке вопросов.

Как правило, экспериментаторов приходится вести за руку только первые несколько раз, когда они проводят эксперимент. С каждым последующим экспериментом они становятся все быстрее и независимее. Чем опытнее экспериментатор, тем лучше он объясняет концепции экспериментов товарищам по команде и со временем сам начинает выступать в качестве эксперта-обозревателя. Тем не менее даже опытным экспериментаторам обычно требуется помощь в экспериментах, требующих уникального ди-зайна или новых показателей.

И LinkedIn, и Microsoft (Google тоже, хотя и не регулярно) проводят занятия, на которых рассказывают об экспериментальных методиках. Популярность этих занятий растет по мере развития культуры экспериментирования.

Как и контрольный список во время разработки эксперимента, регулярные встречи по обсуждению хода эксперимента и для анализа результатов дают аналогичные преимущества своевременного обучения. На этих встречах эксперты изучают результаты прежде всего на предмет достоверности – часто выявляя проблемы с инструментарием, особенно свойственные начинающим экспериментаторам, – прежде чем погрузиться в полезные обсуждения, в результате которых вырабатываются рекомендации по внедрению / отказу от внедрения обновления, которые экспериментаторы могут передать своим руководителям. Эти обсуждения расширяют понимание целей, контрольных отметок, показателей качества и отладки (см. главу 6), и разработчики с большей вероятностью предвидят эти проблемы в течение жизненного цикла разработки. В ходе этих обсуждений формируются компромиссы в отношении показателей, которые можно систематизировать и зафиксировать в ОЕС (см. главу 7). В подобных обзорах экспериментов также обсуждаются и извлекаются уроки из неудачных экспериментов: многие идеи с высоким риском и высокой отдачей не приносят успеха на первой итерации, и извлечение уроков из неудач имеет решающее значение для доработки, необходимой для доведения этих идей до успеха (см. главу 1).

Постепенно эксперты учатся видеть закономерности в изменениях, например видят, как воздействие эксперимента связано с аналогичными предыдущими экспериментами и как это можно в дальнейшем задействовать в метаанализе (см. главу 8), направленном на улучшение взаимодействия с пользователем и обновление определений ключевых показателей. Другой непреднамеренный, но положительный результат, который мы заметили на таких встречах по анализу экспериментов, заключается в том, что они собирают разные команды в одном месте, чтобы они могли учиться друг у друга. Обратите внимание, что команды действительно должны работать над одним и тем же продуктом и использовать одни и те же метрики и ОЕС, чтобы было достаточно общего контекста для обсуждения и обучения. Если команды слишком разные или инструменты анализа недостаточно развиты, эта встреча вряд ли будет полезной. Мы предполагаем, что эта форма обсуждений и проверки становится наиболее продуктивной на поздних этапах зрелости эксперимента – разбега и взлета.

Опираясь на платформу и отлаженные процессы, мы можем широко делиться уроками, извлеченными из экспериментов, будь то метаобучение от экспертов, наблюдающих за множеством экспериментов, или новое знание, полученное в результате одного эксперимента. Распространение знаний может происходить через регулярные информационные бюллетени, твиттер-канал, аккуратно обновляемую домашнюю страницу, внутреннюю «социальную сеть», прикрепленную к экспериментальной платформе для поощрения обсуждения (как это делается на Booking.com), или по другим каналам. В фазе полета становится более полезной институциональная память (см. главу 8).

Для того чтобы эксперименты были успешными и масштабными, в компании должна существовать *культура интеллектуальной честности* – большее значение имеет обучение, а не результаты или то, вносим ли мы изменения. С этой точки зрения критически важна полная прозрачность результатов эксперимента. Вот несколько способов, которыми мы добиваемся этого:

- вычисляйте множество показателей; убедитесь, что важные показатели, такие как ОЕС, ограничения и другие связанные показатели, хорошо видны на панели мониторинга эксперимента, чтобы команды не могли выбирать лучшие значения при публикации результатов;
- рассылайте информационные бюллетени или электронные письма об удивительных результатах (неудачах и успехах), метаанализах предыдущих экспериментов для развития понимания того, как команды проводят эксперименты, и о многом другом (см. главу 8). Цель состоит в том, чтобы подчеркнуть обучение и необходимую культурную поддержку;
- не позволяйте экспериментаторам запускать обновление, если оно отрицательно влияет на важные показатели. Это может быть как пред-

упреждение экспериментатору, так и сообщение людям, которым небезразличны эти показатели, вплоть до потенциальной блокировки запуска (эта крайняя мера может быть контрпродуктивной, так как лучше иметь культуру, в которой решающее значение имеют объективные показатели, а спорные решения можно открыто обсуждать);

- научиться на неудачных идеях. Большинство идей терпит неудачу, поэтому важно извлекать уроки из неудач, чтобы улучшить последующие эксперименты.

4.1.3. Разработать самим или купить готовый продукт?

На рис. 4.1 показано, как Google, LinkedIn и Microsoft масштабировали эксперименты на протяжении многих лет, причем в первый год частота экспериментов составляла более одного эксперимента в день (более 365 в год). График показывает рост на порядок в следующие четыре года для Bing, Google и LinkedIn. В первые годы рост замедляли возможности экспериментальной платформы. В случае Microsoft Office, который начал использовать контролируемые эксперименты в качестве механизма безопасного развертывания для масштабного развертывания функций только в 2017 году, платформа не была ограничивающим фактором благодаря ее предыдущему использованию в Bing, и количество экспериментов выросло более чем на 600 % в 2018 году. Рост замедляется, когда организация достигает культуры «тестировать все» и ограничивающим фактором становится ее способность преобразовывать идеи в код, который можно использовать в контролируемых экспериментах.




Рис. 4.1. Рост количества экспериментов в течение многих лет для Bing, Google, LinkedIn и Microsoft Office. Сегодня Google, LinkedIn и Microsoft проводят более 20 000 контролируемых экспериментов в год, хотя методики подсчета различаются (например, увеличение количества пользователей с 1 до 5–10 % может считаться одним или тремя экспериментами; эксперимент, состоящий из одной контрольной и двух тестовых групп, может считаться одним или двумя экспериментами)

Хотя мы все активно участвовали в создании собственных экспериментальных платформ в наших компаниях, мы вовсе не утверждаем, что каждая компания должна разработать собственную платформу. К решению о рентабельности инвестиций в разработку или покупку, особенно на этапе подготовки, можно прийти в результате обсуждения разных факторов. Вот несколько вопросов, которые следует учитывать при принятии такого решения.

Может ли сторонняя платформа предоставить необходимую функциональность?

- Обдумайте, какие типы экспериментов вы хотите провести, например фронтенд или бэкенд, сервер или клиент, мобильное приложение или онлайн-приложение. Многие сторонние решения недостаточно универсальны, чтобы охватить все типы. Например, решения на основе JavaScript не подходят для экспериментов с бэкендом и не могут хорошо масштабироваться для большинства параллельных экспериментов. Некоторые поставщики сильны в каком-то одном применении, но не в остальных (например, отличный комплект разработчика (SDK) для мобильных устройств, но скудные возможности для работы с интернетом; или отличный редактор WYSIWYG для интернета, но мобильный SDK, который слишком часто дает сбои).
- Учитывайте быстродействие веб-сайта. Для некоторых внешних решений требуется дополнительный код JavaScript, который, как известно, замедляет загрузку страниц. Как показано в главе 5, увеличенная задержка влияет на взаимодействие с пользователем.
- Учитывайте параметры и показатели, которые вы, возможно, захотите использовать. Например, некоторые внешние платформы предлагают ограниченный перечень показателей, которые вы можете вычислять в экспериментах. Во внешних решениях невозможна работа со сложными показателями, требующими обработки сеансов. Зачастую не поддерживаются даже такие показатели, как проценты, которые обычно используются для измерения задержки, когда более чувствительным является хвост, а не среднее значение. Поскольку расширенную бизнес-отчетность наверняка придется формировать отдельно, при покупке готового решения также могут возникнуть трудности с общим языком измерений и показателей.
- Подумайте, какую единицу рандомизации вы хотите использовать и какой совместный доступ к данным приемлем (например, для обеспечения конфиденциальности пользователей). Обычно существуют ограничения на то, какая информация (особенно о пользователях, см. главу 9) может быть передана третьей стороне, что может мешать экспериментам или вызывать дополнительные расходы.
- Легко ли доступны данные, записанные во внешнее хранилище? Нужно ли клиентам входить в два места (двойное ведение журнала)? Что

происходит, когда сводная статистика расходится? Есть ли инструменты для устранения расхождений? Часто это недооцененные сложности, которые снижают доверие и вызывают обоснованные вопросы о надежности различных систем.

- Можете ли вы интегрировать дополнительные источники данных? Хотите ли вы интегрировать данные о покупках, возвратах, демографические данные? Некоторые внешние системы не позволяют присоединять такие внешние данные.
- Вам нужны результаты, близкие к реальному времени (near real-time, NRT)? Они часто полезны для быстрого обнаружения и остановки неудачных экспериментов.
- Достаточно ли вы проводите экспериментов, чтобы сформировать собственную институциональную память? Многие сторонние экспериментальные системы не имеют функций институциональной памяти.
- Можете ли вы реализовать свою функцию в окончательной версии? Многие системы WYSIWYG требуют от вас повторной реализации вашей функции для реального постэксперимента. В масштабе это может быть ограничивающим фактором для целого ряда функций, требующих повторной реализации.

Сколько будет стоить собственная разработка?

Построение масштабируемой системы – дело сложное и дорогое, как вы увидите в нашем обсуждении технических проблем платформы далее в этой главе.

Какова траектория ваших экспериментов?

Этот тип инвестиций в инфраструктуру связан с ожиданием, т. е. с тем, сколько экспериментов *будет* проводить ваша организация, если она действительно поддерживает проведение экспериментов, а не с тем, сколько экспериментов проводится в настоящее время. Если есть внутренняя мотивация и спрос, а объем потенциально может вырасти сверх того, что вмещает внешнее решение, создавайте собственную платформу. Создание внутреннего решения занимает больше времени, но интеграция внешнего решения также требует усилий, особенно если вам придется переключиться на другое решение по мере роста компании.

Нужно ли вам интегрировать эксперименты в методы настройки и развертывания вашей системы?

Экспериментирование может быть неотъемлемой частью процесса непрерывного развертывания. Между экспериментированием и тем, как разработчики выполняют настройку и развертывание, существует много общего (см. главу 15). Если интеграция необходима, например, для более сложных ситуаций отладки, то использование сторонних решений может вызвать дополнительные трудности.

Ваша организация может быть не готова к инвестициям и ответственности за создание собственной платформы, поэтому, возможно, имеет смысл использовать внешнее решение, чтобы убедиться в полезности большего количества экспериментов, прежде чем принимать решение о создании собственной платформы.

4.2. ИНФРАСТРУКТУРА И ИНСТРУМЕНТЫ

В главе 3 мы показали, что эксперимент может пойти не так, как надо. Создание экспериментальной платформы – это не только ускорение инноваций с помощью экспериментов; платформа критически важна для обеспечения достоверности результатов, на которые опираются управленческие решения. Масштабирование экспериментов в компании подразумевает создание не только инфраструктуры для экспериментальной платформы, но также инструментов и процессов, позволяющих глубоко встроить эксперименты в корпоративную культуру, процессы разработки и принятия решений. Цель экспериментальной платформы – сделать эксперименты самодостаточными и минимизировать дополнительные затраты на проведение доверительного эксперимента.

Экспериментальная платформа должна охватывать каждый этап процесса – от разработки и развертывания экспериментов до их анализа. Если вы посмотрите на компоненты экспериментальной платформы от Bing, LinkedIn или Google, то увидите четыре компонента высокого уровня:

- определение, настройку и управление экспериментом через пользовательский интерфейс (UI) или интерфейс прикладного программирования (API) и сохранение настроек в конфигурации экспериментальной системы;
- развертывание эксперимента как на стороне сервера, так и на стороне клиента, включая назначение вариантов и параметризацию;
- инструментарий для экспериментов;
- анализ эксперимента, который включает определение и вычисление показателей и статистических тестов, таких как p -значения.

На рис. 4.2 показано, как эти компоненты сочетаются друг с другом. Далее в этой главе мы подробно рассмотрим каждый из этих компонентов.




Рис. 4.2. Возможная архитектура экспериментальной платформы. Клиент и/или сервер могут вызывать службу назначения вариантов. Служба назначения вариантов может быть отдельным сервером или библиотекой, встроенной в клиент и/или сервер (в этом случае конфигурации будут отправлены прямо клиенту и/или серверу); см. далее в этой главе обсуждение различных вариантов архитектуры

4.2.1. Разработка, настройка и управление экспериментом

Чтобы провести множество экспериментов, экспериментаторам нужен способ легко определять, настраивать и управлять жизненным циклом эксперимента. Чтобы определить или указать эксперимент, нам нужны владелец, имя, описание, даты начала и окончания и несколько других полей (см. главу 12). Платформа также должна поддерживать многократные итерации экспериментов по таким причинам, как:

- развитие обновления на основе результатов экспериментов, включая исправление ошибок, обнаруженных в ходе эксперимента;
- постепенное расширение эксперимента на более широкую аудиторию. Это может быть реализовано либо через заранее определенные расходящиеся кольца (например, разработчики в команде, все сотрудники внутри компании и т. д.), либо через увеличение процента охвата внешней популяции.

Все итерации следует проводить в рамках одного эксперимента. В целом одна итерация для каждого эксперимента должна быть активной в любое время, хотя для разных платформ могут потребоваться разные итерации.

Платформе нужен интерфейс и/или инструменты, чтобы легко управлять многими экспериментами и их многократными итерациями. Функциональные возможности подсистемы управления должны включать:

- написание, редактирование и сохранение черновых спецификаций экспериментов;
- сравнение черновой итерации эксперимента с текущей (работающей) итерацией;
- просмотр истории или временной шкалы эксперимента (даже если он больше не проводится);
- автоматическое присвоение идентификаторов созданным экспериментам, вариантам и итерациям и добавление их в спецификацию эксперимента. Эти идентификаторы необходимы для инструментария эксперимента (обсуждается далее в этой главе);
- проверку на отсутствие очевидных ошибок в спецификациях, таких как конфликты конфигурации, недопустимая целевая аудитория и т. д.;
- проверку статуса эксперимента, а также запуск/остановку эксперимента. Во избежание человеческой ошибки обычно запускать эксперимент могут только владельцы экспериментов или лица со специальным разрешением. Однако из-за асимметрии причинения вреда пользователям остановить эксперимент может любой сотрудник¹, хотя при этом генерируется предупреждение для владельца эксперимента.

¹ Авторы имеют в виду так называемую Большую красную кнопку для аварийной остановки, которой должен быть оснащен любой эксперимент, затрагивающий пользователей. – *Прим. перев.*

Кроме того, поскольку эксперимент влияет на реальных пользователей, необходимы дополнительные инструменты или рабочие потоки для проверки вариантов эксперимента перед их запуском. Способы проверки варьируются от тестового кода, который должен быть запущен перед развертыванием, до системы контроля разрешений, где эксперименты должны получать одобрение от доверенных экспертов.

Помимо этих базовых проверок, особенно на этапе полета, когда эксперименты проводятся с полным охватом, платформа также должна поддерживать:

- автоматизацию запуска и расширения охвата экспериментов (подробнее см. в главе 15);
- мониторинг и оповещение в режиме, близком к реальному времени, для своевременного выявления неудачных экспериментов;
- автоматическое обнаружение и остановку неудачных экспериментов.

Это увеличивает безопасность экспериментов.

4.2.2. Развертывание эксперимента

Когда вы разработали спецификацию эксперимента, на следующем этапе ее нужно развернуть, чтобы повлиять на опыт пользователя. Механизм развертывания обычно включает два компонента.

1. Экспериментальная инфраструктура, предоставляющая описания экспериментов, назначения вариантов и другую информацию.
2. Изменения производственного кода, реализующие поведение вариантов в соответствии с заданием эксперимента.

Инфраструктура экспериментов должна обеспечивать:

- **присвоение варианта:** каким комбинациям экспериментов и вариантов назначен текущий пользователь исходя из его атрибутов (например, страны, языка, ОС, платформы)? Это назначение основано на спецификации эксперимента и псевдослучайном хеш-коде идентификатора, т. е. $f(ID)$. В большинстве случаев, чтобы гарантировать согласованность назначения для пользователя, используется идентификатор пользователя. Присвоение варианта также должно быть независимым, т. е. знание назначения варианта для одного пользователя никак не должно влиять на назначение варианта для другого пользователя. Мы обсудим это более подробно в главе 14. В этой главе мы предполагаем, что единицей рандомизации является пользователь;
- **производственный код, системные параметры и значения.** Теперь, когда у вас есть определения и назначение вариантов, как вы гарантируете, что пользователь получит надлежащий опыт: как вы управляете другим производственным кодом, какие системные параметры должны измениться и на какие значения?

Этот интерфейс (или интерфейсы) представлен на рис. 4.2 как служба назначения вариантов и может возвращать либо только назначение вариантов, либо полную конфигурацию со значениями параметров исходя из соображений быстродействия. В любом случае служба назначения вариантов необязательно должна быть отдельным сервером. Вместо этого ее можно встроить непосредственно в клиент или сервер через общую библиотеку. Независимо от интерфейса, единство реализации имеет решающее значение для предотвращения непреднамеренного расхождения и ошибок.

При реализации инфраструктуры, особенно при масштабных экспериментах, следует учитывать важные нюансы. Например, требуется ли атомарность, и если да, то с какой степенью детализации? Атомарность означает, что все серверы одновременно переключаются на следующую итерацию эксперимента. Одним из примеров того, где важна атомарность, является веб-сервис, где один запрос может вызвать обращение к сотням серверов, а несогласованное назначение приводит к несогласованному взаимодействию с пользователем (например, представьте себе поисковый запрос, направленный на несколько серверов, каждый из которых обрабатывает непересекающуюся часть поискового индекса; если алгоритм ранжирования изменился, все серверы должны синхронно начать использовать один и тот же алгоритм). Чтобы решить эту проблему, головная служба может выполнить назначение варианта и передать его дочерним службам. Существуют также различия в развертывании экспериментов между клиентскими и серверными подходами, которые обсуждаются далее в главе 12.

Еще один вопрос заключается в том, где именно в потоке происходит присвоение вариантов (т. е. когда вызывается интерфейс назначения вариантов). Присвоение вариантов может происходить в нескольких местах: за пределами производственного кода, полностью с использованием разделения трафика (например, во входной двери трафика), на стороне клиента (например, в мобильном приложении) или на стороне сервера. Чтобы принять обоснованное решение, обдумайте следующие ключевые вопросы.

- **В какой момент у вас есть вся необходимая информация для присвоения варианта?** Например, если у вас есть только запрос пользователя, вы располагаете лишь ограниченной информацией, такой как идентификатор пользователя, язык и устройство. Чтобы использовать дополнительную информацию, например возраст учетной записи, время последнего посещения или частоту посещений, потребуется выполнить поиск в клиентской базе данных, прежде чем вы сможете применить эти критерии для назначения вариантов. Это может привести к более позднему назначению варианта в рабочем потоке.
- **Вы применяете эксперимент только в одной точке потока или в нескольких точках?** Если вы находитесь на ранних стадиях создания своей экспериментальной платформы (этапы подготовки или

первых запусков), мы рекомендуем иметь только одну точку, в которой применяется эксперимент, чтобы не усложнять задачу. Если у вас есть несколько точек применения экспериментов, вам потребуется соблюдение ортогональности (например, перекрывающиеся эксперименты, как обсуждается в разделе 4.2.5), чтобы гарантировать, что применение эксперимента, которое происходит раньше, не искажает результаты эксперимента, применяемого в более поздней точке потока.

Теперь, когда вы назначили варианты, пора убедиться, что система оказывает на пользователя соответствующее воздействие. Есть три основных варианта архитектуры.

- Первая архитектура создает вилочный код на основе назначения вариантов:

```
variant = getVariant(userId)
If (variant == Treatment) then
    buttonColor = red
Else
    buttonColor = blue
```

- Вторая архитектура переходит к параметризованной системе, где любое возможное изменение, которое вы хотите протестировать в эксперименте, должно контролироваться параметром эксперимента. Вы можете продолжить использование вилочного кода:

```
variant = getVariant(userId)
If (variant == Treatment) then
    buttonColor = variant.getParam("buttonColor")
Else
    buttonColor = blue
```

или применить следующий способ:

```
variant = getVariant(userId)
...
buttonColor = variant.getParam("buttonColor")
```

- Третья архитектура отказывается даже от вызова `getVariant()`. Вместо этого на ранней стадии потока выполняется присвоение варианта, и конфигурация с вариантом и всеми значениями параметров для этого варианта и для этого пользователя передается вниз через весь оставшийся поток.

```
buttonColor = config.getParam("buttonColor")
```

Каждый системный параметр имеет настройку по умолчанию (например, по умолчанию `buttonColor` хранит значение `blue`), и для тестового воздействия вам нужно только указать, какие системные параметры изменяются, и передать их значения. Таким образом, передаваемый `config` содержит все параметры и соответствующие значения.

У каждой архитектуры есть свои преимущества и недостатки. Основное преимущество первой архитектуры состоит в том, что назначение вариантов происходит близко к фактическому изменению кода, поэтому обработка запуска упрощается. Обе группы, контрольная и тестовая, в первой архитектуре содержат только затронутых пользователей (см. главу 20); однако недостатком может быть рост технического отставания, поскольку управление разветвленными путями кода со временем становится довольно сложной задачей. Вторая архитектура, особенно во втором ее варианте, уменьшает объем кода, сохраняя при этом преимущество более легкой обработки запуска. Третья архитектура выполняет назначение вариантов еще раньше, поэтому обработка запуска становится более сложной задачей. Тем не менее она может оказаться более быстросействующей: по мере роста системы от сотен до тысяч параметров, даже если эксперимент влияет только на несколько параметров, оптимизация обработки параметров, возможно, с помощью кеширования, становится критически важной с точки зрения производительности.

Google перешел с первой архитектуры на третью, основываясь на сочетании соображений производительности, а также из-за накопившегося технического отставания и рассогласования между ветвями кода, когда пришло время объединить эти ветви, чтобы упростить будущие изменения. Bing также использует третью архитектуру. Microsoft Office использует первый вариант во второй архитектуре, но реализовал систему, в которой идентификатор ошибки передается в качестве параметра эксперимента, вызывая предупреждение через три месяца, чтобы напомнить разработчикам об удалении экспериментальных путей в коде.

Независимо от того, какую архитектуру вы выберете, вы должны измерить стоимость и влияние проведения экспериментов. Экспериментальная платформа также может повлиять на быстросействие, поэтому запуск некоторого трафика за пределами экспериментальной платформы сам по себе является экспериментом для измерения воздействия платформы, будь то задержка скорости загрузки сайта, нагрузка на процессор, стоимость машинного времени или любой другой фактор.

4.2.3. Инструменты для экспериментов

Мы предполагаем, что вы уже регистрируете базовые показатели, такие как действия пользователя и производительность системы (см. главу 13, чтобы узнать, что и как измерять). В частности, при тестировании новых функций вы должны обновить свой базовый инструментарий, поскольку эти обновления должны выполнять надлежащий анализ новых изменений. На этапе подготовки основное внимание уделяется этому уровню работы с инструментами, и руководство должно гарантировать, что инструменты постоянно пересматриваются и улучшаются.

Для экспериментов вы также должны регистрировать и обрабатывать каждый пользовательский запрос и взаимодействие, с которым запускает-

ся вариант и итерация. Итерация важна, особенно когда эксперимент начинается или набирает обороты, потому что не все серверы или клиенты одновременно изменяют обращение с пользователем (глава 12).

Во многих случаях, особенно когда мы переходим к этапам «взлет» и «полет», нам нужно регистрировать *контрафактические* (counterfactual) события, т. е. что *могло бы* произойти. Например, для пользователя из тестовой группы мы можем захотеть записать, какие результаты поиска *были бы* возвращены, если бы этот пользователь входил в контрольную группу. В описанной выше архитектуре системных параметров, где назначение вариантов происходит на ранней стадии, контрафактическая регистрация может оказаться довольно сложной, но необходимой (см. главу 20). Ведение контрафактического журнала может быть дорогостоящим с точки зрения производительности, и в этом случае вам придется разработать рекомендации о том, когда это необходимо. Если в вашем продукте есть место, где пользователи могут оставлять отзывы, эти отзывы и идентификаторы вариантов должны быть зарегистрированы. Это полезно, когда обратная связь специфична для варианта.

4.2.4. Масштабирование экспериментов: тонкости назначения вариантов

По мере того как компании переходят от этапа запуска к ускорению, чтобы обеспечить достаточную статистическую мощность для экспериментов, каждому варианту должен быть назначен достаточный процент пользователей. Если требуется максимальная мощность, эксперимент будет проводиться при процентном соотношении 50/50 и включать всех пользователей. При дальнейшем увеличении количества экспериментов пользователи должны участвовать в нескольких экспериментах. Как это работает?

4.2.4.1. Однослойный метод

Назначение варианта – это процесс, с помощью которого пользователей последовательно назначают какому-то варианту эксперимента. На этапе запуска количество экспериментов обычно невелико, трафик нетрудно разделить на части, и каждый вариант эксперимента получает определенную долю от общего трафика. У вас может быть один эксперимент с одним контрольным и двумя тестовыми вариантами, занимающий 60 % трафика, и другой эксперимент с одним контрольным и одним тестовым вариантом, занимающий остальные 40 % трафика (рис. 4.3). Это назначение обычно реализуют с помощью хеш-функции, равномерно распределяющей пользователей по *корзинам* (bucket). В этом примере мы используем 1000 непересекающихся корзин и указываем, какому варианту достанется определенная корзина. В этом примере вариант с 200 корзинами получает 20 % распределения трафика.

Входящие запросы с ID пользователя

$$f(\text{UID}) \% 1000 = m_i$$

Контроль желтый $m_1 - m_{200}$	Тест 1 синий $m_{201} - m_{400}$	Тест 2 зеленый $m_{401} - m_{600}$	Контроль рекомендации вкл. $m_{601} - m_{800}$	Тест рекомендации выкл. $m_{801} - m_{1000}$
--	---	---	---	---

← m →

Рис. 4.3. Пример назначения «контроль–тест» в однослойном методе

Распределение пользователей по корзинам должно быть случайным, но детерминированным. Если вы сравниваете любые две корзины, в которых используется одно и то же тестовое воздействие, предполагается, что они статистически схожи (см. главу 19):

- в каждой корзине должно быть примерно одинаковое количество пользователей (см. главу 3). Если вы разбили их по ключевым параметрам, таким как страна, платформа или язык, сравнение срезов по корзинам также будет примерно одинаковым;
- ваши ключевые показатели (цель, граница, качество) должны иметь примерно одинаковые значения (в пределах нормальной изменчивости).

Мониторинг назначений является ключевой задачей! Google, Microsoft и многие другие компании обнаружили ошибки в коде рандомизации, отслеживая характеристики корзин. Другой распространенной проблемой являются эффекты переноса (см. главу 23), когда предыдущие эксперименты могут испортить корзины для текущего эксперимента. Распространенным решением является повторная рандомизация или перетасовка корзин с каждым экспериментом, чтобы они больше не были смежными.

Однослойный метод (также называемый числовой линией) прост и позволяет проводить несколько экспериментов одновременно (каждый пользователь участвует только в одном эксперименте). Это разумный выбор на ранних этапах экспериментирования, когда одновременно проводится несколько экспериментов; однако основным недостатком является ограничение количества одновременных экспериментов, так как вы должны быть уверены, что каждый эксперимент имеет достаточно трафика для адекватной мощности. С эксплуатационной точки зрения управление экспериментальным трафиком в одноуровневой системе может быть сложной задачей, поскольку даже на этой ранней стадии эксперименты проводятся одновременно, а не над одним пользователем. Чтобы управлять параллелизмом, LinkedIn, Bing и Google начали с ручных методов (в LinkedIn команды согласовывали «диапазоны» трафика с помощью электронной почты; в Bing этим управлял менеджер программы, офис которого обычно был за-

бит людьми, выпрашивающими экспериментальный трафик; в Google все начиналось с электронной почты и обмена мгновенными сообщениями, а затем управление перешло к менеджеру программы). Однако ручные методы не масштабируются, поэтому все три компании со временем перешли к программному распределению трафика.

4.2.5. Параллельные эксперименты

Чтобы масштабировать эксперименты за пределы возможностей однослойного метода, вам необходимо перейти к какой-то системе параллельных (также называемых многослойными или перекрывающимися) экспериментов, где каждый пользователь может участвовать в нескольких экспериментах одновременно. Один из способов добиться этого – создать несколько экспериментальных слоев, каждый из которых ведет себя как однослойный метод. Чтобы обеспечить ортогональность экспериментов по уровням, при назначении пользователей сегментам добавьте идентификатор слоя. Здесь вы также можете добавить, как в описании эксперимента, описанном выше, идентификатор уровня (или какой-либо другой способ указания ограничений).

Когда поступает запрос, назначение вариантов выполняется один раз для каждого слоя (см. рис. 4.4 для примера с двумя слоями). Это означает, что и производственный код, и инструментарий должны обрабатывать вектор идентификаторов вариантов. Главный вопрос в системе параллельных экспериментов – как определить слои, и у решения есть несколько вариантов.




Рис. 4.4. Пример назначения контрольных и тестовых групп в многослойном методе

Одно из возможных решений – расширить план *полного факторного эксперимента* (full factorial experiment) до плана полной факторной плат-

формы. В полном факторном эксперименте каждая возможная комбинация факторов проверяется как отдельный вариант. Если мы расширим это до платформы, то пользователь будет участвовать во всех экспериментах одновременно: пользователю назначается вариант (контроль или любое тестовое воздействие) для каждого запущенного эксперимента. Каждый эксперимент связан с уникальным идентификатором слоя, поэтому все эксперименты ортогональны друг другу. Итерации одного и того же эксперимента обычно используют один и тот же хеш-идентификатор, чтобы обеспечить единообразие взаимодействия с пользователем. Эта простая структура параллельного экспериментирования позволяет легко децентрализованно масштабировать количество экспериментов.

Основным недостатком платформы такого типа является то, что она не позволяет избежать потенциальных конфликтов, когда определенные процедуры из двух разных экспериментов дают пользователям плохой опыт, если они случайно совпадают. Например, мы могли бы тестировать синий текст в первом эксперименте и синий фон во втором эксперименте. У любого пользователя, которому не повезло попасть в эти два эксперимента одновременно, останется ужасное впечатление, которое будет транслировано на оба результата.

С точки зрения статистики эти два эксперимента «взаимодействуют» друг с другом. Это не просто плохой пользовательский опыт. Результаты, измеренные для каждого эксперимента независимо, без учета каких-либо взаимодействий между двумя экспериментами, могут оказаться ошибочными. Обратите внимание, что не все взаимодействия являются антагонистическими – иногда участие в обоих вариантах воздействия оказывается более позитивным, чем воздействие по отдельности.

Несмотря на сказанное выше, факторная платформа может быть предпочтительнее, если снижение статистической мощности при разделении трафика перевешивает потенциальную проблему взаимодействия. Более того, если мы проведем эти эксперименты независимо, мы сможем проанализировать, какие эксперименты взаимодействуют, каковы будут их эффекты без взаимодействия. Конечно, если нет значительного взаимодействия, каждый эксперимент может быть проанализирован отдельно, и каждый получает возможность использовать весь доступный объем трафика для максимальной мощности. Экспериментальная платформа Microsoft имеет надежную систему, которая автоматизирует обнаружение взаимодействий. Чтобы предотвратить плохой пользовательский опыт, мы можем использовать либо *вложенную платформу* (nested platform), либо *платформу с границами* (constraints-based platform). Для лучшей масштабируемости Google, LinkedIn, Microsoft и Facebook используют некоторые варианты этих подходов.

Во вложенной платформе системные параметры разделены на уровни таким образом, что эксперименты, которые в сочетании могут вызвать неудовлетворительное взаимодействие с пользователем, должны находиться на одном уровне и не допускаются проектом для одного и того же пользо-

вателя. Например, может быть один уровень для общих элементов пользовательского интерфейса (например, заголовок страницы и вся информация в заголовке), другой уровень для тела страницы, третий уровень для серверных систем, четвертый уровень для параметров ранжирования и т. д.

В платформе с границами экспериментаторы указывают границы, а система использует алгоритм раскраски графа, чтобы гарантировать, что пользователю не будут представлены два соседних эксперимента, сочетание которых создает проблему. Полезным расширением платформы могут быть автоматизированные системы для обнаружения взаимодействий.

4.2.6. Анализ экспериментов

Чтобы перейти к более поздним этапам экспериментальной зрелости, нам также необходим автоматизированный анализ, имеющий решающее значение как для избавления команд от необходимости выполнять трудоемкий специальный анализ, так и для обеспечения надежности, цельности и научной обоснованности методики, лежащей в основе отчетов. Мы предполагаем, что работа по выбору цели, граничных показателей и показателей качества уже сделана, а все компромиссы в ОЕС согласованы.

Автоматизация анализа в первую очередь требует *обработки данных*, цель которой – привести данные в пригодное для использования состояние для последующего вычисления и визуализации результатов эксперимента. Поскольку обработка пользовательского запроса может выполняться в нескольких системах, обработка данных обычно включает в себя сортировку и объединение различных журналов, а также их очистку, создание сеансов и обогащение. Этот процесс иногда называют *приготовлением данных*.

Когда у вас есть обработанные данные, следующая цель состоит в том, чтобы обобщить и выделить ключевые показатели, чтобы помочь лицам, принимающим решения, принять решение о запуске обновления или отказе от запуска. Для этого требуется вычисление показателей (например, ОЕС, показатели качества, граничные показатели) по сегментам (например, страна, язык, устройство/платформа), вычисление p -значений и доверительных интервалов, а также выполнение проверок достоверности, таких как проверка SRM. Сюда также может входить анализ для автоматического определения наиболее интересных сегментов (см. главу 3). Обратите внимание, что, хотя при обработке данных все это может быть вычислено за один шаг, на практике изучая данные эксперимента, вы должны сначала выполнить проверку достоверности, прежде чем проверять ОЕС, выполнять сегментацию и делать все остальное. Более того, прежде чем вы приступите к обработке данных эксперимента, все процессы приготовления и вычисления данных также должны быть тщательно протестированы и проверены, чтобы гарантировать надежность этих процессов.

Имея результаты вычислений, мы можем наконец создать визуализацию данных, чтобы выделить ключевые показатели, а также представить инте-

ресные показатели и сегменты в простой для понимания форме. Эта визуализация может быть столь же простой, как электронная таблица в стиле Excel. Показатели представляют в виде относительных изменений с четким указанием того, являются ли результаты статистически значимыми, часто с использованием цветового кодирования, чтобы выделить значимые изменения. Для развития культуры интеллектуальной честности убедитесь, что в результатах используются общие определения, которые проверяемы и доступны, а также регулярно обсуждаются, согласовываются и обновляются.

По мере того как организация переходит в фазу активного экспериментирования, показателей может стать довольно много – даже тысячи! Это случается, когда вы группируете показатели по уровням (в масштабах компании, по конкретным продуктам, по конкретным свойствам) или по функциям (ОЕС, цель, граничные показатели, качество, отладка; см. главу 7). Множественное тестирование становится все более важным по мере роста количества показателей, и мы обнаружили, что у экспериментаторов возникает общий вопрос: почему некий показатель значительно изменился, когда он кажется несущественным?

Хотя обучение экспериментаторов играет свою роль в отборе данных, по-прежнему эффективным остается использование в инструментах пороговых значений p , меньших стандартного значения 0,05. Более низкие пороги позволяют экспериментаторам быстро переходить к наиболее значимым показателям.

Используйте инструменты визуализации для создания представлений всех результатов экспериментов по показателям, что позволяет заинтересованным сторонам внимательно следить за глобальным состоянием ключевых показателей и видеть, какие эксперименты наиболее эффективны. Такая прозрачность способствует диалогу между организаторами экспериментов и поставщиками показателей, что в свою очередь увеличивает общие знания об экспериментах в вашей компании.

Визуализация результатов – отличный способ формирования институциональной памяти, когда в компании фиксируют информацию о предмете эксперимента, причины принятия решения, а также успехи и неудачи, которые привели к открытию новых знаний и новому опыту. Например, исследуя исторические записи ранее проведенных экспериментов, вы можете провести метаанализ на предмет того, какие виды экспериментов имеют тенденцию смещать только определенные показатели, а какие показатели склонны изменяться вместе (за пределами их естественной корреляции). Мы обсудим это более подробно в главе 8. Когда к компании присоединяются новые сотрудники, визуализация данных помогает им быстро сформировать понимание, ощутить корпоративные цели и изучить процесс выдвижения гипотез. По мере развития вашей корпоративной экосистемы наличие исторических результатов и уточненных параметров позволит вам повторно провести эксперименты, которые потерпели неудачу.

ЧАСТЬ II



Избранные темы для всех

В части II представлено подробное обсуждение пяти тем, актуальных для всех, кто участвует в экспериментах, особенно для лидеров команд и администраторов.

Мы начнем с главы 5 под названием «Скорость имеет значение!», описывающей комплексный пример тщательного планирования и анализа экспериментов для определения важности задержки и быстродействия сайта как чувствительного суррогатного показателя для оценки взаимодействия с пользователем и дохода. Это также хороший пример обособленного результата, который, вероятно, применим к любым сайтам и областям деятельности.

Далее, поскольку показатели имеют решающее значение для принятия решений на основе данных в каждой компании, мы представляем вашему вниманию главу 6 «Организационные показатели». В этой главе мы обсуждаем показатели, которые руководители должны понимать, обсуждать и определять для своей организации независимо от того, проводят ли они эксперименты. Мы рассказываем о назначении этих показателей, а также о способах их создания, проверки и повторения.

По мере того как организация развивает свои методы экспериментирования, лидерам необходимо обсудить, а в идеале и согласовать метрики для экспериментов и общий критерий оценки (ОЕС). Об этом пойдет речь в главе 7. ОЕС объединяет один или несколько организационных показателей, которые соответствуют определенным критериям в контексте эксперимента. Эта комбинация используется для кодификации компромиссов между показателями, чтобы упростить контролируемые онлайн-эксперименты и стимулировать масштабные инновации.

По мере того как организация дорастает до масштабного применения экспериментов на этапе взлета и полета (см. главу 4), все более полезным становится создание институциональной памяти и метаанализа. Институциональная память фиксирует прошлые эксперименты и изменения и стимулирует инновации, способствуя развитию культуры принятия решений на основе данных и непрерывного обучения.

Наконец, контролируемые онлайн-эксперименты проводятся на реальных людях, поэтому в контролируемых экспериментах очень важны этика и соображения конечных пользователей. В главе 8 мы подчеркиваем важность этики для контролируемых онлайн-экспериментов, резюмируем ключевые важные соображения и даем ссылки на другие ресурсы по этой теме.

Глава 5

Скорость имеет значение!

Опасности медленного веб-сайта: разочарование пользователей, негативное восприятие бренда, увеличение операционных расходов и потеря дохода.

– Стив Содерс (2009)

Инженер, повышающий быстродействие сервера на 10 мс (это 1/30 скорости, с которой моргают наши глаза), с лихвой окупает свою зарплату за год. Каждая миллисекунда на счету.

– Кохави, Дэн, Фраска, Уокер, Сью и Польшманн (2013)

Быстродействие – моя любимая тема.

– Надпись на футболке Google, примерно 2009 г.

Почему это важно: мы начинаем главу с полного примера разработки (с очевидными допущениями), выполнения и интерпретации эксперимента, чтобы продемонстрировать важность скорости. Многие примеры экспериментов посвящены пользовательскому интерфейсу (UI), потому что такие изменения просты и наглядны, но есть много новаций и для бэкэнда, и, как на собственном опыте убедились несколько компаний – скорость имеет большое значение! Конечно, чем быстрее, тем лучше, но насколько важно повысить быстродействие на десятые доли секунды? Следует ли вам иметь отдельного человека, сосредоточенного на этой работе? А может, команду из пяти человек? Окупаемость инвестиций в такие усилия может быть определена количественно с помощью простого эксперимента по замедлению сайта. В 2017 году второе улучшение Bing, позволившее повысить быстродействие всего на 1/10, принесло 18 млн долл. дополнительного годового дохода, чего было достаточно для финансирования большой команды. Основываясь на этих результатах и множестве повторений в нескольких компаниях на протяжении многих лет, мы рекомендуем использовать максимальную допустимую задержку в качестве граничного показателя.

Насколько важно быстроедействие продукта? Где в продукте важно снижение задержки? Контролируемые эксперименты дают четкие ответы на эти вопросы с помощью простой, но действенной методики: экспериментов по замедлению. Замедляя работу продукта, мы можем оценить влияние увеличения задержки на ключевые показатели, включая снижение доходов и удовлетворенность пользователей. При поддающихся простой проверке умеренных предположениях мы можем показать, что улучшение производительности, т. е. уменьшение задержки, улучшает следующие показатели: доход на пользователя и удовлетворенность.

В Amazon эксперимент с замедлением на 100 мс снизил продажи на 1 %. В редком совместном докладе сотрудников из Bing и Google показано значительное влияние быстрогодействия на ключевые показатели, включая отдельные запросы, доход, клики, удовлетворенность и время до клика. Аналогичное исследование 2012 года, проведенное Bing, показало, что каждые 100 мс ускорения увеличивают доход на 0,6 %. В 2015 году, когда быстроедействие Bing ощутимо возросло, встал вопрос о том, есть ли смысл в дальнейшем повышении производительности, если сервер и так возвращает результаты менее чем за секунду на 95-м процентиле. Было проведено дополнительное исследование, и, хотя влияние на выручку несколько уменьшилось, валовая выручка Bing увеличилась настолько, что каждая миллисекунда повышения производительности значила больше, чем в прошлом: уменьшение задержки всего на четыре миллисекунды перекрывало зарплату инженера за целый год!

В статье «Почему важна производительность» (Wagner, 2019) было опубликовано несколько результатов, связанных с производительностью и свидетельствующих об улучшении конверсии и взаимодействия с пользователем, хотя многие из результатов получены не в результате контролируемых экспериментов, поэтому их результаты смешиваются с другими изменениями.

Вы можете решить, стоит ли использовать сторонний продукт для персонализации или оптимизации. Некоторые из этих продуктов требуют, чтобы вы вставляли фрагмент кода JavaScript в начало HTML-страницы. Это тормозящие фрагменты кода, которые значительно замедляют страницу, поскольку они требуют дополнительного обращения к провайдеру и передачи кода JavaScript, который обычно составляет десятки килобайт. Перемещение фрагмента в конец страницы приводит к значительному ускорению отображения этой страницы. На основании результатов эксперимента с задержкой мы можем сказать, что любое улучшение целевых показателей может быть обесценено увеличением задержки. Поэтому мы рекомендуем по возможности использовать персонализацию и оптимизацию на стороне сервера, т. е. чтобы назначение вариантов и генерация HTML для этого варианта выполнялись на сервере (см. главу 12). Наша цель – показать, как измерить влияние быстрогодействия системы на клю-

чевые показатели, а не перечислить конкретные методы повышения производительности.

Еще одним преимуществом проведения экспериментов этого типа является возможность сопоставить дельту (изменение) быстродействия с влиянием на ключевые метрики, чтобы ответить на следующие вопросы.

- Каково непосредственное влияние улучшения быстродействия на доход?
- Есть ли долгосрочное влияние (например, сокращение оттока пользователей) от улучшения быстродействия?
- Каково влияние на показатель X? Часто бывает, что первоначальная реализация новой функции оказывается неэффективной. Если A/B-тест показывает ухудшение показателя X, будет ли достаточно ускорения работы для устранения этого ухудшения? Во многих случаях новая функция немного замедляет работу веб-сайта или приложения, поэтому приходится идти на компромисс, и это сопоставление помогает принять решение.
- Где улучшение быстродействия более критично? Например, увеличенная задержка для элементов, до которых пользователю приходится прокручивать страницу (так называемый подвал страницы), как правило, менее критична. Точно так же оказались менее критичными элементы правой панели.

Чтобы провести контролируемый эксперимент, вы должны изолировать задержку как единственный переменный фактор. Очень сложно повысить быстродействие, иначе разработчики уже внесли бы эти изменения, поэтому мы прибегаем к простому приему: замедляем работу веб-сайта или продукта. Замедляя тест по сравнению с контролем, легко измерить влияние на любой показатель, но вам нужно сделать некоторые предположения.

5.1. КЛЮЧЕВОЕ ПРЕДПОЛОЖЕНИЕ: ЛОКАЛЬНАЯ ЛИНЕЙНАЯ АППРОКСИМАЦИЯ

Ключевое предположение для экспериментов по замедлению заключается в том, что график зависимости показателя (например, дохода) от быстродействия хорошо аппроксимируется прямой линией в окрестностях точки, соответствующей сегодняшней производительности. Это приближение ряда Тейлора первого порядка или *линейная аппроксимация*.

На рис. 5.1 показан график, изображающий общую взаимосвязь между временем (быстродействием) и интересующим показателем (например, коэффициентом кликов или доходом на пользователя). Как правило, чем быстрее сайт, тем лучше (в данном примере выше) значение показателя.




Рис. 5.1. Типичная связь между производительностью (временем) и интересующим показателем

Когда мы вносим замедляющее изменение, мы перемещаемся от точки, где вертикальная линия пересекает график, вправо, и можем измерить изменение показателя. Мы делаем предположение, что, если бы мы переместились влево от вертикальной линии (улучшая быстродействие), вертикальная дельта слева была бы примерно такой же, как и та, которую мы измерили справа.

Реалистично ли такое предположение? Две вещи делают это предположение обоснованным.

1. Исходя из нашего собственного опыта пользователей, чем быстрее поиск, тем лучше. Трудно придумать причины, по которым на графике могут быть разрывы или резкие изменения, особенно в районе сегодняшней точки. Если мы увеличим задержку на три секунды, можно представить себе значительный обвал, но, если прибавить или вычесть десятую долю секунды, это маловероятно.
2. Мы можем сделать выборку графика в двух точках, чтобы убедиться, что линейное приближение является разумным. В частности, Bing провел эксперимент по замедлению на 100 и 250 мс. Дельта для варианта 250 мс была приблизительно в 2,5 раза больше, чем при 100 мс (в пределах доверительных интервалов) для нескольких ключевых показателей, что подтверждает предположение о линейности.

5.2. КАК ИЗМЕРИТЬ БЫСТРОДЕЙСТВИЕ ВЕБ-САЙТА

Измерение быстродействия веб-сайта неочевидно. В этом разделе описаны некоторые сложности и предположения. Эти важные детали влияют на план вашего эксперимента. Мы углубляемся в детали, чтобы показать реальную сложность чего-то, что кажется простым; не стесняйтесь перечитывать этот раздел.

Чтобы надежно измерить задержку, серверы должны быть синхронизированы, поскольку запросы обычно обрабатываются разными серверами, и мы видели, как расхождение часов между серверами способствует проблемам с качеством данных (например, отрицательной продолжительности). Очень важно, чтобы серверы часто синхронизировали свои часы. В наших примерах время клиента и сервера не смешивается, потому что они могут находиться в разных часовых поясах (см. главу 13), а часы клиента обычно менее надежны, иногда с разницей в годы (например, когда их батарея материнской платы компьютера разряжена).

На рис. 5.2 показан запрос на глубоко оптимизированный веб-сайт, например поисковую систему. Запрос состоит из следующих шагов.

1. Пользователь делает запрос в момент времени T_0 , например набирает запрос в адресной строке браузера или в поле поиска и нажимает клавишу ввода или щелкает по изображению лупы.




Рис. 5.2. Измерение времени загрузки страницы (PLT)

2. Запросу требуется время, чтобы достичь сервера, и он поступает в момент времени T_1 . Разность $T_1 - T_0$ кажется чрезвычайно трудной для оценки, но мы можем применить хороший трюк, который объясним ниже, после списка шагов.

3. Получив запрос, сервер обычно отправляет клиенту первый фрагмент HTML в момент T2. Этот фрагмент не зависит от запроса (например, параметров запроса или URL), поэтому его можно быстро обслужить. Обычно он содержит основные элементы страницы, такие как заголовок, элементы навигации и функции JavaScript. На этом этапе полезно предоставить пользователю видимую обратную связь о том, что запрос был получен: страница обычно очищается и отображается новый заголовок с некоторыми элементами дизайна. Поскольку серверу требуется время (до момента T4), чтобы вычислить зависящую от URL-адреса часть страницы (например, запрос или параметры URL-адреса), чем больше «кода» получится отправить на данном этапе, тем быстрее будет страница, поскольку клиент и сеть обычно простаивают.
4. В момент времени T4 сервер начинает отправку остальной части страницы, что может включать дополнительные циклы передачи для других ресурсов (например, изображений).
5. В момент времени T6 браузер запускает событие Onload, сообщая, что страница готова. На этом этапе он отправляет запрос журналирования; обычно это простой запрос изображения 1×1 пиксель (маяк) или что-то подобное. Этот запрос достигает сервера в момент времени T7. Могут быть и другие действия, которые происходят после события Onload и сопровождаются дополнительной записью в журнал (например, действия пользователя, такие как прокрутка, наведение курсора и нажатие).

Время загрузки страницы (page load time, PLT), с которым сталкивается пользователь, равно разности $T_6 - T_0$, которую мы аппроксимируем, измеряя $T_7 - T_1$. Поскольку время, необходимое первоначальному запросу для достижения сервера, вероятно, будет очень похоже на время, необходимое сигналу события Onload для достижения сервера (оба являются небольшими запросами), эти две дельты, вероятно, будут очень похожи и позволят нам аппроксимировать время взаимодействия с пользователем. В более новых браузерах, поддерживающих новые стандарты W3C (World Wide Web Consortium), вызовы Navigation Timing предоставляют разнообразную информацию, связанную с PLT (см. www.w3.org/TR/navigation-timing/). Приведенные выше измерения являются более общими и хорошо совпадают с числами из W3C Navigation Timing.

5.3. СХЕМА ЭКСПЕРИМЕНТА ПО ЗАМЕДЛЕНИЮ

То, что может показаться тривиальным экспериментом, на самом деле намного сложнее. Например, возникает вопрос: куда вставить замедление? Изначально Bing замедлил отправку фрагмента 1 (рис. 5.2), но это замедление оказало слишком большое влияние и было сочтено неподходящим по следующим причинам.

1. Фрагмент 1 отправляется с сервера быстро, потому что вычислять нечего. Поэтому неразумно предполагать, что мы можем уменьшить задержку фрагмента 1.
2. Фрагмент 1 – это то, что дает пользователю обратную связь о том, что запрос был правильно получен, путем отображения нового заголовка или фона страницы. Задержка на этом этапе, влекущая за собой множество негативных последствий, не связана с общей производительностью сайта.

Правильное место для задержки – это когда сервер завершает вычисление фрагмента 2, который является URL-зависимым HTML. Вместо того чтобы немедленно отправить второй фрагмент HTML, мы задерживаем ответ, как если бы серверу потребовалось больше времени для генерации зависимой от запроса части HTML.

Насколько большой должна быть задержка? Здесь необходимо учитывать несколько факторов.

- Каждый вычисляемый показатель имеет доверительный интервал. Мы хотели бы, чтобы эффект тестового воздействия был большим, чтобы мы могли более точно оценить «наклон» графика. На рис. 5.3 показаны два возможных измерения при 100 и 250 мс по оси времени задержки. Если оба имеют одинаковый размер доверительного интервала, то измерение показателя при задержке на 250 мс дает нам гораздо более точные границы наклона. Этот фактор требует увеличения задержки.




Рис. 5.3. Доверительные интервалы для различных случаев задержки

- Более длительная задержка означает, что наша аппроксимация ряда Тейлора первого порядка может быть менее точной. Этот фактор требует уменьшения задержки.
- Длительная задержка причиняет больше вреда нашим пользователям, так как мы твердо уверены, что чем быстрее, тем лучше, и поэтому значительное замедление опыта пользователя причиняет вред. Этот фактор требует уменьшения задержки.

Второй вопрос состоит в том, является ли задержка постоянной или некоторой процентной долей от общего времени ответа на запрос, поскольку существуют географические сетевые различия (например, пользователи Bing в Южной Африке сталкиваются с очень медленной загрузкой страниц, поэтому задержка в 250 мс может показаться им не такой уж большой). Учитывая, что эксперимент моделирует задержку на стороне сервера, мы считаем, что правильным выбором будет постоянная задержка. Если бы мы хотели смоделировать воздействие, связанное с различиями в сети, тогда эксперимент мог бы основываться, например, на размере полезной нагрузки, а не на задержке.

Наконец, возникает вопрос, что важнее – ускорение на первой или последующих страницах сеанса. Некоторые методы ускорения (например, кеширование JavaScript) могут улучшить производительность последующих страниц в сеансе.

Учитывая вышеуказанные факторы, Bing сочла разумным выбором замедление на 100 и 250 мс.

5.4. ВЛИЯНИЕ РАЗЛИЧНЫХ ЭЛЕМЕНТОВ СТРАНИЦЫ

Быстродействие разных областей страницы различается. Скорость отображения результатов алгоритмического поиска Bing была критическим фактором, а замедление существенно повлияло на важнейшие показатели, такие как доход и ключевые показатели пользователей.

А как насчет других областей страницы? Оказывается, они гораздо менее критичны. В Bing некоторые элементы на правой панели загружаются поздно (технически после события `window.onload`). Был проведен эксперимент с контролируемым замедлением, подобный описанному выше, с задержкой отображения элементов правой панели на 250 мс. В итоге не обнаружено статистически значимого влияния на ключевые показатели, несмотря на то что в эксперименте участвовало почти 20 млн пользователей.

PLT часто измеряется с помощью события `window.onload`, чтобы отметить конец полезной активности браузера, а не всей описанной выше последовательности. Однако это измерение имеет серьезные недостатки с современными веб-страницами. Как показал Стив Содерс (2013), страница Amazon может отображаться за 2,0 с до нижней границы экрана, т. е. в видимой части страницы, но событие `window.onload` срабатывает лишь через 5,2 с. Шурман и Брутлаг (2009) сообщили, что помогает возможность постепенно отображать страницу так, чтобы ее заголовок отображался раньше. В качестве наглядного обратного примера можно привести Gmail: событие `window.onload` происходит через 3,3 с, после чего отображается только индикатор выполнения, а верхнее содержимое страницы отображается через 4,8 с.

Интуитивное представление о том, что пользователи начинают интерпретировать страницу как завершенную, как только она отображается в достаточном объеме, часто обозначают термином *воспринимаемое быстродействие*. Однако концепцию воспринимаемого быстродействия легче сформулировать абстрактно, чем измерить на практике, а добавление

метода `perception.ready()` не входит в план развития какого-либо браузера. Для оценки воспринимаемого быстродействия было предложено несколько критериев, в том числе:

- **время до первого результата.** Когда отображается список, например в Twitter, возможный показатель – время до появления первого твита;
- **до нижней границы экрана** (above the fold time, AFT). Вы можете измерить время, пока не будут прорисованы все пиксели в видимой части экрана. Реализации этого подхода должны использовать эвристику для обработки видео, анимированных GIF-файлов, вращающихся галерей и другого динамического содержимого, которое изменяет верхнюю часть страницы. Можно установить пороговые значения «процента прорисованных пикселей», чтобы избежать увеличения измеренного времени из-за незначительных элементов;
- **индекс скорости.** Это обобщение AFT, которое усредняет время отображения видимых элементов на странице. Оно не зависит от того, что малозначащие элементы отображаются позже, но все же страдает от динамического изменения содержимого в видимой области;
- **время фазы страницы и время готовности пользователя.** *Время фазы страницы* (page phase time) требует определения того, какая фаза рендеринга соответствует воспринимаемому быстродействию, а фазы определяются скоростью изменения пикселей. *Время готовности пользователя* (user ready time) измеряет время, пока основные элементы страницы (свои для каждого контекста) не будут готовы к использованию.

Один из способов избежать неоднозначности определения воспринимаемого быстродействия – это измерить время, затрачиваемое пользователем на действие, такое как щелчок. Этот метод хорошо работает, когда от пользователя ожидается действие. Более сложный вариант времени до щелчка – это время до успешного щелчка, где успех можно определить как щелчок, который не приводит к тому, что пользователь возвращается в течение 30 с, что позволяет отфильтровать щелчки по ссылкам-приманкам (кликбейт). Такие показатели не отягощены эвристикой, необходимой для многих показателей быстродействия, и устойчивы ко многим изменениям. Основная проблема с такими показателями заключается в том, что они работают только тогда, когда ожидается действие. Если пользователь задает запрос «время в Париже» и мгновенно получает хороший ответ, нажимать не на что.

5.5. ЭКСТРЕМАЛЬНЫЕ РЕЗУЛЬТАТЫ

Хотя скорость имеет большое значение, мы также получили некоторые результаты, которые считаем завышенными. В своем выступлении по Web 2.0 Марисса Майер, работавшая тогда в Google, описала эксперимент, в кото-

ром Google увеличил количество результатов поиска на странице результатов с 10 до 30. Она утверждала, что трафик и доход от поисковиков Google в экспериментальной группе упали на 20 %. Ее объяснение? На создание страницы ушло еще полсекунды. Производительность является критическим фактором, но было изменено несколько факторов, и мы подозреваем, что на быстродействие в этом примере приходится лишь небольшой процент потерь.

И наоборот, Дэн МакКинли, в 2012 году работавший на Etsy, утверждал, что задержка в 200 мс не имеет никакого значения. Возможно, для пользователей Etsy быстродействие действительно не имеет решающего значения, но мы полагаем, что более вероятная гипотеза заключается в том, что эксперимент не обладал достаточной статистической мощностью для обнаружения различий. Уверенность организации о том, что быстродействие не имеет значения, очень быстро замедлит работу сайта до такой степени, что пользователи массово начнут покидать его.

Наконец, в редких случаях слишком быстрое выполнение запроса может снизить доверие пользователей к выполнению определенных действий, поэтому в некоторых продуктах добавляются фальшивые индикаторы выполнения.

Изучая результаты экспериментов, спросите себя, какой уровень доверия они заслуживают, и помните, что даже если идея сработала для определенного сайта, она может не сработать для другого. Единственное, что вы можете сделать, – это проверить повторяемость предыдущих экспериментов (успешных или нет). Именно так и работает наука.

Глава 6

Организационные показатели

Если вы не можете это измерить, вы не можете это улучшить.

– Питер Друкер (перефразируя лорда Кельвина)

Арбузный показатель: команды думают, что они отлично справляются с задачей получения зеленого шара, однако клиенты смотрят на это иначе и хотят только красную мякоть.

– Барклай Рэй (2014)

При оптимизации с целью развития мы часто встречаем клиентов, пытающихся повысить мощность двигателя, игнорируя проколотое колесо.

– Брайан Айзенберг и Джон Куарто фон Тивадар (2008)

Почему это важно: организациям, которые хотят измерить свой прогресс и подотчетность, нужны правильные показатели. Например, одним из популярных способов управления организацией является использование целей и ключевых результатов (*objectives and key results, OKR*), где цель является долгосрочной, а ключевые результаты – это краткосрочные измеримые достижения, короткие шаги по направлению к цели. При использовании системы OKR качественные показатели являются ключом к отслеживанию прогресса в достижении этих целей. Знание различных типов организационных показателей, важных критериев, которым должны соответствовать эти показатели, способов их создания и оценки, а также необходимости итераций с течением времени помогает сформировать понимание, необходимое для принятия решений на основе данных, независимо от того, проводите ли вы эксперименты.

6.1. Таксономия показателей

В организации, управляемой данными, показатели и сопутствующие анализы данных могут использоваться на всех уровнях – от постановки целей на уровне организации до рабочих команд. Обсуждение того, какими должны быть показатели для организации и команды, полезно для согласования

целей и, следовательно, обеспечения прозрачности и подотчетности при достижении этих целей. В этом разделе основное внимание уделяется организационным показателям в целом, в то время как в главе 7 обсуждаются показатели, специфичные для экспериментов, а в главе 21 раскрывается роль контрольных показателей для оповещения в экспериментах.

При обсуждении организационных показателей обычно используется следующая таксономия: *цели, движущие силы и ограничения*. Эта таксономия полезна независимо от того, говорим ли мы об организации, которая представляет собой целую компанию, или о конкретной команде в более крупной организации.

Целевые показатели (goal metric), также называемые *метриками успеха* (success metric) или *показателем истинного севера* (true north metric), отражают то, что в конечном итоге волнует организацию. Когда вы пытаетесь придумать показатель цели, мы рекомендуем сначала сформулировать то, что вы хотите, простыми словами. Почему существует ваш продукт? Как выглядит успех вашей организации? На эти вопросы должны ответить руководители организации, и ответы часто связаны с заявлением о миссии. Например, если миссия Microsoft состоит в том, чтобы дать возможность каждому человеку и каждой организации на планете достичь большего, или миссия Google состоит в организации мировой информации, то их цели часто напрямую связаны с этими миссиями.

Умение сформулировать свою цель словами важно, поскольку преобразование этой цели в показатели часто бывает несовершенным, а ваши целевые показатели могут отражать то, что вас действительно волнует, и требовать уточнения с течением времени. Понимание людьми ограничений и различий между показателями и формулировкой цели имеет решающее значение для движения бизнеса в правильном направлении. Показатели цели обычно представляют собой единичный или очень небольшой набор показателей, который лучше всего отражает конечный успех, к которому вы стремитесь. Эти показатели иногда очень трудно улучшить в краткосрочной перспективе, потому что каждая отдельная инициатива может очень слабо влиять на показатель или материализация изменений занимает много времени.

Показатели движущей силы (driver metric), также называемые *метрикой дорожного указателя* (sign post metric), *суррогатными показателями* (surrogate metric), *косвенными* (indirect) или *прогнозирующими показателями* (predictive metrics), как правило, являются более краткосрочными, более быстрыми и более чувствительными, чем целевые показатели. Показатели движущей силы отражают ментальную причинно-следственную модель того, что требуется для успеха организации, т. е. гипотезы о факторах успеха, а не то, как выглядит успех.

Существует несколько полезных систем показателей для размышлений о том, что движет успехом: методика HEART (happiness, engagement,

adoption, retention, task success – счастье, вовлеченность, принятие, удержание и успех задачи), методика PIRATE Дэйва МакКлюра (известная так же как AARRR! – Acquisition, Activation, Retention, Referral, Revenue – приобретение, активация, удержание, рефералы, доход) или пользовательские наборы показателей. Эти рамки помогают выделить шаги, ведущие к успеху. Например, прежде чем в конечном итоге получить прибыль, типичная компания должна привлечь пользователей и убедиться, что продукт достаточно интересен, чтобы удерживать их.

Хорошие показатели движущей силы указывают на то, что мы движемся в правильном направлении, чтобы улучшить целевые показатели.

Ограничительные показатели (guardrail metric) защищают от ошибочных гипотез и бывают двух типов: показатели, защищающие бизнес, и показатели, оценивающие надежность и внутреннюю достоверность результатов экспериментов. В этой главе мы обсудим первый тип ограничительных показателей, в то время как предельные показатели надежности экспериментов обсуждаются в главе 21.

В то время как наши взоры обычно прикованы к показателям движущей силы и близости к цели, ограничительные показатели важны для того, чтобы мы двигались к успеху с правильным балансом усилий и без нарушения важных ограничений. Например, наша цель может заключаться в том, чтобы зарегистрировать как можно больше пользователей, но мы не хотим, чтобы уровень вовлеченности каждого пользователя резко упал. Другой пример – компания по управлению паролями. Ей приходится искать компромисс между безопасностью (отсутствие утечки или кражи информации), простотой использования и доступностью (т. е. как часто пользователи блокируются в результате ошибки). В данном случае безопасность является очевидной целью, а показатели простоты использования и доступности могут служить заградительными показателями. Наконец, хотя время загрузки страницы может и не быть целевым показателем, нам все же нужно убедиться, что запуск нововведения не приводит к снижению времени загрузки (см. главу 5). Заградительные показатели часто более чувствительны, чем показатели движущей силы или целевые показатели. В главе 21 мы рассматриваем дополнительные примеры заградительных показателей.

Хотя мы считаем, что упомянутые показатели обеспечивают необходимую степень детализации и полноты, существуют и другие таксономии бизнес-показателей:

- **показатели активов и вовлеченности:** *показатели активов* измеряют накопление статических активов, таких как общее количество пользователей (учетных записей) Facebook или общее количество подключений. *Показатели вовлеченности* измеряют ценность, которую получает пользователь в результате своего действия или действий других пользователей, использующих продукт, например в течение сеанса или просмотра страницы;

- **бизнес-метрики и операционные показатели:** бизнес-метрики, такие как выручка на пользователя или количество активных пользователей в день, отслеживают состояние бизнеса. Операционные показатели, такие как количество запросов в секунду, позволяют отслеживать, есть ли технические проблемы в работе.

Кроме показателей для экспериментов, которые мы обсудим далее в главе 7, существуют и другие типы показателей, также применяемые в экспериментах. **Показатели качества данных** обеспечивают внутреннюю достоверность и надежность базовых экспериментов (см. также главы 3 и 21). **Диагностические или отладочные показатели** полезны при отладке сценария, в котором целевые показатели, показатели движущей силы или ограничительные показатели указывают на наличие проблемы. Они могут обеспечить дополнительную детализацию или другую информацию, которая обычно слишком подробна для отслеживания на постоянной основе, но полезна при детализации ситуации. Например, если ключевым показателем является рейтинг кликов (CTR), у вас может быть 20 диагностических показателей, указывающих на клики в определенных областях страницы. Или, если ключевым показателем является выручка, вы можете разделить его на две части: индикатор выручки, имеющий логическое значение (0/1) и указывающий, совершал ли пользователь покупку; и показатель условного дохода, который отражает доход, если пользователь совершил покупку, и имеет значение null в противном случае (при усреднении учитывается только доход от покупающих пользователей). Средний общий доход – это следствие из этих двух показателей, но каждый из них рассказывает нам разную историю о доходе. Как себя ведет доход – увеличился/уменьшился из-за того, что товар покупают больше/меньше людей, или из-за изменения средней цены товара?

Независимо от используемой таксономии обсуждение показателей всегда идет на пользу, так как согласование показателей требует наличия четко сформулированных и согласованных целей. Эти показатели могут впоследствии использоваться для постановки целей на уровне компании, уровне команды, на уровне функций или на индивидуальном уровне, а также использоваться для всего – от отчетов руководителей до мониторинга инженерных систем. Также ожидается итерация метрик с течением времени, как по мере развития организации, так и по мере развития понимания метрик.

Нам часто необходимо измерять цели, движущие силы и препятствия как на уровне компании, так и на уровне команды. Каждая команда, вероятно, по-своему вносит свой вклад в общий успех компании. Некоторые команды могут быть более сосредоточены на внедрении, другие на удовлетворенности клиента, третьи на удержании, быстродействии или задержке. Каждая команда должна сформулировать свою цель и гипотезу о том, как их показатели соотносятся с общими показателями компании. Один и тот же показатель может играть разную роль для разных команд. Некоторые

команды могут использовать задержку или другие показатели быстрого действия в качестве ограничительного параметра, в то время как команда инфраструктуры может использовать те же самые показатели задержки или производительности в качестве своей целевой метрики и использовать другие бизнес-метрики в качестве своих ограничительных параметров.

Например, предположим, что вы работаете над продуктом, в котором общим целевым показателем является долгосрочный доход, а определяющими показателями на бизнес-уровне являются вовлеченность и удержание пользователей. Теперь у вас есть команда, которая работает над сайтом поддержки для этого продукта. Эта команда попыталась установить «время пребывания на сайте» в качестве ключевого показателя для улучшения, но, если пользователь проводит больше времени на сайте – это хорошо или плохо? Подобные обсуждения полезны для понимания и согласования показателей на каждом уровне компании. Парменер (Parmenter) в своей работе «Ключевые показатели эффективности» (2015) использует диаграмму, показанную на рис. 6.1, чтобы подчеркнуть важность согласования показателей целей и движущих сил с вашей общей бизнес-стратегией.

В зависимости от размера и целей организации у вас может быть несколько команд, каждая со своими целями, движущими силами и заградительными показателями, и все они должны соответствовать вашей общей цели, общим движущим силам и заградительным показателям.



Рис. 6.1. Важно привести показатели каждой команды в соответствие с общей целью и стратегическим направлением

6.2. ВЫРАБОТКА ПОКАЗАТЕЛЕЙ: ПРИНЦИПЫ И МЕТОДЫ

Теперь, когда вы на словах изложили, как выглядят успех и возможные движущие силы развития, давайте приступим к выработке показателей. На этом этапе мы переводим качественную концепцию в конкретное количественное определение. В некоторых случаях, например при учете дохода, ответ может быть очевиден. Однако компания может считать показателем успеха долгосрочный доход, который труднее измерить, чем доход, полученный сегодня. К другим сложным для измерения концепциям успеха относятся удовлетворенность пользователей и их доверие.

Ключевые принципы при выработке целевых показателей и показателей движущих сил – следующие.

1. Убедитесь, что ваши целевые показатели:
 - ♦ **простые:** понятны и широко приняты заинтересованными сторонами;
 - ♦ **стабильные:** нет необходимости обновлять целевые показатели каждый раз, когда вы запускаете обновление.
2. Убедитесь, что показатели движущих сил:
 - ♦ **согласованы с целью:** важно подтвердить, что показатели движущих сил действительно отражают движение по направлению к успеху. Один из распространенных методов проверки – это проведение экспериментов специально для этой цели. Мы обсудим это ниже;
 - ♦ **практичны и актуальны:** команды должны чувствовать, что они могут использовать рычаги воздействия (например, функции продукта) для изменения этих показателей;
 - ♦ **чувствительны:** показатели движущих сил являются базовыми индикаторами целевых показателей. Убедитесь, что они достаточно чувствительны, чтобы измерить влияние большинства обновлений;
 - ♦ **устойчивые к манипуляциям.** Поскольку показатели движущих сил и целевые показатели фактически измеряют успех, постарайтесь защитить их от манипуляций. Подумайте о стимулах и о том, какое поведение может вызывать показатель и как его можно подтасовать (см. также врезку «Манипуляция параметрами» далее в этой главе).

Исходя из упомянутых выше принципов мы предлагаем несколько полезных методов и рекомендаций по выработке показателей.

- Используйте гипотезы из менее масштабируемых методов для генерации идей, а затем проверяйте их в масштабируемом анализе данных для уточнения формулировки (см. главу 10). Например, удовлетворенность пользователей или успех пользовательских задач могут быть напрямую измерены только с помощью опросов пользователей, а методология этого метода не масштабируется. Однако мы можем проводить опросы или исследования пользовательского опыта (см. главу 10), чтобы отслеживать модели поведения, которые обычно коррелируют с успехом и счастьем. Вы можете изучить эти модели поведения с помощью масштабного анализа данных онлайн-журналов, чтобы определить, работают ли эти показатели как метрики высокого уровня. Одним из конкретных примеров является показатель отказов, который представляет собой долю пользователей, которые остаются на веб-сайте лишь на короткое время. Мы можем заметить, что непродолжительное пребывание коррелирует с неудовлетворенностью. Сочетание этого наблюдения с анализом данных помогает определить точный порог (должен ли порог составлять 1 просмотр страницы? 20 секунд?), необходимый для точного определения показателя.

- Учитывайте *качество* при определении целевых показателей или показателей движущих сил. Клик по результату поиска считается «плохим» кликом, если пользователь сразу нажимает кнопку «Назад»; регистрация нового пользователя является «хорошей» регистрацией, если пользователь активно взаимодействует с сайтом; профиль LinkedIn является «хорошим» профилем, если он содержит достаточно информации для представления пользователя, такой как история образования или текущие и прошлые должности. Встраивание концепции качества, такой как человеческая оценка (см. главу 10), в ваши показатели цели и движущих сил поможет уточнить интерпретацию показателей, на основе которых принимают решения.
- При включении статистических моделей в определение показателя важно, чтобы модель была интерпретируемой и подтверждаемой с течением времени. Например, для измерения долгосрочного дохода от подписки обычно вычисляют *жизненную ценность* (lifetime value, LTV) на основе прогнозируемой вероятности выживания клиента. Однако, если функция выживания слишком сложна, может быть сложно заручиться поддержкой заинтересованных сторон, а еще сложнее будет, если придется расследовать внезапное падение показателя. Другим примером является Netflix, использующий в качестве показателей часы просмотра с разбивкой по шкале, поскольку они интерпретируемы и отражают долгосрочное удержание пользователей.
- Иногда бывает проще точно измерить то, чего вы не хотите, например неудовлетворенность или недовольство пользователя, чем измерить то, чего вы хотите. Например, как долго пользователь должен оставаться на сайте, чтобы считаться «удовлетворенным»? На сайтах с конкретными задачами, таких как поисковые системы, короткое посещение сайта, предложенного в результатах поиска, чаще коррелирует с недовольством пользователя, чем длительное посещение. И тем не менее не все так однозначно – длительное посещение необязательно означает, что пользователь нашел то, что ему нужно. Возможно, он из всех сил пытается извлечь из предложенного сайта что-нибудь полезное и на самом деле разочаровывается. Следовательно, отрицательные показатели по своему полезны в качестве контрольных или отладочных показателей.
- Всегда помните, что показатели сами по себе являются косвенными свидетельствами; у каждого есть свой набор неподходящих случаев. Например, поисковая система хочет использовать CTR для измерения взаимодействия с пользователем, но использование только CTR может привести к увеличению количества кликов. В таких случаях необходимо создать дополнительные показатели для измерения крайних случаев. В этом примере один из путей решения – использовать человеческую оценку (см. главу 10) в качестве метрики для измерения релевантности и уравнивания склонности к вознаграждению кликбейта.

6.3. ОЦЕНКА ПОКАЗАТЕЛЕЙ

Мы выделили несколько принципов, которым нужно следовать при разработке показателей. Большая часть оценки и проверки показателей происходит на этапе выработки, но есть работа, которую нужно регулярно выполнять в течение длительного времени. Например, прежде чем добавлять новый показатель, оцените, предоставляет ли он дополнительную информацию по сравнению с вашими существующими показателями. Показатели жизненного цикла клиента должны пересматриваться с течением времени, чтобы ошибки прогнозов оставались небольшими. Показатели, имеющие большое значение для экспериментов, должны периодически рассматриваться на предмет того, поощряют ли они намеренную манипуляцию (т. е. вызывает ли пороговое значение, используемое в определении показателя, желание преднамеренно переместить результат через этот порог).

Одна из наиболее распространенных и сложных оценок – установление причинно-следственной связи между показателями движущих сил и целевыми показателями организации, т. е. тем, действительно ли изменения движущих сил влияют на целевые показатели. Рассуждая о коммерческих организациях, Каплан и Нортон писали: «В конечном итоге причинно-следственные связи всех показателей в оценочной карте должны быть связаны с финансовыми целями». Хаузер и Кац пишут: «Фирма должна определить показатели, на которые команда может повлиять сегодня, но которые в конечном итоге повлияют на долгосрочные цели фирмы». Спитцер пояснял, что «схемы измерения изначально состоят из гипотез (допущений) о ключевых показателях и их причинно-следственных связях. Затем эти гипотезы проверяются на реальных данных, и их можно подтвердить, опровергнуть или изменить». Подобные оценки даются труднее всего, поскольку мы часто не знаем лежащую в основе истинную причинную модель, а просто имеем гипотетическую ментальную причинную модель.

Вот несколько обобщенных подходов к проверке причинно-следственной связи, которые вы также можете применить и для другой оценки показателей:

- используйте альтернативные источники данных, такие как опросы, фокус-группы или исследования пользовательского опыта, чтобы проверить, все ли они указывают в одном направлении;
- анализируйте данные наблюдений. Хотя трудно установить причинно-следственные связи с данными наблюдений (об этом пойдет речь в главе 11), тщательно проведенное наблюдение иногда помогает опровергнуть гипотезы;
- посмотрите, проводится ли аналогичная проверка в других компаниях. Например, несколько компаний поделились исследованиями, показывающими, как скорость сайта влияет на доход и вовлеченность пользователей (см. главу 5). Другой пример – исследования, которые показывают влияние размера приложения на его загрузку;

- проведите эксперимент, основной целью которого является оценка показателей. Например, чтобы определить, увеличивает ли программа лояльности клиентов удержание клиентов и, следовательно, жизненный цикл клиента, запустите эксперименты, которые медленно развертывают программу лояльности клиентов, и измерьте удержание и жизненный цикл клиента. Мы предупреждаем, что эти эксперименты часто проверяют относительно узкую гипотезу, поэтому для обобщения результатов все еще требуется работа;
- используйте совокупность исторических экспериментов в качестве «золотых» образцов для оценки новых показателей. Важно, чтобы эти эксперименты были понятны и заслуживали доверия. Мы можем использовать эти исторические эксперименты для проверки чувствительности и причинно-следственной связи.

Обратите внимание, что проблема соотнесения показателей движущих сил с целевыми показателями также относится к заградительным показателям. Вспомните наш пример в главе 5 о том, как провести эксперимент для измерения влияния задержки (контрольного показателя) на целевые показатели.

6.4. РАЗВИВАЮЩИЕСЯ ПОКАЗАТЕЛИ

Определения показателей со временем развиваются. Даже если концепция останется прежней, точное определение все равно может измениться. Изменения случаются, потому что:

- бизнес развивается: бизнес мог расти и создавать новые направления. Это может привести к смещению акцента в бизнесе, например к переходу от внедрения к вовлечению и удержанию. Следует выделить один конкретный тип эволюции – это изменение базы пользователей. При расчете показателей или проведении экспериментов обратите внимание, что все эти данные поступают из существующей базы пользователей. Первые пользователи, особенно для продуктов на ранней стадии или стартапов, могут не соответствовать той пользовательской базе, которую бизнес желает иметь в долгосрочной перспективе;
- среда развивается: возможно, изменилась конкурентная среда, больше пользователей знает о проблемах конфиденциальности, или могут вступить в силу новые правительственные политики. Все эти изменения могут сместить фокус или перспективу бизнеса и, следовательно, то, что вы измеряете с помощью показателей;
- ваше понимание показателей эволюционирует: даже для показателей, которые вы тщательно оценивали на этапе разработки, при наблюдении за их производительностью в действии (например, в поисках удобства игры) вы можете обнаружить возможности улучшения, которые приводят к большей детализации или другим формулиров-

кам. Хаббард предложил концепцию *ожидаемой ценности информации* (expected value of information, EVI), отражающую, как дополнительная информация помогает вам принимать решения. Затраты времени и усилий на исследование и изменение существующих показателей имеют высокий EVI. Недостаточно быть гибким и измерять, вы должны убедиться, что ваши показатели ведут вас в правильном направлении.

Некоторые показатели могут меняться быстрее, чем другие. Например, показатели движущих сил, границ и качества данных могут развиваться быстрее, чем целевые показатели, часто потому, что они определяются улучшением методологии, а не фундаментальными изменениями бизнеса или окружающей среды.

Поскольку показатели со временем будут развиваться, вам следует совершенствовать процесс обработки изменений показателей по мере роста вашей организации. В частности, вам понадобится инфраструктура для оценки новых показателей и связанных с этим изменений в схемах экспериментов, получения необходимых данных и т. д.

6.5. ДОПОЛНИТЕЛЬНОЕ ЧТЕНИЕ

Существует несколько замечательных книг о показателях, измерениях и индикаторах эффективности (Spitzer 2007, Parmenter 2015, McChesney, Covey and Huling 2012). Спитцер отмечает: «Что делает измерение таким мощным, так это его способность побуждать к осознанным действиям – давать людям возможность вести себя правильным образом в нужное время». В контексте контролируемых экспериментов, поскольку изменение является *причиной* воздействия на каждый показатель (с высокой вероятностью для статистически значимых эффектов), формулировка ключевых показателей представляет собой методику оценки ценности идеи (изменения) в многомерном пространстве полезности.

6.6. ПРИМЕЧАНИЕ: ОГРАНИЧИТЕЛЬНЫЕ ПОКАЗАТЕЛИ

Существует два типа ограничительных показателей: ограничения, связанные с надежностью, и организационные ограничения. Показатели, связанные с надежностью, подробно обсуждаются в главе 21, так как они необходимы для обеспечения достоверности результатов экспериментов. Здесь мы обсуждаем показатели организационных ограничений.

Как мы говорили в главе 5, увеличение задержки даже на несколько миллисекунд может привести к потере доходов и снижению удовлетворенности пользователей. Задержка часто используется в качестве экспериментального воздействия, поскольку она дает очень выражен-

ный эффект, особенно в отношении показателей доходов и удовлетворенности пользователей. Большинство команд обычно работает над обновлениями, которые должны улучшить целевые показатели или движущие силы, но при этом они проверяют задержку и стараются убедиться, что эти изменения не увеличивают задержку. Если это так, то приходится искать компромисс, например обдумывать, перекрывает ли польза от новой функции побочное увеличение задержки, есть ли способы смягчить это увеличение, или есть способы компенсировать издержки обновления с помощью других доработок, улучшающих (уменьшающих) задержку.

Многие контрольные показатели организации в этом смысле похожи на задержку – они представляют собой чувствительные показатели, которые измеряют явления, влияющие на целевые показатели, но при этом сами не должны быть подвержены влиянию изменений. К мерам таких показателей относятся следующие.

1. Размер ответного HTML-кода страницы. На веб-сайте увеличение размера ответа сервера является ранним признаком того, что был добавлен большой объем кода (например, JavaScript). Оповещение о таком изменении – отличный способ обнаружить, возможно, небрежный фрагмент кода, который можно оптимизировать.
2. Ошибки JavaScript на странице. Ухудшение (т. е. увеличение) среднего количества ошибок на странице является серьезной проблемой. Сегментация по браузерам помогает определить, зависит ли проблема JavaScript от браузера.
3. Доход на пользователя. Команда, которая работает над одной частью продукта, например над повышением релевантности, может не осознавать, что она снижает прибыль. Доход на пользователя обычно имеет высокую статистическую дисперсию, поэтому он не подходит в качестве чувствительного ограничения; отличной альтернативой могут быть более чувствительные варианты, например индикатор наличия дохода от пользователя (был ли доход от конкретного пользователя: да/нет), ограничение дохода на пользователя (все, что превышает X долл., ограничивается до X долл.) и доход на страницу (хотя необходимо соблюдать осторожность, чтобы правильно вычислить дисперсию, см. главу 22).
4. Просмотры страниц на пользователя. Поскольку многие показатели измеряются постранично (например, CTR), изменение количества просмотров страниц на пользователя может означать, что изменились многие показатели. Было бы естественно сосредоточиться на числителе, но, если количество просмотров

страниц на пользователя меняется, изменяется и знаменатель, что требует размышлений. Если изменение является неожиданным, стоит внимательно изучить причины. Обратите внимание, что количество просмотров страниц на пользователя не во всех случаях может служить ограничительным показателем; например, если вы тестируете функцию бесконечной прокрутки, то количество просмотров страниц на пользователя почти наверняка изменится.

5. Сбои на стороне клиента. Для клиентского программного обеспечения (например, Office Word/PowerPoint/Excel, Adobe Reader) или приложений для телефона (например, Facebook, LinkedIn, Minecraft, Netflix) частота сбоев является критически важным показателем. В дополнение к числовому показателю (количество сбоев на пользователя) обычно используется индикатор (произошел ли сбой приложения во время эксперимента, да/нет), который усредняется по всем пользователям, поскольку индикаторы имеют меньшую дисперсию и демонстрируют статистическую значимость раньше.

Разные команды могут менять местами показатели цели, движущих сил и ограничений. Например, в то время как большинство команд могут использовать канонические показатели, команда инфраструктуры может использовать в качестве своей цели показатели быстродействия или организационных ограничений (и использовать показатели цели и движущих сил в качестве ограничений). Как и в случае с показателями движущих сил, важно установить причинно-следственную связь между контрольными и целевыми показателями, как это было сделано в главе 5.

6.7. ПРИМЕЧАНИЕ: ПРЕДНАМЕРЕННАЯ МАНИПУЛЯЦИЯ ПОКАЗАТЕЛЯМИ

Вы должны ограничить возможность преднамеренной манипуляции важными показателями: когда задана числовая цель, люди могут быть довольно изобретательными в ее достижении, особенно когда успех сопровождается вознаграждением. В истории есть множество примеров:

- Василий Алексеев, известный российский тяжелоатлет в супертяжелом весе, получал материальное вознаграждение за каждый мировой рекорд, который он побил. В результате он начал бить мировые рекорды по грамму или два за раз, чтобы максимизировать выплату вознаграждения (Spitzer 2007);

- менеджер ресторана быстрого питания стремился получить награду за достижение идеальных 100 % по критерию «эффективности курицы» (отношение количества проданных кусков курицы к количеству выброшенных). Он добился этого, дожидаясь заказа на жареную курицу, прежде чем начать готовить ее. Он получил награду, но обанкротил ресторан из-за недовольства клиентов долгим ожиданием (Spitzer 2007);
- компания выплачивала бонусы персоналу центрального склада запасных частей за поддержание низкого уровня запасов. В результате на складе не было необходимых запасных частей, и работу приходилось останавливать до тех пор, пока детали не будут заказаны и доставлены (Spitzer 2007);
- руководители больницы в Соединенном Королевстве были обеспокоены тем, сколько времени уходит на лечение пациентов в отделении неотложной помощи. Они решили измерить время от регистрации пациента до приема у лечащего врача. Поэтому медперсонал начал просить фельдшеров оставлять своих пациентов в машине скорой помощи до тех пор, пока их не осмотрит лечащий врач, что позволило сократить «среднее время, необходимое для лечения пациентов» (Parmenter 2015);
- в Ханое, во времена французского колониального правления, программа по выплате вознаграждения за каждый сданный крысиный хвост была предназначена для истребления крыс. Вместо этого она привела к выращиванию крыс (Vann 2003). Подобный пример, хотя, вероятно, анекдотический, упоминается в отношении кобр, когда правительство (вероятно, британское) предложило награду за каждую мертвую кобру в Дели, а предприимчивые люди начали разводить кобр для получения дохода;
- между 1945 и 1960 годами федеральное правительство Канады платило всего 70 центов в день на обитателя сиротского приюта, в то время как психиатрические больницы получали 2,25 долл. в день на каждого пациента. Утверждается, что до 20 000 детей-сирот были ложно признаны психически больными, чтобы католическая церковь могла получать 2,25 долл. в день на одного пациента;
- финансирование пожарных подразделений по количеству сделанных пожарных вызовов предназначено для поощрения подразделений, которые выполняют больше всего работы. Однако они могут утратить интерес к мероприятиям, уменьшающим количество пожаров.

Хотя эти примеры показывают важность тщательного выбора показателей, как это применимо в онлайн-сфере? Один из распространен-

ных сценариев – использование краткосрочной выручки в качестве ключевого показателя. Тем не менее вы можете увеличить краткосрочные доходы, повышая цены или заваливая веб-сайт рекламой, и любой из этих факторов, скорее всего, приведет к тому, что пользователи покинут сайт, а LTV клиентов снизится. LTV клиента – полезный руководящий принцип при рассмотрении показателей. В более общем плане можно манипулировать многими неограниченными показателями. Показатель, который измеряет доход от рекламы на строго ограниченном пространстве страницы или учитывает ее релевантность, обеспечивает гораздо более высокое качество обслуживания пользователей. Если нет ограничений по качеству, то можно с легкостью манипулировать количеством запросов, не возвращающих результаты, потому что всегда можно выдать кучу бесполезных результатов поиска и назвать это успехом.

Как правило, мы рекомендуем использовать показатели, которые измеряют ценность и действия пользователя. Вам следует избегать показателей тщеславия, которые указывают на количество ваших действий, безразличных для пользователя (количество показов рекламных баннеров – это типичный показатель тщеславия, тогда как клики по объявлениям указывают на потенциальный интерес пользователей). В Facebook создание пользовательских лайков является примером функции пользовательского интерфейса, которая фиксирует действия пользователя и является фундаментальной частью взаимодействия с пользователем.

Глава 7

Показатели экспериментов и общий критерий оценки

Скажи мне, как ты меня измеришь, и я скажу тебе, как я буду себя вести.
– Элияху М. Голдратт (1990)

Первое правило состоит в том, что хоть какое-то измерение – лучше, чем ничего. Но эффективный показатель будет отражать результат работы, а не просто сопутствующую деятельность. Очевидно, что вы оцениваете продавца по заказам, которые он получает (результат), а не по звонкам, которые он делает (деятельность).

– Эндрю С. Гроув в книге *High Output Management* (1995)

Почему это важно: чтобы разработать и провести хороший управляемый онлайн-эксперимент, вам нужны показатели, соответствующие определенным характеристикам. Они должны быть измеримыми в краткосрочной перспективе (продолжительность эксперимента) и вычислимыми, а также достаточно чувствительными и своевременными, чтобы их можно было использовать для экспериментов. Если вы используете несколько показателей для измерения успеха эксперимента, в идеале вы можете объединить их в общий критерий оценки (ОЕС), который, как считается, причинно влияет на долгосрочные цели. Часто ОЕС нуждается в нескольких итерациях для корректировки и уточнения, но, как подчеркивается в приведенной выше цитате Элияху Голдратта, он обеспечивает четкий механизм согласования действий в организации.

7.1. От бизнес-показателей к показателям, подходящим для экспериментов

Как мы говорили в главе 6, организации, управляемые данными, часто используют показатели трех типов – цели, движущие силы и ограничения – для прозрачного и подотчетного согласования и достижения бизнес-целей. Однако бизнес-цели невозможно напрямую использовать в онлайн-экспериментах, поскольку показатели для экспериментов должны быть:

- измеримыми: даже в онлайн-мире не все эффекты легко измерить. Например, может быть сложно измерить удовлетворенность после покупки;
- назначаемыми. Чтобы вычислить показатели для целей эксперимента, мы должны иметь возможность присваивать значения показателей экспериментальному варианту. Например, чтобы проанализировать, испытывает ли обновленное приложение более частые сбои, чем контрольный вариант, мы должны иметь возможность ассоциировать сбой приложения с конкретным вариантом. Эта атрибуция может быть недоступна для показателей, предоставленных другими поставщиками данных, например третьими сторонами;
- чувствительными и своевременными. Показатели эксперимента должны быть достаточно чувствительными, чтобы своевременно обнаруживать важные изменения. Чувствительность зависит от статистической дисперсии базового показателя, величины эффекта (разницы между тестом и контролем в эксперименте) и количества единиц рандомизации (например, пользователей). В качестве крайнего примера нечувствительного показателя вы можете провести контролируемый эксперимент и посмотреть на курс акций компании. Поскольку способность рутинных изменений продукта повлиять на цену акций в течение периода эксперимента практически равна нулю, показатель цены акций не будет достаточно чувствительным. Кинувшись в другую крайность, вы можете измерить существование новой функции (видна ли она?), и это будет очень точный показатель, но совершенно не информативный относительно реальной ценности этой функции для пользователей. Между этими двумя крайностями располагаются более разумные показатели – переходы по новой функции будут чувствительными, но сильно локализованными; показатели переходов по кликам не будут отражать влияние на остальную часть страницы и возможную каннибализацию других функций. Показатель кликов для всей страницы (особенно если штрафуют за быстрые отмены, когда пользователи быстро возвращаются), показатель успеха (например, состоявшаяся покупка) и время до успеха обычно являются хорошими ключевыми показателями, достаточно чувствительными для экспериментов. Вот еще пара распространенных примеров.

- ♦ Что касается доходов от рекламы, то иногда встречаются выбросы с непропорционально высоким влиянием на доход, например клики с очень высокой ценой за клик. Хотя деньги есть деньги и эти дорогостоящие клики следует включать в бизнес-отчетность, подобные большие выбросы влияют на дисперсию и затрудняют выявление эффектов от изменений. По этой причине вы можете рассматривать усеченную версию дохода как дополнительный, более чувствительный показатель для экспериментов (см. главу 22).
- ♦ Возьмем договор подписки с ежегодным продлением. Если вы не захотите провести годичный эксперимент, будет сложно измерить влияние обновления на количество желающих продлить подписку. В этом случае вместо использования в экспериментах соотношения продлений/отказов обычно находят суррогатные метрики, такие как использование, которые являются ранними индикаторами удовлетворенности, ведущей к продлению подписки.

Исходя из этих соображений, можно сделать вывод, что не все показатели, которые используются в целях бизнес-отчетности, подходят для экспериментов. Мы согласны с приведенной выше цитатой Эндрю Гроува: в случае сомнений измеряйте больше, но – что более важно – хорошо подумайте о том, что и с какой целью вы оптимизируете. Например, если объявить показателем оптимизации время пребывания на сайте, отсутствие таких квалификаторов, как хороший/успешный сеанс, приведет к появлению промежуточных страниц и медленному сайту и к увеличению показателя в краткосрочной перспективе, но отпугнет пользователей в долгосрочной перспективе.

В общем, для экспериментов вам придется выбрать подмножество бизнес-целей, движущих сил и контрольных показателей организации, которые соответствуют требованиям измеримости, вычислимости, чувствительности и своевременности. Затем вам может потребоваться дальнейшее увеличение этого набора показателей с помощью:

- дополнительных суррогатных показателей для ваших бизнес-целей и драйверов;
- более подробных показателей, таких как показатели на уровне отдельных действий, чтобы помочь понять значимость определенных функций. Например, рейтинг кликов страницы может быть разбит на рейтинг кликов по десяткам функций на странице;
- дополнительных ограничений надежности (см. главу 21) и показателей качества данных;
- показателей диагностики и отладки, которые предоставляют слишком подробную информацию для постоянного отслеживания, но полезны при детализации ситуации, когда показатели цели, движущих сил или ограничений указывают на проблему.

С учетом всех различных таксономий и вариантов использования показателей типичная карта результатов эксперимента будет иметь несколько ключевых показателей и от сотен до тысяч других показателей, которые можно сегментировать по параметрам, таким как браузеры и рынки.

7.2. ОБЪЕДИНЕНИЕ КЛЮЧЕВЫХ ПОКАЗАТЕЛЕЙ В ОЕС

Что вы делаете в обычной ситуации, когда у вас есть несколько показателей цели и движущих сил? Выбираете только один показатель или сохраняете несколько? Или объединяете их все в единый комбинированный показатель?

В то время как некоторые книги рекомендуют сосредоточиться только на одном показателе, предлагают выбрать *наиболее значимый показатель* (one metric that matters, OMTM) или сосредоточиться на *чрезвычайно важной цели* (wildly important goal, WIG), мы считаем эти подходы излишне упрощенными. За исключением тривиальных сценариев, обычно не существует единого показателя, отражающего все то, для чего оптимизируется бизнес. Каплан и Нортон приводят хороший пример: представьте, что вы садитесь в современный реактивный самолет. Есть ли какой-то один главный показатель, который вы должны отображать на приборной панели в кабине? Скорость полета? Высота? Остаток топлива? Вы знаете, что пилот должен иметь доступ к этим и другим показателям. Когда у вас есть онлайн-бизнес, у вас будет несколько ключевых показателей цели и движущих сил, обычно измеряющих вовлеченность пользователей (например, активные дни, количество сеансов на пользователя, клики на пользователя) и денежную ценность (например, доход на пользователя). Обычно не существует простой единой метрики для оптимизации.

На практике многие организации исследуют несколько ключевых показателей и формируют ментальную модель компромиссов, на которые они готовы пойти, когда видят какую-либо конкретную комбинацию. Например, у них может быть хорошее представление о том, сколько они готовы потерять пользователей (показатель оттока), если оставшиеся пользователи увеличат свою вовлеченность и доход, чтобы с лихвой компенсировать отток. Другие организации, ставящие во главу угла рост клиентской базы, могут не захотеть пойти на подобный компромисс.

Зачастую, если удастся сформировать приемлемый компромисс, наиболее подходящим решением может стать разработка единого показателя, ОЕС, представляющего собой взвешенную комбинацию целей. И, как и в случае с показателями в целом, критически важно гарантировать, что показатели и их комбинация не поддаются намеренному манипулированию (см. раздел 6.7). Например, баскетбольные табло не отслеживают удары за пределами двух- и трехочковых линий, а только общий счет каждой команды, т. е. ОЕС. Кредитные рейтинги FICO объединяют несколько показателей в единую оценку в диапазоне от 300 до 850. Возможность иметь единую итоговую оценку типична для спорта и имеет решающее значение для бизнеса.

Единый показатель проясняет точное определение успеха и, прежде всего, имеет такое же значение, как согласование перечня показателей: он является продуктом компромисса между мнениями людей в организации. Более того, благодаря обсуждению и явному определению компромиссов достигается большая последовательность в принятии решений, и люди могут лучше понять ограничения текущей комбинации показателей, чтобы определить, когда пора пересмотреть ОЕС. Такой подход позволяет командам принимать решения без необходимости передачи информации руководству и предоставляет возможность автоматического поиска (поиск параметров).

Если у вас несколько показателей, одно из решений, предложенных Роем (Roy, 2001), – это нормализовать каждый показатель к заранее заданному диапазону, скажем 0–1, и присвоить каждому показателю вес. Ваш ОЕС – это взвешенная сумма нормализованных показателей.

Поначалу нелегко придумать единую взвешенную комбинацию показателей, но вы можете начать с классификации своих решений на четыре группы.

1. Если все ключевые показатели равные (статистически не значимые) или положительные (статистически значимые) или хотя бы один показатель положительный, то внедряйте изменение.
2. Если все ключевые показатели равные или отрицательные или хотя бы один показатель отрицательный, отменяйте изменение.
3. Если все ключевые показатели неизменны, не внедряйте изменение и подумайте о том, чтобы увеличить мощность эксперимента и быстро потерпеть неудачу или изменить направление инноваций.
4. Если некоторые ключевые показатели положительны, а некоторые отрицательны, тогда принимайте решение исходя из компромиссов. Когда вы накопите достаточное количество подобных решений, вы сможете назначать показателям веса.

Если вы не можете объединить свои ключевые метрики в единый ОЕС, постарайтесь минимизировать количество ключевых метрик. Пфеффер и Саттон (1999) предупреждают о «проблеме Отиса Реддинга», названной так в честь автора и исполнителя известной песни «На пристани в заливе», в которой есть такая строчка: «Я не могу угодить всем подряд, поэтому лучше останусь прежним». Наличие слишком большого количества показателей способно вызвать когнитивную перегрузку, что может привести к игнорированию организацией ключевых показателей. Уменьшение количества показателей также помогает решить многочисленные проблемы сравнения в статистике. Одно из грубых практических правил – постарайтесь использовать не более пяти ключевых показателей. Хотя условие использования сильного порога p -значения 0,05 само по себе может быть нарушено – p -взлом, если угодно, – мы все же можем использовать базовую статистическую концепцию как способ понять эту эвристику. В частности, если гипотеза о нуле верна (изменений показателя нет), то вероятность p -значения $< 0,05$

для одного показателя составляет 5 %. Когда у вас есть k (независимых) показателей, вероятность того, что хотя бы одно p -значение $< 0,05$, составляет $1 - (1 - 0,05)^k$. При $k = 5$ вероятность увидеть что-то статистически значимое составляет 23 %. При $k = 10$ эта вероятность возрастает до 40 %. Чем больше у вас показателей, тем выше вероятность того, что они будут значительными, что приведет к потенциальным конфликтам или вопросам.

И последнее преимущество согласованного ОЕС: вы можете автоматически утверждать изменения (как в простых экспериментах, так и с вариациями параметров).

7.3. ПРИМЕР: ОЕС для электронной почты на Amazon

В Amazon была создана система для отправки электронных писем на основе плановых кампаний, нацеленных на клиентов, исходя из различных условий, например:

- новое произведение автора, чьи книги ранее уже покупал пользователь: система рассылала им по электронной почте информацию о новом издании;
- история покупок. Программа, использующая алгоритм рекомендаций Amazon, отправляла электронное письмо следующего содержания: «Amazon.com предлагает вам новые рекомендации на основе товаров, которые вы приобрели или сообщили нам, что владеете ими»;
- перекрестное воздействие. Многие программы были очень специфичными и настраивались вручную для рассылки рекомендаций по электронной почте клиентам, которые покупали товары, входящие в определенные комбинации категорий.

Вопрос в том, какие ОЕС следует использовать для этих программ? Первоначально в ОЕС, или «функции приближения», как ее называли в Amazon, ключевое значение придавали показателю на основе доходов, полученных от пользователей, которые переходили к товару по ссылке в электронной почте.

Проблема в том, что этот показатель монотонно увеличивается с увеличением объема электронной почты: чем больше кампаний и больше писем, тем больше доход, что привело к рассылке спама пользователям. Обратите внимание, что это свойство увеличения дохода с увеличением объема электронной почты справедливо даже при сравнении доходов от подопытных пользователей (получающих электронные письма) и контрольных пользователей (тех, кто не получает письма).

Подозрения в некорректности ОЕС усилились, когда пользователи начали жаловаться на получение слишком большого количества писем. Первоначальное решение Amazon заключалось в том, чтобы добавить ограничение: пользователь может получать электронную почту только каждые X дней. Они создали диспетчер трафика электронной почты, но проблема заключалась в том, что он породил задачу оптимизации: какое электронное письмо

следует отправлять каждые X дней, когда несколько рассылочных программ подготовили к отправке свои письма? Как определить, какие пользователи могли бы получать больше электронных писем, если бы сочли их действительно полезными?

Основная идея заключалась в том, что доход от кликов, заложенный в основу ОЕС, оптимизирует краткосрочный доход, а не общую ценность пользователя. Раздраженные пользователи отказываются от подписки, и Amazon теряет возможность настроить таргетинг на них в будущем. В Amazon разработали простую модель для построения нижней границы отказа за время жизни пользователя, когда пользователь отписывается. Их ОЕС выглядел следующим образом:

$$OEC = \left(\sum_i Rev_i - s \times unsubscribe_life_loss \right) / n,$$

где:

- i – получатели электронной почты для варианта;
- s – количество отписок в варианте;
- $unsubscribe_lifetime_loss$ – предполагаемая потеря дохода из-за невозможности отправлять электронное письмо человеку на «всю оставшуюся жизнь»;
- n – количество пользователей в варианте.

Когда они внедрили этот ОЕС, выделив на потери от пожизненного отказа от подписки всего несколько долларов на пользователя, более половины рассылочных кампаний показали отрицательный результат ОЕС!

Что еще более интересно, осознание того, что отказ от подписки приносит такую большую потерю, привело к появлению другой страницы отказа от подписки, где по умолчанию стоял отказ от этого неудачного «семейства рассылок», а не на все электронные письма Amazon, что резко снизило стоимость отказа от подписки.

7.4. ПРИМЕР: ОЕС для поисковой системы Bing

Bing использует два ключевых организационных показателя для измерения развития: доля запросов и доход, как описано в статье *Trustworthy online controlled experiments: Five puzzling outcomes explained* («Доверительные контролируемые онлайн-эксперименты: объяснение пяти загадочных результатов», Кохави и др., 2012). Пример показывает, насколько диаметрально могут расходиться краткосрочные и долгосрочные цели. Эта проблема также включена в исследование *Data Science Interviews Exposed* (Huang и др., 2015). Когда Bing допустил ошибку ранжирования, вследствие которой подопытные пользователи получали очень плохие поисковые результаты, два ключевых организационных показателя значительно улучшились: количество отдельных запросов на пользователя выросло более чем на 10 %, а доход

на пользователя вырос более чем на 30 %. Какой должен быть ОЕС для поисковой системы? Очевидно, что долгосрочные цели поисковой системы не совпадают с этими двумя ключевыми показателями в экспериментах. В противном случае поисковые системы намеренно снизили бы качество выдачи, чтобы увеличить долю запросов и прибыль!

Плохие алгоритмические результаты (основные результаты поисковых систем, показываемые пользователям, также известные как 10 синих ссылок) вынуждали людей делать больше запросов (увеличивая количество запросов на пользователя) и чаще нажимать на объявления (увеличивая доход). Чтобы разобраться в проблеме, давайте обсудим удельные запросы.

Ежемесячные *удельные запросы* (query share) определяются как количество отдельных запросов для поисковой системы, поделенное на количество запросов для всех поисковых систем за один месяц. Количество отдельных запросов в месяц разлагается на произведение этих трех условий, как показано в выражении 7.1:

$$n \frac{\text{пользователи}}{\text{месяц}} \times \frac{\text{сеансы}}{\text{пользователь}} \times \frac{\text{отдельные запросы}}{\text{сеанс}}, \quad (7.1)$$

где второй и третий члены произведения вычисляются за месяц, а сеанс определяется как активность пользователя, которая начинается с запроса и заканчивается 30 мин бездействия в поисковой системе.

Если цель поисковой системы – помочь пользователям как можно быстрее найти ответ или выполнить свою задачу, то сокращение количества отдельных запросов на задачу является очевидной целью, которая противоречит бизнес-цели увеличения доли запросов. Поскольку этот показатель сильно коррелирует с отдельными запросами на сеанс (их легче измерить, чем задачи), отдельные запросы сами по себе не должны использоваться в качестве ОЕС для поисковых экспериментов.

Давайте подробнее рассмотрим три члена декомпозиции, показанной в выражении 7.1.

1. Пользователи в месяц. В контролируемом эксперименте количество уникальных пользователей определяется схемой. Например, в A/B-тесте с разделением 50/50 количество пользователей, попадающих в каждый вариант, будет примерно одинаковым, поэтому вы не можете использовать этот член как часть ОЕС для контролируемых экспериментов.
2. Запросы на отдельную задачу – их количество следует свести к минимуму, но это трудно измерить. В качестве суррогатного показателя вы можете использовать отдельные запросы за сеанс; тем не менее это неоднозначный показатель, поскольку его увеличение может указывать на то, что пользователи вынуждены делать больше запросов для выполнения задачи, но уменьшение его может указывать на отказы пользователей. Следовательно, вы можете стремиться уменьшить

этот показатель, если вы также проверяете, что задача успешно завершена (т. е. количество отказов не увеличивается).

3. Сеансы на пользователя – это ключевой показатель для оптимизации (увеличения) в контролируемых экспериментах. Довольные пользователи заходят чаще.

Выручка на пользователя также не должна применяться в качестве ОЕС для поисковых и рекламных экспериментов без добавления других ограничений. Что касается показателей дохода, мы хотим их увеличить без отрицательного влияния на показатели взаимодействия. Распространенным подходом является ограничение среднего количества пикселей, которые рекламные объявления могут занимать в нескольких запросах. Увеличение дохода от поиска с учетом этого ограничения является проблемой оптимизации ограничений.

7.5. Закон Гудхарта, закон Кэмпбелла и ЗАМЕЧАНИЕ ЛУКАСА

ОЕС должен быть измеримым в краткосрочной перспективе (продолжительность эксперимента), но при этом оставаться причинно-следственным фактором для достижения долгосрочных стратегических целей. Закон Гудхарта, закон Кэмпбелла и замечание Лукаса подчеркивают, что *корреляция не подразумевает причинной связи* и что во многих случаях организации, выбирающие ОЕС, становятся жертвами корреляции.

Чарльз Гудхарт, британский экономист, сформулировал следующий закон: «Любая наблюдаемая статистическая закономерность будет иметь тенденцию разрушаться, как только на нее будет оказано давление в целях контроля». Сегодня больше известна сокращенная формулировка *закона Гудхарта*: «Когда мера становится целью, она перестает быть хорошей мерой».

Закон Кэмпбелла, названный в честь Дональда Кэмпбелла, гласит: «Чем чаще какой-либо количественный социальный показатель используется для принятия социальных решений, тем больше он будет подвержен коррупционному давлению и тем более склонен к искажению и разрушению социальных процессов, для отслеживания которых он предназначен».

Замечание Лукаса гласит, что взаимосвязи, наблюдаемые в исторических данных, не могут считаться структурными или причинными. Политические решения могут изменить структуру экономических моделей, и корреляции, которые существовали исторически, больше не действуют. Кривая Филлипса, например, показала историческую отрицательную корреляцию между инфляцией и безработицей; за период исследования 1861–1957 гг. в Соединенном Королевстве, когда инфляция была высокой, безработица была низкой, и наоборот. Увеличение инфляции в надежде на то, что это снизит безработицу, предполагает неправильную причинно-следственную связь. На самом деле во время рецессии в США 1973–1975 гг. увеличились

и инфляция, и безработица. Сейчас принято считать, что в долгосрочной перспективе уровень инфляции не оказывает причинного влияния на безработицу.

Тим Харфорд иллюстрирует ошибку использования исторических данных на следующем примере: «Форт-Нокс никогда не грабили, поэтому мы можем сэкономить деньги, уволив охранников». Вы не можете смотреть только на эмпирические данные; вам также нужно подумать о стимулах. Очевидно, столь существенное изменение политики безопасности заставит преступников пересмотреть вероятность своего успеха.

Наличие корреляций в исторических данных не означает, что вы можете выбрать точку на корреляционной кривой, изменить одну из переменных и ожидать изменения другой. Чтобы это произошло, взаимосвязь должна быть причинной, что затрудняет выбор показателей для ОЕС.

Глава 8

Институциональная память и метаанализ

Люди иногда прощают, но тело и общество – никогда.

– Лорд Честерфилд (1694–1773)

***Почему это важно:** по мере того как ваша организация переходит в фазу «активной» зрелости экспериментирования, институциональная память, содержащая историю всех проведенных экспериментов и изменений, становится все более важной. Ее можно использовать для выявления закономерностей, которые обобщаются в экспериментах, для развития культуры экспериментирования, для улучшения будущих инноваций и многого другого.*

8.1. Что такое институциональная память?

После полного внедрения контролируемых экспериментов в качестве обязательного шага в инновационном процессе ваша компания может эффективно вести электронный журнал всех изменений, внесенных в ходе экспериментов, включая описания, снимки экрана и ключевые результаты. Каждый из сотен или даже тысяч экспериментов, проведенных в прошлом, представляет собой страницу в журнале с ценными и обширными данными о каждом изменении (реализованном или нет). Этот цифровой журнал мы называем *институциональной памятью* (institutional memory). В этом разделе рассказывается, как использовать институциональную память с помощью метаанализа и анализа данных всех этих исторических экспериментов.

Само собой разумеется, что вам необходимо собирать и систематизировать данные как часть институциональной памяти. Наличие централизованной платформы для экспериментов, на которой тестируются все изменения, безусловно, упрощает задачу. Настоятельно рекомендуется собирать общую информацию по каждому эксперименту, например кто является инициатором; когда начался эксперимент; как долго он работал; описания и снимки экрана, если изменение было визуальным. У вас также должны

быть результаты, показывающие, какое влияние эксперимент оказал на различные показатели, в том числе окончательную систему показателей с триггером и общим влиянием (см. главу 20). Наконец, вы должны завершить гипотезу, на которой основан эксперимент: какое решение было принято и почему.

8.2. ПОЧЕМУ ПОЛЕЗНА ИНСТИТУЦИОНАЛЬНАЯ ПАМЯТЬ?

Что вы можете получить, извлекая данные из всех этих экспериментов? Это то, что мы называем здесь метаанализом. Мы разделили варианты применения данных на пять категорий.

1. **Культура эксперимента.** Краткое изложение прошлых экспериментов может подчеркнуть важность экспериментирования и способствовать укреплению корпоративной культуры. Вот несколько конкретных примеров метаанализа.
 - ♦ **Как экспериментирование способствует достижению более широких целей организации?** Например, если цель компании – улучшить количество сеансов на пользователя, насколько улучшится количество сеансов на пользователя за последующий год благодаря изменениям, начатым в результате экспериментов? Это может быть много маленьких успешных шажков, сложенных вместе. Рекламное подразделение Bing поделилось впечатляющим графиком, показывающим, как рост их доходов в период с 2013 по 2015 гг. был связан с постепенными улучшениями в результате сотен экспериментов (см. главу 1).
 - ♦ **Какие эксперименты имеют большое или неожиданное влияние?** Поскольку числа отлично помогают организациям получить представление о масштабах, люди любят конкретные примеры. Мы считаем полезным регулярно делиться экспериментами, которые приносят большие победы или дают удивительные результаты (см. главу 1). Как мы упоминали в главе 4, можно также делиться регулярными отчетами об экспериментах, которые имеют большое влияние на показатели, волнующие людей.
 - ♦ **Сколько экспериментов положительно или отрицательно повлияли на показатели?** В хорошо оптимизированных областях, таких как Bing и Google, по некоторым параметрам показатель успеха составляет всего 10–20 %. Microsoft сообщает, что треть их экспериментов повлияла на ключевые показатели положительно, треть – отрицательно, а треть не оказала значительного влияния. LinkedIn наблюдала аналогичную статистику. Всегда обидно осознавать, что без достоверных экспериментов мы могли бы в конечном итоге ставить как положительные, так и отрицательные эксперименты, нейтрализующие влияние друг друга.

- ♦ **Какой процент обновлений внедряется через эксперименты? Какие команды провели больше всего экспериментов?** Каков рост поквартально или из года в год? Какая команда наиболее эффективно меняет ваш ОЕС? Какие убытки связаны с изменениями, не проверенными экспериментально? Когда «посмертный» анализ убытков дает ответ на такие вопросы, культура компании меняется, потому что люди начинают понимать, что эксперименты действительно обеспечивают безопасность. В крупных компаниях, где есть много команд, участвующих в проведении множества экспериментов, это помогает совершить прорыв и способствует лучшей подотчетности.
2. **Лучшие подходы к экспериментам.** Экспериментаторы не всегда следуют лучшим практикам. Это особенно часто случается, когда все больше и больше людей начинают экспериментировать. Например, проходит ли эксперимент через рекомендованный период внутреннего бета-тестирования? Достаточно ли мощности эксперимента, чтобы обнаружить изменение ключевых показателей? Когда вы проведете достаточно много экспериментов, вы сможете выполнять метаанализ и сообщать сводную статистику, чтобы показать командам и руководству, где можно добиться улучшений. Для большей ответственности вы можете вести статистику по командам. Эти идеи помогут вам решить, стоит ли инвестировать в автоматизацию, чтобы устранить самые большие пробелы в экспериментировании. Например, изучив графики увеличения количества экспериментов, в LinkedIn обнаружили, что во многих экспериментах слишком много времени уходит на ранние фазы роста, в то время как другие даже не проходят через фазу внутреннего бета-тестирования (см. главу 14). Чтобы решить эту проблему, LinkedIn разработал функцию автоматического развития, которая помогает экспериментаторам своевременно проходить через все фазы эксперимента.
 3. **Будущие инновации.** Для новичка в вашей компании или новичка в команде очень ценно наличие перечня того, что работало, а что нет. Это помогает избежать повторения ошибок и вдохновляет на эффективные инновации. Изменения, которые не работали в прошлом, возможно, стоит попробовать снова, если изменилась окружающая среда. По мере того как вы проводите метаанализ большого числа экспериментов, выявляются закономерности, которые могут подтолкнуть вас к лучшим идеям. Например, какой тип экспериментов наиболее эффективен для изменения ключевых показателей? Какие типы пользовательского интерфейса с большей вероятностью заинтересуют пользователей? GoodUI.org содержит большую подборку шаблонов пользовательского интерфейса, которые неоднократно показывали положительные результаты. Проведя множество экспери-

ментов, оптимизирующих конкретную страницу, например страницу результатов поисковой системы, вы можете предсказать влияние, которое окажет на показатели изменение интервала, жирного шрифта, длины строки, эскизов и т. д. Следовательно, когда вы добавляете новый элемент в поисковую выдачу, вы можете сузить пространство для экспериментов. Другой пример – рассмотрение неоднородности экспериментов в разных странах (см. главу 3), вы можете выявить скрытые данные о том, как страны по-разному реагируют на изменения, что позволяет вам улучшить пользовательский опыт, адаптированный для этих пользователей.

4. **Показатели.** Показатели не отделимы от экспериментов (см. главу 7). Вы можете просмотреть свои эксперименты и узнать, как работают различные показатели, чтобы глубже понять, как лучше их использовать. Вот несколько примеров использования метаанализа показателей:

- ♦ **метрическая чувствительность.** При разработке показателей одним из ключевых критериев является возможность их значимого изменения в ходе экспериментов. Показатель, который ни один эксперимент не может изменить статистически значимо, не является хорошей метрикой (см. главу 7). Хотя дисперсия является ключевым фактором, определяющим чувствительность, также важно учитывать, насколько вероятно может повлиять на показатель экзогенное изменение. Например, *активные пользователи по дням* (daily active users, DAU) – это показатель, который сложно изменить в краткосрочных экспериментах. Изучение существующих показателей путем сравнения их эффективности в прошлых экспериментах позволяет определить потенциальные долгосрочные и краткосрочные показатели. Вы также можете создать корпус доверительных экспериментов для оценки новых показателей и сравнения различных вариантов определения;
- ♦ **связанные показатели.** Вы можете использовать изменение показателей в экспериментах, чтобы определить, как они *связаны* друг с другом. Обратите внимание, что это понятие отличается от *корреляции* между показателями. Например, пользователь, который чаще посещает LinkedIn, обычно отправляет гораздо больше сообщений. Однако в экспериментах сеансы и сообщения необязательно изменяются вместе. Одним из примеров связанных показателей в экспериментах являются ранние индикаторы, которые, как правило, показывают опережающие сигналы для других показателей, проявляющих себя значительно позже. Это особенно полезно, если медленно меняющиеся показатели имеют решающее значение для принятия решений (см. главу 7). Изучая множество экспериментов, вы можете выявить эти связи;

- ♦ **априорные вероятности для байесовских подходов.** Поскольку байесовский взгляд на оценку экспериментов становится все более популярным, одна из ключевых проблем заключается в том, можете ли вы построить разумные априорные вероятности. Для более зрелых продуктов разумно предположить, что изменение показателей в исторических экспериментах может служить источником обоснованных априорных вероятностей. Впрочем, для быстро развивающихся областей неясно, могут ли эмпирические распределения из прошлого адекватно представлять будущее.

5. **Эмпирическое исследование.** Огромный объем экспериментальных данных служит исследователям источником эмпирических данных для оценки и изучения своих теорий с помощью метаанализа. Например, Азеведо и др. (2019) изучили, как компания может наилучшим образом использовать эксперименты для повышения продуктивности инноваций. Они предложили оптимальную стратегию внедрения и экспериментирования, основанную на тысячах экспериментов, которые проводились на экспериментальной платформе Microsoft. Рандомизация эксперимента также может служить отличной инструментальной переменной.

Изучив 700 экспериментов, проведенных по алгоритму «Люди, которых вы можете знать» в LinkedIn в период с 2014 по 2016 гг., Сен-Жак и др. (2018) нашли причинно-следственные доказательства того, что людям помогают найти работу не самые сильные связи, а представляющие компромисс между силой и разнообразием. Ли и Шен (2018) рассмотрели, как суммировать влияние многих экспериментов. Когда проводится серия экспериментов, для запуска в производство обычно выбирают изменения, дающие значительные успешные результаты. Авторы исследуют систематическую ошибку отбора в этом процессе и предлагают метод коррекции, основанный на изучении экспериментов, проводимых на экспериментальной платформе Airbnb.

Глава 9

Этика контролируемых экспериментов

Прогресс науки намного опережает этическое развитие человека.

– Чарли Чаплин (1964)

... это разновидность тестирования, где изменения в программном КОДЕ вызывают ОБМАН пользователя ... [мы] называем этот новый подход C/D-экспериментами, чтобы отличить его от ... A/B-экспериментов.

– Ракель Бенбулан-Фич (2017)

Почему это важно: понимание этики экспериментов имеет решающее значение для всех: от руководителей до инженеров, менеджеров по продуктам и специалистов по данным – все должны помнить об этических соображениях. Контролируемые эксперименты, будь то в технологии, антропологии, психологии, социологии или медицине, проводятся над реальными людьми. В этой главе мы обсудим вопросы и опасения, которые следует учитывать, если вы раздумываете, стоит ли обращаться за советом к эксперту относительно этики ваших экспериментов.

9.1. Что лежит в основе этики

Общее определение *этики* – это набор правил или морали, которые определяют, что мы должны или не должны делать. Этика применительно к исследованиям регулирует правила поведения, обеспечивающие достоверность результатов, ценности, необходимые для совместной работы, публичную подотчетность, а также моральные и социальные ценности, включая как общественную безопасность, так и защиту людей. Применение этики к исследованиям может со временем меняться, отражая переменчивый мир, культуру и реакцию человека на неожиданные последствия научных исследований. Как написал Чарли Чаплин в приведенной выше цитате, развитие правил и норм этического поведения отстает от науки.

Эта тема слишком глубока, чтобы пытаться раскрыть ее полностью, поэтому мы даем только обзор этики исследования контролируемых экспериментов. Для более глубокого изучения мы рекомендуем несколько работ (Loukides, Mason and Patil 2018, FAT/ML 2019, ACM 2018, King, Churchill and Tan 2017, Benbunan-Fich 2017, Meyer 2015, 2018), в которых представлены ключевые принципы, проверочные списки, практические руководства и т. д. Хотя экспериментаторы редко являются знатоками этики, мы должны задавать себе вопросы, критически изучать нашу практику и учитывать долгосрочные интересы наших пользователей и бизнеса. Обратите внимание, что мы пишем это как частные лица, а не как представители Google, LinkedIn или Microsoft.

Два недавних примера из технологической отрасли иллюстрируют необходимость задумываться над этичностью проводимых экспериментов.

1. Исследователи из Facebook и Cornell изучали так называемое эмоциональное заражение через социальные сети, чтобы определить, будут ли публиковать больше негативных постов случайно выбранные участники, получившие в ленте новостей подборку преимущественно негативных постов и, наоборот, будут ли другие случайно выбранные участники, получившие подборку преимущественно положительных постов, публиковать больше положительных постов спустя неделю после воздействия.
2. Популярный сайт знакомств OKCupid провел эксперимент, в котором сформировал пары клиентов, которые, по мнению алгоритма, совместимы на 30, 60 и 90 %, и в каждой из этих трех групп одной трети клиентов сообщили, что они совместимы на 30 %, другой трети сказали, что они совместимы на 60 %, а остальным – на 90%, и смотрели, что из этого получится.

Поскольку перечень этически сомнительных экспериментов не ограничивается этими примерами, перед нами встает вопрос: по каким критериям и какими методами оценивать допустимость А/В-экспериментов?

Для начала мы можем обратиться к отчету Бельмона, выпущенному в 1979 году (Национальная комиссия по защите людей в качестве субъектов биомедицинских и поведенческих исследований, 1979), в котором определены принципы биомедицинских и поведенческих исследований, а также к «Общему правилу» (*Common rule*, Office for Human Research Protections, 1991), которое устанавливает действенные критерии проверки, основанные на этих принципах. Они были сформулированы на основе нескольких примеров, включая исследование сифилиса Таскиги 1930-х гг. (CDC 2015) и эксперимент Милграма 1960-х гг. (Milgram 2009) в области медицины, где риск существенного вреда обычно намного выше, чем в онлайн-экспериментах. Основываясь на этих рекомендациях, мы теперь задаем вопросы о том, оправдано ли конкретное клиническое исследование, и временами случается, что проведение рандомизированных контролируемых исследований невозможно или воспринимается как неэтичное.

Отчет Бельмона и «Общее правило» содержат три ключевых принципа в области биомедицинских и поведенческих исследований людей:

- **уважение к людям:** относитесь к ним с уважением, т. е. воспринимайте каждого человека как независимую личность, насколько это возможно, и защищайте их права, когда они не могут этого сделать. Это означает акцент на прозрачности, правдивости и добровольности (выбор и согласие);
- **полезность:** защищайте людей от вреда. В то время как в отчете Бельмона говорится, что полезность означает минимизацию рисков и максимизацию выгод для участников, «Общее правило» признает сложность такого подхода и вместо этого сосредотачивается на правильной оценке рисков и выгод и их надлежащем балансировании при рассмотрении предлагаемых исследований;
- **справедливость:** обеспечьте справедливое распределение рисков и выгод, исключите возможность эксплуатации участников.

Из-за сложности проблемы «Общее правило» содержит положения, которые не только уравнивают преимущества и риски самого исследования, но также информируют о необходимости прозрачности, правдивости и добровольности участников исследования, включая отказ от участия.

Хотя эти вопросы представляют собой полезную этическую основу для медицины – дисциплины, в которой можно причинить существенный вред, – на них редко можно получить однозначно правильные или неправильные ответы, поэтому перенос этих принципов на конкретные онлайн-овые А/В-эксперименты требует обсуждения, обдумывания, осторожности и опыта. Вот ключевые области, о которых следует подумать в первую очередь.

9.1.1. Риски

С каким риском сталкивается участник вашего исследования? Превышает ли риск минимальный риск, определяемый «Общим правилом» как то, что «вероятность и величина ущерба или дискомфорта, ожидаемые в ходе исследования, должны быть не больше, чем те, которые обычно встречаются в повседневной жизни или во время выполнения обычных физических или психологических обследований и тестов». Ущерб может быть физическим, психологическим, эмоциональным, социальным или экономическим.

Одна из полезных концепций – это *уравновешенность* (equipoise): находят ли соответствующее экспертное сообщество в уравновешенном состоянии, т. е. истинной неопределенности в отношении двух методов воздействия.

При оценке контролируемых онлайн-экспериментов можно использовать один полезный критерий, своего рода лакмусовую бумажку – сможете ли вы применить обновление ко всем пользователям без контролируемого эксперимента, учитывая стандарты организации. Если вы можете внести изменения в алгоритм или внешний вид продукта без эксперимента, вы, несомненно, могли бы провести эксперимент и в первую очередь с научной

точки зрения оценить изменение; возможно, вы обнаружите неожиданные эффекты. Доставка кода пользователям – это, по сути, и есть эксперимент. Только это может быть не контролируемый эксперимент, а скорее, неэффективный *последовательный тест*, в ходе которого исследуются временные ряды; если ключевые показатели (например, доход, отзывы пользователей) отрицательны, изменение отменяется.

Спротивляемость контролируемому онлайн-эксперименту, когда каждый пользователь оказывается либо в контрольной, либо в тестовой группе, иногда называют «А/В-иллюзией». Когда вы решаете что-то сделать, вы предполагаете, какой эффект будет в результате, и это предположение может сбыться или не сбыться. Если вы хотите предложить что-то 100 % пользователей, то применение этого обновления к 50 % с намерением перейти к 100 % в качестве эксперимента также должно дать положительный результат. В одном из примеров Мейер (Meyer, 2015) рассказывает:

«... Глава компании обеспокоена тем, что некоторые из ее сотрудников могут не успеть скопить достаточно средств для выхода на пенсию... Она решает, что с этого момента при рассылке уведомлений о зачислении заработной платы будет включать в них упоминание о том, сколько коллег со стажем до пяти лет подписались на автоматическое отчисление в пенсионный фонд. Она выдвинула гипотезу, что на меньшинство сотрудников, которые не подписались на пенсионные отчисления, может повлиять знание об обратном поведении большинства».

Хотя у главы компании были добрые намерения и исследования показали преимущества влияния сверстников, когда был проведен контролируемый эксперимент, он вылился в оппозиционную реакцию и уменьшил сбережения.

9.1.2. Преимущества и выгоды

Другая сторона оценки рисков – понять преимущества исследования. Часто при планировании контролируемых онлайн-экспериментов преимущества рассматриваются с точки зрения улучшения продукта, что может быть полезно непосредственно для пользователей в тестовой группе, для всех пользователей, которые извлекают выгоду от результатов, или даже косвенно с точки зрения построения устойчивого бизнеса, чтобы пользователи могли продолжать извлечение выгоды. Повышение продуктивности пользователей может относиться к первым двум сегментам, в то время как улучшение доходов от рекламы может относиться к последнему сегменту косвенной выгоды.

Одна из ситуаций, когда оценка преимуществ может быть более сложной, – это проведение экспериментов, которые сознательно предоставляют участникам худший опыт с целью в конечном итоге улучшить опыт для всех пользователей, часто за счет возможности количественно оценить компро-

миссы. Примеры включают проведение экспериментов, которые замедляют взаимодействие с пользователем (см. главу 5), показ дополнительных объяснений для понимания долгосрочных эффектов (см. главу 23) или отключение таких функций, как рекомендации, для определения их ценности. Эти случаи нарушают экспертную уравнилову в том смысле, что существует общее мнение о том, что изучаемое воздействие не приносит пользы, но имеет минимальный риск для пользователей. Выгода от проведения таких экспериментов заключается в нахождении компромиссов, которые можно использовать для более информированного принятия решений и в конечном итоге помочь улучшить взаимодействие с пользователем для всех. Что немаловажно, в этих случаях нет обмана пользователей. Хотя существует профиль более высокого риска с большим потенциалом нанесения вреда, чем в большинстве контролируемых онлайн-экспериментов, для подобных экспериментов существует медицинская аналогия в исследованиях токсичности лекарств: в какой-то момент слишком большое количество лекарства может причинить вред, но без надлежащего исследования мы не можем узнать, насколько сильны и чем грозят последствия передозировки.

Следует подчеркнуть существенное различие между экспериментами для опробования новых функций, нового текста, новых алгоритмов и инфраструктуры, даже для установления компромиссов и экспериментами с обманом или направленным внушением, которые сосредоточены на поведении и отношениях между людьми. Эксперименты с обманом сопряжены с более высоким этическим риском и вызывают вопросы о том, уважают ли участников.

Когда мы думаем об уважении к участникам, в первую очередь мы должны задать вопросы о прозрачности и ожиданиях. Продукты сопровождаются ожиданиями пользователей в отношении пользовательского интерфейса и полезности. Эксперименты должны соответствовать этим ожиданиям.

Наряду с несколькими другими способами обеспечения прозрачности ключевой этической концепцией является информированное согласие, когда участники соглашаются участвовать в исследовании после того, как они будут полностью проинформированы о рисках и преимуществах, процессе, любых альтернативных вариантах, а также о том, какие данные собираются и как они обрабатываются. Обратите внимание, что здесь мы обсуждаем согласие с точки зрения его общего значения, а не конкретного юридического определения, например в соответствии с Европейским Общим регламентом защиты данных (European Commission, 2018). В большинстве медицинских экспериментов каждый участник дает информированное согласие, а те, которые этого не делают, обычно имеют минимальный риск и соответствуют другим условиям, что дает право на отказ от согласия в соответствии с «Общим правилом». Напротив, эксперименты, проводимые поставщиками онлайн-услуг, обычно сопряжены с гораздо меньшим уровнем риска для участников, хотя, по мере того как онлайн-сервисы наращивают влияние на физический опыт пользователей, например связанный с доставкой посылок, совместными поездками и т. д., риск и последствия могут

возрасти. Кроме того, в масштабных экспериментах получение всеобщего информированного согласия обходится непомерно дорого и раздражает пользователей. Вместо этого рассмотрите весь диапазон возможностей от экспериментов, в которых требуется согласие, до экспериментов, в которых риск и потенциальный вред для пользователей очень низок и согласие не требуется. Одной из альтернатив в середине этого спектра является *предполагаемое согласие*, когда меньшую, но репрезентативную группу людей спрашивают, как они будут относиться к участию в исследовании (или классе исследований), и, если они согласны, предполагается, что это мнение можно обобщить на всех участников.

9.1.3. Возможность выбора

Еще одно соображение: какой выбор есть у участников? Например, если вы тестируете изменения в поисковой системе, у участников всегда есть выбор использовать другую поисковую систему. Стоимость переключения на другие онлайн-сервисы может быть выше с точки зрения времени, денег, обмена информацией и т. д. Эти факторы следует учитывать при оценке выбора, предлагаемого участникам, а также рисков и выгод, которые необходимо сбалансировать. Например, в клинических испытаниях новых лекарств от рака основным выбором, с которым сталкивается большинство участников, является смерть, поэтому риск может быть достаточно высоким при условии информированного согласия.

9.2. СБОР ДАННЫХ

Одним из неперенных условий для проведения А/В-экспериментов является наличие инструментов обработки данных для анализа экспериментов и принятия решений. Часто эти данные необходимо собирать для измерения и обеспечения высокого качества обслуживания пользователей. В результате согласие на сбор данных часто включается в условия использования онлайн-сервисов. Хотя в других источниках сбор данных обсуждается более подробно и, конечно, предварительным условием является соответствие любых экспериментов всем применимым законам о конфиденциальности и защите данных, экспериментаторы или разработчики должны иметь возможность ответить на следующие ключевые вопросы о сборе данных.

- Какие данные собираются, и что пользователи знают об этом массиве данных? Конфиденциальность по умолчанию является одним из полезных приемов в этой области.
 - ◆ Понимают ли пользователи, какие данные о них собираются?
 - ◆ Насколько конфиденциальны данные? Включают ли они финансовые данные или данные о состоянии здоровья? Могут ли данные использоваться для дискриминации пользователей в нарушение прав человека?

- ♦ Могут ли данные быть привязаны к конкретному человеку, т. е. считаются ли они персонализируемыми (см. примечание далее в этой главе)?
- ♦ С какой целью собираются данные, и как они могут быть использованы и кем?
- ♦ Обязательно ли собирать данные для этой цели? Как скоро данные можно будет агрегировать или удалять для защиты отдельных пользователей?
- Что может пойти не так со сбором данных?
 - ♦ Какой ущерб причинит пользователям публикация всех этих данных или их части?
 - ♦ Подумайте о вреде для их здоровья, психологического или эмоционального состояния, социального статуса или финансового положения.
- Каковы ожидания пользователей в отношении конфиденциальности, и как эти ожидания обеспечены? Допустим, если за участниками наблюдают в общественных местах (например, на футбольном стадионе), ожидания конфиденциальности ниже. Если исследование проводится на основе существующих общедоступных данных, то нельзя ожидать соблюдения конфиденциальности. Если данные невозможно персонифицировать (см. примечание к главе), то конфиденциальность и приватность необязательно вызывают беспокойство. В ином случае:
 - ♦ какой уровень конфиденциальности могут ожидать участники?
 - ♦ каковы внутренние меры безопасности при работе с этими данными? Может ли кто-нибудь в компании получить доступ к данным, особенно если они персонифицированы, или же данные защищены, и доступ регистрируется и проверяется? Каким образом выявляются, регистрируются и устраняются нарушения безопасности?
 - ♦ какая компенсация предусмотрена (будут ли участники проинформированы), если эти обязательства не будут выполнены?

9.3. КУЛЬТУРА И ПРОЦЕССЫ

Многие проблемы, которые мы решаем, сложны и содержат нюансы. Может возникнуть соблазн просто положиться на экспертов, которые все обдумают за нас и установят принципы. Однако, чтобы обеспечить соблюдение этических соображений, важно, чтобы ваша корпоративная культура и все сотрудники, начиная с вашего руководства, понимали и принимали во внимание эти проблемы и их последствия. Самоанализ имеет решающее значение.

Передовые компании должны самостоятельно позаботиться о должном понимании проблемы безопасности пользователей на всех уровнях:

- установите культурные нормы и настройте образовательные процессы, чтобы сотрудники ознакомились с проблемами, и убедитесь, что эти вопросы упоминаются во время обзоров продуктов и технических решений;

- создайте рабочий процесс, который соответствует целям *институциональных наблюдательных советов* (institutional review boards, IRB). IRB рассматривают возможные исследования на людях, оценивают риски и выгоды, обеспечивают прозрачность, предоставляют поддержку и многое другое для обеспечения честности и уважения к участникам. IRB утверждают, требуют альтернативу или отклоняют исследования. IRB задают экспериментаторам вопросы, ответы на которые обеспечивают тщательный анализ и адекватный самоанализ, а также обеспечивают своевременное самообучение;
- настройте инструменты, инфраструктуру и процессы таким образом, чтобы все данные, персонифицированные или нет, хранились надежно, а доступ ограничивался лишь теми, кому они нужны для выполнения своей работы. Должен быть четкий набор принципов и политик, определяющих, какое использование данных допустимо, а какое – нет. Вы должны следить, чтобы все использованные данные регистрировались и регулярно проверялись на предмет нарушений;
- создайте четкий путь эскалации для решения проблем, связанных с превышением минимального риска или проблемами с конфиденциальностью данных.

Эти вопросы и процессы, связанные с этикой экспериментов, нельзя игнорировать, фактически они улучшают структуру продукта и экспериментов для конечных пользователей.

9.4. ПРИМЕЧАНИЕ: ИДЕНТИФИКАЦИЯ ПОЛЬЗОВАТЕЛЕЙ

Часто задаваемый вопрос: в чем разница между персонифицированными, псевдонимными и анонимными данными? Хотя точные определения могут меняться в зависимости от контекста или применимых законов и все еще обсуждаются, на высоком уровне эти понятия можно объяснить следующим образом:

- **персонифицированные** данные собираются и хранятся вместе с информацией, позволяющей установить личность. Это могут быть имена, идентификаторы (например, номер карты социального страхования или водительские права), номера телефонов и т. д. Идентификатор устройства (например, уникальный серийный номер смартфона) также во многих случаях считается персональным идентификатором. В Европе Общий регламент по защите данных (General data protection regulation, GDPR) придерживается еще более высоких стандартов и считает любые данные персональными данными, если они могут быть связаны с физическим лицом (Европейская комиссия, 2018);
- **анонимные** данные собираются и хранятся без какой-либо ин-

формации, позволяющей установить личность. Эти данные считаются **псевдонимными**, если они хранятся со случайно сгенерированным идентификатором, таким как куки-файл, который назначается некоторому событию, например когда пользователь впервые открывает приложение или посещает веб-сайт, и не имеет сохраненного идентификатора. Однако простое указание на то, что данные являются псевдонимными или анонимными, не означает, что повторная идентификация невозможна. Почему? Мы должны различать анонимные и анонимизированные данные. *Анонимизированные данные* – это персонифицированные или анонимные данные, которые были изучены и каким-то образом гарантируют, что риск повторной идентификации является низким или вовсе отсутствующим, т. е. заполучив эти данные, почти невозможно определить, к какому человеку они относятся. Часто эта гарантия предоставляется с помощью метода Safe Harbor или других методов, таких как *k-анонимность* или *дифференциальная конфиденциальность*. Обратите внимание, что многие из этих методов не гарантируют, что анонимные данные не имеют риска повторной идентификации, а скорее, пытаются количественно оценить риск и ограничения, такие как ограничение запросов или добавление шума с дополнительными запросами.

В европейской литературе о конфиденциальности, которая является нынешней высокой планкой конфиденциальности во всем мире, анонимные данные больше не рассматриваются как отдельная категория, а вместо этого просто говорится о персональных данных и анонимизированных данных.

Итак, если мы собираем данные, которые хранятся и используются в эксперименте, у нас должны возникать следующие вопросы:

- насколько конфиденциальны данные?
- каков риск повторной идентификации людей по данным?

По мере роста уязвимости и рисков вы должны повышать уровень защиты данных, конфиденциальности, контроля доступа, безопасности, мониторинга и аудита и т. д.

ЧАСТЬ III



**Дополнительные
и альтернативные методы
контролируемых экспериментов**

В части III представлены методы, дополняющие контролируемые онлайн-эксперименты. Этот материал особенно полезен для специалистов по обработке данных и других сотрудников, которые могут использовать эти методы, а также для руководителей, чтобы сформировать у них понимание, как распределять ресурсы по областям и проводить эксперименты для принятия решений на основе данных.

Мы начинаем с обзора нескольких *дополнительных методов*, таких как исследования пользовательского опыта, опросы, фокус-группы и человеческая оценка, используемых в сочетании с контролируемыми онлайн-экспериментами. Используйте эти методы как часть механизма генерации и оценки идей в воронке идей перед инвестированием в контролируемый онлайн-эксперимент, а также для выработки и проверки показателей для использования либо для всей организации, либо в качестве суррогатных показателей в управляемых онлайн-экспериментах.

Затем мы сосредоточимся на *наблюдательных исследованиях причинно-следственных связей* (observational causal studies). Хотя контролируемые онлайн-эксперименты считаются золотым стандартом для определения причинно-следственных связей, они не всегда осуществимы. В этой главе мы обсуждаем несколько распространенных сценариев, в которых проведение контролируемых онлайн-экспериментов невозможно, и даем краткий обзор общих методов для таких ситуаций.

Глава 10

Дополнительные методы

Если все, что у вас есть, – это молоток, все предметы вокруг кажутся гвоздями.

– Абрахам Маслоу

Почему это важно: при проведении экспериментов вам необходимо генерировать идеи для тестирования гипотез, выработки и проверки показателей, а также искать обоснования для более широких выводов. Для этих нужд существуют такие методы, как исследование пользовательского опыта, фокус-группы, опросы, человеческая оценка и наблюдательные исследования, которые полезны для дополнения и развития здоровой культуры А/В-тестирования.

10.1. Пространство дополнительных методов

Чтобы проводить успешные А/В-эксперименты, нам нужны не только тщательность и строгость в анализе и создании платформы и инструментов для экспериментов, но также нам необходимы:

- идеи для экспериментов, т. е. *воронка идей*;
- проверенные показатели для измерения эффектов, которые нас волнуют;
- доказательства, подтверждающие или опровергающие гипотезы, когда невозможно провести проверочный эксперимент;
- необязательные показатели, дополняющие показатели, вычисленные в контролируемых экспериментах.

Для воронки идей следует использовать все имеющиеся в вашем распоряжении методы генерации идей, включая такие методы, как наблюдение за пользователями в исследованиях пользовательского опыта. Идеи, которые легко реализовать, мы рекомендуем протестировать напрямую, запустив управляемый эксперимент; однако для идей, которые обходятся дорого, можно использовать один из дополнительных методов для ранней оценки и отсеивания идей, чтобы снизить затраты на реализацию.

В качестве другого примера использования дополнительных методов можно назвать прокси-метрику для оценки удовлетворенности пользовате-

лей – сущность, которую довольно сложно измерить. Вы можете провести опрос и собрать данные об удовлетворенности пользователей, полученные с их слов, а затем проанализировать данные инструментальных наблюдений, чтобы увидеть, какие крупномасштабные показатели коррелируют с результатами опроса. Затем вы можете продолжить исследование, запустив контролируемые эксперименты для проверки предполагаемых прокси-метрик.

Методы, обсуждаемые в этой главе, можно условно распределить по двум осям: масштабу (т. е. количеству пользователей) и глубине информации для каждого пользователя, как показано на рис. 10.1, и, рассмотрев каждый из них поочередно, мы найдем компромисс обобщаемости между необходимой глубиной информации и охватом пользователей.




Рис. 10.1. Количество пользователей в зависимости от глубины информации на пользователя

10.2. Анализ на основе журналов

Одним из предварительных условий для проведения доверительных А/В-экспериментов является наличие надлежащего инструментария пользовательских представлений, действий и взаимодействий для вычисления показателей контролируемых экспериментов. То же самое верно и для *анализа на основе журналов*, также называемого *ретроспективным анализом*. Польза от ретроспективного анализа заключается в следующем:

- **развитии понимания.** Найдите ответы на вопросы, помогающие сформировать показатели:

- ♦ каково распределение сеансов на пользователя или CTR?
- ♦ в чем разница по ключевым сегментам, например по странам или платформам (см. главу 3)?
- ♦ как эти распределения меняются со временем? Как со временем растет число пользователей?

Понимание этих моментов поможет вам оценить базовый уровень вашего продукта и системы, каковы различия, что происходит органически независимо от экспериментов, какое изменение размера может быть практически значительным и многое другое;

- **характеризации потенциальных показателей:** развитие понимания является предпосылкой для характеристики потенциальных показателей. Характеризация помогает понять дисперсию и распределение, как новые показатели соотносятся с существующими. Анализ на основе журнала позволяет увидеть, как потенциальный показатель мог бы работать в прошлых экспериментах. Например, был бы он полезен для принятия решений? Предоставляет ли он новую/лучшую информацию, чем существующие показатели?
- **выработке идей для А/В-экспериментов на основе изучения базовых данных:** вы можете изучить коэффициент конверсии на каждом этапе воронки покупки, чтобы выявить большие провалы. Анализ данных по сеансам пользователей может показать, что конкретная последовательность действий заняла больше времени, чем ожидалось. Этот подход вдохновит вас на идеи о том, как улучшить ваш продукт, независимо от того, вводите ли вы новые функции или изменяете дизайн пользовательского интерфейса;
- **изучении реализуемости идей,** созданных с помощью этих дополнительных методов, в большом масштабе и проверке, стоит ли тратить время на их реализацию и оценку с помощью А/В-эксперимента. Например, прежде чем вкладывать средства в упрощение доступа к вложениям электронной почты, оцените верхнюю границу воздействия, проанализировав количество отправленных вложений;
- **естественных экспериментах:** они происходят время от времени либо из-за внешних обстоятельств (например, внешняя компания меняет какие-то параметры по умолчанию), либо из-за ошибок (например, ошибки, из-за которой все пользователи выходят из системы). В таких случаях выполните наблюдательный анализ (см. главу 11), чтобы измерить эффект;
- **наблюдательных исследованиях причинно-следственных связей** (см. главу 11): вы можете проводить эти исследования, когда эксперименты невозможны, например вы можете использовать квазиэкспериментальные планы. Использование квазиэкспериментов в сочетании с экспериментами может способствовать достижению более общего результата.

Анализ журналов может служить многим целям, дополняющим A/B-эксперименты. Ограничение состоит в том, что такой анализ может делать выводы о том, что произойдет в будущем, только на основании того, что произошло в прошлом. Например, вы можете принять решение не вкладывать дополнительные средства в функцию обработки вложений электронных писем, поскольку в настоящее время ее используют мало; однако текущая низкая востребованность могла быть вызвана тем фактом, что ее трудно использовать, а это невозможно выявить только анализом журналов. Комбинирование анализа на основе журналов с исследованием пользователей и рынка, как мы обсудим далее в этой главе, дает более полную картину.

10.3. ЭКСПЕРТНАЯ ОЦЕНКА

Экспертная оценка – это когда компания платит специально нанятым людям, так называемым *оценщикам* или *рейтерам* (rater), за выполнение некоторой задачи. Затем результаты их оценки применяются в последующем анализе. Это распространенный метод оценки в поисковых и рекомендательных системах. Простые рейтинги могут быть построены на вопросах наподобие «Какую сторону вы предпочитаете, А или В?» или «Является ли это изображение порнографическим?» или выглядят сложнее, например: «Добавьте метку к этому изображению» или «Насколько релевантен этот результат для данного запроса?» Более сложные оценочные задачи могут иметь подробные инструкции для обеспечения более точных нормализованных оценок. Обычно одна и та же задача поручается нескольким оценщикам, поскольку оценщики могут иметь разные мнения; вы можете использовать различные механизмы голосования или другие механизмы разрешения разногласий для получения высококачественной совокупной оценки. Например, качество данных из платежных систем, таких как Mechanical Turk, варьируется в зависимости от стимулов и суммы платежа, что увеличивает важность контроля качества и разрешения разногласий.

Одним из ограничений экспертной оценки является то, что оценщики обычно не являются вашими целевыми пользователями. Оценщики лишь выполняют возложенные на них задачи – часто мимоходом, в то время как ваш продукт – это то, что ваши конечные пользователи естественным образом вносят в свою жизнь. Кроме того, оценщики могут упустить из виду локальный контекст реальных пользователей. Например, поисковый запрос «5/3» для многих оценщиков является арифметическим запросом и предполагает результат 1,667, однако пользователи, живущие рядом с банком Fifth Third Bank¹, логотипом которого является «5/3», ожидают увидеть ин-

¹ Fifth Third Bank – американская банковская корпорация со штаб-квартирой в Цинциннати, штат Огайо, являющаяся основным дочерним предприятием холдинговой компании Fifth Third Bancorp. Название Fifth Third Bank является результатом слияния Fifth National Bank и Third National Bank. – *Прим. перее.*

формацию об этом банке. Это пример того, как сложно оценить алгоритмы персонализированных рекомендаций. Однако это ограничение также может быть преимуществом, поскольку оценщиков можно обучить обнаруживать спам или другие вредоносные действия, которые обычные пользователи могут не суметь понять или обнаружить. Лучше всего полагать, что ваша экспертная оценка предоставляет откалиброванные маркированные данные, которые дополняют данные, полученные от реальных пользователей.

Вы можете использовать показатели, основанные на экспертной оценке, в качестве дополнительных показателей для оценки A/B-экспериментов. Опять же, давайте воспользуемся изменениями поискового рейтинга. Вы можете попросить экспертов оценить результаты некоторого запроса, предоставленные контрольной или тестовой группе, и суммировать оценки, чтобы увидеть, какой вариант предпочтительнее; или использовать параллельный эксперимент, в котором результаты поиска для контрольной и тестовой группы отображаются рядом, а эксперты оценивают, какая из сторон «лучше». Например, масштабируемые программы экспертной оценки Bing и Google достаточно быстры, чтобы их можно было использовать вместе с результатами контролируемых онлайн-экспериментов и принимать решение, следует ли вносить изменения.

Результаты экспертной оценки также полезны для отладки: вы можете детально изучить результаты, чтобы понять, где изменения работают хорошо, а где плохо. В нашем примере поискового запроса результаты, получившие плохую оценку, могут быть исследованы, чтобы определить, почему алгоритм вернул такой результат. Вы также можете объединить экспертную оценку с анализом на основе журнала, чтобы понять, какие наблюдаемые действия пользователя коррелируют с наиболее релевантными результатами запроса.

10.4. ИССЛЕДОВАНИЕ ПОЛЬЗОВАТЕЛЬСКОГО ОПЫТА

Хотя *исследование пользовательского опыта* (user experience research, UER) использует множество методов, мы сосредоточим внимание на подмножестве полевых и лабораторных исследований, которые углубленно изучают ограниченный круг пользователей, наблюдая за их выполнением интересующих задач и ответами на вопросы либо в лабораторных условиях, либо *in situ* (в естественной среде, лат.). Этот тип исследования является глубоким и интенсивным, как правило, с участием не более десятков пользователей и полезен для генерации идей, выявления проблем и получения информации путем прямого наблюдения и своевременных вопросов. Например, если вы развиваете интернет-магазин, вы можете наблюдать, как пользователи пытаются совершить покупку, и разрабатывать идеи для показателей на основе наблюдения за тем, где они преодолевают трудности: может быть, покупка занимает много времени? Испытывают ли пользователи проблемы и вынуждены идти в «кроличью нору», например в поисках кода купонов?

В данных типах полевых и лабораторных исследований могут применяться:

- специальное оборудование для сбора данных, таких как трекинг движений глаз, которые вы не можете получить с помощью своих инструментов;
- дневниковые исследования, при которых пользователи самостоятельно документируют свое поведение в долгосрочном плане. Дневники полезны для сбора данных, аналогичных онлайн-инструментам, но дополняются данными, которые вы не можете собрать с помощью инструментов, например намерениями пользователей или внешними действиями.

Эти методы могут быть полезны для генерации измерительных идей, основанных на корреляции «истинного» намерения пользователя с тем, что мы наблюдаем с помощью инструментов. Вы должны подтвердить эти идеи, используя методы, которые масштабируются для большего числа пользователей, такие как наблюдательный анализ и контролируемые эксперименты.

10.5. Фокус-группы

Фокус-группы – это групповые обсуждения с действующими или потенциальными пользователями. Вы можете направить обсуждение на любой диапазон тем – от широких вопросов об отношении пользователей до более конкретных вопросов, возможно, используя снимки экрана или демонстрационный пример для получения обратной связи.

Фокус-группы более масштабируемы, чем исследование UER, и пригодны для обсуждения неоднозначных открытых вопросов аналогичного уровня, которые могут служить ориентиром при разработке продукта и гипотез. Однако, учитывая групповой характер и формат обсуждения, можно охватить меньше вопросов, чем в исследовании UER, а выводы могут стать жертвой группового мышления и совпадения мнений. То, что клиенты говорят в рамках фокус-группы или опроса, может не соответствовать их истинным предпочтениям. Есть хорошо известный пример этого явления, когда Philips Electronics провела фокус-группу для выяснения предпочтений подростков в отношении параметров музыкальных центров Boombox. Во время обсуждения в фокус-группе участники выразили явное предпочтение магнитофонам в желтом корпусе, охарактеризовав черные магнитофоны как «консервативные». Тем не менее, когда участники вышли из комнаты и получили возможность забрать домой магнитофон в качестве награды за свое участие, большинство выбрало черный цвет.

Фокус-группы могут быть полезны для получения отзывов о плохо сформулированных гипотезах на ранних этапах разработки изменений, которые станут будущими экспериментами, или для попытки понять лежащие в основе эмоциональные реакции, часто на изменения в бренде или маркетинге.

Опять же, цель состоит в том, чтобы собрать информацию, которую невозможно измерить с помощью инструментов, и получить обратную связь о еще не полностью сформированных изменениях, чтобы способствовать дальнейшему процессу проектирования.

10.6. ОБЗОРЫ

Чтобы провести опрос, вы набираете популяцию, члены которой ответят на ряд вопросов. Количество вопросов может быть разным, как и их тип. У вас может быть несколько вариантов ответов или открытые вопросы, на которые пользователи дают ответы в произвольной форме. Это можно сделать лично, по телефону или онлайн прямо в вашем приложении, на сайте или с помощью других методов охвата и таргетинга пользователей (например, Google Surveys). Вы также можете проводить опросы внутри продуктов, потенциально объединяя их с контролируруемыми экспериментами. Например, операционная система Windows предлагает пользователям один или два коротких вопроса об операционной системе и о других продуктах Microsoft; у Google есть способ задать быстрый вопрос, связанный с впечатлениями пользователя от продукта и его удовлетворенностью.

Хотя опросы могут показаться простыми, на самом деле их довольно сложно разработать и проанализировать:

- вопросы должны быть тщательно сформулированы, поскольку они могут быть неверно истолкованы или непреднамеренно побудить респондентов дать определенные или неоткалиброванные ответы. Порядок вопросов может повлиять на то, как респонденты ответят. И если вы хотите получать данные в течение длительного времени, вам нужно быть осторожным с изменениями в опросе, поскольку изменения могут со временем сделать сравнения недействительными;
- ответы формулируются субъективно: пользователи не могут давать полные или правдивые ответы даже в анонимных опросах;
- популяция легко может оказаться предвзятой и нерепрезентативной для истинной популяции пользователей. Это усугубляется «предвзятостью ответа», т. е. сам факт ответа может быть предвзятым (например, отвечают только недовольные люди). Из-за этой предвзятости относительные результаты опроса (например, от одного периода времени к другому) могут быть более полезными, чем абсолютные результаты.

Эти ловушки предполагают, что опросы почти никогда нельзя напрямую сравнивать с какими-либо результатами, наблюдаемыми с помощью средств измерения. Вы можете использовать опросы для охвата большего числа пользователей, чем UER или фокус-группы, но они в первую очередь полезны для получения ответов на вопросы, которые вы не можете извлечь из ваших инструментальных данных, например что происходит,

когда у пользователя нет доступа к интернету, или оценки мнения пользователей, доверия и уровня удовлетворенности. Мы можем задать вопрос, какую еще информацию использовал пользователь при принятии решения о покупке, в том числе о простых действиях, таких как разговор с другом или вопрос об уровне удовлетворенности пользователя через три месяца после покупки. Опросы также полезны для отслеживания тенденций по вопросам, не поддающимся непосредственному измерению, таким как доверие или репутация, и иногда используются для корреляции с тенденциями по сильно агрегированным бизнес-показателям, таким как общее использование или рост. Эта корреляция может затем стимулировать инвестиции в такую размытую область, как повышение доверия пользователей, но необязательно генерировать конкретные идеи. Вы можете воспользоваться исследованиями UER для генерации идей, как только вы определили широкую область.

В зависимости от согласия участников опроса вы можете соединить результаты опроса с анализом наблюдений, чтобы увидеть, какие ответы на опрос коррелируют с наблюдаемым поведением пользователей, но предвзятость респондентов опроса повлияет на достоверность и обобщаемость результатов.

10.7. ВНЕШНИЕ ДАННЫЕ

Внешние данные – это данные, относящиеся к вашей компании и к предмету вашего исследования, собранные и проанализированные внешней стороной. Есть несколько источников внешних данных.

- Компании, предоставляющие детализированные данные по каждому сайту (например, это количество пользователей веб-сайта или подробная информация об онлайн-привычках пользователей) на основе данных, собранных при наборе большой группы пользователей, которые согласились на отслеживание всех их действий в сети. Здесь возникает вопрос о репрезентативности этих пользователей – хотя они отбираются из четких демографических сегментов, могут быть и другие различия в пользователях, согласившихся на отслеживание на этом уровне детализации.
- Компании, предоставляющие детализированные данные по каждому пользователю, например сегменты пользователей, которые потенциально могут быть объединены с данными на основе журналов.
- Компании, проводящие опросы и анкеты для самостоятельной публикации, или те, кого вы можете нанять для проведения индивидуальных опросов. Эти компании используют различные методы, чтобы ответить на вопросы, которые могут вас заинтересовать, например сколько устройств есть у пользователей или их мнение о том, насколько заслуживает доверия бренд.

- Опубликованные научные статьи. Исследователи часто публикуют материалы, представляющие интерес. Есть много статей, например, посвященных отслеживанию взгляда – то, на что пользователь смотрел в лаборатории во время работы с поисковой системой, дает вам хорошее представление о том, насколько репрезентативны ваши данные о кликах.
- Компании и веб-сайты, предлагающие готовые выработанные рекомендации, часто используют результаты краудсорсинга для подтверждения рекомендаций. Это могут быть шаблоны проектирования пользовательского интерфейса.

Если ваш сайт присутствует в одном из списков провайдера внешних данных, это поможет вам проверить простые бизнес-метрики. Например, если вы хотите узнать общее количество посетителей вашего сайта, вы можете сравнить свое значение, вычисленное на основе внутреннего наблюдательного анализа, с числами, предоставленными службами comScore или Hitwise, или можете сравнить долю покупательского трафика в каждой «вертикальной» категории с тем, что вы видите на своем сайте. Эти числа редко будут точно совпадать. Лучший способ выполнить проверку – это посмотреть на временные ряды как внутренних, так и внешних данных, чтобы увидеть, совпадают ли временные ряды с точки зрения тренда или сезонной изменчивости. Вы также можете найти подтверждения своих бизнес-метрик либо непосредственно измеряемых величин или хотя бы получить представление о том, какие измеримые показатели служат хорошим заменителем других, более сложных для измерения параметров.

В общедоступных научных статьях, например касающихся пользовательского опыта, часто упоминается общая эквивалентность различных типов показателей. В одном примере сравнивается удовлетворенность поисковой задачей, о которой сообщают пользователи, с измеренной продолжительностью задачи, что дает хорошую общую корреляцию между удовлетворенностью и продолжительностью, хотя и с оговорками. Это исследование помогло проверить показатель *продолжительность*, который может быть выражен численно и коррелирует с показателем, который невозможно представить численно – удовлетворенность пользователей.

Внешние данные также могут добавить уровень к иерархии доказательств. Например, компании могут использовать опубликованные работы Microsoft, Google и других крупных игроков, чтобы установить, что задержка и производительность важны, без необходимости проведения собственных контролируемых онлайн-экспериментов (см. главу 5). Компаниям придется провести собственные эксперименты, чтобы найти конкретные компромиссы для своего продукта, но в небольшой компании, не обладающей ресурсами, общее направление и инвестиции могут быть основаны на внешних данных.

Внешние данные также могут послужить основой для исследований о том, как ваша компания выглядит на фоне конкурентов. Исходя из этого

вы можете провести сравнительный анализ своих бизнес-показателей и понять, чего можете достичь на текущем этапе.

Одно предостережение: поскольку вы не контролируете выборку или не знаете точные методы, используемые для проведения анализа, абсолютные числа не всегда могут быть полезны, но тенденции, корреляции, а также разработка и проверка показателей – все это хорошие варианты использования внешних данных.

10.8. Подведем итог главы

Существует множество способов сбора данных о пользователях, вопрос лишь в том, как выбрать, какой из них использовать. Во многом это зависит от вашей цели. Вы хотите выяснить, как измерить конкретный пользовательский опыт? Вы хотите проверить показатели? Если вы не знаете, какие показатели собирать в первую очередь, лучше подойдут более подробные, качественные, интеллектуально нагруженные методы, такие как исследования UER или фокус-группы. Если нет возможности получить данные, потому что взаимодействия происходят не на вашем сайте, вам придется опросить пользователей. Для проверки показателей хорошо подходят внешние данные и анализ наблюдений, поскольку данные обычно собираются по достаточно большой совокупности, чтобы уменьшить ошибку выборки или другие проблемы измерения.

Все эти методы содержат компромиссы. Вы должны учитывать, от скольких людей вы можете собирать данные. Это влияет на возможность обобщения результатов; другими словами, от этого зависит, можете ли вы установить внешнюю значимость. Количество пользователей часто является компромиссом с тем, какую детализацию вы можете получить. Например, журналы обычно содержат обширные записи действий пользователя, но не пояснения, «почему» пользователь действует определенным образом, как вы могли бы выяснить в полевом исследовании UER. Также следует учитывать, на какой стадии производственного цикла вы находитесь. На раннем этапе, когда у вас слишком много идей для тестирования, имеет смысл применить методы качественной оценки, такие как фокус-группы и исследование пользовательского опыта. И по мере того, как вы приближаетесь к количественным данным, все больше смысла приобретают наблюдения и эксперименты.

Наконец, помните, что надежность результатов возрастает при использовании нескольких методов триангуляции для более точного измерения – установлении иерархии доказательств. Поскольку ни один метод не может полностью воспроизвести результаты другого метода, используйте несколько методов для определения границ ответа. Например, чтобы увидеть, довольны ли пользователи вашими индивидуальными рекомендациями по продукту, вы должны определить признаки «удовольствия». Для этого вы

можете наблюдать за пользователями в исследовании UER, видеть, используют ли они персонализированные рекомендации, и задавать им вопросы о том, считают ли они эти рекомендации полезными. Основываясь на этой обратной связи, вы можете посмотреть данные наблюдений для этих пользователей и увидеть, какие поведенческие сигналы вы можете отследить, например более длительное время чтения экрана или определенный порядок кликов. Затем вы можете провести большой наблюдательный анализ, чтобы проверить идеи показателей, полученные в результате небольшого исследования UER, увидеть взаимодействие с общими бизнес-метриками, а затем потенциально подкрепить это экранным опросом, чтобы охватить более широкий круг пользователей простыми вопросами о том, понравились ли им рекомендации. Сочетание этого исследования с обучающими экспериментами, которые изменяют рекомендации, позволит вам лучше понять, как показатели удовлетворенности пользователей соотносятся с общими бизнес-показателями, и улучшить ваш ОЕС.

Глава 11

Наблюдательные исследования причинно-следственных связей

Слабые люди верят в удачу. Сильные люди верят в причину и следствие.
– Ральф Уолдо Эмерсон

Почему это важно: рандомизированные контролируемые эксперименты – золотой стандарт для установления причинно-следственной связи, но иногда проведение такого эксперимента невозможно. Учитывая, что организации собирают огромные объемы данных, существуют методики исследований, которые можно использовать для оценки причинно-следственной связи, хотя и с более низким уровнем доверия. Если контролируемый онлайн-эксперимент невозможен, вам пригодятся наблюдательные исследования.

11.1. Когда контролируемые эксперименты НЕВОЗМОЖНЫ

Как изменится взаимодействие с продуктом, если пользователь сменит марку телефона с iPhone на Samsung? Сколько пользователей вернется, если мы принудительно прервем их сеанс в системе? Что произойдет с доходом, если коды купонов будут введены как часть бизнес-модели? Для всех этих вопросов цель состоит в том, чтобы измерить причинно-следственную связь между воздействием и откликом, для чего необходимо сравнить свойства двух популяций – контрольной и подвергшейся воздействию. «Основная сущность причинного вывода» выглядит следующим образом (Varian, 2016):

Результат с воздействием – Результат без воздействия =
[Результат с воздействием – Результат с воздействием, при отсутствии воздействия] +
[Результат с воздействием, при отсутствии воздействия – Результат без воздействия] =
Влияние воздействия на тестовую популяцию + Ошибка смещения

– и показывает, что сравнение фактического воздействия (что происходит с тестовой популяцией) с контрфактическим (что произошло бы, если бы воздействия не было) является критическим понятием для установления причинной связи.

Контролируемые эксперименты являются золотым стандартом для оценки причинно-следственной связи, потому что при случайном назначении экспериментальных единиц вариантам первый член – это наблюдаемая разница между тестом и контролем, а второй член имеет ожидаемое значение, равное нулю.

Однако иногда невозможно должным образом провести контролируемый эксперимент. Рассмотрим несколько примеров таких ситуаций:

- когда организация не контролирует проверяемое причинное действие. Например, вы хотите понять, как меняется поведение пользователя, когда он переходит с iPhone на Samsung Galaxy. Даже если вы – Samsung и у вас есть рычаги, побуждающие потенциально рандомизируемых пользователей к переходу, обычно вы не контролируете выбор пользователей и платите людям за переход, искажая результаты;
- когда подопытных единиц слишком мало. Например, в сценарии слияния и поглощения (M&A) происходит (или не происходит) только одно событие, и очень сложно оценить противоположный вариант;
- при формировании контрольной популяции могут возникнуть слишком большие альтернативные издержки. Например, рандомизированные эксперименты могут оказаться дорогостоящими для редких событий, таких как определение влияния показа рекламы во время Суперкубка или когда желаемый ОЕС требует слишком много времени для измерения, например коэффициент возврата к веб-сайту для покупки нового автомобиля через пять лет после покупки текущего;
- когда изменение стоит дорого по сравнению с воспринимаемой ценностью. Некоторые эксперименты проводятся, чтобы попытаться лучше понять взаимосвязи. Например, сколько пользователей уйдет, если вы начнете принудительно прерывать сеансы всех пользователей через определенный период времени? Или что, если вы перестанете показывать рекламу в такой поисковой системе, как Bing или Google?
- когда желаемая единица рандомизации не может быть рандомизирована должным образом. При измерении ценности телеобъявлений их практически невозможно рандомизировать по зрителям. Альтернатива в виде использования *назначенных рыночных зон* (designated market area, DMA) приводит к гораздо меньшему количеству единиц (например, около 210 в США) и, следовательно, к низкой статистической мощности даже при использовании таких методов, как формирование пар;

- когда предмет тестирования является неэтичным или незаконным, например отказ от лечения, которое считается полезным.

В вышеупомянутых ситуациях часто лучшим подходом является оценка эффектов с использованием нескольких методов, которые находятся ниже в иерархии доказательств, т. е. поиск ответа на вопрос при помощи нескольких методов, включая мелкомасштабные исследования пользовательского опыта, опросы и наблюдательные исследования. Некоторые из этих методов мы обсуждали в главе 10.

В этой главе мы сосредоточимся на оценке причинно-следственного эффекта наблюдательных исследований, которые будем называть *наблюдательными исследованиями причинно-следственных связей*. В некоторых книгах используют термин *наблюдательные (причинные) исследования* для обозначения исследований, в которых нет манипуляций с объектами, а термин *квазиэкспериментальные планы* – для исследований, в которых объекты распределяются по вариантам, но распределение не является случайным. Обратите внимание, что мы отличаем наблюдательное исследование причинно-следственных связей от более общего наблюдательного или ретроспективного анализа данных. Хотя оба они выполняются на исторических данных журнала, цель исследования причинно-следственных связей состоит в том, чтобы попытаться получить результат, как можно более близкий к причинно-следственному описанию. В свою очередь ретроспективный анализ данных, как обсуждалось в главе 10, преследует другие цели, включая обобщение распределений и рассмотрение, насколько распространены определенные поведенческие паттерны, анализ возможных показателей и поиск интересных закономерностей. Впоследствии эти исследования могут вылиться в гипотезы для проверки в контролируемых экспериментах.

11.2. Планы для наблюдательных исследований причинно-следственных связей

При наблюдательных исследованиях причинно-следственных связей возникают следующие проблемы:

- как построить контрольную и тестовую группы для сравнения;
- как смоделировать воздействие, оказываемое этими контрольными и тестовыми группами.

11.2.1. Прерывистый временной ряд

Прерывистый временной ряд (interrupted time series, ITS) – это квазиэкспериментальный план, в котором вы можете контролировать изменения в своей

системе, но не можете рандомизировать воздействие, чтобы иметь надлежащую контрольную и тестовую популяцию. Вместо этого вы используете одну и ту же популяцию для контроля и тестирования и меняете то, что она испытывает с течением времени.

В частности, план использует несколько измерений во времени до воздействия для создания модели, которая может предоставить оценку интересующего показателя после воздействия – т. е. контрфактуальную. После воздействия также проводится несколько измерений, и эффект воздействия оценивается как средняя разница между фактическими значениями интересующего показателя и значениями, предсказанными моделью. Одним из дополнений к простому плану ITS является применение воздействия, а затем его отмена; при необходимости эту процедуру повторяют несколько раз. Например, влияние полицейского наблюдения с вертолета на домашние кражи со взломом оценивалось с использованием нескольких циклов воздействия, поскольку в течение нескольких месяцев наблюдение осуществлялось и прекращалось несколько раз. Каждый раз, когда осуществлялось наблюдение с вертолета, количество краж со взломом уменьшалось; каждый раз, когда наблюдение прекращали, количество краж со взломом увеличивалось. В сети аналогичный пример – изучение влияния интернет-рекламы на посещения сайтов, связанных с поиском. Обратите внимание, что для определения эффекта может потребоваться сложное моделирование с анализом байесовских структурных временных рядов (рис. 11.1).

Одна из распространенных проблем, связанных с исследованиями причинно-следственных связей, заключается в том, чтобы гарантировать, что вы не приписываете какой-либо эффект изменению, хотя на самом деле имеется некоторый совместный эффект. Наиболее распространенные проблемы ITS – это временные эффекты, поскольку сравнения производятся в разные моменты времени. Очевидный пример – сезонность, но вас также могут сбивать с толку и другие системные изменения. Эти побочные эффекты могут быть сглажены за счет многократного переключения между воздействием и бездействием. Другая проблема при использовании ITS – это взаимодействие с пользователем: заметят ли пользователи, что их опыт переключается туда-сюда? Если это так, то эффект может быть вызван не самим воздействием, а раздражением и недовольством пользователей.




Рис. 11.1. Прерывистые временные ряды с использованием байесовских структурных временных рядов. График (а) показывает точность модели в период до воздействия и фактический наблюдаемый показатель сплошной линией, а пунктирной линией – предсказанное расхождение. По оси абсцисс отложены дни с окрашенными вертикальными полосами, обозначающими выходные. График (б) показывает разницу между фактическим и прогнозным значением; если модель хороша, то это оценка эффекта воздействия. Выходные закрашены серым

11.2.2. Эксперименты с чередованием

План *экспериментов с чередованием* – это распространенный план, используемый для оценки изменений алгоритма ранжирования, например в поисковых системах или при поиске на веб-сайте. В эксперименте с чередованием у вас есть два алгоритма ранжирования, X и Y . Алгоритм X покажет результаты $x_1, x_2, \dots, x_n$ в этом порядке, а алгоритм Y покажет $y_1, y_2, \dots, y_n$. Эксперимент с чередованием будет чередовать результаты, смешанные вместе, например $x_1, y_1, x_2, y_2, \dots, x_n, y_n$ с удалением повторяющихся результатов. Один из способов оценить алгоритмы – это сравнить рейтинг кликов по результатам двух алгоритмов. Хотя это мощный экспериментальный план, его применимость ограничена, поскольку результаты должны быть однородными. Если, как это часто бывает, первый результат занимает больше места или влияет на другие области страницы, возникают сложности.

11.2.3. Метод разрывной регрессии

Метод разрывной регрессии (regression discontinuity design, RDD) – это план эксперимента, который можно использовать всякий раз, когда есть четкий порог, который идентифицирует исследуемую популяцию. Основываясь на этом пороговом значении, мы можем уменьшить систематическую ошибку

отбора, определяя популяцию, которая чуть ниже порога, как контрольную, а популяцию, которая чуть выше порога, как тестовую.

Например, когда присуждается стипендия, легко определить победителей. Если стипендия предоставляется учащимся, набравшим 80 % от максимального балла, то предполагается, что тестовая группа, получившая оценки чуть выше 80 %, аналогична контрольной группе, получившей оценки чуть ниже 80 %. Предположение нарушается, когда участники могут повлиять на воздействие; например, если критерием служит проходной балл, но учащиеся могут убедить своих учителей «смиловаться». Пример использования RDD – оценка влияния употребления алкоголя на смертность: американцы старше 21 года могут пить алкогольные напитки легально, поэтому мы можем рассмотреть количество смертей по дням рождения, как показано на рис. 11.2. «Риск смертности возрастает сразу после 21-го дня рождения... примерно на 100 смертей относительно базового уровня около 150 в день. Скачок в возрасте 21 года, похоже, не является обычным следствием празднования дня рождения. Если бы этот всплеск отражал просто вечеринки по случаю дня рождения, мы наблюдали бы увеличение числа смертей и после 20-го и 22-го дня рождения, но этого не происходит» (Angrist and Pischke, 2014).

Как и в приведенном выше примере, ключевой проблемой снова является наложение факторов. В RDD поведение показателя может быть искажено другими факторами, которые связаны с тем же порогом. Например, исследование влияния алкоголя, в котором в качестве порогового значения выбирается возраст, равный 21 году, может быть загрязнено тем фактом, что это также порог для легального участия в азартных играх.




Рис. 11.2. Смертность в зависимости от 20-го, 21-го и 22-го дня рождения (Angrist and Pischke 2014)

RDD чаще всего применяется, когда есть алгоритм, который генерирует оценку, и что-то происходит на основе порогового значения этой оценки. Обратите внимание, что, когда это происходит в программном обеспечении, хотя одним из вариантов является использование RDD, это также сценарий, который легко поддается рандомизированным контролируемым экспериментам или некоторому их гибриду.

11.2.4. Инструментальные переменные и естественные эксперименты

Инструментальные переменные (instrumental variables, IV) – это метод, который пытается аппроксимировать случайное назначение. В частности, цель состоит в том, чтобы найти *инструмент*, который позволяет нам аппроксимировать случайное распределение (это органично происходит в естественном эксперименте).

Например, при анализе разницы в заработках ветеранов и неветеранов выборочный призыв на войну во Вьетнаме аппроксимирует случайный призыв людей в армию; места в частных спецшколах распределяются посредством лотереи и, таким образом, могут быть хорошим инструментом для некоторых исследований. В обоих примерах лотерея не гарантирует соответствие, но оказывает на него большое влияние. Затем для оценки эффекта обычно используется двухэтапная регрессионная модель наименьших квадратов.

Иногда возможно проведение *естественных экспериментов* (natural experiment), которые «практически случайны». В медицине монозиготные близнецы позволяют проводить исследования близнецов как вполне естественные эксперименты. При изучении социальных или одноранговых сетей проведение контролируемых экспериментов над участниками становится сложной задачей, поскольку эффект не может быть ограничен только подопытной популяцией из-за общения между участниками. Однако очереди уведомлений и порядок доставки сообщений – это типы естественных экспериментов, которые можно использовать для понимания влияния уведомлений на вовлеченность.

11.2.5. Отбор подобного по склонности

Другой класс подходов состоит в построении сопоставимых контрольных и подопытных групп, часто путем сегментации пользователей на основании общих специфических свойств или склонностей к чему-либо, – это что-то вроде стратифицированной выборки. Идея состоит в том, чтобы гарантировать, что различие между контрольной и подопытной популяциями не связано с изменениями состава популяции. Например, если мы изучаем экзогенное изменение воздействия перехода пользователей с Windows на iOS, то хотим убедиться, что мы не измеряем демографическую разницу в населении.

Мы можем продолжить этот подход, перейдя к *отбору подобного по склонности* (propensity score matching, PSM), которое вместо сопоставления

единиц на ковариатах сопоставляет одно число: сформированную оценку склонности (Rosenbaum and Rubin, 1983). Этот подход использовался в онлайн-пространстве, например для оценки воздействия рекламных кампаний в интернете. Ключевое беспокойство по поводу PSM заключается в том, что учитываются только наблюдаемые ковариаты; неучтенные факторы могут привести к скрытым предубеждениям. Джуды Перл (Judea Pearl, 2009) писала: «Розенбаум и Рубин ... очень ясно предупреждали практикующих, что оценка предрасположенности работает только в условиях “сильного игнорирования”. Однако они не смогли понять, что недостаточно предупредить людей об опасностях, которые они не могут распознать». Кинг и Нильсен (King and Nielsen, 2018) утверждают, что PSM «часто достигает противоположной цели – тем самым увеличивая дисбаланс, неэффективность, зависимость от модели и предвзятость».

Для всех этих методов основной проблемой является наложение факторов.

11.2.6. Дифференциальная разница

Многие из вышеперечисленных методов сосредоточены на том, как определить контрольную группу, которая максимально похожа на подопытную. В продолжение описания этого подхода можно сказать, что одним из методов измерения эффекта является *метод дифференциальной разницы* (difference in differences, DD или DID), который учитывает разницу в различиях в контрольной и подопытной группе. Иными словами, группы «могут различаться при отсутствии воздействия, но двигаться параллельно» (Angrist and Pischke, 2014).

Этот метод обычно используется в географических экспериментах. Допустим, вы хотите понять влияние телерекламы на привлечение, взаимодействие и удержание пользователей. Вы запускаете телевизионную рекламу в одном DMA и сравниваете ее с другим DMA. Например, как показано на рис. 11.3, в подопытную группу во время T1 вносятся изменения. Измерения проводятся в той и другой группе непосредственно перед T1 и в более позднее время T2. Предполагается, что разница в представляющих интерес показателях, таких как ОЕС, между двумя периодами в контрольной группе отражает внешние факторы (например, сезонность, состояние экономики, инфляцию) и, таким образом, представляет собой контрфактический пример того, что произошло бы с подопытной группой. Эффект воздействия оценивается как разница в интересующем показателе за вычетом разницы в контрольной группе для этого показателя за тот же период.

Обратите внимание, что этот метод также можно применять, даже если вы не вносите изменения и они происходят экзогенно. Например, когда в штате Нью-Джерси было внесено изменение в минимальную заработную плату, исследователи, которые хотели изучить его влияние на уровень занятости в ресторанах быстрого питания, сравнили его с восточной Пенсильванией, которая соответствовала многим характеристикам (Card and Krueger 1994).




Рис. 11.3. Разница в различиях

11.3. ЛОВУШКИ ПРИЧИННО-СЛЕДСТВЕННЫХ СВЯЗЕЙ

Хотя наблюдательные исследования причинно-следственных связей иногда являются наилучшим вариантом, они скрывают много подводных камней, о которых вам следует знать. Как упоминалось выше, основная ошибка, независимо от метода, при проведении наблюдательных исследований причинно-следственных связей – это непредвиденные заблуждения, которые могут повлиять на измеряемый эффект или привести к попытке объяснить причинностью заурядную смену интересов. Из-за этих заблуждений наблюдательные исследования причинно-следственных связей требуют большой осторожности; иначе вы не получите заслуживающие доверия результаты. Существует множество примеров опровергнутых наблюдательных исследований причинно-следственных связей (см. раздел 11.4 и некоторые примеры в главе 17).

Один из распространенных типов заблуждений – это нераспознанная **общая причина**. Например, у людей размер ладони сильно коррелирует с продолжительностью жизни: в среднем чем меньше ваша ладонь, тем дольше вы проживете. Однако общей причиной меньших размеров ладоней и большей продолжительности жизни является пол: женщины имеют меньшие ладони и в среднем живут дольше (рис. 11.4).




Рис. 11.4. Не существует зависимости между размером ладони и продолжительностью жизни; пол является общей причиной, объясняющей и то и другое

Другой пример: для многих сервисов, в том числе Microsoft Office 365, чем больше пользователи сталкиваются с ошибками, тем *меньше* они покидают сервис! Но не пытайтесь увеличивать число ошибок, ожидая уменьшения оттока пользователей, так как эта корреляция обусловлена общей причиной: интенсивностью использования. Самые активные пользователи чаще сталкиваются с ошибками, но и уходят реже. Владельцы сервисов нередко обнаруживают, что пользователи новых функций реже покидают сервис, и делают вывод, что именно эта функция снижает отток. Действительно ли это влияние новой функции, или, что более вероятно, дело в том, что активные пользователи реже уходят и чаще пользуются новыми функциями? В этих случаях, чтобы оценить, действительно ли новая функция снижает отток, запустите управляемый эксперимент (и проанализируйте новых и активных пользователей по отдельности).

Еще одна ловушка, о которой следует помнить, – это **ложные, или обманчивые, корреляции**. Обманчивая корреляция может быть вызвана сильными выбросами, например как показано на рис. 11.5, где маркетинговая компания может заявить, что их энергетический напиток сильно коррелирует со спортивными результатами и подразумевает причинно-следственную связь: выпейте наш энергетический продукт, и ваши спортивные результаты улучшатся.



Рис. 11.5. Обманчивая корреляция между спортивными результатами и количеством потребляемого энергетического напитка. Корреляция не предполагает причинной связи!

Почти всегда можно найти ложные корреляции. Если мы проверяем множество гипотез и у нас нет глубокого понимания, чтобы отвергнуть причинное утверждение, как в приведенном выше примере, мы можем в них поверить. Например, если кто-то сказал вам, что он обнаружил фактор, который имеет сильную корреляцию ($r = 0,86$) с числом людей, убитых ядовитыми пауками, у вас может возникнуть соблазн действовать в соответствии с этой информацией. Однако, когда вы видите, что количество смертей коррелирует с длиной слова-победителя в конкурсе National Spelling Bee¹, как показано на рис. 11.6, вы быстро отклоняете идею о сокращении длины слова как неразумную.

Даже при соблюдении предосторожностей нет гарантии, что не будет другого фактора, не включенного в исследование причинно-следственных связей, но способного повлиять на результаты. Квазиэкспериментальные методы, выявляющие контрфакты для сравнения и последующего установления причинной связи, требуют принятия множества предположений, любое из которых может быть неверным, а некоторые предположения далеко не очевидны. Неправильные предположения могут привести к недостаточной внутренней валидности, но в зависимости от допущений и их ограниченности они также могут повлиять и на внешнюю валидность исследования. И хотя развитая система знаний, как мы говорили в главе 1, помогает улучшить качество предположений, она не решает все возможные

¹ Национальный конкурс по орфографии в США. Команды соревнуются в написании самых длинных и трудных слов. Словом-победителем считается слово, в котором команды совершили больше всего ошибок. Трудных слов, незнакомых командам, остается все меньше, поэтому проводить конкурс становится все сложнее. – *Прим. перев.*

проблемы. Поэтому золотым стандартом науки для установления причинной связи по-прежнему является контролируемый эксперимент.



Рис. 11.6. Ложная корреляция между количеством людей, убитых ядовитыми пауками, и длиной слова в National Spelling Bee

11.4. ПРИЛОЖЕНИЕ: ОПРОВЕРГНУТЫЕ ИССЛЕДОВАНИЯ ПРИЧИННО-СЛЕДСТВЕННЫХ СВЯЗЕЙ

Заявление о причинно-следственной связи на основе неконтролируемых наблюдений требует множества предположений, которые невозможно проверить и которые легко нарушаются. Хотя многие исследования причинно-следственных связей позже подтверждаются рандомизированными контролируемыми экспериментами, столь же многие не находят подтверждения. Иоаннидис (Ioannidis, 2005) оценил утверждения, полученные из высоко цитируемых исследований; из шести наблюдательных исследований причинно-следственных связей, включенных в его обзор, пять не удалось воспроизвести. Стэнли Янг и Алан Карр (Stanley Young, Alan Karr, 2019) сравнили опубликованные результаты медицинских гипотез, подтвержденных при наблюдательных (т. е. неконтролируемых) исследованиях причинно-следственных связей, с более надежными рандомизированными клиническими испытаниями. Из 52 утверждений в 12 статьях *ни одно* не было воспроизведено в рандомизированных контролируемых исследованиях. И в 5 случаях из 52 изменение оказалось статистически значимым в направлении, противоположном направлению исследования причинно-следственных связей. Авторы сделали вывод: «Любое утверждение, исходящее из наблюдательного исследования, скорее всего, будет ошибочным».

Одним из примеров из онлайн-пространства является попытка измерить эффективность интернет-рекламы, другими словами, приводит ли демонстрация онлайн-объявления к увеличению активности бренда или даже к вовлечению пользователей. Для измерения подобного эффекта часто требуются наблюдательные исследования причинно-следственных связей, поскольку воздействие (реклама) и эффект (подписка или взаимодействие пользователя) обычно реализуются на разных сайтах и, следовательно, в разных сферах контроля. Льюис, Рао и Рейли (Lewis, Rao, Reiley, 2011) сравнили оценку эффективности интернет-рекламы, сделанную с помощью наблюдательных исследований причинно-следственных связей, с контролируемыми экспериментами по «золотому стандарту» и обнаружили что в наблюдательных исследованиях причинно-следственных связей эффект рекламы сильно переоценивается. В частности, они провели три эксперимента.

Во-первых, пользователям была показана реклама, и вопрос заключался в следующем: каково увеличение (рост) числа пользователей, выполняющих поиск по ключевым словам, связанным с брендом, показанным в объявлении. При использовании нескольких наблюдательных исследований 50 млн пользователей, включая три регрессионных анализа с контрольными переменными, расчетный прирост составил от 871 до 1198 %. Этот расчетный прирост на несколько порядков выше прироста на 5,4 %, измеренного в контролируемом эксперименте. Заблуждение основано на том, что многие пользователи начинали посещение интернета с Yahoo!: пользователи, которые активно посещают Yahoo!, в определенный день с большей вероятностью *одновременно* увидят медийную рекламу и выполнят поиск. Показ рекламы и поведение при поиске сильно коррелируют, но медийная реклама оказывает очень небольшое причинное влияние на поиск.

Затем пользователям были показаны видеоролики, и вопрос был в том, приведут ли они к увеличению активности. Подбор пользователей осуществлялся через Amazon Mechanical Turk. Половине из них показали 30-секундную видеорекламу, продвигающую услуги Yahoo.com (воздействие), а другой половине – политическую видеорекламу (контроль), и цель заключалась в том, чтобы измерить, увеличилась ли активность пользователей на Yahoo!. Было проведено два анализа: наблюдательное исследование причинно-следственной связи экспериментальной группы до и после воздействия 30-секундной рекламы Yahoo! и экспериментального анализа, сравнивающего активность двух групп после просмотра рекламы. Наблюдательное исследование причинно-следственных связей преувеличило эффект рекламы на 350 %. Ошибка заключается в том, что активность на Amazon Mechanical Turk

в определенный день увеличивала шансы пользователей участвовать в эксперименте и одновременно быть активными на Yahoo!

Наконец, пользователям Yahoo! была показана рекламная кампания, чтобы определить, будут ли пользователи, увидевшие рекламу, с большей вероятностью регистрироваться на сайте конкурента в день просмотра объявления. Наблюдательное исследование причинно-следственных связей сравнивало поведение пользователей в день просмотра рекламы с поведением пользователей недель ранее, в то время как эксперимент сравнивал количество пользователей, которые не видели рекламу, но посетили Yahoo!, с пользователями, посетившими Yahoo! в тот же день и увидевшими рекламу конкурента. По данным наблюдательного исследования причинно-следственных связей, пользователи с большей вероятностью регистрировались на сайте конкурента в день просмотра рекламы по сравнению с неделей ранее. Однако в ходе контролируемого эксперимента наблюдался почти идентичный подъем. Этот результат аналогичен нашему предыдущему обсуждению оттока и ошибок: более активные пользователи просто с большей вероятностью будут выполнять более широкий круг действий. Как правило, важно использовать активность как фактор.

Это всего лишь одна история и одно сравнение. Более недавнее сравнительное исследование также показало, что исследования причинно-следственных связей менее точны, чем контролируемые онлайн-эксперименты (Gordon et al, 2018). Мы размещаем множество других историй в интернете по адресу <https://bit.ly/experimentGuideRefutedObservationalStudies>, показывая примеры неуставленных общих причин, зависящих от времени факторов, снижение внешней валидности из-за различий между популяциями и многое другое. Будьте осторожны, если вам необходимо провести исследование причинно-следственной связи.

ЧАСТЬ IV



**Платформы для экспериментов:
углубленное изучение**

Часть IV расширяет материал главы 4 о создании экспериментальных платформ и состоит из пяти коротких глав, предназначенных для инженеров и специалистов по данным. Менеджеры по продукту должны, по крайней мере, понимать обсуждаемые здесь вопросы, поскольку они могут повлиять на план эксперимента, а также на качество данных для анализа эксперимента.

На протяжении всей книги, чтобы упростить обсуждение, мы в первую очередь сосредоточены на экспериментах на стороне сервера. Однако есть много толстых клиентов, особенно мобильных или настольных приложений, где нам нужно проводить эксперименты на стороне клиента. Мы приводим ключевые различия, которые следует учитывать при проведении экспериментов на стороне клиента.

Следующие две темы являются основополагающими независимо от того, на какой стадии экспериментальной зрелости вы находитесь.

Во-первых, качественный *инструментарий* – необходимое условие для проведения доверительных контролируемых экспериментов в сети. Без инструментария вы не сможете получить данные или показатели для анализа экспериментов или даже для определения базовой производительности вашей системы. В этой части мы обсуждаем ключевые моменты инструментария в контексте экспериментов.

Далее, хотя мы для простоты в этой книге предполагали, что единицей рандомизации является *пользователь*, есть и другие варианты, такие как *сеанс* или *страница*. Выбор единицы рандомизации, как правило, глубоко встроен в вашу систему и может повлиять как на взаимодействие с пользователем, так и на достоверность анализа. Мы описываем различные варианты, которые вы можете использовать, и даем рекомендации по их выбору.

По мере того как вы масштабируете эксперименты, вам придется обратить внимание на дополнительные области.

Во-первых, принципиальное и контролируемое наращивание экспериментов имеет решающее значение для масштабирования. Мы обсудим наращивание воздействия в эксперименте: компромисс между скоростью, качеством и риском.

Наконец, для масштабирования экспериментов также важен автоматизированный и масштабируемый конвейер анализа данных. Мы расскажем про общие шаги, необходимые для масштабирования анализа экспериментов, включая обработку, вычисление и отображение данных.

Глава 12

Эксперименты на стороне клиента

Разница между теорией и практикой на практике больше, чем разница между теорией и практикой в теории.

– Ян Л. А. ван де Снепшют

***Почему это важно:** вы можете проводить эксперименты как на тонком клиенте, таком как веб-браузер, так и на толстом клиенте, таком как собственное мобильное приложение или клиентское приложение для настольных ПК. Изменения веб-страницы, независимо от того, относятся ли они к веб-интерфейсу или серверной части, полностью контролируются сервером. Это сильно отличается от толстого клиента. В связи со взрывным ростом использования мобильных устройств количество экспериментов, проводимых над мобильными приложениями, также выросло. Понимание различий между тонкими и толстыми клиентами из-за процесса выпуска, инфраструктуры и поведения пользователей полезно для обеспечения достоверных экспериментов.*

На протяжении большей части этой книги, рассуждая о разработке и проведении экспериментов, мы предполагали использование тонких клиентов, чтобы упростить обсуждение. Эта глава посвящена обсуждению проведения экспериментов на толстых клиентах, их различий и последствий.

12.1. Различия между серверной и клиентской стороной

Чтобы упростить терминологию, мы будем использовать термин «эксперимент на стороне клиента» для обозначения экспериментальных изменений, сделанных в толстом клиенте. Мы будем использовать «эксперимент на стороне сервера» для обозначения экспериментальных изменений, внесенных на стороне сервера, независимо от того, влияет ли это на толстый или тонкий клиент, и независимо от того, является ли это изменением пользовательского интерфейса или серверной части.

Есть два основных различия между серверной и клиентской стороной, которые влияют на онлайн-эксперименты: процесс выпуска и передача данных.

12.1.1. Отличие №1: процесс выпуска

На веб-сайтах обновления обычно выпускаются непрерывно, иногда несколько раз в день. Поскольку изменения контролируются организацией, обновление серверного кода относительно легко выполняется в рамках непрерывной интеграции и развертывания. Когда пользователь посещает сайт, сервер отправляет данные (например, HTML) в браузер, не прерывая работу конечного пользователя. В контролируемом эксперименте вариант, который видит пользователь, полностью управляется сервером, и никаких действий со стороны конечного пользователя не требуется. Показывать ли красную или желтую кнопку, показывать ли обновленную домашнюю страницу или нет – это все изменения, которые могут произойти мгновенно после развертывания на стороне сервера.

Когда дело доходит до клиентских приложений, многие обновления могут по-прежнему зависеть от служб, т. е. кода на стороне сервера, такого как контент канала, отображаемый в приложении Facebook. Изменения, влияющие на них, будут следовать аналогичному процессу выпуска, как описано выше для веб-страницы. Фактически чем больше мы можем полагаться на службы, тем проще экспериментировать, как в отношении гибкости, так и согласованности воздействия между разными клиентами. Например, многие изменения в Bing, Google, LinkedIn и Office вносятся на стороне сервера и влияют на всех клиентов, будь то веб-клиенты или толстые клиенты, такие как мобильные приложения.

Однако значительный объем кода поставляется с самим клиентом. Любые изменения в этом коде должны выпускаться иначе. Например, в мобильном приложении разработчики не имеют полного контроля над циклом развертывания и выпуска. В процессе выпуска участвуют три стороны: владелец приложения (например, Facebook), магазин приложений (например, Google Play или Apple App Store) и конечный пользователь.

Когда код готов, владелец приложения должен отправить сборку в магазин приложений для проверки. Даже если предположить, что сборка прошла проверку (что может занять несколько дней), передача кода в распространение не означает, что у всех, кто запустит приложение, будет новая версия. Вместо этого получение новой версии представляет собой обновление программного обеспечения, и пользователи могут отложить или даже проигнорировать обновление, продолжая использовать старую версию. Некоторым конечным пользователям требуются недели, чтобы адаптироваться. Некоторые корпоративные организации могут отказаться от обновлений и не разрешать их своим пользователям.

Некоторое программное обеспечение, например Exchange, работает в служебных облаках, которым запрещено вызывать неувержденные службы. Все эти соображения означают, что в любой момент времени существует несколько версий приложения, которые владелец приложения должен поддерживать. Аналогичные проблемы существуют и для нативных настоль-

ных клиентов, у которых есть собственные механизмы выпуска (например, Office, Adobe Acrobat, iTunes), даже если процесс проверки в магазине приложений к ним не применяется.

Стоит отметить, что магазины приложений Google Play и Apple теперь поддерживают поэтапное развертывание. Оба они позволяют владельцам приложений сделать новую версию доступной только для определенного процента пользователей и приостановить обновление, если обнаружатся какие-то проблемы. Поэтапное развертывание – это, по сути, рандомизированные эксперименты, поскольку подходящие пользователи выбираются случайным образом. К сожалению, такие развертывания нельзя анализировать как случайные эксперименты, поскольку владельцы приложений не знают, какие пользователи имеют доступ к скачиванию нового приложения. Владельцы приложений знают только, кто «принял» новое приложение. Мы обсудим это подробнее позже в этой главе.

Владельцы приложений могут избегать частых обновлений версии клиента. Несмотря на то что нет строгих ограничений на количество выпусков новой версии, каждое обновление отнимает часть пропускной способности сети и потенциально может раздражать пользователей (в зависимости от настроек частоты обновления и уведомлений). Windows или iOS – отличный пример ограниченной возможности обновлений, потому что некоторые обновления требуют перезагрузки.

12.1.2. Отличие №2: обмен данными между клиентом и сервером

Наконец, когда новое приложение оказалось в руках пользователей, оно должно взаимодействовать с сервером. Клиенту необходимо получить необходимые данные с сервера и передать свои данные обратно на сервер. Хотя мы отсылаем читателей к главе 13, посвященной инструментам на стороне клиента, здесь мы выделим некоторые ключевые факторы, имеющие значение, когда речь идет о передаче данных для нативного мобильного приложения. Рассуждая о мобильных устройствах, имейте в виду, что с радикальным улучшением технологий разрыв между мобильными и настольными компьютерами становится номинальным в силу роста возможностей мобильных устройств и улучшения сетевых подключений.

Во-первых, передача данных между клиентом и сервером может испытывать ограничения или задержки:

- **подключение к интернету** может быть нестабильным или непостоянным. В некоторых странах пользователи могут не иметь доступа в сеть в течение нескольких дней. Даже пользователи, которые обычно находятся в сети, могут не иметь доступа к интернету в самолете или временно находиться в зоне, где нет доступных сотовых или Wi-Fi-сетей. В результате изменения на стороне сервера могут не передаваться этим клиентам. Точно так же данные, собранные на

стороне клиента, могут задерживаться при передаче обратно на сервер. Эти задержки различаются в зависимости от страны или демографической группы и должны учитываться при инструментальной и последующей обработке;

- **пропускная способность сотовых каналов передачи данных.** Большинство пользователей имеют ограниченные тарифные планы для передачи данных в сотовой сети, поэтому возникает вопрос, загружаете ли вы данные телеметрии только тогда, когда пользователь подключен к Wi-Fi, или в любой момент времени. Большинство приложений по умолчанию предпочитают отправлять данные телеметрии только через Wi-Fi, что может задерживать получение этих данных на стороне сервера. Также существуют различия между странами, поскольку мобильная инфраструктура в некоторых странах слабее, чем в других, когда речь идет о пропускной способности, стоимости и т. д. Ограничения заложены не только в канал передачи данных. Даже если соединение хорошее, использование сети может повлиять на производительность устройства и в конечном итоге – на взаимодействие пользователя с приложением;
- **батарея.** Чем интенсивнее обмен данными, тем больше расход заряда батареи. Например, приложение может чаще выходить из спящего режима для отправки дополнительных данных телеметрии, но это ускорит разряд. Более того, мобильные устройства в режиме низкого заряда батареи ограничивают некоторые функции приложений;
- **процессор, задержка и производительность.** Несмотря на то что в настоящее время многие мобильные устройства ведут себя как мини-компьютеры, по-прежнему существуют мобильные устройства более низкого уровня, ограниченные мощностью процессора. Частая агрегация данных на устройстве и обмен данными с сервером могут сделать приложение менее отзывчивым и снизить общее быстродействие приложения;
- **память и хранилище.** Кеширование – это один из способов уменьшить передачу данных, но этот способ влияет на размер и быстродействие кода и увеличивает частоту удалений приложения. Вдобавок кеширование является более серьезной проблемой для пользователей слабых устройств с меньшим объемом памяти и хранилища.

Пропускная способность канала связи и быстродействие устройства – все это части одной и той же экосистемы, но есть компромиссы. Например, мы можем получить более стабильное интернет-соединение, используя больше сотовых данных; мы можем потратить больше ресурсов процессора на вычисления и агрегирование на устройстве, чтобы уменьшить количество данных, отправляемых обратно на сервер; мы можем подождать, пока Wi-Fi отправит данные отслеживания, сохраненные в дополнительном хранилище на устройстве. Эти компромиссы могут повлиять как на видимость того,

что происходит на стороне клиента, так и на взаимодействие и поведение пользователей (по аналогии с главой 5), что делает это плодотворной областью для экспериментов, но также и областью, в которой необходимо проявлять осторожность, чтобы гарантировать достоверные результаты.

12.2. Следствия из компромиссов

Следствие №1: необходимо предвидеть изменения как можно раньше

Поскольку клиентский код трудно доставлять конечным пользователям, необходимо заранее планировать контролируемые эксперименты с любыми изменениями на стороне клиента. Другими словами, все эксперименты, включая все варианты для каждого из этих экспериментов, должны быть закодированы и поставляться с текущей сборкой приложения. Любые новые варианты, включая исправления ошибок в любом существующем варианте, должны дожидаться следующего выпуска. Например, в типичном ежемесячном выпуске Microsoft Office поставляется с сотнями изменений кода, которые развертываются по методам безопасного развертывания. Отсюда вытекают три последствия.

1. Новое приложение может быть выпущено до того, как будет завершена разработка определенных опций. В этом случае применение опций ограничивают параметрами конфигурации, так называемыми флажками, по умолчанию отключающими эти опции. Отключенные таким образом опции называются темными. Когда опция завершена и готова, иногда после завершения разработки службы на стороне сервера ее можно включить.
2. Большинство встроенных работающих опций можно настраивать со стороны сервера. Это позволяет оценивать их с помощью А/В-тестов, что помогает измерять эффективность с помощью контролируемых экспериментов и обеспечивает безопасность. Если обновление не работает должным образом, мы можем немедленно вернуться к исходному состоянию (вариант в контролируемом эксперименте), не проходя через длительный цикл выпуска клиента. Это может спасти конечных пользователей от застревания в неисправном приложении на несколько недель до следующего выпуска.

Для увеличения гибкости при создании новых вариантов без необходимости выпуска клиентской версии может широко использоваться *тонкая параметризация*. Дело в том, что, даже если мы не можем быстро передать клиенту новый код, мы с легкостью можем передать ему новые параметры конфигурации, что фактически создает новый вариант, если приложение-клиент поддерживает изменяемые конфигурации. Например, мы захотели провести эксперимент с количеством элементов страницы новостей, которые нужно получать с сервера за раз. Мы могли бы заложить наши лучшие

предположения в код клиента и экспериментировать только с тем, что запланировали, или можем параметризовать число и иметь свободу экспериментов после выпуска кода. Windows 10 параметризовала текст поля поиска на панели задач и проводила эксперименты через год после выпуска, при этом победивший вариант увеличил вовлеченность пользователей и выручку Bing на миллионы долларов. Другой распространенный пример – обновление параметров модели машинного обучения с сервера, чтобы модель можно было настраивать по мере необходимости.

Хотя мы считаем, что для блага пользователей лучше всего ограниченно тестировать новые функции перед запуском для всех пользователей приложения, магазины приложений могут накладывать ограничения на то, какие функции могут поставляться в затемненном виде. Мы рекомендуем внимательно ознакомиться с политикой магазина приложений и соответствующим образом раскрывать темные функции.

Следствие № 2: будьте готовы к задержке данных и времени запуска

Ограниченная или отложенная передача данных между клиентом и сервером не только задерживает применение инструментов для обработки данных, но и задерживает время начала самого эксперимента. Во-первых, реализация эксперимента на стороне клиента должна поставляться с новой версией приложения. Затем мы можем активировать эксперимент для небольшого процента пользователей. Однако даже в этом случае эксперимент не полностью активен, потому что:

- пользовательские устройства могут не получить новую конфигурацию эксперимента, либо устройства являются автономными, либо они находятся в условиях ограниченной или низкой пропускной способности, когда продвижение новых конфигураций может привести к увеличению затрат или неудовлетворительному опыту для пользователя;
- если новая конфигурация эксперимента загружается только тогда, когда пользователь открывает приложение, обновление может не вступить в силу до следующего сеанса, поскольку мы не хотим изменять взаимодействие с пользователем прямо посередине текущего сеанса. Для активных пользователей, проводящих несколько сеансов в день, эта задержка невелика, но для пассивных пользователей, редко посещающих сайт, эксперимент может начаться только через неделю;
- может быть много устройств со старыми версиями без нового кода эксперимента, особенно сразу после выпуска нового приложения. Исходя из нашего опыта, на начальном этапе проведения эксперимента требуется около недели для достижения более стабильной скорости внедрения, хотя это может сильно варьироваться в зависимости от группы пользователей и типа приложения.

Эти задержки времени начала эксперимента и прибывающих на сервер данных могут повлиять на анализ эксперимента, особенно если он чувствителен ко времени, например должен происходить в реальном времени или с минимальной задержкой. Во-первых, сигналы в начале эксперимента кажутся более слабыми (меньший размер выборки), а также имеют сильную предвзятость отбора в сторону частых пользователей и владельцев подключения по Wi-Fi. Поэтому иногда приходится увеличивать продолжительность эксперимента, чтобы учесть задержки. Еще одно важное следствие состоит в том, что варианты тестирования и контроля могут иметь разное действительное время запуска. Некоторые экспериментальные платформы позволяют использовать общие контрольные варианты, и в этом случае контрольный вариант может быть развернут до запуска тестового варианта и, следовательно, иметь другую популяцию пользователей из-за смещения выбора. Кроме того, если контрольный вариант развернут раньше, соответствующие кеши для него уже сформированы, поэтому ответы на запросы к серверу выполняются быстрее, что может привести к дополнительному смещению. Следовательно, необходимо тщательно выбирать период времени для сравнения вариантов.

Следствие № 3: создайте отказоустойчивую систему для обработки отключений и первого запуска

Когда пользователи открывают приложение, их устройство может не иметь сетевого подключения. Из соображений согласованности мы должны кешировать назначение эксперимента на случай, если следующий запуск приложения произойдет, когда сеть недоступна. Кроме того, если сервер не передает конфигурацию, необходимую для принятия решения о назначении, у нас должен быть вариант по умолчанию для эксперимента. Некоторые приложения также распространяются по соглашению о производстве оригинального оборудования (ОЕМ). В этих случаях эксперименты должны быть правильно подготовлены к ситуации первого запуска. Подготовка включает получение конфигураций, которые повлияют только на следующий запуск, и стабильный идентификатор рандомизации до и после регистрации или входа пользователей.

Следствие № 4: для иницируемого анализа может потребоваться отслеживание назначения эксперимента на стороне клиента

Возможно, вам придется принять дополнительные меры для включения иницируемого анализа для экспериментов на стороне клиента. Например, одним из способов сбора иницирующей информации является отправка данных отслеживания на сервер при проведении эксперимента. Однако, чтобы уменьшить количество сообщений от клиента к серверу, информация о назначении эксперимента обычно извлекается для всех активных экспериментов сразу (например, при запуске приложения) независимо от того,

запущен эксперимент или нет (см. главу 20). Если полагаться на данные отслеживания во время выборки для инициированного анализа, это приведет к избыточной инициации. Одним из способов решения этой проблемы является отправка информации о назначении, когда опция фактически используется, что требует от клиента отправки инструментов эксперимента. Имейте в виду, что большое количество событий отслеживания может вызвать проблемы с задержкой и быстройдействием.

Следствие № 5: Отслеживайте важные ограничения на уровне работоспособности устройства и приложения

Рабочая нагрузка на уровне устройства может повлиять на работу приложения. Например, тестовый вариант может потреблять больше ресурсов процессора и расходовать больше энергии батареи. Если мы будем отслеживать только данные о взаимодействии с пользователем, мы не сможем обнаружить проблему разрядки батареи. Другой пример – обновленный вариант может отправлять пользователям больше push-уведомлений, которые затем вынуждают пользователя отключить уведомления через настройки устройства. Это может не проявиться как заметное снижение вовлеченности во время эксперимента, но окажет значительное долгосрочное влияние.

Также важно отслеживать общее состояние приложения. Например, мы должны отслеживать размер приложения, поскольку больший размер приложения с большей вероятностью приведет к сокращению загрузок и побудит людей к удалению. Подобное поведение может возникать из-за загрузки полосы пропускания сетевого подключения, ускорения разряда батареи или частоты сбоев. В случае сбоев журналирование выхода из приложения позволяет отправлять телеметрию при следующем запуске приложения.

Следствие № 6: Отслеживайте общий эффект от изменений с помощью квазиэкспериментальных методов

Не все изменения в новом приложении можно отнести к параметрам A/B. Чтобы провести полноценный рандомизированный контролируемый эксперимент для нового приложения, можно было бы объединить обе версии в одном приложении и организовать для некоторых пользователей запуск новой версии, оставив других на старой. Однако это непрактично и плохо подходит для большинства приложений, так как может удвоить размер приложения. С другой стороны, поскольку не все пользователи принимают новую версию приложения одновременно, есть период времени, когда обе версии приложения обслуживают реальных пользователей. Если мы можем исправить предвзятость принятия обновления, то фактически в этот период времени мы имеем достаточно эффективный A/B-эксперимент. Сюй и Чен (2016) рассказывали о методах устранения предвзятости в настройке мобильных устройств.

Следствие № 7: Остерегайтесь разнообразия устройств/платформ и взаимодействий между ними

Обычно пользователь получает доступ к одному и тому же сайту через несколько устройств и платформ, например через настольный компьютер и смартфон. Отсюда вытекают два последствия.

1. Идентификаторы устройств могут различаться. В результате один и тот же пользователь может быть рандомизирован в разные варианты на разных устройствах.
2. Между различными устройствами существует потенциальное взаимодействие. Многие браузеры, включая Edge, теперь имеют функцию синхронизации «Продолжить на рабочем столе» или «Продолжить на мобильном устройстве», чтобы пользователям было проще переключаться между настольным ПК и мобильным устройством. Также распространено переключение трафика между мобильными приложениями и мобильным веб-сайтом. Например, если пользователь читает электронное письмо от Amazon в почтовом приложении на своем телефоне и нажимает на ссылку в письме, он может либо перейти непосредственно в приложение Amazon (при условии, что оно установлено), либо на мобильный веб-сайт. При анализе эксперимента важно знать, может ли пользователь как-то страдать от этих взаимодействий. Если это так, мы не можем оценивать производительность приложения изолированно, но должны рассматривать поведение пользователя в целом на разных платформах. Еще одна вещь, на которую следует обратить внимание, – это то, что пользовательский опыт на одной платформе (обычно в приложении) может быть лучше, чем на другой платформе. Переключение трафика из приложения на сайт приводит к снижению общего взаимодействия, что может быть мешающим эффектом, не предусмотренным самим экспериментом.

12.3. Выводы

Мы посвятили эту главу различиям в экспериментах с тонкими и толстыми клиентами. Одни различия очевидны, другие не столь заметны, но не менее критичны. Нам нужно проявить особую осторожность, чтобы правильно спланировать и проанализировать эксперименты. Также важно отметить, что в связи с быстрым развитием технологий многие различия и последствия со временем наверняка будут только усугубляться.

Глава 13

Инструментарий экспериментов

Все, что происходит, происходит так, как должно, и если вы внимательно понаблюдаете, то убедитесь в этом.

– Марк Аврелий

***Почему это важно:** прежде чем вы начнете проводить какие-либо эксперименты, у вас должны быть инструменты для регистрации того, что происходит с пользователями и системой (например, с веб-сайтом, приложением). Более того, каждый бизнес должен иметь базовое представление о том, как работает система и как пользователи взаимодействуют с ней, что тоже требует определенных инструментов. При проведении экспериментов критически важно иметь развернутые данные о том, что видели пользователи, их взаимодействия (например, клики, наведения указателя и время до щелчка) и производительности системы (например, задержки).*

Подробное обсуждение инструментария систем выходит за рамки этой книги и сильно зависит от архитектуры системы. В этой главе обсуждаются ключевые моменты инструментария в контексте экспериментов. Когда дело касается инструментария, одним из решающих факторов является конфиденциальность, которую мы обсуждали в главе 9. В контексте этой книги мы используем термины «инструмент», «трек» и «журнал» как синонимы.

13.1. ИНСТРУМЕНТЫ НА СТОРОНЕ КЛИЕНТА И СЕРВЕРА

При выборе инструментов важно понимать, что происходит на стороне клиента и на стороне сервера. Инструментарий на стороне клиента фокусируется на том, что пользователь испытывает, включая то, что он видит и делает:

- **действия пользователя:** какие действия выполняет пользователь, например щелчок мышью, наведение курсора, прокрутка? В какое время это делается? Какие действия выполняются на стороне клиента без обращения к серверу? Например, отображение справочного текста при наведении курсора или возникновение ошибки в поле формы. Слайдшоу позволяют пользователям щелкать и пролистывать слайды, поэтому важно фиксировать время этих событий;

- **быстродействие:** сколько времени требуется странице (веб-странице или странице приложения), чтобы отобразиться или стать интерактивной? В главе 5 мы обсуждаем сложности, связанные с измерением времени от подачи поискового запроса до отображения полной страницы;
- **ошибки JavaScript** являются обычным явлением и могут зависеть от браузера, поэтому очень важно отслеживать ошибки и сбои в клиентском программном обеспечении.

Инструментарий на стороне системы фокусируется на том, что делает система, включая:

- **быстродействие:** сколько времени требуется серверу для генерации ответа, и какой компонент занимает больше всего времени? Каковы показатели 99-го перцентиля?
- **статистика ответов системы:** сколько запросов сервер получил от пользователя? Сколько страниц обслужил сервер? Как обрабатываются повторные попытки?
- **системная информация:** сколько исключений или ошибок выдает система? Какова частота обращений к кешу?

Инструментарий на стороне клиента полезен, так как предлагает представление о том, что пользователь видит и делает. Например, вредоносное ПО на стороне клиента может модифицировать ответ сервера, и это можно обнаружить только с помощью инструментов на стороне клиента. Однако инструментальные средства на стороне клиента имеют недостатки с точки зрения точности данных и стоимости для пользователя. Вот конкретные проблемы для клиентов на основе JavaScript (о проблемах, связанных с мобильными устройствами, см. главу 12).

1. Инструменты на стороне клиента могут давать значительную нагрузку на процессор и пропускную способность сети, а также разряжать батареи устройства, влияя на взаимодействие с пользователем. Большие фрагменты JavaScript влияют на время загрузки. Эта увеличенная задержка влияет не только на взаимодействие пользователей во время посещения, но и на вероятность их возвращения (см. главу 5).
2. Инструменты JavaScript могут работать с потерями: для отслеживания действий пользователя часто используются веб-маяки, например когда пользователи щелкают по ссылке, чтобы перейти на новый сайт; однако эти маяки могут быть потеряны, когда:
 - a) новый сайт загружается до того, как веб-маяк будет успешно отправлен, а это означает, что маяки могут быть проигнорированы и потеряны. Уровень потерь из-за этого состояния гонки зависит от браузера;
 - b) мы принудительно отправляем веб-маяк до загрузки нового сайта, например с помощью синхронного перенаправления. В то время как потери маяков уменьшаются, задержка увеличивается, что

- ухудшает взаимодействие с пользователем и увеличивает вероятность того, что пользователь откажется от щелчка;
- с) вы можете реализовать любой сценарий в зависимости от приложения. Например, так как клики по рекламе должны надежно отслеживаться, поскольку они связаны с платежами и требованиями соответствия, пункт б) является предпочтительным сценарием, даже несмотря на дополнительную задержку;
 - д) клиентские часы могут настраиваться вручную или автоматически. Это означает, что фактическое время на стороне клиента не может быть полностью синхронизировано со временем сервера, что необходимо учитывать при последующей обработке. Например, никогда не вычитайте время клиента и сервера, так как оно может значительно отличаться даже после настройки часовых поясов.

Инструментарий на стороне сервера меньше страдает от этих проблем. Он предлагает менее четкое представление о том, что на самом деле делает пользователь, но может обеспечить лучшую детализацию того, что происходит внутри вашей системы и почему. Например, вы можете зарегистрировать время создания HTML для страницы; поскольку на него не влияет сеть, данные, как правило, имеют меньшую дисперсию, что позволяет использовать более чувствительные метрики. В результатах поисковой системы есть внутренние баллы, указывающие, почему были возвращены определенные результаты поиска, и их рейтинг. Инструментальные средства этих оценок полезны для отладки и настройки алгоритма поиска. Другой пример – регистрация фактических серверов или центров обработки данных, из которых обслуживается запрос, что позволяет отлаживать неисправное оборудование или выявлять центры обработки данных в состоянии перегрузки. Важно помнить, что серверы также нужно часто синхронизировать. Может возникнуть ситуация, при которой запрос обслуживается одним сервером, а маяк регистрируется другим, что приводит к расхождению меток времени.

13.2. ОБРАБОТКА ЖУРНАЛОВ ИЗ НЕСКОЛЬКИХ ИСТОЧНИКОВ

Вероятно, у вас будет несколько журналов из разных инструментальных потоков, например:

- журналы от разных типов клиентов (например, браузер, мобильный);
- журналы с серверов;
- журнал состояний каждого пользователя (например, согласие и отказ).

Важно убедиться, что соответствующие журналы можно легко использовать и объединять при последующей обработке. Во-первых, должен быть способ доступа к журналам. В идеальном случае во всех журналах должен быть общий идентификатор, служащий ключом отбора.

Ключ отбора должен указывать, какие события относятся к одному и тому же пользователю или единице рандомизации (см. главу 14). Вам также мо-

жет понадобится ключ отбора для определенных событий. Например, есть событие на стороне клиента, которое указывает, что пользователь видел определенный экран, и соответствующее событие на стороне сервера, которое объясняет, *почему* пользователь видел этот конкретный экран и его элементы. Ключ отбора позволит вам узнать, что данные записи журналов были двумя представлениями одного и того же события, показанного одному и тому же пользователю.

Заранее предусмотрите общий формат, чтобы упростить последующую обработку. Этим общим форматом могут быть общие поля (например, отметка времени, страна, язык, платформа) и настраиваемые поля. Общие поля часто являются основой для сегментов, используемых для анализа и таргетинга.

13.3. КУЛЬТУРА ИЗМЕРЕНИЙ

Средства измерений и контроля должны рассматриваться как критически важный компонент работающего сайта. Представьте, что вы летите на самолете с неисправными приборами на панели. Это явно небезопасно, но пилоты могут утверждать, что поломка приборов не влияет на пассажиров. Откуда им знать? У этого экипажа нет информации, чтобы знать, правильно ли это предположение, потому что без надлежащих измерений они летят вслепую. На самом деле самая сложная часть использования инструментов – это заставить разработчиков им пользоваться. Эта трудность возникает как из-за задержки во времени (время от момента написания кода до момента проверки результатов), так и из-за функциональной разницы (т. е. разработчик, создающий код, часто не тот, кто анализирует журналы, чтобы увидеть, как работает приложение). Вот несколько советов, как сгладить последствия такого разделения:

- установите нерушимую культурную норму: ничто не может быть внедрено без инструментария. Учитывайте инструменты как часть спецификации. Убедитесь, что неисправные приборы имеют тот же приоритет, что и неисправное обновление. Управлять самолетом с неисправным компасом или высотомером слишком рискованно, даже если он все еще может летать;
- инвестируйте в инструментарий во время разработки. Разработчики, создающие код, должны иметь возможность добавлять любые необходимые инструменты и проверять их в тестах перед развертыванием своего кода (и перед код-ревью!);
- следите за качеством необработанных журналов. Сюда входят такие понятия, как количество событий по ключевым параметрам или вариантам, которые должны быть истинными (т. е. отметки времени попадают в определенный диапазон). Убедитесь, что есть инструменты для обнаружения выбросов по ключевым наблюдениям и показателям. Если в инструментарии обнаружена проблема, разработчики в вашей организации должны немедленно исправить ее.

Глава 14

Выбор единицы рандомизации

[Для генерации случайных цифр] источник импульсов случайной частоты, обеспечивающий в среднем около 100 000 импульсов в секунду, стробировался примерно один раз в секунду импульсом постоянной частоты... Результат работы исходной машины показал статистически значимые смещения, и инженерам пришлось сделать несколько модификаций и усовершенствований схем, пока не было достигнуто приемлемое качество работы. Затем в течение мая и июня 1947 года была составлена основная таблица из миллиона цифр. Эту таблицу подвергли довольно глубоким испытаниям, и было обнаружено, что она все еще содержит небольшие, но статистически значимые смещения.

– Миллион случайных цифр с нормальным отклонением
100000 (RAND 1955)

Почему это важно: выбор единицы рандомизации имеет решающее значение при планировании эксперимента, поскольку он влияет как на взаимодействие с пользователем, так и на то, какие показатели могут использоваться для измерения эффекта от воздействия. При планировании эксперимента вам необходимо продумать, какие варианты вы хотите сделать доступными. Понимание вариантов и соображений, которые следует использовать при выборе вариантов, приведет к улучшению плана и анализа эксперимента.

Идентификаторы важны как базовая единица рандомизации для экспериментов. Тот же идентификатор может также использоваться в качестве ключа отбора для последующей обработки файлов журнала (см. главы 13 и 16). Обратите внимание, что в этом разделе мы сосредоточимся на выборе идентификатора, а не на базовых критериях для самой рандомизации, таких как обеспечение независимости назначения (т. е. присвоение идентификатора одному варианту не должно говорить нам ничего о присвоении идентификатора другому варианту); а также на обеспечении независимости назначения между экспериментами, если идентификатор может быть назначен нескольким экспериментам одновременно (см. главу 4).

Один из факторов, которые следует учитывать при выборе единицы рандомизации, – это степень детализации. Например, веб-сайты имеют следующую естественную степень детализации:

- **уровень страницы:** каждая новая веб-страница, просматриваемая на сайте, считается единицей эксперимента;
- **уровень сеанса:** этот блок представляет собой группу веб-страниц, просмотренных за одно посещение. Сеанс или посещение обычно заканчивается после 30 мин бездействия;
- **уровень пользователя:** все события от одного пользователя – это единица. Обратите внимание, что пользователь обычно является аппроксимацией реального пользователя с обычно используемыми файлами куки или идентификаторами входа. Файлы куки могут быть удалены или использоваться в закрытых/инкогнито сеансах браузера, что приводит к завышению количества пользователей. В случае регистрации идентификаторов входа использование общих учетных записей может привести к занижению статистики, тогда как несколько учетных записей (например, пользователи могут иметь несколько учетных записей электронной почты) могут привести к завышению показателей.

Далее мы будем обсуждать основные соображения на примере веб-сайтов.

Для поисковых систем, где на один запрос может приходиться несколько просмотров страниц, он может служить уровнем детализации между страницей и сеансом. Мы также можем рассматривать в качестве единицы эксперимента комбинацию пользователя и дня, где события от одного и того же пользователя в разные дни находятся в разных единицах.

При выборе степени детализации необходимо найти ответы на два основных вопроса.

1. Насколько важно единообразие пользовательского опыта?
2. Какие показатели важны?

Для единообразия главный вопрос – заметит ли пользователь изменения. В качестве крайнего примера представьте, что эксперимент проводится с цветом шрифта. Если мы используем мелкую детализацию, такую как уровень страницы, то цвет шрифта может меняться с каждой страницей. Другой пример – эксперимент, вводящий новую функцию; эта функция может спонтанно появляться и исчезать, если рандомизация выполняется на уровне страницы или на уровне сеанса. Это потенциально плохой и непостоянный пользовательский опыт, который может повлиять на ключевые показатели. Чем больше пользователь будет замечать тестируемое воздействие, тем важнее использовать более грубую гранулярность при рандомизации, чтобы обеспечить единообразие взаимодействия с пользователем.

Ваш выбор показателей и ваш выбор единицы рандомизации также взаимодействуют между собой. Более тонкие уровни детализации создают больше экспериментальных объектов, поэтому дисперсия среднего значения показателя меньше, и эксперимент будет иметь большую статистическую

мощность для обнаружения меньших изменений. Стоит отметить, что рандомизация (и анализ) по просмотрам страниц приведет к небольшой недооценке дисперсии эффекта воздействия, но на практике эта недооценка очень мала и обычно игнорируется.

Хотя более низкая дисперсия показателей может показаться преимуществом в пользу выбора более высокой степени детализации для рандомизации, следует учитывать несколько факторов.

1. Вы не можете использовать для рандомизации тот уровень, на котором применяется тестируемое воздействие. Например, если у вас есть персонализация или другие зависимости между страницами, то рандомизация по просмотру страницы больше не действует, поскольку то, что происходит на одной странице, влияет на то, что пользователь видит на следующей странице, и страницы больше не являются независимыми. В качестве другого конкретного примера, если в эксперименте используется рандомизация на уровне страницы и первый запрос пользователя попадает в тестовую группу, а обновление приводит к плохим результатам поиска, пользователь может сделать переформулированный второй запрос, который попадает в контрольную группу.
2. Точно так же если показатели вычисляются на этом уровне детализации, то их нельзя использовать для измерения результатов. Например, эксперимент, в котором используется рандомизация на уровне страниц, не может определить, влияет ли тестовое воздействие на общее количество пользовательских сеансов.
3. Предоставление пользователям различных вариантов может нарушить допущение о стабильной стоимости единицы воздействия (SUTVA, см. главу 3), в котором говорится, что экспериментальные единицы не должны мешать друг другу. Если пользователи замечают наличие различных вариантов, эти знания могут повлиять на их поведение и помешать эксперименту (см. главу 22).

В некоторых корпоративных сценариях, таких как Office, экспериментаторы предпочитают иметь обобщенный опыт для предприятия, ограничивая возможность случайного выбора по пользователю. В рекламных компаниях, где есть аукционы, на которых конкурируют рекламодатели, вы можете рандомизировать их по рекламодателям или по группам рекламодателей, которые часто участвуют в одних и тех же аукционах. В социальных сетях вы можете рандомизировать группы друзей, чтобы минимизировать помехи, и эксперимент обычно охватывает всю сеть.

14.1. ЕДИНИЦА РАНДОМИЗАЦИИ И ЕДИНИЦА АНАЛИЗА

Как правило, мы рекомендуем, чтобы единица рандомизации была такой же или более грубой, чем единица анализа в показателях, которые вам нужны.

Легче правильно вычислить дисперсию показателей, когда единица анализа такая же, как единица рандомизации, потому что предположение о независимости между единицами разумно на практике, и некоторые исследователи (Deng et al., 2017) подробно обсуждают предположение о *независимом и идентичном распределении* (independent and identical distribution, IID) в отношении выбора единицы рандомизации. Например, рандомизация по страницам означает, что клики при каждом просмотре страницы независимы, поэтому вычисление дисперсии среднего значения рейтинга кликов (клики на просмотры страниц) является стандартным. Точно так же если единицей рандомизации является *пользователь* и единицей анализа показателей также является *пользователь*, например количество сеансов на пользователя, количество кликов на пользователя и количество просмотров страниц на пользователя, то анализ относительно прост.

Если единица рандомизации будет более грубой, чем единица анализа, например рандомизация по пользователю, то анализ рейтинга кликов (по страницам) будет работать, но для этого требуются более тонкие методы анализа, такие как бутстраппинг или дельта-метод (см. главы 18 и 19). В этой ситуации результаты эксперимента могут быть искажены ботами, которые используют один идентификатор пользователя, например бот, который имеет 10 000 просмотров страниц, и все они выполняются с одним и тем же идентификатором пользователя. Если этот тип сценария вызывает беспокойство, подумайте о том, чтобы ограничить вклад любого отдельного пользователя в более детализированный показатель, или переключитесь на пользовательский показатель, такой как средний рейтинг кликов на пользователя, – оба подхода ограничивают влияние отдельного пользователя на общий результат.

И наоборот, когда показатели вычисляются на уровне пользователя (например, сеансы на пользователя или доход на пользователя), а рандомизация осуществляется на более высоком уровне детализации (например, на уровне страницы), опыт пользователя, вероятно, содержит сочетание вариантов. В результате вычисление показателей на уровне пользователя не имеет смысла; вы не можете использовать показатели на уровне пользователя для оценки эксперимента, если рандомизация выполняется по страницам. Если эти показатели являются частью вашего ОЕС, вы не можете использовать более тонкие уровни детализации для рандомизации.

14.1 Рандомизация на уровне пользователя

Рандомизация на уровне пользователя является наиболее распространенной, поскольку она позволяет избежать смешанного опыта пользователя и позволяет проводить долгосрочные измерения, такие как удержание пользователей. Если вы используете рандомизацию на уровне пользователя, вам все равно нужно обдумать несколько вариантов:

- идентификатор пользователя или логин, который пользователи могут использовать на разных устройствах и платформах. Идентификаторы входа в систему обычно стабильны не только на разных платформах, но и во времени;
- псевдонимный идентификатор пользователя, например файл куки. На большинстве веб-сайтов при посещении пользователем веб-сайт записывает файл куки, содержащий идентификатор (обычно в основном случайный). На мобильных устройствах для нативных приложений ОС часто предоставляет файлы куки, такие как Apple idFA или idFV или рекламный идентификатор Android. Эти идентификаторы различаются на разных платформах, поэтому один и тот же пользователь, заходящий через браузер настольного компьютера и мобильный интернет, будет считаться двумя разными пользователями. Пользователь может контролировать эти файлы куки либо с помощью элементов управления на уровне браузера, либо с помощью элементов управления на уровне ОС устройства, а это означает, что файлы куки обычно менее устойчивы в долгосрочном плане, чем идентификатор пользователя, выполнившего вход;
- идентификатор устройства – это неизменный идентификатор, привязанный к конкретному устройству. Поскольку они неизменяемы, эти идентификаторы считаются надежными. Идентификаторы устройств не имеют связи между устройствами или платформой, как идентификатор пользователя, вошедшего в систему, но обычно стабильны в долгосрочном плане.

При обсуждении этих вариантов следует учитывать некоторые ключевые аспекты – функциональные и этические (см. главу 9).

С функциональной точки зрения основное различие между этими разными идентификаторами заключается в их объеме. Идентификаторы пользователей, выполнивших вход, применяются на разных устройствах и платформах, поэтому, если вам нужен такой уровень согласованности и он доступен, идентификатор пользователя, выполнившего вход, действительно станет вашим лучшим выбором. Если вы тестируете процесс, который выходит за рамки входа пользователя в систему, например процесс подключения нового пользователя, который включает в себя вход пользователя в систему в первый раз, то более эффективным будет использование файла куки или идентификатора устройства.

Другой вопрос относительно области действия – длительная стабильность идентификатора. В некоторых экспериментах цель может состоять в том, чтобы проверить, есть ли долгосрочный эффект. Примеры могут включать изменения задержки или скорости (см. главу 5) или реакцию пользователей на узнаваемую рекламу. В этих случаях используйте долговечную единицу рандомизации, такую как идентификатор пользователя, выполнившего вход, долгоживущий файл куки или идентификатор устройства.

Последний вариант, который мы не рекомендуем, если он не единственный из возможных, – это IP-адрес. Назначение варианта на основе IP может быть единственным вариантом для тестирования изменений инфраструктуры, например для сравнения задержки при использовании одной службы хостинга (или одного местоположения хостинга) с другой, поскольку это часто можно контролировать только на уровне IP. Однако мы не рекомендуем использовать IP-адреса в более общем плане, поскольку они различаются по степени детализации. С одной стороны, IP-адрес устройства пользователя может измениться, когда пользователь перемещается (например, IP-адрес дома отличается от рабочего), что создает противоречивые результаты. С другой стороны, крупные компании или интернет-провайдеры имеют множество пользователей, совместно использующих небольшой набор IP-адресов, представляющих брандмауэр. Это может привести к низкой статистической мощности (т. е. нехватке уникальных IP-адресов, особенно для обработки большой дисперсии), а также к потенциальным проблемам с перекосом и выбросами из-за объединения большого числа пользователей в единое целое. Рандомизация на уровне субпользователя полезна только в том случае, если нет переноса или утечки (см. главу 22), и часто выбирается в таких ситуациях в связи с увеличением мощности.

Глава 15

Развитие эксперимента: компромисс между скоростью, качеством и риском

Настоящая мера успеха – это количество экспериментов, которые можно втиснуть в 24 часа.

– Томас А. Эдисон

***Почему это важно:** хотя эксперименты широко используются для ускорения разработки продуктов, скорость их внедрения может быть ограничена тем, как мы экспериментируем. Чтобы контролировать неизвестные риски, связанные с запуском новых функций, мы рекомендуем, чтобы эксперименты проходили постепенно, с плавным увеличением трафика для обновлений. Если мы не будем неуклонно соблюдать это правило, то можем получить снижение стабильности продукта по мере масштабирования экспериментов. Разумное наращивание охвата эксперимента требует уравнивания трех ключевых факторов: скорости, качества и риска.*

15.1. Что такое РАМПИНГ?

Мы часто говорим о проведении экспериментов с заданным распределением трафика, обеспечивающим достаточную статистическую мощность. На практике обычно эксперимент проходит через процесс постепенного изменения масштаба, так называемый *рампинг* (ramping), сопровождаемый увеличением количества неизвестных рисков, связанных с запуском новых функций (также известных как управляемое воздействие). Например, новая функция может начинаться с предоставления доступа только небольшому проценту пользователей. Если показатели выглядят разумно, а система хорошо масштабируется, тогда мы сможем подвергать воздействию все больше и больше пользователей. Мы увеличиваем трафик до тех пор, пока тестовое воздействие не достигнет желаемого масштаба.

Один из самых известных негативных примеров – это первый запуск сайта Healthcare.gov. Сайт рухнул, когда его развернули для 100 % пользователей в первый же день, только чтобы понять, что он не готов справиться с нагрузкой. Последствия можно было бы смягчить, если бы они разворачивали сайт по географическим регионам или по первой букве фамилии пользователя. Вывод о необходимости рампинга стал ключевым уроком для последующих запусков сайтов.

Как мы решаем, каким должно быть приращение и как долго мы должны оставаться на каждом шаге? Слишком медленное наращивание тратит время и ресурсы. Слишком быстрое наращивание может повредить пользователям и привести к риску принятия неоптимальных решений. Несмотря на то что мы можем демократизировать экспериментирование с помощью полностью проприетарной платформы, как описано в главе 4, нам не обойтись без понимания того, с какой скоростью наращивать масштаб, чтобы руководить экспериментаторами, и в идеале следует иметь инструменты для автоматизации процесса и применения принципов экспериментирования в большом масштабе.

В первую очередь нас заботит плавное *наращивание*. Плавное *снижение* обычно используется, когда мы наблюдаем отрицательный эффект, и в этом случае мы обычно очень быстро сворачиваем эксперимент до нуля, чтобы ограничить влияние на пользователей. Кроме того, крупные предприятия обычно сами контролируют обновления на стороне клиента, поэтому они фактически исключаются из некоторых экспериментов и процессов рампинга.

15.2. Шаблон SQR для рампинга

Как мы можем быстро выполнять итерацию, контролируя риски и улучшая качество решений в процессе рампинга? Другими словами, как сбалансировать скорость, качество и риск (speed, quality, risk, SQR)? Давайте вспомним, зачем мы проводим контролируемые онлайн-эксперименты:

- для измерения эффекта воздействия и рентабельности инвестиций в обновление, если оно начато до 100 % развертывания;
- для снижения риска за счет минимизации ущерба и затрат для пользователей и бизнеса во время эксперимента (т. е. при отрицательном воздействии);
- чтобы узнать о реакции пользователей – в идеале по сегментам, – выявить потенциальные ошибки и сообщить о планах на будущее. Это происходит либо при проведении стандартных экспериментов, либо при проведении экспериментов, предназначенных для обучения (см. главу 5).

Если единственной причиной для проведения контролируемого эксперимента является измерение, мы могли бы запустить эксперимент при *макси-*

мальном уровне мощности (maximum power ramp, MPR)¹, что часто означает выделение 50 % трафика под тестовое воздействие для обеспечения наибольшей статистической чувствительности при условии, что мы стремимся довести это воздействие до 100 %. Это дает самые быстрые и точные измерения. Однако мы редко хотим начинать с максимальной мощности – вдруг что-то пойдет не так? Вот почему обычно начинаем с небольшого масштаба с целью сдержать воздействие и снизить потенциальный риск.

Нам также могут понадобиться промежуточные шаги линейного изменения между MPR и 100 %. Например, по техническим причинам может потребоваться подождать на уровне 75 %, чтобы гарантировать, что новые службы или конечные точки могут масштабироваться в соответствии с возрастающей нагрузкой.

Другой распространенный пример – исследование. Поскольку исследование должно быть частью каждого рампинга, мы иногда применяем длительную задержку, когда небольшая часть (например, 5–10 %) пользователей не получает новое воздействие в течение определенного периода времени (например, два месяца) в первую очередь для исследовательских нужд. Цель состоит в том, чтобы узнать, будет ли воздействие, измеренное во время MPR, устойчивым в долгосрочной перспективе. Дополнительную информацию см. в главе 23.

15.3. ЧЕТЫРЕ ФАЗЫ РАМПИНГА

На рис. 15.1 показаны принципы и методы балансировки скорости, качества и риска на четырех фазах рампинга. Для простоты предположим, что наша цель – довести единичное воздействие до 100 % охвата, следовательно, MPR имеет 50%-ный охват. В целом шаблон SQR делит весь процесс рампинга на четыре фазы, каждую со своей основной целью.

Первая фаза предназначена в основном для снижения рисков, поэтому SQR фокусируется на компромиссе между скоростью и риском. Вторая фаза предназначена для точных измерений, поэтому основное внимание уделяется скорости и качеству. Последние две фазы являются необязательными и направлены на решение дополнительных эксплуатационных проблем (третья фаза) и исследование долгосрочного воздействия (четвертая фаза).

¹ Если в эксперименте задействован весь 100%-ный трафик только с одним воздействием, дисперсия в t -тесте для двух выборок пропорциональна $1/q(1 - q)$, где q – процент тестового трафика. MPR в этом случае имеет распределение трафика 50/50. Если для экспериментов на один тест и один контроль доступно только 20 % трафика, MPR имеет распределение 10/10, и т. д. Если есть четыре варианта с разделением 100 % трафика, то каждый вариант должен получить 25 %.



Рис. 15.1. Четыре фазы процесса рампинга

15.3.1. Первая фаза рампинга: до MPR

На этом этапе мы стремимся безопасно определить, что риск невелик, и быстро достичь уровня MPR. В нашем распоряжении следующие методы.

1. Создание «расходящихся кругов» из тестируемых популяций и постепенно подвергать воздействию все более широкие круги, чтобы снизить риск. Первые круги обычно предназначены для получения качественной обратной связи, поскольку трафика просто не хватает для получения значимых данных. Следующие круги могут иметь количественное значение, но все же остаются бесполезными, поскольку статистическая мощность мала. Многие ошибки могут быть обнаружены на ранних этапах. Обратите внимание на то, что измерения ранних кругов могут быть необъективными, поскольку эти пользователи, вероятно, являются инсайдерами. Обычно используемые круги:
 - а) внесенные в белый список лица, такие как команда, реализующая новую функцию. Вы можете получить дословную обратную связь от членов вашей команды;
 - б) сотрудники компании, так как они обычно более снисходительны, если случаются действительно плохие ошибки;
 - в) бета-пользователи или инсайдеры, которые, как правило, открыты и лояльны; они хотят увидеть новые функции раньше и обычно готовы дать отзыв;
 - г) центры обработки данных для изоляции взаимодействий, которые может быть сложно идентифицировать, таких как утечки памяти или другое ненадлежащее использование ресурсов, например перегрузка интерфейса ввода-вывода (см. главу 22). В Bing обычным явлением является запуск небольшого трафика одного центра обработки данных (например, 0,5–2 %). Когда один центр обработки данных без проблем доведен до приличного трафика, можно увеличить трафик и для остальных центров.

2. Автоматическое наращивание трафика до желаемого распределения. Желаемое распределение может быть либо конкретным «кругом», либо заранее установленным процентом распределения трафика. Даже если желаемое распределение составляет лишь небольшой процент (например, 5 %), дополнительный час для достижения 5 % может помочь ограничить влияние плохих ошибок без значительных задержек.
3. Измерение ключевых ограничительных показателей в режиме реального времени или близко к нему. Чем раньше вы узнаете, является ли эксперимент рискованным, тем быстрее сможете решить проблему и перейти к следующей фазе рампинга.

15.3.2. Вторая фаза рампинга: MPR

MPR – это фаза, посвященная непосредственно измерению экспериментального эффекта. Многочисленные рассуждения по поводу получения заслуживающих доверия результатов, которые мы вели на протяжении всей книги, непосредственно применимы на этом этапе. Мы хотим подчеркнуть нашу рекомендацию держать эксперименты на уровне MPR в течение недели или дольше, если присутствуют эффекты новизны или первенства.

Эта фаза рампинга должна быть достаточно продолжительной, чтобы учесть зависящие от времени факторы. Например, эксперимент, который длится всего один день, приведет к смещению результатов в сторону активных пользователей. Точно так же пользователи, которые посещают сайт в будние дни, обычно отличаются от пользователей, посещающих сайт в выходные.

Обычно при более длительном эксперименте мы получаем меньшую дисперсию, но чем дольше мы ждем, тем меньше эффект. По нашему опыту, повышение точности, достигнутое через неделю, обычно невелико, если воздействие не обладает эффектами новизны или первенства.

15.3.3. Третья фаза рампинга: пост-MPR

К тому времени, когда эксперимент пройдет стадию MPR, не должно остаться никаких опасений относительно воздействия на конечного пользователя. Оптимально было бы также решить эксплуатационные проблемы на более ранних этапах. Есть некоторые опасения по поводу увеличения трафика через отдельные инженерные инфраструктуры, которые могут потребовать увеличения скорости еще до того, как охват достигнет 100 %. Наращивание этих структур должно занимать всего день или меньше, обычно покрывая периоды пиковой нагрузки при тщательном мониторинге.

15.3.4. Четвертая фаза рампинга: длительное удержание или репликация

Мы наблюдаем растущую популярность длительных задержек воздействия, также называемых удержаниями, когда определенные пользователи не подвергаются воздействию в течение длительного времени. Мы хотим под-

черкнуть, что не следует делать длительную задержку шагом по умолчанию в процессе рампинга. Помимо стоимости, это также может быть неэтичным, если вы знаете, что есть лучшее предложение, но намеренно откладываете предоставление такого опыта отдельным клиентам, особенно когда все клиенты платят одинаково. Принимайте обдуманное решение о длительной задержке, только если это действительно полезно. Вот три сценария, в которых длительная задержка может оказаться полезной.

1. Когда длительный эффект воздействия может отличаться от краткосрочного (см. главу 23). Возможно, что:
 - a) известно, что область эксперимента имеет эффект новизны или первенства, или
 - b) краткосрочное влияние на ключевые показатели настолько велико, что мы должны обеспечить устойчивость воздействия по причинам, таким как финансовое прогнозирование, или
 - c) краткосрочное влияние практически отсутствует, но команды верят в отсроченный эффект (например, из-за принятия или обнаружения).
2. Когда метрика раннего индикатора показывает влияние, но метрика истинного севера – это долгосрочный показатель, например удержание в течение одного месяца.
3. Когда есть выгода от сокращения дисперсии при более длительном воздействии (см. главу 22).

Существует заблуждение, что задержка всегда должна проводиться, когда большая часть трафика отведена под тестовое воздействие, например, 90 или 95 %. Хотя в целом это может работать хорошо, для обсуждаемого здесь сценария 1(c), где краткосрочное воздействие уже слишком мало, чтобы его можно было обнаружить на MPR, мы должны по возможности продолжать удержание на MPR. Статистической чувствительности, полученной при более продолжительной работе, обычно недостаточно, чтобы компенсировать потерю чувствительности при переходе от MPR к 90 %.

Помимо задержки на уровне экспериментов, есть компании, практикующие сверхзадержки, когда при запуске обновления некоторая часть трафика удерживается в течение длительного времени (часто квартал), чтобы измерить совокупный эффект от экспериментов. Bing проводит глобальную проверку для измерения накладных расходов на платформу экспериментов, где 10 % пользователей Bing не участвуют в каких-либо экспериментах. Также могут проводиться обратные эксперименты, когда пользователей снова переводят в контрольную группу спустя несколько недель (или месяцев) после того, как охват доведен до 100 % (см. главу 23).

Когда результаты эксперимента вызывают удивление, хорошее практическое правило – повторить их. Повторите эксперимент с другим набором пользователей или с повторной ортогональной рандомизацией. Если результаты останутся такими же, у вас будет гораздо больше уверенности

в том, что результаты заслуживают доверия. Репликация – простой, но эффективный способ устранения ложных ошибок. Более того, когда было проведено много итераций эксперимента, результаты последней итерации могут быть смещены вверх. Запуск репликации снижает необходимость многократного тестирования и дает объективную оценку. Более подробно об этом рассказано в главе 17.

15.4. Что после рампинга?

Мы еще не говорили о том, что происходит после развития эксперимента до 100 %. В зависимости от деталей реализации эксперимента (см. главу 4) после рампинга может потребоваться некоторая очистка. Если экспериментальная система использует архитектуру, которая создает вилку кода на основе назначения вариантов, после запуска следует очистить ветку мертвого кода. Если в экспериментальной системе используется параметризация, то очистка будет просто означать использование нового значения параметра по умолчанию. Этот процесс можно упустить из виду в быстро меняющемся процессе разработки, но он крайне важен для поддержания работоспособности производственной системы. Например, в первом случае могут быть катастрофические последствия, когда случайно выполняется ветка мертвого кода, которая давно не поддерживается.

Глава 16

Анализ масштабных экспериментов

Если вы хотите увеличить свой успех, удвойте долю неудач.

– Томас Дж. Вотсон

***Почему это важно:** при переходе компании к более поздним этапам экспериментальной зрелости использование конвейеров анализа данных как части экспериментальной платформы может гарантировать, что методология будет надежной, последовательной и научно обоснованной и что реализация заслуживает доверия. Это также помогает избавить команды от необходимости выполнять трудоемкий специальный анализ. Если вы намерены двигаться в этом направлении, вам пригодится понимание общих принципов устройства инфраструктуры для обработки данных, вычислений и визуализации.*

16.1. Подготовка данных

Чтобы привести необработанные инструментальные данные в состояние, подходящее для вычислений, нам нужно их подготовить. *Подготовка данных* обычно включает следующие шаги.

1. **Сортировка и группировка данных.** Поскольку информация о запросе пользователя может регистрироваться несколькими системами, включая журналы как на стороне клиента, так и на стороне сервера, мы начинаем с сортировки записей и объединения нескольких журналов (см. главу 13). Мы можем сортировать записи как по идентификатору пользователя, так и по отметке времени. Это позволяет объединять события для создания сеансов или посещений, а также группировать все действия по заданному окну времени. Возможно, вам не потребуется материализовать эту связь, поскольку виртуальной связи в качестве шага во время обработки и вычислений может быть достаточно. Материализация полезна, если выходные данные используются не только для анализа эксперимента, но также для отладки, генерации гипотез и многого другого.

2. **Очистка данных.** Сортировка и группировка данных упрощает их очистку. Мы можем использовать эвристику для удаления сеансов, которые вряд ли созданы реальными пользователями (боты или мошенничество, см. главу 3). Вот некоторые полезные эвристики для отбраковки сеансов: слишком много или слишком мало активности в сеансах, слишком мало времени между событиями, слишком много кликов на странице, взаимодействие с сайтом способами, противоречащими законам физики и т. д. Мы также можем исправить проблемы с инструментарием, такие как обнаружение повторяющихся событий или неправильная обработка меток времени. Очистка данных не исправит отсутствующие события, утерянные в результате пропуска исходных данных. Например, ведение журнала кликов по своей сути является компромиссом между точностью и скоростью. В некоторых случаях фильтрация может случайно удалить больше событий из одного варианта, чем из другого, вызывая SRM (см. главу 3).
3. **Обогащение данных.** Некоторые данные можно анализировать и дополнять, чтобы получить полезные измерения. Например, мы часто добавляем семейство и версию браузера, анализируя необработанную строку пользовательского агента. Из дат можно извлечь день недели. Обогащения могут происходить на уровне каждого события, сеанса или пользователя, например можно отмечать событие как повторяющееся или вычислять длительность события, добавлять общее количество событий во время сеанса или общую продолжительность сеанса. В частности, вы можете указать, следует ли включать данный сеанс в вычисление результатов эксперимента. Эти аннотации являются частями бизнес-логики, которые часто добавляются во время обогащения по соображениям эффективности. Другие специальные отметки экспериментов, которые следует учитывать при анализе, включают информацию о переходах экспериментов (например, начало эксперимента, ускорение эксперимента, изменение номера версии), чтобы знать, следует ли включать этот сеанс в вычисление результатов эксперимента. Эти отметки представляют собой части бизнес-логики, которые также добавляют из соображений эффективности.

16.2. Вычисление данных

Обладая подготовленными данными, вы можете вычислить сегменты и показатели и агрегировать результаты, чтобы получить сводную статистику для каждого эксперимента, включая как оцениваемый эффект воздействия (например, дельта среднего или процентиля), так и статистическую значимую информацию (p -значение, доверительный интервал и т. д.). На этапе вычисления данных также может появиться дополнительная информация, например о том, какие сегменты представляют интерес.

Есть много вариантов построения архитектуры вычисления данных. Мы опишем два общих подхода. Не ограничивая обобщенность, далее мы предполагаем, что единичный объект эксперимента является пользователем.

1. Первый подход состоит в том, чтобы материализовать статистику для каждого пользователя (т. е. для каждого пользователя подсчитать количество просмотров страниц, показов и кликов) и присоединить ее к таблице, которая сопоставляет пользователей с экспериментами. Преимущество этого подхода в том, что вы можете использовать статистику по пользователям для общей бизнес-отчетности, а не только для экспериментов. Чтобы эффективно использовать вычислительные ресурсы, вы также можете рассмотреть гибкий способ вычисления показателей или сегментов, которые необходимы только для одного или небольшого набора экспериментов.
2. Альтернативная архитектура должна полностью объединять вычисление показателей для каждого пользователя с анализом эксперимента, где показатели для каждого пользователя вычисляются в процессе по мере необходимости без отдельной материализации. Обычно в такой архитектуре есть способ совместно использовать определения показателей и сегментов для обеспечения согласованности между различными конвейерами, такими как конвейер вычисления данных экспериментов и конвейер вычисления общей бизнес-отчетности. Эта архитектура обеспечивает большую гибкость повторных экспериментов (что также может сэкономить ресурсы машины и хранилища), но требует дополнительных усилий по обеспечению согласованности между несколькими конвейерами.

Скорость и эффективность возрастают по мере того, как экспериментирование распространяется по всей организации. Bing, LinkedIn и Google ежедневно обрабатывают терабайты экспериментальных данных. По мере увеличения количества сегментов и показателей вычисления могут потребовать значительных ресурсов. Более того, любая задержка в создании оценочной карты эксперимента может добавить задержку в принятии решения, что может быть дорогостоящим, поскольку эксперименты становятся все более обычным явлением и неотъемлемой частью инновационного цикла. На заре экспериментальной платформы Bing, Google и LinkedIn ежедневно создавали оценочные таблицы экспериментов с приблизительно 24-часовой задержкой (например, данные за понедельник появляются к концу дня среды). Сегодня у всех нас есть методы, *близкие к реальному времени* (near real-time, NRT). Метод NRT имеет более простые метрики и вычисления (например, только суммы и счетчики, отсутствие фильтрации спама, минимальные статистические тесты), используется для отслеживания самых явных проблем (таких как неправильно сконфигурированный или ошибочный эксперимент) и часто работает непосредственно с «сырыми» журналами без упомянутой выше обработки данных (за исключением обработки

спама в реальном времени). Затем NRT может запускать предупреждения и автоматическое отключение эксперимента. Конвейер пакетной обработки обрабатывает внутрисдневные вычисления и обновления данных и вычислений, чтобы гарантировать своевременную доступность достоверных результатов экспериментов.

Для обеспечения скорости и эффективности, а также правильности и надежности мы рекомендуем, чтобы каждая платформа для экспериментов:

- имела способ определять общие показатели и определения, чтобы все использовали стандартный словарь, все строили одну и ту же ментальную схему данных, и вы могли обсуждать интересные вопросы о продукте, а не тратить время на согласование определений и исследование удивительных различий между похожими показателями, созданными в разных системах;
- обеспечивала согласованность в реализации этих определений, будь то общая реализация, тестирование или механизм постоянного сравнения;
- имела механизм управления изменениями. Как было сказано в главе 4 про модели экспериментальной зрелости, ОЕС и сегменты будут развиваться, поэтому определение и распространение изменений – это повторяющийся процесс. Изменение определения существующего показателя часто бывает более сложной задачей, чем добавление или удаление. Например, стоит ли журналировать изменения (т. е. распространять изменения исторически), и если да, то как долго хранить историю?

16.3. ФОРМИРОВАНИЕ СВОДКИ И ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ

В конечном итоге цель состоит в том, чтобы наглядно резюмировать результаты и выделить ключевые показатели и сегменты, чтобы помочь лицам, принимающим решения. В ваших заключениях и визуализациях:

- выделите ключевые тесты, такие как SRM, чтобы четко указать, заслуживают ли результаты доверия. Например, платформа для экспериментов Microsoft (ExP) скрывает систему показателей, если не пройдены ключевые тесты;
- выделите ОЕС и критические показатели, но также покажите многие другие показатели, включая ограничения, качество и т. д.;
- представляйте показатели как относительные изменения с четкими указаниями на то, являются ли результаты статистически значимыми. Используйте цветовую кодировку и активируйте фильтры, чтобы сильные изменения были более заметны.

Детализация по сегментам, включая автоматическое выделение интересных сегментов, помогает убедиться в правильности решений и определить, есть ли способы улучшить продукт для плохо функционирующих сегментов.

Если эксперимент имеет триггерные условия, важно учитывать общее воздействие в дополнение к влиянию на выбираемую популяцию (более подробно об этом говорится в главе 20).

Помимо самой визуализации, чтобы по-настоящему масштабировать эксперименты, визуализация системы показателей должна быть понятна и доступна людям с различным уровнем технической подготовки: от маркетологов до специалистов по обработке данных, от инженеров до менеджеров по продуктам. Для этого необходимо убедиться, что не только экспериментаторы, но и руководители и другие лица, принимающие решения, видят и понимают информационную панель. Иногда приходится скрывать некоторые показатели, особенно отладочные данные, от менее технической аудитории, чтобы избежать путаницы. Доступность информации помогает найти общий язык для определений и сформировать культуру прозрачности и любознательности, побуждая сотрудников проводить эксперименты и узнавать о том, как изменения влияют на бизнес или как финансовый отдел может связать результаты A/B-тестов с перспективами бизнеса.

Инструмент визуализации предназначен не только для результатов каждого эксперимента, но также полезен для перехода к результатам с разбивкой по показателям внутри эксперимента. В то время как инновации, как правило, децентрализованы и оцениваются путем экспериментов, глобальное состояние ключевых показателей обычно тщательно контролируется заинтересованными лицами. Эти люди должны иметь представление о главных экспериментах, влияющих на важные для них показатели. Если эксперимент приводит к ухудшению этих показателей выше некоторого порога, они могут захотеть участвовать в принятии решения о запуске обновления. Визуальные представления экспериментов и показателей могут быть реализованы на централизованной платформе. Платформа полезна тем, что может предоставить две дополнительные функции для развития здорового процесса принятия решений:

- 1) позволяет людям подписываться на важные для них показатели и получать по электронной почте дайджест с наиболее важными экспериментами, влияющими на эти показатели;
- 2) если эксперимент оказывает негативное влияние, платформа может инициировать процесс согласования и заставить разработчика эксперимента начать переговоры с владельцами показателей до начала наращивания эксперимента. Это способствует не только прозрачности в отношении решений о запуске экспериментов, но и обсуждениям, которые увеличивают общие знания об экспериментах в компании.

Инструменты визуализации также могут служить способом доступа к **институциональной памяти** (см. главу 8).

Наконец, по мере того как организация переходит к следующим этапам зрелости эксперимента, количество показателей, используемых вашей ор-

ганизацией, будет продолжать расти, вплоть до тысяч, и на этом этапе мы предлагаем использовать следующие функции:

- распределение показателей по **разным группам**, исходя из уровня или функциональности. Например, LinkedIn классифицирует показатели по трем уровням: 1) по значимости для компании, 2) по характеристикам продукта, 3) по характеристикам функциональности. Microsoft группирует показатели по критериям: 1) качество данных, 2) ОЕС, 3) ограничения, 4) локальные функции / диагностика. Google использует категории, аналогичные LinkedIn. Инструмент визуализации предоставляет элементы управления для анализа различных групп показателей;
- по мере роста количества показателей возрастает важность **многократного тестирования**, и экспериментаторы часто задаются одним общим вопросом: почему этот показатель сильно изменился, когда он кажется несущественным? Хотя обычно помогает изучение и пересмотр показателей, простым, но эффективным вариантом является использование пороговых значений p , меньших чем стандартное значение 0,05, поскольку это позволяет экспериментаторам быстро переходить к наиболее значимым показателям. В главе 17 более подробно говорится о хорошо изученных подходах, таких как процедура Бенджамини–Хохберга, для решения множества проблем тестирования;
- **интересующие показатели**. Когда экспериментатор просматривает результаты эксперимента, он, вероятно, уже имеет в виду набор показателей, которые нужно проанализировать. Однако всегда есть вероятность обнаружить неожиданные изменения других показателей, которые стоит изучить. Платформа может автоматически определять эти показатели, комбинируя несколько факторов, таких как важность этих показателей для компании, статистическая значимость и ложноположительная корректировка;
- **связанные показатели**. Изменение или отсутствие изменения показателя часто можно объяснить другими связанными показателями. Например, чем вызвано повышение рейтинга кликов (CTR) – увеличением количества кликов или уменьшением просмотров страниц? Разные причины изменения могут привести к различным решениям о внедрении. Другой пример – показатели с высокой дисперсией, такие как доход. Наличие более чувствительной версии с меньшей дисперсией, такой как сокращенный доход или другие показатели, позволяет принимать более обоснованные решения.

ЧАСТЬ V



Развернутое описание анализа экспериментов

Часть V состоит из семи глав, посвященных углубленному описанию анализа экспериментов и предназначенных в первую очередь для специалистов по обработке данных и тех, кто заинтересован в более глубоком понимании планов и анализа контролируемых экспериментов.

Мы начинаем с главы о *статистике контролируемых онлайн-экспериментов*, в которой описываются t -критерий, расчет p -значения и доверительного интервала, предположения о нормальности, статистическая мощность и ошибки I/II типа. Она охватывает множественное тестирование и метод Фишера для метаанализа.

Следующая глава посвящена *оценке дисперсии и повышению чувствительности*, где мы начинаем со стандартной формулы, но затем показываем очень распространенную ловушку, требующую использования дельта-метода. Затем мы рассматриваем способы уменьшения дисперсии, что повышает чувствительность экспериментов.

A/A-тест представляет, возможно, лучший способ повысить надежность экспериментальной системы и выявить практические проблемы и ошибки в программном обеспечении или используемой статистике. Многие из обсуждаемых нами подводных камней были обнаружены благодаря A/A-тестам.

В главе про *повышенную чувствительность срабатывания триггера* подробно рассматривается важная концепция, которую организации должны понимать при использовании методики триггера. Поскольку не каждый эксперимент влияет на всех пользователей, концентрация внимания на популяции, подвергшейся воздействию, улучшает чувствительность за счет снижения шума от пользователей, которые не могли быть затронуты. По мере развития организаций использование триггеров растет, а вместе с ними растет и набор инструментов, помогающих анализировать и устранять проблемы.

В следующей главе рассматриваются *несоответствие коэффициента выборки (SRM)* и другие *ограничительные показатели*. SRM часто встречается на практике, и когда есть SRM, результаты выглядят как крайне положительные, так и крайне отрицательные, но им нельзя доверять. Автоматическое выполнение этого и других тестов имеет решающее значение для достоверности результатов.

В некоторых практических сценариях, таких как многосторонние торговые площадки и социальные сети, варианты эксперимента могут привести к утечке информации, о чем говорится в главе про *утечку и взаимовлияние вариантов*.

Мы завершаем эту часть книги главой про важную проблему, которая все еще является предметом исследования: *измерение долгосрочных эффектов воздействия*. Мы представляем несколько экспериментальных проектов, направленных на достижение этой цели.

Глава 17

Статистика контролируемых онлайн-экспериментов

Курение – один из любимых предметов статистики.

– Флетчер Кнебель

***Почему это важно:** статистика имеет фундаментальное значение для разработки и анализа экспериментов.*

Ранее мы упоминали несколько концепций статистики. В этой главе более подробно рассматриваются понятия статистики, критически важные для экспериментирования, включая проверку гипотез и статистическую мощность.

17.1. Двухвыборочный t -ТЕСТ

Двухвыборочный t -тест является наиболее распространенным критерием статистической значимости для определения того, является ли разница, которую мы видим между тестовой и контрольной группой, реальной или просто шумом. Двухвыборочный t -тест оценивает размер разницы между двумя средними значениями относительно дисперсии. Значимость разницы представлена p -значением. Чем ниже значение p , тем сильнее доказательство того, что тестовая группа отличается от контрольной.

Чтобы применить двухвыборочный t -тест к интересующему показателю Y (например, числу запросов на пользователя), предположим, что наблюдаемые значения показателя для пользователей в контрольной и тестовой группе являются независимыми реализациями случайных величин Y^t и Y^c . Гипотеза нулевого значения состоит в том, что Y^t и Y^c имеют одинаковое среднее значение; альтернативная гипотеза состоит в том, что это не так (см. уравнение 17.1):

$$\begin{aligned} H_0: \text{mean}(Y^t) &= \text{mean}(Y^c) \\ H_0: \text{mean}(Y^t) &\neq \text{mean}(Y^c). \end{aligned} \tag{17.1}$$

Двухвыборочный t -тест основан на t -статистике T :

$$T = \frac{\Delta}{\sqrt{\text{var}}}(\Delta), \quad (17.2)$$

где $\Delta = \bar{Y}^t - \bar{Y}^c$ – разница между средним значением контрольной и тестовой группы, объективная оценка сдвига среднего. Поскольку образцы независимы:

$$\text{var}(\Delta) = \text{var}(\bar{Y}^t - \bar{Y}^c) = \text{var}(\bar{Y}^t) + \text{var}(\bar{Y}^c). \quad (17.3)$$

Таким образом, t -статистика T – это просто нормализованная версия Δ .

Интуитивно понятно, что чем больше T , тем меньше вероятность того, что средние значения совпадают. Другими словами, вы с большей вероятностью отвергнете гипотезу о нуле. Как это измерить?

17.2 p -ЗНАЧЕНИЕ И ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ

Теперь, когда у вас есть t -статистика T , вы можете вычислить p -значение, которое представляет собой вероятность того, что T будет, по крайней мере, иметь такое значение, если действительно нет разницы между группами. По соглашению, любое различие с p -значением меньше 0,05 считается «статистически значимым», хотя продолжают дискуссии о необходимости более низких p -значений по умолчанию. Значение p менее 0,01 считается очень значимым.

Несмотря на то что p -значение является одним из наиболее известных понятий статистики, его часто неправильно интерпретируют. Одно из распространенных заблуждений состоит в том, что p -значение отражает вероятность того, что гипотеза о нуле верна при наблюдаемых данных. На первый взгляд это разумная интерпретация, поскольку большинство экспериментаторов ожидают получить вероятность того, окажет ли их воздействие статистически значимое влияние. Однако правильная интерпретация почти противоположна: это вероятность наблюдения дельты, если гипотеза нулевого значения верна. Чтобы увидеть, насколько эти две интерпретации различны, но связаны между собой, вы можете расписать это утверждение с помощью правила Байеса:

$$\begin{aligned} P(H_0 \text{ истина} \mid \Delta \text{ набл.}) &= \frac{P(\Delta \text{ набл.})P(H_0 \text{ истина})}{P(\Delta \text{ набл.})} = \\ &= \frac{P(H_0 \text{ истина})}{P(\Delta \text{ набл.})} \times P(\Delta \text{ набл.} \mid H_0 \text{ истина}) = \frac{P(H_0 \text{ истина})}{P(\Delta \text{ набл.})} \times p\text{-значение}. \end{aligned} \quad (17.4)$$

Как следует из уравнения, чтобы узнать, верна ли нулевая гипотеза на основе собранных данных (апостериорная вероятность), вам необходимо знать не только p -значение, но и вероятность того, что нулевая гипотеза верна.

Другой способ проверить, является ли дельта статистически значимой, – это проверить, не перекрывается ли доверительный интервал с нулем. Некоторые исследователи находят доверительные интервалы более интуитивным способом интерпретации шума и неопределенности вокруг наблюдаемой дельты, чем p -значение. Доверительный интервал 95 % – это диапазон, который покрывает истинную разницу в 95 % случаев и соответствует p -значению 0,05; дельта является статистически значимой на уровне значимости 0,05, если 95%-ный доверительный интервал не содержит нуля или если значение p меньше 0,05. В большинстве случаев доверительный интервал для дельты центрируется вокруг наблюдаемой дельты с расширением примерно на два стандартных отклонения с каждой стороны. Это верно для любой статистики, которая (приблизительно) соответствует нормальному распределению, включая процентную дельту.

17.3. ПРЕДПОЛОЖЕНИЕ О НОРМАЛЬНОСТИ

В большинстве случаев мы вычисляем p -значения с предположением, что t -статистика T следует нормальному распределению и, согласно гипотезе о нуле, распределение имеет среднее значение 0 и дисперсию 1. Значение p – это просто площадь под нормальной кривой, как показано на рис. 2.1 в главе 2. Многие люди неверно истолковывают предположение о нормальности как предположение о выборочном распределении показателя Y и считают его плохим предположением, поскольку почти ни один из показателей, используемых на практике, не соответствует нормальному распределению. Однако в большинстве онлайн-экспериментов размеры выборок как для контроля, так и для тестирования исчисляются как минимум тысячами. Хотя выборочное распределение Y не следует нормальному распределению, среднее $\bar{Y}$ обычно следует ему в силу *центральной предельной теоремы*. Рисунок 17.1 иллюстрирует сходимость с выборками Y , взятыми из бета-распределения. По мере увеличения размера выборки распределение среднего $\bar{Y}$ становится более нормальным.



Рис. 17.1. По мере увеличения размера выборки n распределение среднего $\bar{Y}$ стремится к нормальному

Одно практическое правило для минимального количества образцов, необходимых для среднего $\bar{Y}$ для нормального распределения, составляет $355s^2$ для каждого варианта, где s – коэффициент асимметрии выборочного распределения показателя Y , определенного, как в уравнении 17.5:

$$s = \frac{E[Y - E(Y)]^3}{[Var(Y)]^{3/2}}. \quad (17.5)$$

Некоторые показатели, особенно показатели доходов, как правило, имеют высокий коэффициент асимметрии. Одним из эффективных способов уменьшения асимметрии является преобразование показателя или ограничение значений. Например, после того как Bing ограничил доход на пользователя до 10 долл. на пользователя в неделю, асимметрия упала с 18 до 5, а минимальная необходимая выборка упала в десять раз с 114 до 10 тыс. Это практическое правило дает хорошее представление о том, когда $|s| > 1$, но не дает полезной нижней границы, если распределение симметрично или имеет небольшую асимметрию. С другой стороны, в целом верно то, что при меньшей асимметрии требуется меньше выборки.

Для двухвыборочных t -тестов, поскольку вы смотрите на *разницу* между двумя переменными с похожими распределениями, количество выборок, необходимых для того, чтобы предположение о нормальности было правдоподобным, как правило, меньше. Это особенно верно, если контрольные и тестовые группы имеют равные распределения трафика, поскольку распределение разницы приблизительно симметрично (оно идеально симметрично с нулевой асимметрией согласно нулевой гипотезе).

Если вы когда-нибудь задумывались, достаточно ли велик размер вашей выборки, чтобы предполагать нормальность, проверьте его хотя бы один раз с помощью компьютерного моделирования. Вы можете случайным образом перемешивать выборки между группами, чтобы сгенерировать нулевое распределение и сравнить это распределение с нормальной кривой, используя статистические тесты Колмогорова–Смирнова и Андерсона–Дарлинга. Поскольку хвостовое распределение представляет интерес для проверки гипотез, вы также можете повысить чувствительность теста, сосредоточившись только на том, ограничена ли частота ошибок типа I заданным порогом, например 0,05.

Когда предположение о нормальности не срабатывает, вы можете провести перестановочный тест и посмотреть, где находится ваше наблюдение относительно смоделированного нулевого распределения. Обратите внимание, что, даже несмотря на то, что перестановочное тестирование очень дорого обходится в масштабной реализации, случаи, когда это необходимо, часто связаны с небольшими размерами выборки, поэтому на практике оно хорошо работает.

17.4. Ошибки типа I/II и статистическая мощность

При любом тесте случаются ошибки. При проверке гипотез мы заботимся об ошибках типа I и II. *Ошибка типа I* заключается в том, что мы наблюдаем значительную разницу между контролем и воздействием, когда реальной разницы нет. *Ошибка типа II* – это когда мы делаем вывод об отсутствии значительной разницы, хотя она действительно есть. Принято отслеживать уровень ошибок типа I на уровне 0,05, делая вывод о статистической значимости только в том случае, если p -значение ниже этого уровня. Очевидно, что между этими двумя ошибками есть компромисс. Использование более высокого порогового значения p означает более высокую частоту ошибок типа I, но меньшую вероятность пропуска реальной разницы, следовательно, более низкую частоту ошибок типа II.

Концепция ошибок типа II более известна как мощность. *Мощность* – это вероятность обнаружения разницы между вариантами, т. е. отклонения нуля, когда действительно есть разница (см. уравнение 17.6):

$$\text{Мощность} = 1 - \text{ошибка типа II.} \quad (17.6)$$

Мощность обычно параметризована дельтой δ – это минимальная дельта, представляющая практический интерес. Математически предполагая, что желаемый уровень уверенности составляет 95 %, приходим к уравнению 17.7:

$$\text{Мощность } \delta = P(|T| \geq 1.96 \mid \text{истинная разница равна } \delta). \quad (17.7)$$

Согласно отраслевому стандарту в наших тестах мощность должна составлять не менее 80 %. Поэтому обычно перед началом эксперимента про-

водят анализ мощности, чтобы решить, сколько образцов необходимо для достижения достаточной мощности. Предполагая, что контрольная и тестовая группа имеют одинаковый размер, общее количество образцов, необходимое для достижения мощности 80 %, может быть получено из приведенной выше формулы мощности и приблизительно вычисляется по уравнению 17.8:

$$n \approx \frac{16\sigma^2}{\delta^2}, \quad (17.8)$$

где σ^2 – дисперсия выборки, а δ – разница между воздействием и контролем.

Часто люди задают вопрос: как они узнают δ до проведения эксперимента? Действительно, мы не знаем истинного значения δ , и это причина для начала эксперимента.



Рис. 17.2. Аналогия статистической мощности с игрой «Найди отличия». Для большей разницы мощность выше

Однако мы знаем размер δ , который имел бы *практическое* значение. Например, вы можете не заметить разницу в 0,1 % в доходе, и это нормально, но падение дохода на 1 % – это заметно. В этом случае 0,1 % практически не имеет значения, а 1 % имеет. Чтобы оценить требуемый минимальный размер выборки, используйте наименьшее значение δ , которое имеет практическое значение (также называемое *минимальным обнаруживаемым эффектом*).

Оценка размера выборки онлайн-экспериментов является более сложной, поскольку онлайн-пользователи периодически посещают сайт с течением времени, и продолжительность эксперимента также играет роль в фактическом размере выборки эксперимента. В зависимости от единицы рандомизации дисперсия выборки σ^2 также может изменяться со временем. Еще одна проблема заключается в том, что при запуске анализа по условию (см. главу 20) значения σ^2 и δ меняются по мере изменения условий запуска в разных экспериментах. По этим причинам в главе 15 мы представляли

более практичный подход к принятию решения о распределении трафика и продолжительности большинства онлайн-экспериментов.

Мы хотим подчеркнуть распространенное неправильное толкование понятия статистической мощности. Многие люди считают мощность абсолютным свойством теста и забывают, что она зависит от величины эффекта, который вы хотите обнаружить. Эксперимент, у которого достаточно мощности, чтобы обнаружить разницу в 10 %, необязательно сможет обнаружить разницу в 1 %. Хорошая аналогия – игра «Найди отличия». Рисунок 17.2 демонстрирует, что, по сравнению с разницей в точках (сплошной кружок), легче обнаружить разницу в листьях кувшинок (пунктирный кружок), поскольку это более выраженная разница.

Как вы понимаете, анализ мощности тесно связан с ошибками типа I и II. Гельман и Карлин (Gelman and Carlin, 2014) утверждают, что для планов с небольшим размером выборки также важно рассчитать: а) вероятность того, что неправильно оценили направление изменения (ошибка типа S [sign, знак]), и б) коэффициент, на который величина эффекта могут быть переоценены (ошибка типа M [magnitude, размах], или *коэффициент преувеличения*).

17.5. СМЕЩЕНИЕ

Смещение результата эксперимента возникает, когда оценка и истинное значение среднего систематически различаются. Это может быть вызвано ошибкой платформы, неудачным планом эксперимента или нерепрезентативной выборкой, такой как сотрудники компании или тестовые учетные записи. Мы обсуждали несколько примеров и рекомендаций по предотвращению и обнаружению смещения в главе 3.

17.6. МНОЖЕСТВЕННОЕ ТЕСТИРОВАНИЕ

Поскольку для каждого эксперимента рассчитываются сотни показателей, мы часто слышим от экспериментаторов: «Почему этот нерелевантный показатель имеет значение?» Вот упрощенное объяснение. Если вы вычислите 100 показателей для своего эксперимента, сколько показателей вы сочтете статистически значимыми, даже если ваша функция ничего не делает? При уровне значимости 5 % ответ будет около пяти (при условии, что показатели независимы). Проблема усугубляется при изучении сотен экспериментов и нескольких итераций за эксперимент. При параллельном тестировании нескольких изменений количество ложных открытий увеличивается. Это называется проблемой «множественного тестирования».

Как мы можем гарантировать, что при многократном тестировании ошибки типа I и типа II по-прежнему остаются под разумным контролем? Есть много хорошо изученных подходов; однако большинство из них либо просты, но слишком консервативны, либо сложны и, следовательно, менее доступны. Например, популярная *поправка Бонферрони* (Bonferroni

correction), в которой используется постоянный, но гораздо меньший порог p -значения (0,05, деленный на количество тестов), попадает в первую категорию. В *процедуре Бенджамини–Хохберга* (Hochberg and Benjamini, 1995) используются различные пороги p -значения для разных тестов, и она попадает во вторую категорию.

Итак, что делать, если показатель неожиданно стал значительным? Вот простое двухэтапное правило.

1. Разделите все показатели на три группы:
 - ♦ показатели первого порядка, на которые, по вашему мнению, повлияет эксперимент;
 - ♦ показатели второго порядка, которые могут испытать косвенное влияние (например, вследствие каннибализации кликов);
 - ♦ показатели третьего порядка: на них вряд ли что-то повлияет.
2. Примените отдельные уровни значимости к каждой группе (например, 0,05, 0,01 и 0,001 соответственно).

Это практическое правило основано на интересной байесовской интерпретации: насколько вы верите в истинность нулевой гипотезы (H_0) еще до того, как вы проведете эксперимент? Чем сильнее убеждение, тем ниже уровень значимости, который вам следует использовать.

17.7. МЕТААНАЛИЗ ФИШЕРА

Мы уже обсуждали в главе 8, как идентифицировать закономерности, а также создавать и использовать институциональные воспоминания на основе метаанализа исторических экспериментов. В этом разделе мы сосредоточимся на объединении результатов нескольких экспериментов, которые проверяют одну и ту же гипотезу. Например, это распространенный метод воспроизведения эксперимента, который дал удивительные результаты. Воспроизведение выполняется либо с использованием ортогональной рандомизации, либо с привлечением пользователей, не включенных в первый раунд эксперимента. Эти два эксперимента – исходный и повторный – производят независимые друг от друга p -значения. Интуитивно, если оба значения p меньше 0,05, это более сильное доказательство того, что тестовое воздействие оказывает влияние, чем наличие только одного p -значения меньше 0,05. Фишер формализует это представление в своем методе метаанализа (Fisher, 1925), говоря, что мы можем объединить p -значения из нескольких независимых статистических тестов в общую статистику, как показано в уравнении 17.9:

$$X_2^2 k^2 = -2 \sum_{i=1}^k \ln(p_i), \quad (17.9)$$

где p_i – p -значение для i -й проверки гипотезы. Если все k нулевых гипотез верны, эта статистика следует распределению хи-квадрат с $2k$ степенями

свободы. Браун (1975) расширяет метод Фишера на случаи, когда p -значения не являются независимыми. Существуют и другие методы комбинирования p -значений, обсуждение которых выходит за рамки этой книги.

В целом метод Фишера (или любой другой метод метаанализа) отлично подходит для увеличения мощности и уменьшения количества ложноположительных результатов. Вы можете провести эксперимент, который окажется недостаточно мощным даже после применения всех техник увеличения мощности, таких как распределение трафика для максимальной мощности (см. главу 15) и уменьшение дисперсии (см. главу 22). В этом случае вы можете рассмотреть две или более (ортогональных) репликации одного и того же эксперимента (одну за другой) и добиться более высокой мощности, комбинируя результаты с использованием метода Фишера.

Глава 18

Оценка дисперсии и повышение чувствительности: подводные камни и решения

Чем больше мощность, тем меньшим воздействием можно обойтись.

– Неизвестный автор

Почему это важно: какой смысл проводить эксперимент, если вы не можете его достоверно проанализировать? Дисперсия – это суть анализа эксперимента. Почти все ключевые понятия статистики, которые мы ввели, связаны с дисперсией, такие как статистическая значимость, p -значение, мощность и доверительный интервал. Крайне важно не только правильно оценить дисперсию, но и понять, как добиться уменьшения дисперсии, чтобы повысить чувствительность тестирования статистических гипотез.

В этой главе рассматривается дисперсия, которая является наиболее важным элементом для вычисления p -значений и доверительных интервалов. В первую очередь мы сосредоточены на двух темах: распространенных ошибках (и решениях) при оценке дисперсии и методах уменьшения дисперсии, способствующих повышению чувствительности.

Давайте рассмотрим стандартную процедуру вычисления дисперсии среднего показателя с $i = 1, \dots, n$ независимых одинаково распределенных выборок. В большинстве случаев i является пользователем, но это также может быть сеанс, страница, пользовательский день и т. д.:

- вычислите метрику (среднее значение): $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$;
- вычислите дисперсию выборки: $\text{var}(Y) = \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$;
- вычислите дисперсию среднего показателя, которая представляет собой дисперсию выборки, масштабированную с коэффициентом n :

$$\text{var}(\bar{Y}) = \text{var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n^2} \times n \times \text{var}(Y) = \frac{\hat{\sigma}^2}{n}.$$

18.1. РАСПРОСТРАНЕННЫЕ ОШИБКИ

Если вы неправильно оцениваете дисперсию, то p -значение и доверительный интервал будут неверными, что заставит вас сделать ошибочные выводы из результатов проверки гипотезы. Завышенная дисперсия приводит к ложноотрицательным результатам, а заниженная – к ложноположительным. Вот несколько распространенных ошибок при оценке дисперсии.

18.1.1. Дельта или процентная дельта?

При сообщении результатов эксперимента очень часто используется относительная разница вместо абсолютной. Трудно понять, является ли значительным увеличение количества сеансов среднего пользователя на 0,01, или как это соотносится с влиянием на другие показатели. Лица, принимающие решения, обычно хорошо понимают увеличение частоты сеансов на 1 %. Относительная разница, называемая *процентной дельтой*, определяется как:

$$\Delta\% = \frac{\Delta}{Y^c}. \quad (18.1)$$

Чтобы правильно вычислить доверительный интервал $\Delta\%$, нам необходимо оценить дисперсию. Дисперсия для дельты – это сумма дисперсий каждого компонента:

$$\text{var}(\Delta) = \text{var}(\bar{Y}^t - \bar{Y}^c) = \text{var}(\bar{Y}^t) + (\bar{Y}^c)^2. \quad (18.2)$$

Распространенной ошибкой при оценке дисперсии $\Delta\%$, является деление $\text{var}(\Delta)$ на $(\bar{Y}^c)^2$, т. е. $\frac{\text{var}(\Delta)}{(\bar{Y}^c)^2}$. Это неверно, поскольку само значение $\bar{Y}^c$ является случайной величиной. Правильный способ оценки дисперсии:

$$\text{var}(\Delta\%) = \text{var}\left(\frac{\bar{Y}^t - \bar{Y}^c}{\bar{Y}^c}\right) = \text{var}\left(\frac{\bar{Y}^t}{\bar{Y}^c}\right). \quad (18.3)$$

Мы обсудим, как найти дисперсию отношения, в следующем разделе.

18.1.2. Показатели отношения: когда уровень анализа отличается от уровня эксперимента

Многие важные показатели извлекаются из отношения двух показателей. Например, рейтинг кликов (CTR) обычно определяется как отношение об-

щего количества кликов к общему количеству просмотров страниц; доход за клик определяется как отношение общего дохода к общему количеству кликов. В отличие от таких показателей, как количество кликов на пользователя или доход на пользователя, когда вы используете отношение двух показателей, единицей анализа становится уже не пользователь, а просмотр страницы или клик. Если эксперимент рандомизирован по пользователям, это может создать проблему для оценки дисперсии.

Формула дисперсии $var(Y) = \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ настолько проста

и элегантна, что легко забыть о стоящем за ней важном предположении: выборки $(Y_1, \dots, Y_n)$ должны быть независимо одинаково распределены или, по крайней мере, не коррелированы. Это предположение выполняется, если уровень анализа совпадает с уровнем эксперимента (рандомизации). В противном случае предположение обычно нарушается. Для показателей уровня пользователя каждый Y_i представляет собой измерение для пользователя. Уровень анализа соответствует уровню эксперимента и, следовательно, предположение о независимом одинаковом распределении верно. Однако для показателей уровня страницы каждый Y_i представляет собой измерение для страницы, в то время как эксперимент рандомизирован по пользователям, поэтому Y_1 , Y_2 и Y_3 могут происходить от одного и того же пользователя и «коррелированы». Из-за такой «внутрипользовательской корреляции» дисперсия, вычисляемая с использованием простой формулы, будет смещена.

Чтобы правильно оценить дисперсию, вы можете записать показатель отношения как отношение «среднего значения показателей уровня пользователя» (уравнение 18.4):

$$M = \frac{\bar{X}}{\bar{Y}}. \quad (18.4)$$

Поскольку $\bar{X}$ и $\bar{Y}$ совместно являются двумерными нормальными в пределе, M как отношение двух средних также имеет нормальное распределение. Следовательно, с помощью дельта-метода мы можем вычислить дисперсию, как в уравнении 18.5:

$$var(M) = \frac{1}{\bar{Y}^2} var(\bar{X}) + \frac{\bar{X}^2}{\bar{Y}^4} var(\bar{Y}) - 2 \frac{\bar{X}}{\bar{Y}^3} cov(\bar{X}, \bar{Y}). \quad (18.5)$$

В случае $\Delta \% Y^t$ и Y^c независимы, следовательно:

$$var(\Delta\%) = \frac{1}{\bar{Y}^c} var(\bar{Y}^t) + \frac{\bar{Y}^{t^2}}{\bar{Y}^c} var(\bar{Y}^c). \quad (18.6)$$

Заметим, что когда средние значения в группах тестирования и контроля существенно различаются, то и оценка $\text{var}(\Delta\%)$ существенно отличается от

неправильной оценки $\frac{\text{var}(\Delta)}{y^c{}^2}$.

Обратите внимание, что есть показатели, которые нельзя записать в виде отношения двух показателей уровня пользователя, например 90-й процентиль времени загрузки страницы. Для этих показателей, возможно, придется прибегнуть к методу бутстрапа, в котором вы моделируете рандомизацию путем выборки с заменой и оцениваете дисперсию на основе множества повторяющихся имитаций. Несмотря на то что бутстрап требует больших вычислительных ресурсов, это мощный, широко применимый метод и хорошее дополнение к дельта-методу.

18.1.3. Выбросы

Выбросы бывают разных видов. Наиболее распространены выбросы вследствие деятельности ботов, выполняющих множественные клики или просмотры страниц. Выбросы имеют большое влияние как на среднее значение, так и на дисперсию. В статистическом тестировании влияние на дисперсию имеет тенденцию перевешивать влияние на среднее значение, как мы продемонстрируем с помощью следующей модели.

Пусть в этой модели тестовое воздействие дает положительную истинную дельту по сравнению с контролем. Мы добавляем один положительный выброс в тестовую группу. Размер выброса кратен размеру дельты. По мере того как мы меняем множитель (относительный размер), мы замечаем, что, хотя выброс увеличивает среднее значение тестовой группы, он еще больше увеличивает дисперсию (или стандартное отклонение). В результате на рис. 18.1 вы можете видеть, что t -статистика уменьшается по мере увеличения относительного размера выброса, и в конечном итоге тест перестает быть статистически значимым.

При оценке дисперсии очень важно удалить выбросы. Практичный и эффективный метод – просто ограничить наблюдения разумным порогом. Например, пользователи-люди вряд ли будут выполнять поиск более 500 раз подряд или иметь более 1000 просмотров страниц за один день. Также существует множество других методов удаления выбросов.




Рис. 18.1. В нашей модели, когда мы увеличиваем размер единственного выброса, тест с двумя выборками превращается из очень значимого в совсем не значимый

18.2. ПОВЫШЕНИЕ ЧУВСТВИТЕЛЬНОСТИ

При проведении контролируемого эксперимента мы стремимся обнаружить эффект от воздействия, если он существует. Способность обнаружения обычно называют мощностью или чувствительностью. Один из способов улучшить чувствительность – уменьшить дисперсию. Вот некоторые из множества способов добиться меньшей дисперсии:

- использование показателя с меньшим отклонением, дающего при этом аналогичную информацию. Например, количество поисковых запросов имеет более высокую дисперсию, чем количество выполняющих запросы пользователей; сумма покупки (реальная стоимость) имеет более высокую дисперсию, чем факт покупки (логическое значение). Кохави и соавторы в одной из публикаций приводят конкретный пример, когда использование коэффициента конверсии вместо расходов на закупки уменьшило необходимый размер выборки в 3,3 раза;
- преобразование показателя с помощью ограничения, бинаризации или преобразования журнала. Например, вместо использования средней продолжительности потоковой передачи Netflix использует двоичные показатели, указывающие, смотрел ли пользователь видео более x часов за указанный период времени. Для тяжелых длинных показателей рассмотрите возможность преобразования журнала, особенно если интерпретируемость не имеет значения. Однако

есть некоторые показатели, такие как доход, для которых преобразованная версия может оказаться неправильной целью с точки зрения оптимизации бизнеса;

- использование выборочного анализа (см. главу 20). Это отличный способ удалить шум, создаваемый людьми, которые не затронуты тестовым воздействием.
- использование стратификации, контрольных переменных или *контролируемого эксперимента с предварительно известными данными* (controlled experiment using pre-experiment data, CUPED). При стратификации вы делите область выборки на страты, делаете выборки внутри каждой страты по отдельности, а затем объединяете результаты по отдельным стратам для общей оценки, которая обычно имеет меньшую дисперсию, чем оценка без стратификации. Обычно страты делят по платформам (настольные и мобильные), типам браузеров (Chrome, Firefox и Edge), дням недели и т. д. Хотя стратификация чаще всего проводится на этапе отбора измерений (во время выполнения), ее внедрение в больших масштабах обычно обходится слишком дорого. Поэтому в большинстве приложений используется *отложенная стратификация* – применение стратификации ретроспективно на этапе анализа. Когда размер выборки большой, этот подход работает как стратифицированная выборка, хотя он может и не уменьшить дисперсию, если размер выборки мал, а изменчивость между выборками велика. Подход с контрольными переменными основан на аналогичной идее, но в нем используют ковариаты в качестве переменных регрессии вместо их использования для построения страт. CUPED – это применение этих методов для онлайн-экспериментов, в котором особое внимание уделяется использованию данных, полученных *до* проведения экспериментов;
- проведение рандомизации среди более детализированных уровней. Например, если вас интересует показатель времени загрузки страницы, вы можете существенно увеличить размер выборки, выполняя рандомизацию по странице. Вы также можете рандомизировать каждый поисковый запрос, чтобы уменьшить дисперсию, если вас интересуют показатели каждого запроса. Обратите внимание, что у рандомизации уровнем ниже пользователя есть недостатки:
 - ♦ если эксперимент направлен на внесение заметных изменений в пользовательский интерфейс, предоставление одному и тому же пользователю разнородных пользовательских интерфейсов ухудшит пользовательский опыт;
 - ♦ невозможно измерить какое-либо влияние на уровне пользователя с течением времени (например, удержание пользователей).
- планирование парных экспериментов. Если вы можете показать одному и тому же пользователю как тестовый, так и контрольный вариант в парном эксперименте, вы сможете устранить вариативность между

пользователями и добиться меньшей дисперсии. Одним из популярных методов оценки ранжированных списков является схема с чередованием, при которой вы чередуете элементы двух ранжированных списков и представляете пользователю объединенный список;

- объединение контрольных групп. Если у вас есть несколько экспериментов, получающих долю трафика, и каждый имеет свою собственную контрольную группу, подумайте о том, чтобы объединить отдельные контрольные группы в большую общую контрольную группу. Сравнение каждой тестовой группы с этой общей контрольной группой увеличивает мощность всех задействованных экспериментов. Если вам известны размеры всех тестовых групп, с которыми вы сравниваете контрольную группу, вы можете математически определить оптимальный размер для общей контрольной группы. Вот соображения по реализации этого метода на практике:
 - ♦ если каждый эксперимент имеет свое собственное условие запуска, может быть трудно сравнить их все с одной контрольной группой;
 - ♦ возможно, вы захотите сравнить тестовые группы напрямую друг с другом. Насколько важна статистическая мощность в таком случае по сравнению с традиционным контролируемым экспериментом?
 - ♦ в одинаковом размере контрольной и тестовой группы есть свои преимущества, даже несмотря на то, что объединенная контрольная группа, несомненно, больше, чем тестовые группы. Сбалансированным парам «тест–контроль» присуща более быстрая сходимость нормальности (см. главу 17) и они вызывают меньшую озабоченность по поводу размеров кеша (в зависимости от того, как вы кешируете реализацию).

18.3. ДИСПЕРСИЯ ДРУГИХ СТАТИСТИЧЕСКИХ ДАННЫХ

В большинстве рассуждений в этой книге мы предполагаем, что интересующим статистическим параметром является среднее значение. Что, если вас интересуют другие статистические данные, например квантили? Когда дело доходит до показателей на основе времени, таких как время загрузки страницы (PLT), для измерения скорости загрузки сайта обычно используют квантили, а не среднее значение. Например, 90-й или 95-й процентиля обычно измеряют время загрузки, связанное с вовлечением пользователя, в то время как 99-й перцентиль чаще измеряет задержку на стороне сервера.

Хотя вы всегда можете прибегнуть к бутстрапину для проведения статистического теста путем нахождения «хвостовых» вероятностей (вероятностей большого отклонения), это становится дорогостоящим с точки зрения вычислений по мере роста размера данных. С другой стороны, если статистика асимптотически следует нормальному распределению, вы мо-

жете дешево оценить дисперсию. Например, асимптотическая дисперсия квантильных показателей является функцией плотности (Lehmann and Romano, 2005). Оценивая плотность, вы можете оценить дисперсию.

Есть и другое затруднение. Большинство зависящих от времени показателей находятся на уровне события/страницы, тогда как эксперимент рандомизируется на уровне пользователя. В этом случае примените комбинацию оценки плотности и дельта-метода (Liu и др., 2018).

Глава 19

А/А-тестирование

Если вам кажется, что все под контролем, значит, вы двигаетесь недостаточно быстро.

– Марио Андретти

Если все под контролем, значит, вы проводите А/А-тест.

– Ронни Кохави¹

Почему это важно: проведение А/А-тестов является важной частью формирования доверия к экспериментальной платформе. Эта идея чрезвычайно полезна, потому что на практике тесты много раз терпят неудачу, что приводит к переоценке предположений и выявлению ошибок.

Идея А/А-теста проста: разделите пользователей на две группы, как в обычном А/В-тесте, но сделайте группу В идентичной группе А (отсюда и название: А/А-тест). Если система работает правильно, то при повторных испытаниях примерно в 5 % случаев данный показатель должен быть статистически значимым с p -значением менее 0,05. При проведении t -тестов для вычисления p -значений их распределение из повторных испытаний должно быть близко к равномерному распределению.

19.1. Почему нужны А/А-тесты?

Теория контролируемых экспериментов хорошо изучена, но практическая реализация открывает множество подводных камней. А/А-тест, иногда называемый *нулевым тестом*, очень полезен для формирования доверия к вашей экспериментальной платформе.

А/А-тесты проводятся так же, как А/В-тесты, но пользователи из контрольной и тестовой группы получают идентичный опыт. Вы можете использовать А/А-тесты для нескольких целей, например:

- проверки того, что ошибки типа I ведут себя, как ожидалось (например, на уровне 5 %). Как будет показано в примере 1 далее в этой главе, могут быть неверными стандартные расчеты дисперсии для

¹ <https://twitter.com/ronnyk/status/794357535302029312>

некоторых показателей или может не выполняться предположение о нормальности. Непредвиденные провалы А/А-тестов укажут на проблемы, которые необходимо решить;

- оценки изменчивости показателей. Мы можем изучить данные А/А-теста, чтобы установить, как дисперсия показателя изменяется со временем по мере того, как в эксперимент включается все больше пользователей, и ожидаемое уменьшение дисперсии среднего может не произойти;
- чтобы убедиться, что у пользователей из контрольной и тестовой группы нет предвзятости, особенно при повторном использовании популяций из предыдущих экспериментов. А/А-тесты очень эффективны для выявления предвзятости, особенно для единиц, вводимых на уровне платформы. Например, Bing использует непрерывное А/А-тестирование для выявления эффекта переноса (или остаточного эффекта), когда предыдущие эксперименты могут повлиять на последующие эксперименты, проводимые на тех же пользователях;
- сравнения данных с записями системы. Обычно А/А-тест используется в качестве первого шага перед началом использования контролируемого эксперимента в организации. Если данные собираются с использованием отдельной системы журналирования, хорошим предварительным шагом является проверка соответствия ключевых показателей (например, количество пользователей, доход, рейтинг кликов) с данными в журнале;
- если система журналирования показывает, что Х пользователей посетили веб-сайт во время эксперимента, и вы направили по 20 % трафика в каждую группу, действительно ли вы видите примерно 20 % от Х пользователей в каждой группе? Не ускользают ли некоторые пользователи от измерений?
- оценки дисперсии для статистических расчетов мощности. А/А-тесты предоставляют дисперсии показателей, которые помогают определить, как долго нужно проводить А/В-тесты для заданного минимального обнаруживаемого эффекта.

Мы настоятельно рекомендуем проводить непрерывные А/А-тесты параллельно с другими экспериментами, чтобы выявить проблемы, включая несоответствие распределения и аномалии платформы.

В следующих примерах показано, почему и как следует проводить А/А-тесты.

19.1.1. Пример 1: уровень анализа отличается от уровня рандомизации

Как было сказано в главе 14, иногда желательно рандомизировать пользователей, но выполнять анализ на уровне страниц. Например, системы оповещения обычно следят за временем загрузки страницы (PLT и CTR), агрегируя каждую страницу в режиме, близком к реальному времени. Поэтому часто требуется оценка эффекта воздействия по страницам.

Теперь мы возьмем показатель CTR и обсудим два распространенных способа его вычисления, каждый с разными единицами анализа. Первый – это подсчет кликов и деление на количество просмотров страницы; второй – усреднить CTR каждого пользователя, а затем усреднить все CTR. Если выполнялась рандомизация пользователей, то первый механизм использует другой уровень анализа относительно рандомизации, что нарушает предположение о независимости и усложняет вычисление дисперсии.

В этом примере мы проанализируем и сравним оба метода.

Пусть n – количество пользователей, а K_i – количество просмотров страниц для пользователя i . N – общее количество просмотров страниц: $N = \sum_{i=1}^n K_i$. $X_{i,j}$ – количество кликов пользователя i на его j -й странице.

Теперь рассмотрим подробнее два наших обоснованных определения CTR.

1. Подсчитаем все клики и разделим на общее количество просмотров страниц:

$$CTR_1 = \frac{\sum_{i=1}^n \sum_{j=1}^{K_i} X_{i,j}}{N}. \quad (19.1)$$

Если у нас есть два пользователя, один без кликов и с одним просмотром страницы, а другой с двумя кликами, по одному при каждом из двух просмотров страниц, то:

$$CTR_1 = \frac{0 + 2}{1 + 2} = \frac{2}{3}. \quad (19.2)$$

2. Усредним CTR каждого пользователя, а затем усредним все CTR, по сути, получив двойное усреднение:

$$CTR_2 = \sum_{i=1}^n \frac{\sum_{j=1}^{K_i} X_{i,j}}{K_i} / n. \quad (19.3)$$

Воспользуемся числовым примером из первого определения:

$$CTR_2 = \frac{0}{1} + \frac{2}{2} / 2 = \frac{1}{2}. \quad (19.4)$$

В приведенных выше уравнениях нет правильного или неправильного определения, оба являются полезными определениями для CTR, но использование разных средних значений пользователей дает разные результаты. На практике в оценочных карточках обычно отображают оба показателя, хотя мы обычно рекомендуем второе определение, поскольку считаем его более устойчивым к выбросам, таким как боты, дающие много просмотров страниц или кликов.

При вычислении дисперсии легко ошибиться. Если А/В-тест рандомизирован по пользователям, то при вычислении дисперсии, согласно первому определению, мы получаем:

$$\text{var}(CTR_1) = \sum_{i=1}^n \sum_{j=1}^{K_i} (X_{ij} - CTR_1)^2 / N^2. \quad (19.4)$$

Это неверно, так как предполагается, что X_{ij} независимы (см. главы 14 и 18). Чтобы вычислить объективную оценку дисперсии, используйте метод дельты или бутстраппинг.

Первоначально мы сделали это наблюдение не потому, что это было очевидным нарушением предположения о независимости, а потому, что в наших А/А-тестах CTR_1 был статистически значимым намного чаще, чем ожидаемые 5 %.

19.1.2. Пример 2: поощрение остановки эксперимента при достижении статистической значимости

В книге «А/В-тестирование: самый эффективный способ превратить клики в клиентов» (*A/B Testing: The Most Powerful Way to Turn Clicks into Customers*, Siroker and Koomen, 2013) предложена неправильная процедура завершения экспериментов: «Как только тест достигнет статистической значимости, вы получите свой ответ» и «Когда тест пришел к статистически значимому заключению...» Традиционная статистика предполагает, что в конце эксперимента будет проведен только один тест, и «подглядывание» нарушает это предположение, приводя к гораздо большему количеству ложных срабатываний, чем ожидалось при использовании классической проверки гипотез.

Ранние версии Optimizely поощряли «подглядывание» и, следовательно, раннюю остановку эксперимента, что приводило ко многим ложным успехам. Когда некоторые экспериментаторы начали проводить А/А-тесты, они поняли это, что привело к появлению таких статей, как «Как оптимально (почти) меня уволили» (Borden, 2014). К их чести, в Optimizely работали с экспертами в этой области, такими как Рамеш Джохари, Лео Пекелис и Дэвид Уолш, и обновили свой метод, назвав его «Новый механизм статистики Optimizely» (Пекелис 2015, Пекелис, Уолш и Джохари, 2015).

19.1.3. Пример 3: переадресация браузера

Предположим, вы создаете новую версию своего веб-сайта и хотите провести А/В-тестирование старой версии по сравнению с новой. Пользователей из группы В перенаправляют на ваш новый сайт. Спойлер: с большой вероятностью группа В проиграет. Это решение о перенаправлении простое, элегантное и неправильное, как и многие другие идеи.

У данного подхода есть три проблемы.

1. Различия в производительности. Перенаправленные пользователи страдают от дополнительного перенаправления. В лабораторных условиях это может показаться быстрым, почти незаметным, но для пользователей из других регионов время ожидания может составлять 1–2 с.

2. Боты. Роботы по-разному обрабатывают перенаправление: некоторые могут игнорировать его; некоторые могут рассматривать его как новую невидимую область и глубоко сканировать, создавая много не связанного с пользователями трафика, который может повлиять на ваши ключевые показатели. Обычно удаление всех ботов с малой активностью не является критичным, поскольку они распределены равномерно во всех вариантах, но новый или обновленный сайт может вызвать совсем другое поведение.
3. Закладки и общие ссылки вызывают перекрестное влияние. Пользователи, которые заходят вглубь веб-сайта (например, на страницу сведений о продукте) с помощью закладки или общей ссылки, все равно должны быть перенаправлены. Эти перенаправления должны быть симметричными, поэтому вы должны перенаправить пользователей из контрольной группы на сайт А.

Наш опыт показывает, что перенаправления обычно не проходят А/А-тесты. Либо используйте технологию без перенаправлений (например, пусть сервер возвращает одну из двух домашних страниц), либо выполняйте перенаправление как для контрольной, так и для тестовой группы (что ухудшает контрольную группу).

19.1.4. Пример 4: неравное распределение по группам

Неравное разделение (например, 10/90 %) может пострадать от общих ресурсов, обеспечивающих явную выгоду более крупному варианту. В частности, наиболее давно использованные (least recently used, LRU) кеши, совместно принадлежащие контрольной и тестовой группам, имеют больше записей для более крупного варианта (обратите внимание, что идентификаторы экспериментов всегда должны быть частью любой системы кеширования, на которую может повлиять эксперимент, поскольку эксперименты могут кешировать разные значения для того же хеш-ключа); см. также главу 18.

В некоторых случаях проще запустить эксперимент с распределением 10/10 (не используя 80 % данных, столь полезных в теории), чтобы избежать проблем с LRU-кешированием, но это необходимо делать во время выполнения; нельзя запустить эксперимент с распределением 10/90 % и выбросить данные. Вы можете обойтись без А/А-теста при распределении 50/50, но, если вы проводите эксперименты при распределении 90/10, все-таки не поленитесь выполнить А/А-тестирование.

Другая проблема с неравным распределением заключается в том, что различается скорость сходимости к нормальному распределению. Если у вас сильно асимметричное распределение для показателя, центральная предельная теорема утверждает, что среднее будет сходиться к нормальному, но когда проценты неравны, скорость будет разной. В А/В-тесте значение имеет дельта показателя между контрольной и тестовой группой, и эта дельта может быть более нормальной, если две составляющие имеют оди-

наковое распределение (даже если оно не является нормальным); см. подробности в главе 17.

19.1.5. Пример 5: различия в оборудовании

У Facebook была служба, работающая на множестве компьютеров. Они создали вторую версию службы и хотели провести А/В-тестирование. Однако сначала они провели А/А-тест между новым и старым оборудованием, и, хотя считалось, что оборудование идентично, оно не прошло А/А-тест. Небольшие аппаратные различия могут привести к неожиданно значительным различиям в результатах.

19.2. КАК ПРОВОДИТЬ А/А ТЕСТЫ

Всегда выполняйте серию А/А-тестов перед запуском системы А/В-тестирования. В идеале смоделируйте тысячу А/А-тестов и постройте распределение p -значений. Если распределение далеко от равномерного, у вас проблема. Не доверяйте своей системе А/В-тестирования до решения этой проблемы.

Если интересующий показатель является непрерывным и у вас есть простая гипотеза нулевого значения, например равные средние в нашем примере А/А-теста, то распределение p -значений при нулевом значении должно быть равномерным.

На рис. 19.1 представлена реальная гистограмма, показывающая далеко не равномерное распределение.

На рис. 19.2 показано, что после применения дельта-метода распределение стало гораздо более равномерным.




Рис. 19.1. Неравномерное распределение p -значений из А/А-тестов для показателя, дисперсия которого не вычисляется правильно, поскольку уровень анализа отличается от уровня рандомизации




Рис. 19.2. Распределение близко к равномерному после применения дельта-метода для вычисления дисперсии

Проведение тысячи А/А-тестов может быть дорогостоящим, но есть небольшой трюк, который вы можете использовать: воспроизвести последнюю неделю. Это, конечно, предполагает, что вы сохранили соответствующие необработанные данные. Это пример того, почему стоит хранить ваши данные для запуска будущих тестов и применения новых показателей. Конечно, у этого подхода есть ограничения: вы не обнаружите проблем с производительностью или общими ресурсами, такими как упомянутый выше LRU-кеш, но это очень ценное упражнение, которое приводит к выявлению многих проблем.

Поскольку вы на самом деле не вносите изменения в свой продукт и два тестируемых варианта идентичны, вы можете просто смоделировать А/А-тест. Для каждой итерации выберите новое начальное значение хеша рандомизации для назначения пользователей и воспроизведите данные за последнюю неделю, разделив пользователей на две группы. Затем сгенерируйте p -значение для каждого интересующего показателя (обычно от десятков до сотен показателей) и накопите их в гистограммах, по одной для каждого показателя.

Теперь запустите тест на *критерий согласия* (goodness of fit), такой как тест Андерсона–Дарлинга или Колмогорова–Смирнова, чтобы оценить, близки ли распределения к однородности.

19.3. Когда А/А-ТЕСТ НЕ ПОДХОДИТ

Существует несколько распространенных сценариев p -значения, в которых тест не соответствует требованиям для равномерного распределения.

1. Распределение искажено и явно не близко к равномерному. Распространенная проблема – это проблема с оценкой дисперсии показателей (см. главу 18). Проверьте следующее:
 - а) нарушается ли предположение о независимости (как в примере CTR) из-за того, что единица рандомизации отличается от единицы анализа? Если это так, примените дельта-метод или бутстраппинг (см. главу 15).
 - б) имеет ли показатель сильно искаженное распределение? Нормальное приближение может не сработать для небольшого числа пользователей. В некоторых случаях минимальный размер выборки может превышать 100 000 пользователей. Могут потребоваться ограниченные показатели или установка минимального размера выборки (см. главу 17).
2. Имеется большая масса около p -значения 0,32, что указывает на проблему с выбросами. Например, предположим, что в данных есть один очень большой выброс o .
При вычислении t -статистики

$$T = \frac{\Delta}{\sqrt{\text{var}}}(\Delta) \quad (19.1)$$

выброс попадет в один из двух вариантов, а дельта средних будет близка к o/n (или к отрицательному значению этой дроби), так как все остальные числа будут подавлены этим выбросом. Дисперсия среднего для этого варианта будет также рядом с σ^2/n^2 , поэтому значение T

будет близко к 1 или к -1 , что соответствует значению p около 0,32.

Если вы это наблюдаете, то необходимо выяснить причину выброса или ограничить данные. При таких больших выбросах t -критерий редко приводит к статистически значимым результатам (см. главу 18).

3. Распределение имеет несколько точечных скоплений с большими промежутками. Это происходит, когда данные однозначны (например, 0) с несколькими редкими случаями ненулевых значений. В таких сценариях дельта среднего может принимать только несколько дискретных значений, и, следовательно, p -значение тоже может принимать только несколько значений. Здесь t -критерий снова неточен, но это не такая серьезная проблема, как в предыдущем сценарии, потому что, если новое воздействие вызывает частое повторение редкого события, эффект воздействия будет большим и статистически значимым.

Даже после того, как A/A-тест пройден, мы рекомендуем регулярно запускать A/A-тесты одновременно с A/B-тестами, чтобы выявить регрессии в системе или новый показатель, который не работает из-за изменения его распределения или из-за того, что начали появляться выбросы.

Глава 20

Включение по условию для повышения чувствительности

Убедитесь, что вы правильно определили цель, прежде
чем нажимать на курок.
– Том Флинн

***Почему это важно:** включение по условию дает экспериментаторам возможность повысить чувствительность (статистическую мощность) путем фильтрации шума, создаваемого пользователями, на которых эксперимент не мог повлиять. По мере совершенствования экспериментальной зрелости организации в ней применяют все больше экспериментов с управляемым включением.*

Пользователи включаются (триггируются) в анализ эксперимента, если есть (хотя бы потенциально) некоторая разница в системе или поведении пользователей между вариантом, в котором они находятся, и любым другим вариантом (контрфактическим). Включение по условию (триггирование, triggering) – ценный инструмент в вашем арсенале, но есть несколько подводных камней, которые могут привести к неверным результатам. Важно, чтобы вы выполнили этап анализа по крайней мере для всех включенных пользователей. Выявить включенную совокупность пользователей будет легче, если включающие события регистрируются во время выполнения.

20.1. Примеры включения по условию

Если вы вносите изменение, которое затрагивает только некоторых пользователей, эффект изменения для тех, на кого это не влияет, будет равен нулю. Простой охват анализом только пользователей, на которых могло повлиять ваше изменение, имеет глубокие последствия для анализа эксперимента и может значительно улучшить чувствительность или статистическую мощность. Давайте рассмотрим несколько примеров включения по условию, расположенных в порядке нарастания сложности.

20.1.1. Пример 1: преднамеренно частичное воздействие

Предположим, вы вносите изменения и проводите эксперимент на определенном сегменте населения: только на пользователях из США. Вам следует анализировать только пользователей из США. Пользователи из других стран не подверглись изменению, поэтому эффект воздействия для них равен нулю, и их добавление в анализ просто увеличивает шум и снижает статистическую мощность. Обратите внимание, что вы должны включить в анализ «смешанных» пользователей как из США, так и из других стран, если они могли заметить изменение. Увидев изменения, обязательно зарегистрируйте все их действия, даже выполненные за пределами Соединенных Штатов, потому что они подверглись воздействию и могут возникнуть остаточные последствия для визита из региона за пределами США.

Это замечание относится и к другим частичным воздействиям, таким как внесение изменения, которое применяется только к пользователям браузера Edge, или изменения, касающегося только пользователей, адрес доставки которых находится в заданном почтовом индексе, или внесение изменений для активных пользователей, посетивших ваш веб-сайт по крайней мере три раза за последний месяц (обратите внимание, что очень важно сформулировать критерий включения на основе данных, имевшихся до начала эксперимента, а не тех, которые получены после воздействия).

20.1.2. Пример 2: условное воздействие

Предположим, что это воздействие применяют только к пользователям, достигающим заданного места вашего веб-сайта, например страницы оплаты заказа, или пользователям, использующим заданную функцию, например построение графика в Excel, а затем анализируют только этих пользователей. В этих примерах, как только пользователь столкнулся с изменением, он включается (триггируется) в эксперимент, потому что возникает некоторое различие между пользователями. Условное воздействие – очень распространенный сценарий включения по условию; вот еще несколько примеров.

1. Изменение в оформлении заказа: включайте только тех пользователей, которые начали оформление заказа.
2. Изменение режима совместной работы, например совместное редактирование документа в Microsoft Word или Google Docs: включайте только пользователей, участвующих в совместной работе.
3. Изменение экрана отказа от подписки: включайте только пользователей, видящих эти изменения.
4. Изменение способа отображения ответа о погоде на странице результатов поисковой системы: включайте только пользователей, отправляющих запрос, в результате которого отображается ответ о погоде.

20.1.3. Пример 3: Увеличение охвата

Предположим, что ваш сайт предлагает бесплатную доставку пользователям, у которых стоимость корзины более 35 долл., и вы тестируете нижний порог в 25 долл. Ключевой момент заключается в том, что изменение коснется только тех пользователей, которые в какой-то момент начали оформлять заказ с корзиной стоимостью от 25 до 35 долл. Пользователи с корзиной стоимостью более 35 долл. и те, у которых корзина стоит менее 25 долл., ведут себя в обеих группах одинаково. Включайте в анализ пользователей, получивших предложение бесплатной доставки, только тогда, когда в их корзине есть покупки на сумму от 25 до 35 долл. В этом примере мы предполагаем, что на сайте нет «рекламы» бесплатной доставки; если в какой-то момент для пользователя отображается предложение бесплатной доставки и между контрольной и тестовой группой есть разница, это событие немедленно становится триггером.

На рис. 20.1 этот пример показан в виде диаграммы Венна: контрольный вариант предлагает некоторым пользователям бесплатную доставку, а тестовый вариант расширяет охват до более широкого круга пользователей. Вам не нужно включать пользователей, не входящих в эти группы (как в примере 2), но вам также не нужно включать пользователей, соответствующих критериям как контрольного, так и тестового варианта, потому что для них предложение (воздействие) одинаково.




Рис. 20.1. Воздействие увеличивает охват. Запускаются только пользователи в Т\С.

Те, кто в С (и в Т), видят одно и то же предложение, поэтому эффект воздействия равен нулю

20.1.4. Пример 4: изменение покрытия

Все становится немного сложнее, если охват не увеличивается, а изменяется, как показано на диаграмме Венна на рис. 20.2. Например, предположим, что контрольный вариант предлагает бесплатную доставку покупателям, у которых в корзине не менее 35 долл., а тестовый предлагает бесплатную доставку пользователям, у которых в корзине не менее 25 долл., за исключением случаев, когда они вернули товар в течение 60 дней до начала эксперимента.

И контрольный, и тестовый вариант должны учитывать «другое», т. е. контрфактическое, условие и отмечать пользователей как включенных только в том случае, если есть разница между двумя вариантами.




Рис. 20.2. Воздействие изменяет охват. Если пользователи на пересечении сталкиваются с одним и тем же воздействием, включаются только оставшиеся пользователи

20.1.5. Пример 5: контрфактическое включение для моделей машинного обучения

Предположим, у вас есть машинообучаемый классификатор, который классифицирует пользователей по одной из трех рекламных акций, или рекомендательная модель, которая рекомендует продукты, связанные с продуктом, показанным на странице. Вы обучили новый классификатор или рекомендательную модель, и вторая версия хорошо показала себя в ваших офисных тестах. Теперь можете посмотреть, улучшит ли это ваш ОЕС (см. главу 7).

Ключевое соображение заключается в том, что если новая модель совпадает со старой моделью для большинства пользователей, например при создании одинаковых классификаций или рекомендаций для одних и тех же входных данных, то эффект от применения новой модели для этих пользователей равен нулю. Как вам поступить? Вы должны создать противопоставление. Во время эксперимента запускают обе модели для каждого пользователя из каждой группы. Но при этом пользователю из контрольной группы показывают результат работы контрольной модели (старая версия), а пользователю из тестовой группы показывают результат работы тестовой модели (новая версия) и регистрируют и сравнивают между собой выходные данные обеих моделей. Пользователи включаются в анализ, если выходы моделей различаются.

Обратите внимание, что вычислительные затраты в этом сценарии возрастают (например, стоимость вывода модели из расчета на одно воздействие фактически удваивается), поскольку должны выполняться обе модели машинного обучения. На результат также может повлиять задержка, если две модели не запускаются одновременно, а контролируемый эксперимент не может выявить различия в выполнении модели (например, если одна из них работает быстрее или занимает меньше памяти).

20.2. Числовой пример

Исходя из показателя ОЕС со стандартным отклонением σ и желаемым уровнем чувствительности Δ , т. е. величиной изменения, которую вы хотите обнаружить, минимальный размер выборки для доверительного уровня 95 % и мощности 80 % вычисляется, как показано в следующем уравнении:

$$n = \frac{16\sigma^2}{\Delta^2}. \quad (20.1)$$

Давайте рассмотрим сайт интернет-магазина, на котором 5 % пользователей, посетивших в течение экспериментального периода, совершили покупку. Событие конверсии – это испытание Бернулли с $p = 0,05$. Стандартное отклонение σ Бернулли равно $\sqrt{p(1-p)}$ и, следовательно, $\sigma^2 = 0,05(1 - 0,05) = 0,0475$. Согласно приведенной выше формуле вам потребуется не менее $16 \times 0,0475 / (0,05 \times 0,05)^2 = 121\,600$ пользователей.

Если вы внесли изменения в процесс оформления заказа, как в примере 2, то анализируйте только включенных пользователей, которые начали процесс оформления заказа. Предположим, что 10 % пользователей инициируют оформление заказа, так что при 5 % скорости покупки половина из них завершает оформление заказа, или $p = 0,5$. Дисперсия $\sigma^2 = 0,5(1 - 0,5) = 0,25$. Таким образом, вам понадобится не менее $16 \times 0,25 / (0,05 \times 0,05)^2 = 6400$ пользователей, оформивших заказ. Поскольку 90 % пользователей не инициируют оформление заказа, количество пользователей в эксперименте должно быть не менее 64 000, это почти половина от вычисленного ранее. Следовательно, для искомой мощности эксперимента достаточно почти половины пользователей (поскольку есть повторные пользователи, охват половины пользователей обычно занимает меньше половины времени).

20.3. ОПТИМАЛЬНОЕ И КОНСЕРВАТИВНОЕ ВКЛЮЧЕНИЕ

При сравнении двух вариантов оптимальным условием является включение в анализ только тех пользователей, для которых была некоторая разница между двумя сравниваемыми вариантами, например между вариантом, в котором находился пользователь, и контрфактическим вариантом.

Если существует несколько воздействий, в идеале регистрируется информация, представляющая все варианты, как фактические, так и контрфактические. Затем накопленная информация позволяет оптимально включать в анализ пользователей, которых затронула проблема. Тем не менее такой подход влечет за собой значительные затраты, поскольку для создания контрфактов необходимо запустить несколько моделей.

На практике иногда проще выполнить не оптимальный, а консервативный анализ, например включить больше пользователей, чем оптимально.

Это не делает анализ недействительным, а скорее снижает статистическую мощность. Если консервативный подход ненамного завышает число включенных пользователей, то может оказаться полезным нацеленный на простоту компромисс. Вот некоторые примеры.

1. Множественные воздействия. Любое различие между вариантами включает пользователя в анализ. Вместо того чтобы регистрировать вывод каждого варианта, просто зарегистрируйте логическое значение, указывающее, что они различаются. Возможно, что поведение для контроля и воздействия 1 было идентичным для некоторых пользователей, но отличалось для воздействия 2. Таким образом, при сравнении только контроля и воздействия 1 включите пользователей с известным нулевым эффектом воздействия.
2. Ретроспективный анализ. Предположим, что эксперимент был запущен и что-то пошло не так с контрфактуальной регистрацией, возможно, рекомендательная модель, использованная во время проверки, неправильно регистрировала контракты. Вы можете использовать условие включения, такое как «завершение заказа, инициированное пользователем». Несмотря на то что оно определяет больше пользователей, чем те, для которых выходные данные рекомендательной модели при оформлении заказа различались, все же получится удалить 90 % пользователей, которые никогда не инициировали оформление заказа, поэтому демонстрировали нулевой эффект воздействия.

20.4. ОБЩИЙ ЭФФЕКТ ВОЗДЕЙСТВИЯ

При вычислении эффекта воздействия для включенной популяции вы должны распространить эффект на всю базу пользователей, что иногда называют разбавленным воздействием или побочным воздействием. Если вы увеличили доход на 3 % для 10 % пользователей, улучшили ли вы общий доход на $10 \times 3 = 0,3$ %? НЕТ (распространенная ошибка)! Общее влияние может быть от 0 до 3 %!

Пример 1

Если изменение было внесено в процесс оформления заказа, то включенными пользователями были те, кто инициировал оформление заказа. Если единственный способ получить доход – это инициировать оформление заказа, то вы улучшите как включенный, так и общий доход на 3 %, и распространение этого эффекта на всю базу пользователей просто ничего не изменит.

Пример 2

Если изменение было внесено в список участников с очень низкими расходами, которые тратят 10 % от среднего пользователя, то вы увеличили доход

на 3 % для 10 % пользователей, которые тратят 10 %, поэтому вы увеличили доход на 3 % от 10 % от 10 % = 0,03 %, – весьма незначительное улучшение.

- Пусть ω обозначает всю пользовательскую вселенную, а θ пусть обозначает включенную популяцию.
- Пусть C и T обозначают контроль и тест соответственно.

Для данного показателя M имеем:

- $M_{\omega C}$ – значение показателя для невключенного контроля;
- $M_{\omega T}$ – значение показателя для невключенного тестового воздействия;
- $M_{\theta C}$ – значение показателя для включенного контроля;
- $M_{\theta T}$ – значение показателя для включенного тестового воздействия.

Обозначим через N количество пользователей и определим $\Delta_{\theta} = M_{\theta T} - M_{\theta C}$, т. е. абсолютный эффект на включенную популяцию.

Определим $\delta_{\theta} = \Delta_{\theta}/M_{\theta C}$, т. е. относительное влияние на включенную популяцию. Коэффициент включения, τ , представляет собой процент пользователей, которые были включены, $N_{\theta C}/N_{\omega C}$.

Вместо контроля можно использовать тест или комбинировать их, как показано в следующем уравнении:

$$(N_{\theta C} + N_{\theta T}) / (N_{\omega C} + N_{\omega T}). \quad (20.2)$$

Вот два способа представить себе влияние разбавленного процента.

1. Как абсолютный эффект воздействия, разделенный на общее количество не включенных пользователей:

$$\frac{\Delta_{\theta} \times N_{\theta C}}{M_{\omega C} \times N_{\omega C}}. \quad (20.3)$$

2. Как «отношение эффекта воздействия к показателю без включения», умноженного на коэффициент включения:

$$\frac{\Delta_{\theta}}{M_{\omega C}} \times \tau. \quad (20.4)$$

Поскольку τ равно $N_{\theta C}/N_{\omega C}$, мы можем видеть, что это эквивалентно предыдущему уравнению (20.3).

Что является распространенной ошибкой при прямом разбавлении на коэффициент включения? Вычисление выполняют чаще всего так, как показано в следующем уравнении:

$$\frac{\Delta_{\theta}}{M_{\theta C}} \times \tau. \quad (20.5)$$

Это дает правильный результат, когда включенная популяция является случайной выборкой, но если она искажена, как это часто бывает, то результат сопровождается погрешностью на коэффициент $M_{\omega C}/M_{\theta C}$.

В данном случае необходимо использовать более точные формулы. Обратите внимание, что здесь может возникнуть парадокс Симпсона (см. главу 3), когда эффект во включенной популяции увеличивается, но разбавленный глобальный эффект уменьшается.

20.5. Достоверность включения

Вы должны выполнить две проверки, чтобы убедиться в достоверности выбранного триггера, на основании которого происходит включение пользователя в анализ. Мы обнаружили, что эти проверки очень важны, и они регулярно указывают на проблемы.

1. Несоответствие коэффициента выборки (SRM; см. главу 3). Если в общем эксперименте нет SRM, но триггируемый анализ показывает наличие SRM, то в методике включения пользователей присутствует некоторая систематическая ошибка. Обычно контрфактическое включение не выполняется должным образом.
2. Анализ остатков. Создайте оценочную карту для никогда не включавшихся пользователей, и вы должны получить оценочную карту A/A (см. главу 19). Если статистически значимые показатели превышают ожидаемые, то есть большая вероятность, что триггер выбран неверно; ваше воздействие влияет на пользователей, не входящих в условие триггера.

20.6. РАСПРОСТРАНЕННЫЕ ОШИБКИ

Триггирование – мощная концепция, но следует помнить о нескольких подводных камнях.

Ошибка 1: экспериментирование с маленькими сегментами, которые трудно обобщить

Если вы пытаетесь улучшить показатель для всей популяции, то имеет значение разбавленная значимость вашего эксперимента. Даже если вы улучшите показатель на огромные 5 %, если включенная популяция составляет 0,1 % от общего числа пользователей, тогда ваше разбавленное значение составит $\tau = 0,001$, когда вы вычисляете разбавленное значение на основе уравнения 20.6:

$$\frac{\Delta_{\theta}}{M_{\theta c}} \times \tau. \quad (20.6)$$

Это частный случай закона Амдала (Amdahl law), часто упоминаемого в компьютерной архитектуре как причина, по которой не следует сосредотачиваться на ускорении компонентов системы, занимающих небольшую часть общего времени выполнения.

Из этого правила есть одно важное исключение – обобщение небольшой, но важной идеи. Например, в августе 2008 года MSN UK провела эксперимент, в котором ссылка на Hotmail открывалась в новой вкладке (или в новом окне для старых браузеров), что увеличило вовлеченность пользователей MSN, измеряемую количеством кликов на пользователя на домашней странице, на 8,9 % для включенных пользователей, которые щелкнули ссылку Hotmail. Это было серьезное улучшение, но для относительно небольшого сегмента. Тем не менее в течение нескольких лет была проведена серия экспериментов, направленных на обобщение этой идеи, которая в то время была очень спорной. К 2011 году MSN US провела очень большой эксперимент с более чем 12 млн пользователей, которые открывали результаты поиска в новой вкладке/окне, а вовлеченность, измеряемая количеством кликов на пользователя, увеличилась на колоссальные 5 %. Это было одно из лучших обновлений, когда-либо реализованных MSN с точки зрения увеличения вовлеченности пользователей.

Ошибка 2: включенный пользователь не участвует должным образом в оставшейся части эксперимента

Как только пользователи включены, анализ должен учитывать их дальнейшие действия. Воздействие может повлиять на их будущее поведение из-за некоторой разницы в опыте. Анализ включенных пользователей по дням или сеансам подвержен влиянию предыдущего опыта. Например, предположим, что обновление сайта вызывает такие ужасные впечатления, что пользователи значительно сокращают посещения. Если вы анализируете пользователей по дням или по сеансам, вы недооцениваете эффект воздействия. Если в целом количество посещений на пользователя существенно не изменилось статистически, вы можете повысить статистическую мощность, просмотрев посещения только для включенных пользователей.

Ловушка 3: влияние контрфактического журналирования на быстрое действие

При контрфактическом журналировании и контрольный, и тестовый вариант будут выполнять код друг друга (например, модели). Если модель для одного варианта работает значительно медленнее, чем для другого, это не будет видно в контролируемом эксперименте. Вам помогут следующие приемы.

1. Осведомленность о проблеме. Код может регистрировать время выполнения для каждой модели, чтобы их можно было сравнить напрямую.
2. Запустите эксперимент A/A'/B, где A – исходная система (контроль), A' – исходная система с контрфактическим журналированием, а B – новая система с ним же. Если A и A' существенно различаются, вы можете выдать предупреждение о том, что контрфактическое журналирование оказывает заметное влияние.

Стоит отметить, что контрфактическое журналирование очень затрудняет использование общих контрольных групп (см. главы 12 и 18), поскольку они обычно работают без изменения кода. В некоторых случаях условия включения могут быть определены другими способами, хотя это может привести к неоптимальному включению или ошибочным условиям.

20.7. ОТКРЫТЫЕ ВОПРОСЫ

Ниже перечислены проблемы, с которыми мы сталкиваемся, но не имеем четкого ответа. Осведомленность важна, даже когда у нас есть доводы за и против, а не готовый «ответ».

Вопрос 1: уровень включения

Включая пользователя, вы можете получить только зарегистрированные действия после точки включения. Очевидно, что тестовое воздействие не повлияло на данные до точки включения. Мы сделали это, но сеансы этих включенных пользователей являются неполными, а их показатели аномальны (например, показатель количества кликов до оформления заказа равен нулю, чего не может быть). Может, лучше захватить весь сеанс? Целый день? Возможно, все действия пользователя с самого начала эксперимента?

С вычислительной точки зрения легче взять пользователя, включая данные с начала эксперимента, если они включатся впоследствии; однако это вызывает небольшую потерю статистической мощности.

Вопрос 2: график показателей с течением времени

Построение графика показателя с течением времени при увеличении числа пользователей обычно приводит к ложным выводам. Лучше всего смотреть на графики от времени, где каждый день показывает пользователя, посетившего сайт в этот день. Когда мы работаем с включенными пользователями, у нас та же проблема: в первый день мы включили 100 % пользователей, а во второй день меньше, поскольку некоторые из них были включены в первый день, но пришли и во второй день. Это снижение проявляется, как правило, в виде уменьшения эффекта воздействия со временем. Возможно, лучше каждый день строить новый график с участием пользователей, которые посетили сайт в этот день и были включены в анализ в этот же день. Ключевой вопрос заключается в том, что общий эффект воздействия должен учитывать все дни, поэтому однодневные и совокупные результаты не совпадают.

Глава 21

Несоответствие коэффициента выборки и другие ограничительные показатели

Основное различие между тем, что может пойти не так, и тем, что не может пойти не так, состоит в том, что, когда что-то, что не может пойти не так, идет не так, обычно оказывается невозможным до этого добраться или отремонтировать.

– Дуглас Адамс

***Почему это важно:** ограничительные показатели – это критически важные метрики, предназначенные для предупреждения экспериментаторов о нарушенных предположениях. Есть два типа ограничительных показателей: организационные и доверительные. В главе 7 обсуждаются организационные показатели, используемые для защиты бизнеса, а в этой главе подробно рассмотрено несоответствие коэффициента выборки (SRM), которое является доверительным ограничением. Ограничение SRM должно быть включено в каждый эксперимент, поскольку оно используется для обеспечения внутренней валидности данных и достоверности результатов эксперимента. Здесь также описаны несколько других ограничительных показателей, связанных с доверием.*

Как следует из цитаты Дугласа Адамса, многие люди предполагают, что эксперимент пройдет в соответствии с планом. Когда это предположение оказывается неверным, а это случается чаще, чем люди ожидают, анализ обычно бывает сильно предвзятым, и некоторые выводы неверны. Несколько компаний сообщили о том, что сталкивались с SRM, и подчеркнули важность проверки этого ограничительного показателя.

21.1. Несоответствие коэффициента выборки (SRM)

Показатель несоответствия коэффициента выборки (sample ratio mismatch, SRM) рассматривает соотношение числа пользователей (или других еди-

ниц, см. главу 14) между двумя вариантами, обычно тестовым и контрольным. Если план эксперимента требует наличия определенного соотношения пользователей (скажем, 1:1) для двух вариантов, то результаты должны точно соответствовать плану. В отличие от показателей, на которые может повлиять тестовое воздействие, решение предоставить пользователю вариант не должно зависеть от воздействия, поэтому соотношение пользователей в вариантах должно соответствовать плану эксперимента. Например, если вы подбросите честную монету 10 раз и откроете 4 решки и 6 орлов, то получите соотношение вариантов 0,67, и это не удивительно. Однако закон больших чисел подразумевает, что с большой вероятностью соотношение должно приближаться к единице по мере увеличения размера вашей выборки.

Когда p -значение для показателя коэффициента выборки низкое, это означает, что вероятность наблюдения такого или более экстремального отношения невелика, следовательно, наблюдается SRM, и все другие показатели, вероятно, недействительны. Для вычисления p -значения вы можете использовать стандартный t -критерий или критерий хи-квадрат. Пример электронной таблицы Excel доступен по адресу <http://bit.ly/srmCheck>.

Сценарий 1

В этом эксперименте контрольной и тестовой группе назначают по 50 % пользователей. Вы ожидаете увидеть примерно равное количество пользователей в каждой группе, но ваши результаты:

- контроль: 821 588 пользователей;
- тестирование: 815 482 пользователя.

Соотношение между ними составляет 0,993, тогда как для каждого плана эксперимента соотношение должно быть 1,0. Значение p для вышеуказанного коэффициента выборки 0,993 составляет $1,8 \times 10^{-6}$, поэтому вероятность увидеть это соотношение в эксперименте с равным количеством пользователей в группах составляет $1,8 \times 10^{-6}$, или менее 1 из 500 000!

Вы только что наблюдали крайне маловероятное событие. Поэтому более вероятно, что в проведении эксперимента есть ошибка, и вы не должны доверять никаким другим показателям.

Сценарий 2

Этот эксперимент также проводится с двумя группами, которым назначено по 50 % пользователей, и соотношение в итоге составляет 0,994. Вы вычисляете p -значение, и оно составляет 2×10^{-5} , что все еще очень маловероятно. Это небольшой процент, так как далеко могут быть показатели? Неужели нужно отбросить результаты?

На рис. 21.1 показана реальная система показателей от Bing.

	Treatment	Control	Delta	Delta %	P-Value	P-Move	Treatment	Control	Delta	Delta %	P-Value	P-Move
▼ Metadata												
ScorecardId	96699772						96762547					
Sample Ratio [by user]	0.9938 = 959,716 (T) / 965,679 (C)						0.9993 = 924,240 (T) / 924,842 (C)					
Sample Ratio [by page]	0.9914 = 6,906,537 (T) / 6,966,740 (C)						0.9955 = 6,652,169 (T) / 6,682,151 (C)					
Trigger Rate [by user]							0.9604 = 1,849,082 (T+C) / 1,925,395 (T+C)					
Trigger Rate [by page]							0.9612 = 13,334,320 (T+C) / 13,873,277 (T+C)					
▼ Main Metrics												
▼ Success Metrics												
Sessions/UU												

менте X не должны участвовать в эксперименте Y) и попытки сбалансировать ковариаты, просматривая исторические данные (см. начальное значение хеша в главе 19);

- в одном реальном примере экспериментальное воздействие сначала применили к 100 % сотрудников команды Microsoft Office внутри компании Microsoft, а затем был запущен A/B-эксперимент, в котором внешние пользователи были представлены в равных долях 10/10 %. Относительно небольшого числа дополнительных пользователей Office в тестовой группе оказалось достаточно, чтобы исказить результаты и сделать тестовое воздействие неестественно хорошим (поскольку это активные пользователи). SRM стал полезным барьером для защиты достоверности результата; когда эти внутренние пользователи Microsoft были удалены, сильный эффект воздействия исчез;
- проблемы с конвейером данных, такие как бот-фильтрация, упомянутая в сценарии 2 выше;
- остаточные эффекты. Иногда после исправления ошибки эксперименты возобновляются. Когда эксперимент уже был запущен, возникает желание избежать повторной рандомизации пользователей, ограничившись лишь использованием даты начала анализа на момент устранения ошибки. Если ошибка была достаточно серьезной, чтобы вынудить пользователей отказаться от дальнейшего участия, то возникнет SRM;
- неправильное условие включения. Условие включения должно охватывать любого пользователя, на которого может быть оказано воздействие. Типичный пример – перенаправление: веб-сайт A перенаправляет определенный процент пользователей на веб-сайт A', где и тестируется их поведение. Поскольку перенаправление приводит к некоторым потерям, SRM обычно возникает, если учитывают только переадресованных пользователей (см. главу 20);
- отбор пользователей на основе атрибутов, затронутых экспериментом. Например, предположим, что вы запускаете кампанию для неактивных пользователей на основе атрибута *неактивности*, хранящегося в базе данных профилей пользователей. Если обновление достаточно эффективно, чтобы сделать некоторых бездействующих пользователей более активными, то отбор пользователей на основе этого атрибута в конце эксперимента даст SRM: пользователи, которые раньше бездействовали, а теперь активны, будут исключены по условию отбора. Для анализа следует использовать значение атрибута активности, зафиксированное до начала эксперимента (или до назначения каждого пользователя). Условия отбора, основанные на алгоритмах машинного обучения, особенно подозрительны, поскольку модели могут обновляться во время проведения эксперимента и на них влияет эффект тестового воздействия.

21.3. УСТРАНЕНИЕ SRM

Как отмечалось выше, когда p -значение для ограничительного показателя отношения выборок низкое, вы должны отвергнуть гипотезу о том, что проект реализован правильно, и предположить, что где-то в системе есть ошибка. Даже не смотрите на другие показатели, кроме как для отладки того, что пошло не так. Устранение SRM – сложная работа, и для этого обычно создаются внутренние инструменты, например, путем реализации некоторых из приведенных ниже методов.

Вот общие рекомендации, которые мы сочли полезными.

- Убедитесь, что нет никакой разницы между вариантами до точки рандомизации или точки запуска. Например, если вы анализируете пользователей, начиная с точки оформления заказа, потому что вы изменили функцию оформления заказа, убедитесь, что нет разницы между вариантами, предшествующими этой точке. Если вы оцениваете 50%-ную скидку или акцию «два по цене одного» на кассе, вы не можете упоминать ни один из этих вариантов на главной странице; если вы это сделаете, вам придется анализировать пользователей, начиная с главной страницы.
- Команда Bing Image проводит эксперименты с пользователями, выполняющими поиск изображений с помощью этой службы. Они обнаружили, что иногда эксперимент влияет на обычные результаты веб-поиска Bing, встраивая результаты поиска изображений в обычную поисковую выдачу, и тем самым часто вызывая SRM.
- Проверьте правильность распределения пользователей по вариантам. Правильно ли рандомизированы пользователи в верхней части конвейера данных? Хотя большинство систем назначения вариантов начинается с простых схем рандомизации, основанных на хешировании идентификатора пользователя, механизм назначения вариантов со временем усложняется, поддерживая параллельные эксперименты и изолированные группы, где разные эксперименты гарантированно не будут доступны одним и тем же пользователям.
- Например, предположим, что в одном эксперименте цвет шрифта изменяется с черного на темно-синий, и начинается параллельный эксперимент, который изменяет цвет фона, но этот эксперимент отфильтровывает пользователей, у которых установлен черный шрифт. Из-за логики выполнения кода второй эксперимент «крадет» пользователей у первого, но только у варианта с черным шрифтом. Конечно, это вызывает SRM.
- Пройдитесь по этапам конвейера обработки данных, чтобы увидеть, не приводит ли какой-либо этап к появлению SRM. Например, очень распространенным источником SRM является бот-фильтрация. Для удаления ботов обычно используются эвристические алгоритмы,

поскольку боты увеличивают шум и делают анализ менее чувствительным. В Bing более 50 % трафика в США фильтруется как принадлежащие ботам, а в Китае и России 90 % трафика генерируется ботами! В одном крайнем случае из опыта MSN тестируемое изменение настолько хорошо увеличило частоту использования службы, что лучшие пользователи превысили эвристический порог и были классифицированы как боты. Если не учитывать возникновение SRM, то могло показаться, что тестируемое изменение дает намного худший результат, потому что лучших пользователей исключили из анализа.

- Исключите начальный период. Возможна ли у вас ситуация, когда оба варианта не запускались одновременно? В некоторых системах контрольная группа задействована в нескольких экспериментах. Более позднее начало тестирования может вызвать множество проблем, даже если период анализа начнется после запуска эксперимента. Например, кешам нужно время для наполнения, приложениям нужно время для загрузки, смартфоны могут оказаться вне сети, что тоже вызывает задержки.
- Проверьте соотношение выборок для сегментов:
 - ♦ рассмотрите каждый день по отдельности; случилось ли в какой-то день аномальное событие? Например, случилось ли в какой-то день значительное увеличение показателей эксперимента? Или начался очередной эксперимент и «украл» трафик?
 - ♦ существуют ли отдельные сегменты пользователей разных браузеров, как в сценарии 2 выше?
 - ♦ отличаются ли соотношения новых и вернувшихся пользователей?
- Посмотрите на пересечение с другими экспериментами. Процентное распределение между вариантами во всех экспериментах должно быть одинаковым.

В некоторых случаях, если источник SRM понятен, можно устранить причину (например, боты) на этапе анализа. Однако в других случаях удаление трафика (например, удаление пользователей браузера из-за ошибки в этом браузере) подразумевает, что некоторые сегменты не были должным образом подвергнуты тестовому воздействию, и лучше повторить эксперимент.

21.4. ДРУГИЕ ОГРАНИЧИТЕЛЬНЫЕ ПОКАЗАТЕЛИ, СВЯЗАННЫЕ С ДОВЕРИЕМ

Помимо SRM, существуют и другие показатели, указывающие на недостатки эксперимента. Иногда причины скрыты достаточно глубоко и связаны с ошибками программного обеспечения, как показывают следующие примеры.

- Точность телеметрии. Отслеживание кликов обычно выполняется с использованием веб-маяков, которые, как известно, работают с потерями, т. е. регистрируется менее 100 %. Если тестируемое изменение влияет на коэффициент потерь, результаты могут быть лучше или хуже, чем реальный пользовательский опыт. Имея показатель для оценки потерь, например через внутренние источники перехода на веб-сайт или через клики, которые используют двойное ведение журнала (иногда используется в кликах по рекламе, которые требуют высокой точности), можно обнаружить проблемы с точностью учета.
- Показатели попадания в кеш. Как отмечалось в главе 3, общие ресурсы могут нарушать SUTVA. Наличие показателей для общих ресурсов, таких как частота попаданий в кеш, может помочь выявить неожиданные факторы, влияющие на надежность эксперимента.
- Скорость записи файлов куки – частота, с которой какой-либо вариант записывает постоянные (несессионные) файлы куки. Это явление, получившее название «затирание файлов куки» (Дмитриев и др., 2016), может вызвать серьезные искажения других показателей из-за ошибок браузера. В одном из экспериментов Bing выполнялась запись файла куки, содержащего случайное число на каждой странице ответа на запрос. Больше нигде этот файл не использовался. Результаты показали резкое ухудшение поведения пользователей по всем ключевым показателям, включая количество сеансов на пользователя, количество запросов на пользователя и доход на пользователя.

Быстрые запросы – это два или более поисковых запроса, которые поступают от одного и того же пользователя в поисковую систему с интервалом в одну секунду друг от друга. Google и Bing наблюдали это явление, но до сих пор не смогли объяснить его причину. Мы лишь знаем, что некоторые виды воздействия увеличивают или уменьшают долю быстрых запросов, и эти экспериментальные результаты считаются ненадежными.

Глава 22

Утечка и интерференция между вариантами

Неважно, насколько хороша ваша теория, не имеет значения, насколько вы умны. Если теория противоречит эксперименту, она неправильная.

– Ричард Фейнман

***Почему это важно:** в большинстве анализов экспериментов мы предполагаем, что на поведение каждого объекта эксперимента не влияет присвоение вариантов другим объектам. Это достоверное предположение для большинства практических сценариев. Однако есть также много случаев, когда это предположение не выполняется.*

В большинстве рассуждений в этой книге мы исходим из *причинно-следственной модели* Рубина (Имбенс и Рубин, 2015), стандартной основы для анализа контролируемых экспериментов. В этой главе мы обсуждаем допущения, сценарии, в которых они не работают, и подходы к устранению проблем.

Ключевым допущением, сделанным в причинно-следственной модели Рубина, является допущение о стабильном влиянии воздействия на объект эксперимента (stable unit treatment value assumption, SUTVA), т. е. предположение о том, что на поведение каждого объекта в эксперименте не влияет присвоение вариантов другим объектам, как показано в уравнении 22.1:

$$Y_i(z) = Y_i(z_i) \quad (20.6)$$

с вектором назначения вариантов $z = (z_1, z_2, \dots, z_n)$ для всех n единиц.

Это правдоподобное предположение для большинства практических применений. Например, пользователь, которому нравится новый процесс оформления заказа, описанный в главе 2, с большей вероятностью совершит покупку, и такое поведение не зависит от поведения других пользователей, использующих тот же сайт интернет-магазина. Однако, если предположение SUTVA не выполняется (см. примеры далее в этой главе), анализ

результатов приводит к потенциально неверным выводам. Мы определяем *интерференцию* или *взаимовлияние* как нарушение SUTVA, иногда называемое *перетеканием между вариантами*.

Интерференция может возникнуть двумя способами: через прямые или косвенные связи. Например, два экспериментальных объекта могут быть напрямую связаны, если они являются друзьями в социальной сети или если они одновременно посещали одно и то же физическое местоположение. Косвенные связи – это связи, которые существуют из-за определенных скрытых переменных или общих ресурсов, таких как экспериментальные объекты в контрольной и тестовой группах, которые имеют один и тот же источник финансирования рекламной кампании. Эти две категории похожи тем, что в обоих случаях существует среда, которая связывает элементы разных групп и позволяет им взаимодействовать. Взаимосвязь может быть опосредована через материализованную дружескую связь в социальной сети либо через общий рекламный бюджет, когда плата за клики взимается у пользователей той и другой группы. Важно понимать механизм, посредством которого может проявляться интерференция, поскольку наилучшие решения для их устранения могут отличаться.

Далее мы рассмотрим примеры с более подробными пояснениями.

22.1. ПРИМЕРЫ

Прямые связи

Два экспериментальных объекта могут быть напрямую связаны, если они являются друзьями в социальной сети или одновременно посещали одно и то же физическое местоположение. Эти связанные объекты могут случайно оказаться в разных группах, что приведет к интерференции между вариантами.

Facebook / LinkedIn. В социальных сетях, таких как Facebook или LinkedIn, на поведение пользователей, скорее всего, влияет их социальное окружение. Пользователи находят новую функцию более ценной, если все больше знакомых использует ее, и, следовательно, с большей вероятностью будут использовать ее сами. Например, с точки зрения пользователя:

- я с большей вероятностью буду использовать видеочат на Facebook, если его используют мои друзья;
- я с большей вероятностью напишу своим друзьям в LinkedIn, если они напишут мне;
- я с большей вероятностью буду размещать сообщения в LinkedIn, если друзья из моей сети публикуют такие сообщения.

В А/В-эксперименте это означает, что, если эксперимент оказывает значительное влияние на пользователя, эффект может распространиться на его социальные связи независимо от того, в какой группе они находятся.

Например, улучшенный рекомендательный алгоритм «Люди, которых вы можете знать» на LinkedIn побуждает пользователей отправлять больше приглашений на установление контакта. Однако пользователи, которые получают эти приглашения, могут находиться в контрольной группе, и когда они заходят в LinkedIn, чтобы принять приглашение, они могут найти еще больше людей, с которыми можно связаться. Если основным интересующим показателем является общее количество отправленных приглашений, то следует иметь в виду, что частота приглашений возрастет для обеих групп, поэтому дельта эксперимента будет смещена вниз и не полностью отразит преимущества нового алгоритма. Точно так же, если эксперимент побуждает пользователей отправлять больше сообщений, контрольная группа также продемонстрирует увеличение количества сообщений, отправленных в ответ на запросы пользователей из тестовой группы (рис. 22.1).




Рис. 22.1. По мере того как пользователи в режиме Treatment отправляют больше сообщений в свою сеть, пользователи в Control также будут отправлять больше сообщений, отвечая на эти сообщения

Звонки по Skype. В каждом звонке по Skype участвуют как минимум две стороны. Ясно, что, если пользователь решает позвонить другу по Skype, тот в конечном итоге будет использовать Skype больше, по крайней мере, чтобы ответить на этот звонок. Вполне вероятно, что друг также начнет использовать Skype, чтобы звонить своим друзьям. Предположим, что Skype улучшил качество звонков для подопытной группы, увеличив тем самым количество звонков в этой группе. Эти вызовы могут быть направлены пользователям, которые находятся в той или другой группе. В результате количество звонков среди пользователей в контрольной группе также увеличивается, поэтому дельта между группами оказывается заниженной.

Косвенные связи

Два объекта эксперимента могут иметь косвенную связь из-за определенных скрытых переменных или общих ресурсов. Как и прямые связи, эти косвенные связи также могут вызывать интерференцию и искажение эффекта эксперимента.

- **Airbnb.** Если бы сайт AirBnB, посвященный аренде домов, улучшил поток конверсии для пользователей в тестовой группе, что привело бы к увеличению количества бронирований, это, естественно, привело бы к сокращению доступных предложений для пользователей контрольной группы. Это означает, что доход, полученный от контрольной группы, будет меньше, чем мог бы быть в отсутствие контрольной группы. Сравнение тестовой и контрольной группы приведет к завышенной оценке эффекта воздействия.
- **Uber/Lyft.** Представьте себе, что Uber хочет протестировать другой алгоритм «всплеска цен», который настолько хорош, что пассажиры в экспериментальном варианте с большей вероятностью согласятся на поездку. Теперь на дороге доступно меньше водителей, цена на поездки в контрольной группе повышается, что приводит к уменьшению количества поездок. В результате дельта сравнения экспериментальной и контрольной группы завышена.
- **eBay.** Предположим, что экспериментальное воздействие на покупателей, например скидки или рекламные акции, поощряет повышение ставок. Поскольку пользователи из обеих групп конкурируют за одни и те же товары, более высокая цена предложения от тестовой группы, безусловно, снижает шансы пользователей контрольной группы на победу в аукционе. Если интересующим показателем является общее количество транзакций, дельта между группами является завышенной.
- **Рекламные кампании.** Рассмотрим эксперимент, который показывает пользователям разные схемы расстановки одной и той же рекламы. Если обновленный вариант стимулирует больше кликов по объявлению, он быстрее расходует бюджет кампании. Поскольку бюджет данной кампании распределяется между экспериментальной и контрольной группами, вторая группа получает меньший бюджет. В результате разница между группами завышена. Кроме того, из-за бюджетных ограничений эксперименты, влияющие на доход от рекламы, как правило, дают результаты в начале и конце месяца (или квартала).
- **Обучение модели релевантности.** Модели релевантности обычно в значительной степени полагаются на данные о вовлеченности пользователей, чтобы узнать, что актуально, а что нет. Чтобы понять концепцию, представьте себе поисковую систему, которая использует для ранжирования простую модель релевантности на основе кликов. В этом случае, если больше пользователей переходит на условный сайт target.com при поиске слова «обувь», поисковая система обучится и бу-

дет ранжировать target.com выше по ключевому слову «обувь». Этот процесс представляет собой *обучение модели*, и он происходит постоянно по мере поступления свежих данных. Рассмотрим модель релевантности тестовой популяции, которая лучше умеет предсказывать, на что пользователи любят нажимать. Если мы будем использовать данные, собранные от всех пользователей, для обучения старой и новой модели, чем дольше длится эксперимент, тем больше «хороших» переходов достанется тестовой популяции.

- **Влияние нагрузки процессора.** Когда пользователь выполняет действие на веб-сайте, такое как добавление товара в корзину или переход по результату поиска, это обычно приводит к отправке запроса на сервер веб-сайта. Если говорить упрощенно, запрос обрабатывается серверами, а информация возвращается пользователю. В А/В-экспериментах контрольные и тестовые запросы обычно обрабатываются одними и теми же машинами. Мы сталкивались с примерами, когда ошибка в тестовом коде неожиданно тормозила процессоры и занимала память на машинах, и в результате запросы от разных групп пользователей требовали разного времени для обработки. Этот негативный эффект необходимо учитывать, если мы проводим эксперимент в течение длительного времени.
- **Уровень эксперимента ниже уровня пользователя.** Как мы обсуждали в главе 14, хотя пользователь является более часто используемым единичным объектом эксперимента, бывают случаи, когда эксперимент рандомизируется по другим критериям, таким как посещение страницы или сеанс. Использование экспериментальных объектов уровнем ниже пользователя, таких как просмотры страницы, может вызвать «перетекание» эффекта между сеансами одного и того же пользователя, если воздействие дает сильный эффект обучения. В таком случае «пользователь» – это скрытая связь. В качестве примера предположим, что у нас есть обновление, которое значительно сокращает задержку выдачи страницы, и мы рандомизируем просмотры страниц, чтобы один и тот же пользователь выполнял просмотры страниц как в обновленном, так и в контрольном варианте. Более быстрая загрузка страницы обычно приводит к большему количеству кликов и большему доходу (см. главу 5); однако, поскольку опыт пользователя неоднозначен, его поведение на быстрых страницах может зависеть от поведения медленных страниц, и наоборот. И вновь эффект воздействия оказывается заниженным.

22.2. НЕКОТОРЫЕ ПРАКТИЧЕСКИЕ РЕШЕНИЯ

Хотя искажения в этих примерах могут быть вызваны разными причинами, все они могут привести к ошибочным результатам. В рекламной кампании, например, вы можете увидеть положительную разницу в доходе во

время эксперимента, но, когда обновление запускается для всех пользователей, влияние может быть нейтральным из-за бюджетных ограничений. Когда мы проводим эксперимент, мы хотим оценить разницу между двумя параллельными мирами: в одном все объекты подвергаются экспериментальному воздействию, в другом каждый объект находится в контрольной популяции. Интерференция между популяциями искажает оценку. Как мы можем предотвратить или исправить это?

Существует несколько категорий практических подходов к устранению интерференции в контролируемых экспериментах.

22.2.1. Полезное правило: ценность действия в экосистеме

Не все действия пользователя в экспериментальной группе оказывают влияние на контрольную. Вы можете выявить действия, которые потенциально вызывают интерференцию, и прибегнуть к вмешательству, только если эти действия существенно повлияют на эксперимент. Обычно это означает не только действие первого порядка, но и потенциальные реакции на действия. Например, возьмем следующие показатели для эксперимента в социальной сети:

- общее количество отправленных сообщений и сообщений, на которые были даны ответы;
- общее количество созданных сообщений и общее количество лайков/комментариев, которые они получили;
- общее количество лайков и комментариев, а также общее количество авторов, получивших эти лайки и комментарии.

Эти показатели могут указывать на отдаленное влияние. Измерение отклика дает оценку глубины и масштабов потенциального воздействия на экосистему действий первого порядка. Эксперимент с положительным влиянием на действия первого порядка и без влияния на последующие показатели вряд ли будет иметь измеримый побочный эффект.

После выявления показателей, указывающих на отдаленное влияние, вы можете сформировать *общее* представление о том, как каждое действие преобразуется в ценности или вовлеченность для всей экосистемы. Например, в какой степени сообщение от пользователя А трансформируется в сеансы посещений как от А, так и от его знакомых? Один из способов реализации этого практического правила заключается в использовании исторических экспериментов, которые, как было показано, оказывают влияние на последующие действия, и последующей экстраполяции этого влияния на действия X/Y/Z с использованием инструментальных переменных.

Этот практический подход относительно легко реализовать, потому что для определения ценности действия в экосистеме требуется однократное усилие, а затем вы применяете его в любом рандомизированном эксперименте Бернулли. Он более чувствителен, чем другие подходы, поскольку основан на рандомизации Бернулли для измерения значимого воздействия на последующие показатели. Однако у этого подхода есть ограничения.

По своей природе эмпирическое правило является лишь приблизительным и может не работать для всех сценариев. Например, некоторые сообщения, возникающие в результате определенного экспериментального воздействия, могут оказать более сильное влияние на экосистему, чем в среднем.

22.2.2. Изоляция

Взаимовлияние передается через связь, соединяющую тестовую и контрольную группы. Вы можете устранить мешающее влияние, выявив эту связь и изолировав каждый вариант. Эмпирический подход использует схему рандомизации Бернулли, чтобы вы могли оценить влияние на экосистему во время анализа. Чтобы изолировать варианты, вы должны рассмотреть другие экспериментальные схемы и убедиться, что ваши группы пользователей хорошо разделены. Вот несколько практических приемов изоляции.

- **Разделение общих ресурсов.** Если общий ресурс вызывает взаимное влияние, то очевидным решением будет разделение этого ресурса между группами пользователей. Например, вы можете разделить рекламный бюджет в соответствии с распределением вариантов и решить использовать только 20 % бюджета для варианта, которому выделено 20 % трафика. Точно так же в примере обучаемого алгоритма релевантности вы можете разделить обучающие данные в соответствии с вариантами, из которых они собраны.

При применении этого подхода следует учитывать две вещи.

1. Можно ли разделить взаимодействующие ресурсы точно в соответствии с распределением трафика для ваших вариантов? Хотя это легко сделать для бюджета или обучающих данных, в других случаях это бывает невозможно. Например, при совместном использовании серверов существует неоднородность между отдельными машинами, и простое распределение трафика между разными машинами вносит слишком много других мешающих факторов, которые трудно устранить.
 2. Вносит ли ваше распределение трафика (размер разделения ресурсов) смещение? Что касается обучающих данных, точность модели увеличивается по мере того, как она получает больше обучающих данных. Если тестовая модель получает только 5 % обучающих данных, а контрольная модель – 95% данных, это вносит смещение в пользу контрольной модели. Это одна из причин, по которой мы рекомендуем разделение трафика 50/50.
- **Рандомизация на географическом уровне.** Есть много примеров, когда интерференция случается, когда два объекта находятся географически близко, например два отеля соревнуются за одних и тех же туристов или два такси соревнуются за одних и тех же пассажиров. Разумно предположить, что объекты (отели, такси, водители и т. д.) из

разных регионов изолированы друг от друга. Это позволяет выполнить рандомизацию на уровне региона, чтобы исключить взаимовлияние. Одно предостережение: рандомизация на географическом уровне ограничивает размер выборки количеством доступных географических местоположений. Это приводит к увеличению дисперсии и уменьшению мощности для А/В-тестов. Мы обсуждали способы уменьшения дисперсии и достижения большей мощности в главе 18.

- **Рандомизация по времени.** Вы можете изолировать воздействие, используя время. В любой момент t вы можете подбросить монету и решить, применить ли ко всем пользователям тестовое воздействие, или оставить контрольный вариант. Конечно, для того чтобы это работало, искажение, которое может быть вызвано одним и тем же пользователем с течением времени, не должно вызывать беспокойства (см. выше обсуждение плана эксперимента с дополнительным пользователем). Единица времени может быть короткой (секунды) или длинной (недели) в зависимости от практических возможностей и количества необходимых точек выборки. Например, если ваша единица измерения – «день», вы успеете собрать только семь выборок за неделю, что, вероятно, недостаточно быстро. Следует иметь в виду, что обычно существуют сильные отклонения показателей во времени, такие как эффекты дня недели или часа дня. Обычно удастся уменьшить дисперсию за счет использования этой информации в парных t -тестах или ковариатных корректировках (см. главу 18 для более подробной информации). Подобный метод, называемый прерывистыми временными рядами, обсуждается в главе 11.
- **Рандомизация сетевого кластера.** Подобно рандомизации на географическом уровне, в социальных сетях мы создаем «кластеры» узлов, которые находятся близко друг к другу, исходя из их вероятности взаимовлияния. Мы используем каждый кластер как «мегаобъект» и произвольно разделяем их на группы эксперимента или контроля. У этого подхода есть два ограничения.
 1. На практике редко удается идеальная изоляция. В большинстве социальных сетей графы соединений обычно слишком плотные, чтобы их можно было разрезать на идеально изолированные кластеры. Например, при попытке создать 10 000 изолированных и сбалансированных кластеров из всего графа LinkedIn между кластерами по-прежнему оставалось более 80 % связей.
 2. Как и в других подходах к рандомизации мегаобъектов, эффективный размер выборки (количество кластеров) обычно невелик, что приводит к компромиссу между дисперсией и смещением при построении кластеров. Большее количество кластеров приводит к меньшей дисперсии, но также дает нам большее смещение при меньшей изоляции.

- **Сетевая эгоцентрическая рандомизация.** В подходе рандомизации сеть–кластер кластеры конструируются путем минимизации границ между кластерами, и ни один кластер не обладает обособленной структурой. Во время выполнения эксперимента все узлы в кластере также обрабатываются одинаково. Эгоцентрическая рандомизация решает аналогичные проблемы взаимовлияния в социальных сетях, но имеет меньше ограничений. Она обеспечивает лучшую изоляцию и меньшую дисперсию за счет создания кластеров, каждый из которых состоит из «эго» (центральная сущность) и его «альтеров» (подсущности, с которыми эго непосредственно связано). Это позволяет вам определять назначение вариантов для «эго» и подсущностей по отдельности. Например, примените экспериментальное воздействие ко всем подсущностям без исключения и только к половине экземпляров «эго». Сравнивая эффект от воздействия на «эго» в контрольной и тестовой группе, вы можете измерить воздействие первого порядка и последующее связанное воздействие.

Всегда старайтесь комбинировать методы изоляции, чтобы получить больший размер выборки. Например, применяя рандомизацию на уровне сетевого кластера, вы можете расширить размер выборки, используя время t в качестве измерения выборки. Если большая часть взаимовлияния происходит за короткий промежуток времени, а эффект воздействия сам по себе является транзакционным, вы можете использовать ежедневный бросок монеты для определения назначения варианта для каждого кластера. Иногда вы можете улучшить изоляцию, предсказав, где может возникнуть искажение. Например, пользователи не отправляют сообщения каждому соседу в своей социальной сети. Зная, что сама сеть связей обычно слишком плотная, чтобы создавать изолированные кластеры, выявление подграфа, в котором, вероятно, будет происходить обмен сообщениями, может создать лучшие кластеры.

22.2.3. Анализ на уровне ребер графа

При четко выраженном взаимодействии между двумя пользователями так же происходит некоторая утечка воздействия. Эти взаимодействия (ребра графа) легко определить. Вы можете использовать рандомизацию Бернулли для пользователей, а затем пометить ребра на основе экспериментального назначения пользователей (узлов) как один из следующих четырех типов: воздействие–воздействие, воздействие–контроль, контроль–контроль и контроль–воздействие. Резко противоположные взаимодействия (например, сообщения, лайки), происходящие на разных ребрах, позволяют понять важные сетевые эффекты. Например, используйте различие между ребрами воздействие–воздействие и контроль–контроль, чтобы оценить несмещенную дельту или определить, нет ли опосредованного взаимодействия между объектами экспериментального воздействия через объекты контроля.

22.2.4. Обнаружение и мониторинг взаимовлияния

Понимание механизма взаимовлияния – ключ к поиску хорошего решения. Но, хотя не всегда целесообразно получать точные измерения для каждого эксперимента, важно иметь надежную систему мониторинга и оповещения для обнаружения искажений. Например, если весь доход от рекламы во время эксперимента поступает только от рекламодателей с ограниченным или не ограниченным бюджетом, результат эксперимента не может быть обобщен на всех рекламодателей. Фазы рампинга могут также выявить действительно серьезные помехи (например, экспериментальное воздействие потребляет все ресурсы ЦП), скажем, при первом расширении эксперимента до всех сотрудников компании или небольшого центра обработки данных (см. подробности в главе 15).

Глава 23

Измерение долгосрочных эффектов

Мы склонны переоценивать эффект технологии в краткосрочной перспективе и недооценивать его же в долгосрочной перспективе.

– Рой Амара

***Почему это важно:** иногда эффект, который вы хотите измерить, может накапливаться в течение месяцев или даже лет – это долгосрочный эффект. В онлайн-мире, где продукты и услуги разрабатываются быстро и гибко, попытка измерить долгосрочный эффект является сложной задачей. Хотя это по-прежнему область активных исследований, всегда полезно иметь понимание основных проблем и текущей методологии, если вы решаете проблему такого рода.*

23.1. Что такое долгосрочные эффекты?

В большинстве сценариев, обсуждаемых в этой книге, мы рекомендуем проводить эксперименты в течение одной-двух недель. Эффект воздействия, измеренный в этот короткий период времени, называется *краткосрочным эффектом*. Для большинства экспериментов знание краткосрочного эффекта – это все, что нам нужно, поскольку он стабилен и обобщается на долгосрочный эффект, который обычно нас и волнует. Однако есть сценарии, в которых долгосрочный эффект отличается от краткосрочного. Например, повышение цен, вероятно, увеличит краткосрочный доход, но снизит долгосрочный, поскольку пользователи откажутся от продукта или услуги. Отображение неудачных результатов поиска в поисковой системе заставит пользователей сделать повторные поисковые запросы; доля запросов возрастет в краткосрочной перспективе, но уменьшится в долгосрочной перспективе по мере перехода пользователей на более совершенную поисковую систему. Аналогичным образом показ большего количества рекламы, в том числе более низкокачественной, может увеличить количество кликов по рекламным объявлениям и доход в краткосрочной перспективе, но сни-

жает доход за счет уменьшения количества кликов и даже поиска в долгосрочной перспективе.

Долгосрочный эффект определяется как асимптотический эффект воздействия, который теоретически может длиться годы. На практике принято считать, что длительный период составляет более трех месяцев или определяется количеством воздействий (например, эффект от воздействия новой функции на пользователей не менее 10 раз).

Мы сознательно исключаем из обсуждения изменения, которые имеют короткий срок жизни. Например, вы можете провести эксперимент с заголовками новостей, срок жизни которых составляет всего несколько часов. Однако вопрос о том, должны ли заголовки быть «броскими» или «забавными», является хорошей долгосрочной гипотезой, поскольку первоначальное краткосрочное увеличение числа просмотров может также быть связано с увеличением числа отказов от них в долгосрочной перспективе. За исключением случаев, когда вы специально проводите эксперименты по таким краткосрочным изменениям, при тестировании обновления вам действительно полезно было бы знать, как оно будет действовать в долгосрочной перспективе.

В этой главе мы рассмотрим причины, по которым долгосрочные эффекты могут отличаться от краткосрочных, и обсудим методы измерения. Мы сосредоточимся только на сценариях, в которых краткосрочные и долгосрочные эффекты воздействия различаются. Мы не рассматриваем другие важные различия между краткосрочными и долгосрочными экспериментами, такие как разница в размере выборки, которая может привести к разнице в измерении эффекта воздействия и дисперсии.

Одна из ключевых проблем при определении ОЕС (см. главу 7) заключается в том, что он должен быть измеримым в краткосрочной перспективе, но при этом считается, что он причинно влияет на долгосрочные цели. Измерение долгосрочных эффектов, обсуждаемых в этой главе, может дать новый взгляд на измерение краткосрочных показателей, влияющих на долгосрочные цели.

23.2. Причины, по которым могут различаться КРАТКОСРОЧНЫЕ И ДОЛГОСРОЧНЫЕ ЭФФЕКТЫ

Есть несколько причин, по которым могут различаться краткосрочные и долгосрочные эффекты. Некоторые из них мы упоминали в контексте достоверности в главе 3.

- **Эффект обучения пользователей.** Когда пользователи обучаются и адаптируются к изменениям, их поведение меняется. Например, сбои продукта – ужасный пользовательский опыт, который может не отпугнуть пользователей с первого раза. Однако, если сбои случаются часто, пользователи это усвоят и могут решить отвергнуть

продукт. Пользователи могут изменить частоту кликов по объявлениям, если поймут, что качество объявлений низкое. Изменение поведения также может быть связано с необходимостью обнаружения новой функции – нужно время, чтобы пользователи заметили ее, но как только они обнаруживают ее полезность, то начинают активно пользоваться. Пользователям также может потребоваться время, чтобы адаптироваться к новой функции, потому что они привыкли к старому варианту или они дольше исследуют новое изменение. В таких случаях долгосрочный эффект может отличаться от краткосрочного, поскольку пользователи в конечном итоге достигают точки равновесия.

- **Сетевые эффекты.** Когда пользователи видят друзей, использующих функцию Live Video в коммуникационном приложении, таком как Facebook Messenger, WhatsApp или Skype, более вероятно, что они тоже воспользуются ею. На поведение пользователей, как правило, влияют люди в их сети, хотя может потребоваться некоторое время, чтобы функция достигла своего полного эффекта по мере ее распространения по их сети (см. главу 22, в которой обсуждается вмешательство на рынках с ограниченными или общими ресурсами, с акцентом на предвзятость измерения эффекта в краткосрочной перспективе из-за утечки между вариантами). Ограниченные ресурсы создают дополнительные проблемы, поскольку мы измеряем долгосрочное воздействие. Например, на двусторонних торговых площадках, таких как Airbnb, eBay и Uber, новая функция может очень эффективно стимулировать спрос на товар, такой как дом для аренды, компьютерная клавиатура или поездка, но предложение иногда отстает от спроса. В результате влияние на выручку может занять больше времени, поскольку поставки отсутствуют. Подобные примеры существуют и для других областей, таких как рынки приема на работу (соискатели и рабочие места), площадки для рекламы (рекламодатели и издатели), системы рекомендаций контента (новостные ленты) или связи (люди, которых вы можете знать в LinkedIn). Поскольку существует ограниченное количество людей, которых знает один человек («предложение»), новый алгоритм может лучше работать вначале, но достигнет более низкого равновесия в долгосрочной перспективе из-за ограниченного предложения (аналогичный эффект можно увидеть в алгоритмах рекомендаций в более общем плане, где новый алгоритм может поначалу работать лучше из-за разнообразия или просто показа новых рекомендаций).
- **Запоздалый опыт и измерения.** Может пройти некоторое время, прежде чем пользователь ощутит весь эффект воздействия. Например, для таких компаний, как Airbnb и Booking.com, могут пройти месяцы между взаимодействием пользователя в сети и физическим прибытием пользователя в пункт назначения. Задержка взаимодей-

ствия с пользователем может повлиять и на такие важные показатели, как удержание пользователей. Другой пример – годовые контракты: пользователи, оформившие годовую подписку, имеют точку принятия решения по окончании года, и их совокупный опыт за этот год определяет, продлят ли они подписку.

- **Изменение экосистемы.** Многие вещи в вашей экосистеме со временем меняются и могут повлиять на реакцию пользователей на воздействие, в том числе:
 - ◆ **запуск очередных обновлений.** Например, если больше команд встраивают функцию Live Video в свой продукт, она становится более ценной;
 - ◆ **сезонность.** Например, эксперименты с подарочными картами, которые хорошо работают в рождественский сезон, могут оказаться менее эффективными в непраздничный сезон из-за различных намерений пользователей при совершении покупки;
 - ◆ **конкурентный ландшафт.** Например, если ваш конкурент предлагает аналогичное обновление, его ценность может снизиться;
 - ◆ **государственная политика.** Например, Общий регламент ЕС по защите данных (GDPR) изменяет способ управления пользователями своими онлайн-данными и, следовательно, данными, которые вы можете использовать для таргетинга онлайн-рекламы (Европейская комиссия, 2018, Google, Помощь рекламодателям в соблюдении GDPR, 2019);
 - ◆ **изменение приоритетов.** Производительность моделей машинного обучения, обученных на данных, которые не обновляются, со временем может снижаться по мере изменения приоритетов;
 - ◆ **устаревание программ.** После выхода новых программ, если они не поддерживаются, они имеют тенденцию ухудшаться относительно окружающей среды. Это может быть вызвано, например, системными предположениями, сделанными кодом, который со временем становится недействительным.

23.4. ЗАЧЕМ ИЗМЕРЯТЬ ДОЛГОСРОЧНЫЕ ЭФФЕКТЫ?

Хотя долгосрочный эффект, безусловно, может отличаться от краткосрочного по разным причинам, не все такие различия стоит измерять. То, чего вы хотите достичь с помощью долгосрочного эффекта, играет решающую роль в определении того, что вы должны измерять и как вы должны это измерять. Мы резюмируем основные причины.

- **Атрибуция.** Компании с сильной культурой, основанной на данных, используют результаты экспериментов для отслеживания командных целей и эффективности, умело включая результаты экспериментов в долгосрочное финансовое прогнозирование. В этих сценариях необ-

ходимы правильная оценка и объяснение долгосрочного воздействия эксперимента. Как бы мир выглядел в долгосрочной перспективе без введения новой функции сейчас? Этот тип атрибуции является сложной задачей, потому что нам необходимо учитывать как эндогенные причины, такие как эффекты от воздействия на пользователя, так и экзогенные причины, такие как изменения конкурентной среды. На практике, поскольку будущие изменения продукта обычно основываются на предыдущих обновлениях, может быть трудно предсказать такое сложное воздействие.

- **Институциональное обучение.** В чем разница между краткосрочным и долгосрочным воздействием? Если разница значительная, в чем ее причина? Если наблюдается сильный эффект новизны, это может указывать на неоптимальный пользовательский опыт. Например, если пользователю требуется слишком много времени, чтобы открыть для себя новую функцию, которая ему нравится, вы можете ускорить освоение, используя обучение внутри продукта. С другой стороны, если многие пользователи привлечены новой функцией, но попробуют ее только один раз, это может указывать на низкое качество или кликбейт. Изучение разницы может послужить источником идей для улучшения в последующей итерации.
- **Обобщение.** Во многих случаях мы измеряем долгосрочное влияние на некоторые эксперименты, чтобы впоследствии экстраполировать его на другие эксперименты. Насколько долгосрочное влияние оказывает рассматриваемой изменение? Можем ли мы вывести общий принцип для определенных областей (например, поисковой рекламы)? Можем ли мы создать краткосрочный показатель, прогнозирующий долгосрочный эффект? Если мы можем обобщить или предсказать долгосрочный эффект, мы можем принять это обобщение во внимание в процессе принятия решений. Для этой цели вы можете изолировать долгосрочное влияние от внешних факторов, особенно от сильных потрясений, которые вряд ли повторятся в будущем.

23.5. ДЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ

Самый простой и самый популярный подход к измерению долгосрочных эффектов – продолжать эксперимент в течение длительного времени. Вы можете измерить эффект воздействия в начале эксперимента (на первой неделе) и в конце эксперимента (на последней неделе). Обратите внимание, что этот подход к анализу отличается от типичного анализа эксперимента, который измеряет средний эффект за весь период воздействия. Первое измерение $p\Delta_1$ процентной дельты считается краткосрочным эффектом, а последнее измерение $p\Delta_T$ – долгосрочным эффектом, как показано на рис. 23.1.




Рис. 23.1. Измерение долгосрочного эффекта на основе длительного эксперимента

Хотя это жизнеспособное решение, такому плану длительного эксперимента присущи несколько проблем и ограничений. Мы рассмотрим некоторые из них, имеющие отношение к измерению долгосрочных эффектов, организованных вокруг атрибуции и институционального обучения.

- **Атрибуция:** измерение эффекта последней недели длительного эксперимента ($r\Delta_T$) может не отражать истинный долгосрочный эффект воздействия по следующим причинам:
 - ◆ разбавление эффекта воздействия;
 - ◆ пользователь может использовать несколько устройств или точек входа (например, мобильное и стационарное устройство), в то время как эксперимент захватывает только подмножество. Чем дольше длится эксперимент, тем больше вероятность, что пользователь будет использовать несколько устройств в течение периода эксперимента. Для пользователей, которые посетили сайт или запустили приложение в течение последней недели, только часть их опыта в течение всего периода времени T фактически подвергалась воздействию. Следовательно, если пользователи учатся, то измерение $r\Delta_T$ является не долгосрочным воздействием в течение времени T , а разбавленной версией. Обратите внимание, что это разбавление может иметь значение не для всех функций, а скорее для подмножества, в котором важна дозировка воздействия;
 - ◆ если вы рандомизируете объекты эксперимента на основе файлов куки, эти файлы могут обновляться из-за поведения пользователя или блокироваться из-за проблем с браузером. Пользователь, который уже подвергся экспериментальному воздействию, мог быть рандомизирован в контрольную группу с новым файлом куки. Как и в двух предыдущих пунктах, чем дольше длится эксперимент,

тем больше вероятность того, что пользователь побывает в той и другой группе;

- ♦ если присутствуют сетевые эффекты, если у вас нет идеальной изоляции между вариантами, эффект воздействия может «просочиться» от экспериментальной группы к контрольной (см. главу 22). Чем дольше длится эксперимент, тем вероятнее, что эффект будет все шире распространяться по сети, создавая большую утечку.
- **Систематическая ошибка выживания.** Не все пользователи, задействованные в начале эксперимента, доживут до его окончания. Если коэффициент выживания разный для экспериментальной и контрольной группы, $p\Delta_T$ будет страдать от систематической ошибки выживания, которая должна вызвать срабатывание предупреждения о SRM (см. главы 3 и 21). Например, если те пользователи подопытной группы, которым не нравится новая функция, со временем откажутся от нее, $p\Delta_T$ будет отражать только предвзятое мнение о тех, кто остается (и новых пользователей, подключенных к эксперименту). Подобная предвзятость может также существовать, если воздействие приводит к появлению ошибки или побочного эффекта, изменяющих коэффициент обновления файлов куки.
- **Взаимодействие с другими новыми функциями.** Во время длительного эксперимента может быть добавлено множество других функций, и они могут взаимодействовать с конкретной тестируемой функцией. Эти новые функции могут со временем свести на нет результаты эксперимента. Например, первый эксперимент по рассылке push-уведомлений пользователям может быть очень эффективным, но по мере того, как другие функции начинают рассылать уведомления, эффект первого уведомления ослабевает.
- **Экстраполяция эффекта во времени.** Мы должны проявлять осторожность и не интерпретировать любую разницу между $p\Delta_0$ и $p\Delta_T$ как значимую разницу, вызванную самим воздействием. Помимо рассмотренных выше проблем атрибуции, которые усложняют интерпретацию самого $p\Delta_T$, разница может возникнуть чисто из-за экзогенных факторов, таких как сезонность. В общем, если основная популяция или внешняя среда изменились между двумя моментами времени, мы больше не можем напрямую сравнивать краткосрочные и долгосрочные результаты экспериментов.

Разумеется, проблемы, связанные с атрибуцией и измерением экстраполированных по времени эффектов, также затрудняют распространение результатов конкретных длительных экспериментов на более масштабные сценарии. Существуют также проблемы, связанные с тем, как узнать, что долгосрочный результат достаточно стабилизирован и пора прекратить эксперимент. В следующем разделе рассматриваются методологии планирования экспериментов и анализа, которые частично решают эти проблемы.

23.6. АЛЬТЕРНАТИВНЫЕ МЕТОДЫ ДЛЯ ДЛИТЕЛЬНЫХ ЭКСПЕРИМЕНТОВ

Существуют различные методы для улучшения результатов длительных экспериментов. Каждый метод, обсуждаемый в этом разделе, предлагает некоторые улучшения, но ни один из них полностью не устраняет ограничения во всех сценариях. Мы настоятельно рекомендуем вам всегда оценивать, применяются ли эти ограничения, и если да, то насколько они влияют на ваши результаты или интерпретацию результатов.

23.6.1. Метод №1: когортный анализ

Вы можете создать стабильную когорту пользователей до начала эксперимента и анализировать только краткосрочные и долгосрочные эффекты для этой когорты. Один из методов – выбрать когорту на основе стабильного признака, например идентификаторов, вошедших в систему пользователей. Этот метод может быть эффективным при устранении систематической ошибки разбавления и выживаемости, особенно если когорту можно стабильно отслеживать и измерять. Следует помнить о двух важных моментах.

1. Вам необходимо оценить, насколько стабильна когорта, поскольку это имеет решающее значение для эффективности метода. Например, если идентификатор основан на файлах куки, то при высокой вероятности обновления файлов куки этот метод не помогает исправить систематические ошибки.
2. Если когорта не является репрезентативной для всей популяции, могут возникнуть проблемы с внешней достоверностью, поскольку результаты анализа не могут быть обобщены на всю совокупность пользователей. Например, анализ только что вошедших в систему пользователей может вызвать предвзятость, поскольку они отличаются от пользователей, не вошедших в систему. Вы можете использовать дополнительные методы для улучшения обобщаемости, такие как корректировка веса на основе стратификации. В этом подходе вы сначала разделяете пользователей на подгруппы (например, на основе доэкспериментального высокого, среднего и низкого уровня вовлеченности), а затем вычисляете средневзвешенное значение эффектов воздействия для каждой подгруппы, причем веса отражают распределение популяции. Этот подход имеет те же ограничения, что и наблюдательные исследования, подробно обсуждаемые в главе 11.

23.6.2. Метод № 2: постпериодный анализ

В этом методе вы выключаете эксперимент по прошествии некоторого времени (время T), а затем измеряете разницу между пользователями в подопытной и контрольной группах в течение времени T и $T + 1$, как показано

на рис. 23.2. В том случае, если вы не можете ограничить воздействие из-за проблем с пользовательским интерфейсом, вы все равно можете применить этот метод, «расширив» воздействие на всех пользователей. Ключевым аспектом этого метода является то, что в течение периода измерения пользователям в подопытной и контрольной группах доступны одни и те же функции. Разница между группами, однако, заключается в том, что в первом случае подопытная группа подвергалась воздействию набора функций, которым не подвергалась контрольная группа, или во втором случае «расширения воздействия» подопытная группа подвергалась воздействию обновления в течение более длительного времени, чем контрольная группа.




Рис. 23.2. Измерение долгосрочного эффекта на основе измерения A/A после периода воздействия

Хохнхольд и др. (Hohnhold et al., 2015) называют эффект, измеренный в постпериоде, *заученным эффектом*. Чтобы правильно его интерпретировать, вам необходимо понять, какое конкретное изменение было изучено в эксперименте. Есть два типа заученного эффекта.

1. **Пользовательский эффект.** Пользователи освоили обновление и постепенно адаптировались к изменениям. Хохнхольд и др. (2015) исследовали влияние увеличения рекламной нагрузки на поведение пользователей при нажатии на рекламу. В их тематическом исследовании обучение пользователей считается ключевой причиной постэффекта.
2. **Системный эффект.** Система могла «запомнить» информацию периода воздействия. Например, эксперимент может побудить большее количество пользователей обновить свой профиль, и эта обновленная информация останется в системе даже после завершения эксперимента. Или, если больше пользователей подопытной группы раздражены электронными письмами и откажутся от участия во

время эксперимента, они не будут получать электронные письма в течение постпериода. Другой распространенный пример – персонализация с помощью моделей машинного обучения, например таких, которые показывают больше рекламы пользователям, которые склонны больше нажимать на рекламу. После воздействия, заставляющего пользователей нажимать больше на рекламу, система персонализации может заучить информацию о поведении пользователя и, как следствие, показывать им больше рекламы даже после окончания эксперимента.

При наличии достаточного количества экспериментов метод может оценить заученный эффект на основе параметров системы и впоследствии экстраполировать результаты новых краткосрочных экспериментов для оценки ожидаемого долгосрочного эффекта. Эта экстраполяция является разумной, когда эффекты, заученные системой, равны нулю, т. е. в постпериод A/A пользователям подопытной и контрольной группы предоставляется один и тот же набор функций. Примеры того, когда эффект, заученный системой, отличен от нуля, включают постоянные изменения состояния пользователя, такие как более постоянная персонализация, отказ от подписки, превышение пределов показов и т. д.

Тем не менее этот подход эффективен для изоляции эффекта воздействия от внешних факторов, меняющихся с течением времени, и от потенциального взаимодействия с другими недавно запущенными функциями. Поскольку заученный эффект измеряется отдельно, он позволяет лучше понять, почему краткосрочные эффекты отличаются от долгосрочных. Этот метод страдает от потенциального разбавления и систематической ошибки выживания. Однако, поскольку заученный эффект измеряется отдельно в постпериоде, вы можете попытаться применить к нему корректировку, чтобы учесть разбавление, или комбинировать его с методом когортного анализа, рассмотренным ранее.

23.6.3. Метод №3: воздействие с интервалом во времени

Обсуждаемые до сих пор методы просто требуют, чтобы экспериментатор подождал «достаточно» времени, прежде чем проводить длительные измерения. Но как долго должно длиться это «достаточно»? Очевидный подход – наблюдать за линией тренда эффекта воздействия и решить, что прошло достаточно времени, когда кривая стабилизируется. На практике это не работает, поскольку эффект воздействия редко бывает стабильным в течение длительного времени. При больших событиях или даже при зависимости от дня недели волатильность во времени имеет тенденцию подавлять долгосрочный тренд.

Чтобы определить время измерения, вы можете организовать две версии одной и той же процедуры, запущенных с некоторой разницей во времени. Одна версия (T_0) начинается в момент времени $t = 0$, а другая (T_1) начинается

в момент времени $t = 1$. В любой момент времени $t > 1$ вы можете измерить разницу между двумя версиями воздействия. Обратите внимание, что в момент времени t , T_0 и T_1 фактически являются А/А-тестом с той лишь разницей, что их пользователи подвергаются воздействию. Мы можем провести t -тест с двумя выборками, чтобы проверить, является ли разница между $T_1(t)$ и $T_0(t)$ статистически значимой, и заключить, что два воздействия сходятся, если разница небольшая, как показано на рис. 23.3. Обратите внимание, что важно определить практически значимую дельту и убедиться, что сравнение имеет достаточную статистическую мощность для ее обнаружения. На этом этапе мы можем применить постпериодный анализ после времени t для измерения долгосрочного эффекта. При измерении разницы между двумя видами воздействия может быть важнее обеспечить более низкий уровень ошибок типа II, чем типичные 20 %, даже за счет увеличения частоты ошибок типа I до более чем 5 %.




Рис. 23.3. Измерение долгосрочного эффекта после того, как мы увидим, что два разнесенных по времени воздействия совпали

Этот метод предполагает, что разница между двумя воздействиями со временем уменьшается. Другими словами, $T_1(t) - T_0(t)$ является убывающей функцией t . Хотя это правдоподобное предположение, на практике вам также необходимо обеспечить достаточный промежуток времени между двумя последовательными сеансами воздействия. Если заученному эффекту требуется некоторое время для проявления, и две процедуры начинаются сразу после друг друга, может не хватить времени для того, чтобы две процедуры имели разницу в начале T_1 .

23.6.4. Метод №4: сдерживание и обратный эксперимент

Долгосрочные эксперименты могут оказаться невыполнимыми, если не хватает времени для доведения воздействия до всех пользователей. С другой стороны, контрольные группы могут быть дорогостоящими: у них есть альтернативные издержки, поскольку они не получают обновление. Одним из решений проблемы является *задержка эксперимента*: удержание 10 % пользователей в контрольной группе в течение нескольких недель (или месяцев) после запуска обновления для 90 % пользователей. Эксперименты с задержкой – типичная разновидность длительных экспериментов. Поскольку у них небольшой контрольный вариант, они, как правило, имеют статистическую мощность меньше оптимальной. Важно убедиться, что снижение чувствительности не повлияет на измерение того, что вы хотели бы обнаружить при помощи задержки (см. подробное описание в главе 15).

Есть альтернативный вариант – *обратные эксперименты*. В обратном эксперименте мы возвращаем 10 % пользователей обратно в контрольную группу через несколько недель (или месяцев) после запуска воздействия для 100 % пользователей. Преимущество этого подхода в том, что все на какое-то время испытали воздействие. Если воздействие представляет собой новую функцию, в которой сетевой эффект влияет на ее принятие пользователями, или если предложение ограничено на рынке, обратный эксперимент дает время для достижения нового равновесия. Недостатком является то, что, если воздействие вносит видимые изменения, возвращение пользователей в контрольную группу может их запутать.

Предметный указатель

А

Активные пользователи по дням 148

Анализ

на основе журналов 164

по выборке с воздействием 72

ретроспективный 164

Б

Бережливая стратегия 46

Быстрые запросы 270

В

Вариант 31

Взаимовлияние 272

Включение по условию 254

Воспринимаемое быстроедействие 118

Время

готовности пользователя 119

загрузки страницы 116

фазы страницы 119

Г

Граничный показатель 47

Д

Данные

анонимизированные 158

анонимные 157

внешние 170

персонифицированные 157

подготовка 219

псевдонимные 158

Дифференциальная

конфиденциальность 158

Длительность жизненного цикла

клиента 37

Доверительный интервал 57, 70

Дополнительные методы 161

Допущение о стабильном влиянии

воздействия на экспериментальный

объект 70

Достоверность

внешняя 76

внутренняя 70

Доход на пользователя 54

Ж

Жизненная ценность 127

З

Зависимая переменная. См. Реакция

Задержка эксперимента 292

Закон

Амдала 261

Гудхарта 143

Кэмпбелла 143

Замечание Лукаса 143

И

Иерархия доказательств 33

Индикатор покупки 59

Институциональная память 145

Институциональный наблюдательный совет 157

Инструментальные переменные 180

Интерференция 272

Исследование пользовательского опыта 167

К

Квазиэкспериментальные планы 176

Ключевые результаты 121

Контрафактические события 101

Корзина 101

Коэффициент

ложного обнаружения 69

отклика 42

преувеличения 235

Критерий согласия 252

Культура интеллектуальной честности 90

Л

Линейная аппроксимация 113

М

Максимальный уровень мощности 213

Метод

близкий к реальному времени 221

дифференциальной разницы 181

разрывной регрессии 178

Метрика

дорожного указателя 122

Метрика успеха. См. Показатель

целевой

Минимальный обнаруживаемый

эффект 234

Многорукий бандит 50

Модель зрелости эксперимента 85

Мощность 233

Н

Наблюдательные исследования 161, 176

Назначенные рыночные зоны 175

Начальное среднее значение 56

Независимое и идентичное

распределение 209

Несоответствие коэффициента

выборки 72, 264

Нулевая гипотеза 56

Нулевой тест 246

О

Обратный эксперимент 292

Общий критерий оценки 29

Общий регламент по защите

данных 157

Объект эксперимента 32

Однослойный метод 102

Ожидаемая ценность

информации 50, 130

Окупаемость инвестиций 29

Операционная эффективность 46

Отбор подобного по склонности 180

Оценка 31

Оценщик 166

Ошибка

типа I 233

типа II 233

Ошибка выжившего 71

П

Парадокс Симпсона 82

Параметр 31

Перетекание между вариантами. См.

Интерференция

Платформа

вложенная 104

с границами 104

Показатель

активов 123

вовлеченности 123

движущей силы 122

диагностический (отладочный) 124

истинного севера. См. Показатель

целевой

качества данных 124

косвенный 122

наиболее важный 138

ограничительный 123

прогнозирующий 122

суррогатный 122

успеха 54

целевой 54, 122

Полный факторный эксперимент 103

Поправка Бонферони 235

Предполагаемое согласие 155

Прерывистый временной ряд 176

Причинно-следственная модель

Рубина 271

Пробный полет 29

Процедура Бенджамин–Хохберга 235

Процентная дельта 239

Р

Рампинг 212

Рандомизатор 32

Реакция 31

Результат 31

Рейтер. См. Оценщик

С

Сбалансированная система

показателей 31

Сплит-тест 29

Стандартная ошибка среднего 56

Статистическая мощность 57
Стратегическая целостность 47

Т

Тест
 многовариантный 31
 с корзиной 29
Тонкая параметризация 197
Триггирование. См. Включение по условию

У

Удельные запросы 142
Уравновешенность 152
Уровни доказательности 34

Ф

Фактор. См. Параметр
Фокус-группа 168
Функция пригодности 31

Ц

Цель 121
 чрезвычайно важная 138
Центральная предельная теорема 231

Э

Эксперимент
 доверительный 19
 естественный 180
 контролируемый 19
 полевой 29
 рандомизированный 29
 с чередованием 178
 удостоверяющий 40
Экспертная оценка 166
Этика 150
Эффект
 долгосрочный 282
 заученный 289
 краткосрочный 281
 новизны 76
 первичности 76
 условного среднего воздействия 80

А

A/B-тест 19

С

CATE, conditional average treatment effects. См. Эффект условного среднего воздействия
CLV, customer lifetime value. См. Длительность жизненного цикла клиента
CTR, click-through rate. См. Коэффициент отклика

D

DAU, daily active users. См. Активные пользователи по дням

E

EVI, expected value of information. См. Ожидаемая ценность информации; См. Ожидаемая ценность информации

G

GDPR, General data protection regulation. См. Общий регламент по защите данных

H

HiPPO 21

I

IRB, institutional review boards. См. Институциональный наблюдательный совет
ITS, interrupted time series. См. Прерывистый временной ряд

K

k-анонимность 158

L

LTV, lifetime value. См. Жизненная ценность

M

MPR, maximum power ramp. См. Максимальный уровень мощности
MVP, minimum viable product 38
MVT, multivariate test. См. Тест многовариантный

O

OEC, overall evaluation criterion. См.

Общий критерий оценки

OMTM, one metric that matters. См.

Показатель наиболее важный

P

p-значение 56

PLT, pay load time. См. Время загрузки
страницы

PSM, propensity score matching. См.

Отбор подобного по склонности

R

RDD, regression discontinuity design 178

ROI, return of investment. См.

Окупаемость инвестиций

S

SRM, sample ratio mismatch. См.

Несоответствие коэффициента
выборки

SUTVA, stable unit treatment value
assumption 70. См. Допущение о
стабильном влиянии воздействия

W

WIG, wildly important goal. См. Цель,
чрезвычайно важная

Книги издательства «ДМК Пресс» можно заказать
в торгово-издательском холдинге «Планета Альянс» наложенным платежом,
выслав открытку или письмо по почтовому адресу:
115487, г. Москва, 2-й Нагатинский пр-д, д. 6А.

При оформлении заказа следует указать адрес (полностью),
по которому должны быть высланы книги;
фамилию, имя и отчество получателя.

Желательно также указать свой телефон и электронный адрес.
Эти книги вы можете заказать и в интернет-магазине: **www.a-planet.ru**.

Оптовые закупки: тел. **(499) 782-38-89**.
Электронный адрес: **books@aliens-kniga.ru**.

Рон Кохави
Диана Тан
Я Сюй

Доверительное А/В-тестирование

Практическое руководство по контролируемым экспериментам

Главный редактор	<i>Мовчан Д. А.</i>
Зам. главного редактора	<i>Сенченкова Е. А.</i>
	<i>dmkpress@gmail.com</i>
Перевод	<i>Яценков В. С.</i>
Корректор	<i>Абросимова Л. А.</i>
Верстка	<i>Луценко С. В.</i>
Дизайн обложки	<i>Мовчан А. Г.</i>

Формат 70×100 1/16.
Гарнитура «PT Serif». Печать цифровая.
Усл. печ. л. 24,21. Тираж 200 экз.

Веб-сайт издательства: www.dmkpress.com